

概率论与数理统计课程小论文

大数定律：机器学习的理论支撑

班 号	计科 5 班
学 号	220110515
姓 名	金正达
日 期	2023.11.26
成 绩	

摘要

人类从自己的学习方式出发，设计了机器学习的方法。而大数定律为机器学习的样本训练及模型评估提供基本的理论支撑。在大数定律的视角下，大规模的训练集不仅带来更可靠的模型参数估计和模型泛化能力，还为随机算法的设计提供了一定的理论支持。同时，在机器学习模型评估方面，大数定律为多种验证方式的正确性提供了基本的保证。

关键词：机器学习；大数定律；归纳-演绎；参数估计与泛化；模型评估；

一. 人的学习方式与机器学习方式

（一） 人类的学习方式

对于人类来说，学习最初就是从观察自然界的各种生物和现象得到的一般规律。例如，在人类多次观测到天空乌云密布并且伴随狂风后有大暴雨的到来之后，便从中总结出了这样的规律：天气阴沉预示着大雨的到来。在长期的实践探索中，人类积累了大量的经验，从中总结出了大量的一般规律，并将其用于具体的生产生活实践之中，即“归纳-演绎”步骤。所谓归纳，即从事件中观测数据，根据数据的规律总结出更为抽象的规律；所谓演绎，即将归纳所得的抽象规律用于更多未知的场景。归纳与演绎构成了人类认识世界的方法。

（二） 机器学习的方式

与人类学习的方式一样，机器设计时也希望像人类一样由“归纳-演绎”来从数据集合中总结规律并应用于未知场景。机器从数据集合中分析其一般规律，再总结出抽象规律。那么什么样的“归纳-演绎”才能保证更高的准确性呢？这就必须从统计的角度来进行审视。从统计的角度，即不拘束于身边的个体案例，而将目光放在规模庞大的样本上，通过随机抽验分析来总结出统计总体的一般规律。但是在这过程之中，抽样所得结果的正确性如何保证？例如，在一个黑箱里有许多个黑白两色的小球，进行一次抽样检测，抽样出的10个小球中有7个白色，那么我们又能否断定黑箱中白色小球的数量占比约为70%呢？对于人类来说，可能会对这个结果有一定的怀疑，比如黑箱只有7个白球，全部集中在上面部分，被我们的一次抽样所包含了，但是对于机器来说，这符合其“归纳-演绎”的逻辑，所以不会对其产生“怀疑”。既然基于有限样本的判断与推断可能都是错误的，那机器学习又该何去何从呢？大数定律给出了答案。

二. 大数定律基础

（一） 大数定律

大数定律是描述相当多次重复实验的结果的定律，分为弱大数定律和强大数定律。弱大数定律陈述了对于任意小的正数，样本均值在样本数量足够大时以高概率收敛于总体期望值。数学表述为

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \varepsilon) = 0$$

强大数定律指出，对于任意小的正数，样本均值在样本数量足够大时以概率1收敛于总体期望值。数学表述为

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1$$

上述公式中 $\bar{X}_n$ 为随机变量， μ 为样本均值， ε 为任意正数^[1]。

（二）大数定律的解释

大数定律对于机器的“归纳-演绎”做出了这样的解释：样本量越大，抽样统计值就越接近事物的真实概率。具体而言，对于独立同分布的随机变量 X_i ，样本均值 $\bar{X}_n$ 的期望值为总体期望值 μ 。随着实验次数的增加（即样本数量 n 的增加），样本均值的方差减小，使得样本均值逐渐逼近总体期望值。运用大数定律，可以基于有限观测来进行机器的统计学习，最终的学习结果不是对统计结果的信任，而是基于概率的统计结果信任。

三．机器学习中的样本规模与性能关系

（一）模型参数估计与样本规模的关系

在机器学习中，模型的参数通过训练数据进行估计。大数定律为我们提供了关于样本规模对模型参数估计的解释，即对机器学习中“归纳”的理论阐述。随着样本规模的增加，模型参数的估计更趋近于总体参数的真实值，对应于大数定律中高概率收敛于真实值，即偏差较大的概率极小，几乎可以忽略。更大的样本规模提供了更多的信息，使得对模型参数的估计更为准确。大数定律为我们提供了理论保证，表明通过增加样本规模，我们可以期望得到更为可靠的模型参数估计。

（二）泛化能力与大数定律的联系

泛化能力是机器学习模型的关键性能指标，它衡量了模型在未知的数据集上的表现。大数定律表明，当训练样本足够大时，模型更好地捕捉了总体分布的特征，从而提高了泛化性能^[3]，即对应机器学习中“演绎”能力的保证。随着样本规模的增加，模型更有可能学到总体分布的真实特征，减小了过拟合的风险。

（三）随机性算法的稳定性与大数定律的启示

许多机器学习算法涉及到随机性，大数定律为这些算法的稳定性提供了解释。随机性梯度下降的每次迭代都涉及对样本的随机选择，即选择一个样本中的例子来进行近似计算，而大数定律表明，随着迭代次数的增加，算法最终收敛到全局最优解的概率较高。这些随机性算法在实践中通常能够在相对较短的时间内找到良好的解，其随机性的稳定性和收敛性在大数定律下得到了保证。

四．大数定律在模型评估中的应用

（一）性能评估的稳定性

在模型评估中，我们关注的是模型在不同数据集上的性能表现。大数定律为性能评估提供了稳定性的理论基础。通过增加数据集的规模，我们能够更可靠地评估模型的平均性能，减少由于特定样本选择而引起的评估偏差^[2]。大数定律确保了在大样本情况下，性能评估结果更加稳健，更能代表模型在总体上的真实表现。

（二）对小样本问题的警示

尽管大数定律在大样本情况下提供了可靠性，但对于小样本问题，我们需要谨慎对待。大数定律的警示在于，当样本规模较小时，评估结果可能更容易受到偶然因素的影响，导致其结果波动较大，从而引发对模型性能的误解。在小样本问题中，应更加小心地解释和推断模型的性能，避免过于绝对的结论。

（三）大数定律在交叉验证与测试集评估中的影响

交叉验证和测试集评估是常用的模型评估手段，而大数定律对它们的影响是显著的，即增加交叉验证折数或测试集的规模，可以提高评估的可靠性。在交叉验证中，更多的折数提供了更多独立的评估结果，增加了对模型性能的信心。同样，在测试集评估中，更大的测试集规模提高了性能评估的稳定性，使其更具代表性。

五. 总结

本文通过人类学习与机器学习来引入大数定律在机器学习领域的应用,以及对样本规模与性能关系的详细解释。机器学习采用人类一般的“归纳-演绎”法来进行规律总结和规律应用,而大数定律为其准确性提供了理论支撑。在模型参数估计方面,大数定律的数学表述为我们提供了理论保证,说明随着样本规模的增加,模型参数估计更趋近于总体参数的真实值,增强了对模型的准确理解。在泛化能力方面,我们通过大数定律理解到足够大的训练样本可以提高模型对总体分布的学习能力,从而提高了泛化性能。此外,针对随机性算法,大数定律为其稳定性和收敛性提供了支持,解释了为什么这些算法在实践中表现出色。在模型评估方面,大数定律在性能评估的稳定性、对小样本问题的警示以及交叉验证与测试集评估中的影响上发挥了关键作用。通过本文的阐述,我们更全面地理解了大数定律在机器学习中的实际应用,为正确解读和信任模型性能评估结果提供了理论基础。

参考文献

- [1]. 李蕊.浅谈几个著名的大数定律及应用[J].科学咨询(科技·管理),2010(12):64-65. [2] 辛希孟. 信息技术与信息服务国际研讨会论文集: A 集[C]. 北京: 中国科学出版社, 1999.
- [2]. 田世杰,张一名.机器学习算法及其应用综述[J].软件,2023,44(07):70-75.....
- [3]. 陈琳, 范元凯, 何震瀛等.SQL-to-text 模型的组合泛化能力评估方法[J/OL].计算机工程 :1-10[2023-11-28].<https://doi.org/10.19678/j.issn.1000-3428.0067251>. [13] Kanamori H. Shaking Without Quaking[J]. Science, 1998, 279 (5359): 2063-2064.