



哈爾濱工業大學 (深圳)
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

操作系统 (Operating System)


第八章：I/O与存储

陈芳林 副教授

哈尔滨工业大学（深圳）

2024年秋

Email: chenfanglin@hit.edu.cn



- 1、导论与操作系统结构
- 2、进程与线程
- 3、并发与同步
- 4、处理器调度
- 5、死锁
- 6、内存管理
- 7、虚拟内存
- 8、I/O与存储
- 9、文件及文件系统


- 设备管理概述
- I/O控制方式
- 缓冲技术
- 磁盘设备

- 设备管理概述


- I/O控制方式

- 缓冲技术

- 磁盘设备



- 计算机操作系统包含不同厂商的各种外设，并且外设不断更新换代
- 操作系统如何管理这些外设，为用户提供服务？
 - 两端接口规范，中间管理高效
- 想一想，大家为什么要安装设备驱动程序？
 - 操作系统最关键的生态之一：外设支持




■ 设备管理是操作系统的重要组成部分

同其他管理来说，该部分内容比较复杂凌乱。因为设备种类繁多，各自有着不同的特点，所以需要制定一个**通用的、规范的管理框架、方法**


■ 设备管理的方法主要有3种：

- (1) 操作系统**直接操纵**设备的运行，例如直接程序控制、中断方式控制
- (2) 操作系统**间接操纵**设备的运行，例如DMA和通道方式
- (3) 操作系统通过使用**设备驱动程序**，将设备管理工作通过任务（进程）的形式来体现。OS只需制定标准，将具体操纵设备的程序交给不同的制造商去开发

认识计算机外设与计算机!



磁盘的I/O过程



■ CPU向控制器中的寄存器读写数据



■ 控制器完成真正的工作，并向CPU发中断信号

想让外设工作
并不复杂!

```
int fd = open("/dev/something");  
for (int i = 0; i < 10; i++) {  
    fprintf(fd, "Count %d\n", i);  
}  
close(fd);
```

- (1) 不论什么设备都是open, read, write, close
 - 操作系统为用户提供**统一的接口**!
- (2) 不同的设备对应不同的文件(设备文件)
 - 设备文件中存放了**设备的属性**!

显然操作系统将完成...



IO系统组成

■ 用户库函数接口

高级语言库函数接口

■ IO内核子系统

系统调用接口

- IO调度（磁盘寻道）、缓冲（文件系统磁盘访问）、错误处理、保护

IO内核子系统

■ 设备驱动程序（中断服务程序）

设备驱动程序

- 隐藏设备差异，为操作系统和设备提供商提供标准的接口

IO硬件

■ IO硬件

- 字符设备、块设备；读写；同步异步



```
1 [root@tom ~]# cd /dev /*进入/dev目录*/
2 [root@tom dev]# ls -l /*列出/dev中文件的信息*/
3 /*第1字段 2 3 4 5 6 7 8 */
4 crw-rw----+ 1 root root 14, 12 12-21 22:56 adsp
5 crw----- 1 root root 10, 175 12-21 22:56 agpgart
6 crw-rw----+ 1 root root 14, 4 12-21 22:56 audio
7 brw-r----- 1 root disk 253, 0 12-21 22:56 dm-0
8 brw-r----- 1 root disk 253, 1 12-21 22:56 dm-1
9 crw-rw---- 1 root root 14, 9 12-21 22:56 dmmidi
```


■ 主要接口如下表

函数名	功能
create()	创建设备
remove()	删除设备
open()	打开设备
close()	关闭设备
read()	从设备中读取数据
write()	向设备中写入数据
ioctl()	控制设备(例如设置波特率等)

I/O系统如何向设备发命令?

- I/O系统向设备控制器发命令
- 设备控制器的结构





I/O系统向设备发命令方式?

■ 读写设备控制器的寄存器!

■ 怎么读写? **mov [100], ax**

关键是地址


■ 设备寄存器的编址

➤ **独立编址**: 需要独立的指令。比如X86:in,out; 能与DX,AX,AL寄存器结合使用。如out 0x21, AL

➤ **内存映像编址**: 是内存物理地址空间的一部分, 使用mov命令, 如

mov [0x8000f000], AL

查查硬件手册就知道了!





- 设备管理概述
- I/O控制方式
- 缓冲技术
- 磁盘设备

- 设备管理的主要任务之一是控制设备和内存或CPU之间的数据传送
- I/O控制方式一般有4种：
 - 程序直接控制（查询）方式
 - 中断控制方式
 - 直接内存存取（DMA）方式
 - 通道控制方式（智能设备）




控制I/O硬件的方式

■ 方案1: 原地踏步等待! 查询 (轮询)



例子：程序方法控制I/O设备读入数据流程




程序直接控制（查询）方式工作步骤小结：

- (1) 当某进程需要输入/输出数据时，由CPU向设备控制器发出一条I/O指令启动设备工作（对于输出操作，则CPU还要向数据寄存器中存放输出数据）；
- (2) 在设备输入/输出数据期间，CPU不断地循环进行查询设备状态寄存器的值（检查I/O工作是否完成）。
- (3) 若完成，对输入操作来说CPU则从数据寄存器中取出数据，然后进行下一次的输入/输出数据或结束。

控制I/O硬件的方式?


■ 方案2: 设备就绪了告诉CPU一声! 中断

中断是大部分I/O
的处理方式!




```
set_trap_gate(??, do?())
do?()
{ in AL, 0x??
  if (AL!=ready)
  { error(); }
  读数据...
}
```

例子：中断方法控制I/O设备读入数据流程



中断在某些场合还不够!

■ 如果用中断来读磁盘...




每个字节从缓存移动内存都由CPU负责完成

可以设计有一定处理能力的外围设备，将一些简单任务交给它!

I/O系统发完命令后做什么？

- 方案3: 简单任务自己做，完成了告诉CPU一声！
- 引入DMA（直接内存存取）



幸运的是: 该方式的细节由DMA设计者考虑, 对于操作系统而言, 考虑的仍然只是中断处理

例子：DMA方式数据输入过程

- (1) 当一个进程要求设备输入数据时，CPU对DMA进行初始化工作：
 - 存放数据的内存起始地址 — DMA控制器的内存地址寄存器；
 - 要输入数据的字节数 — DMA控制器的传送字节数寄存器；
 - 控制字（中断允许、DMA启动位=1） — DMA控制器的控制状态寄存器；
 - 启动位被置1，则启动DMA控制器开始进行数据传输。
- (2) 该进程放弃CPU，进入阻塞等待状态，等待第一批数据输入完成。进程调度程序调度其他进程运行。
- (3) 由DMA控制器控制整个数据的传输。
 - 当输入设备将一个数据送入DMA控制器的数据缓冲寄存器后，DMA控制器立即取代CPU，接管数据地址总线的控制权（CPU工作周期挪用），将数据送至相应的内存单元；
 - DMA控制器中的传输字节数寄存器计数减1；
 - 恢复CPU对数据地址总线的控制权；
 - 第（3）步过程循环直到数据传输完毕。

例子：DMA方式数据输入过程

- (4) 当一批数据输入完成，DMA控制器向CPU发出**中断信号**，请求中断运行进程并转向执行中断处理程序。
- (5) 中断程序首先保存被中断进程的现场，唤醒等待输入数据的那个进程，使其变成就绪状态，**恢复现场**，返回被中断的进程继续执行。
- (6) 当进程调度程序调度到要求输入数据的那个进程时，该进程就到指定的内存地址中**读取数据**进行处理。

■ 方案4：可以交办复杂任务，完成后汇报！引入**通道**（channel）方式

➤ 通道具有简单的CPU功能，可编程，可管理多个设备同时工作。从而真正实现了CPU与外部设备的并行工作。

■ **通道控制方式的工作过程：**

- (1) 当一个进程要求输入输出数据时，CPU根据请求**形成有关通道程序**，然后执行输入输出指令启动通道工作；
- (2) 申请输入输出数据的进程放弃CPU进入**阻塞等待状态**，等待数据输入输出工作的完成，于是进程调度程序调度其他进程运行；
- (3) 通道开始执行CPU放在主存中的通道程序，**独立负责**外设与主存的数据交换；
- (4) 当数据交换完成后，通道向CPU发出**中断信号**，中断正在运行的进程，转向中断处理程序；
- (5) 中断处理程序首先保护被中断进程的现场，唤醒申请输入输出的那个进程，使其变为就绪状态，关闭通道，然后**恢复现场**，返回被中断的进程继续运行；
- (6) 当进程调度程序调度到申请输入输出数据的那个进程时，该进程就到指定的内存地址中进行数据处理。

通道与DMA相比

■ 共同点:

- 都能实现IO设备和内存之间建立数据直传通路;

■ 不同点:

- DMA只能实现固定的数据传送控制, 而通道有自己的指令和程序, 具有更强的独立处理数据输入和输出的能力。
- DMA只能控制一台或者少数几台同类设备, 而一个通道可以控制多台同类或者不同的设备。

■ 通道的思想是从早期的大型计算机系统中发展起来的。在早期的大型计算机系统中, 一般配有大量的I/O设备。为了把对I/O设备的管理从计算机主机中分离出来, 形成了I/O通道的概念, 并专门设计出I/O通道处理机。

■ I/O通道在计算机系统中是一个非常重要的部件, 它对系统整体性能的提高起了相当重要的作用。不过, 随着技术不断的发展, 处理机和I/O设备性能的不断提高, 专用的、独立I/O通道处理机已不容易见到。

- 设备管理概述
- I/O控制方式
- 缓冲技术
- 磁盘设备

- **缓冲的目的**：解决CPU和外设速度不匹配的矛盾，提高CPU与外设之间的并行性，减少对CPU的中断频率
- **缓冲技术的实现方法**：硬件缓冲、软件缓冲
 - (1) **硬件缓冲**：利用专门的硬件寄存器作为缓冲区，一般由外设自带的专用寄存器构成。例如：Printer、CD-ROM等
 - (2) **软件缓冲**：借助操作系统的管理，在内存中专门开辟若干单元作为缓冲区

单缓冲，双缓冲，环形缓冲，缓冲池


■ 1. 单缓冲：在内存中开辟一个固定大小的区域作为缓冲区

- 外设和CPU交换数据时，先将被交换的数据写入缓冲区，然后再由需要数据的CPU或外设从缓冲区中取出。
- 该方式中，外设与CPU对缓冲区的操作是串行的。

■ 2. 双缓冲：在内存中设置2个大小相同的缓冲区。

- 外设和CPU可以交替使用这2个缓冲区，从而在一定程度上实现并行交换数据。

■ **3. 环形缓冲:** 在内存中设置大小相等的多个缓冲区，并将它们链接成为一个环形链表。




- Head一直指向缓冲区链表的第一个缓冲区；
- Full一直指向缓冲区链表中的第一个存满数据的缓冲区；
- Empty一直指向缓冲区链表中的第一个空白的缓冲区。
- 初始化时: Head=Full=Empty, 整个缓冲区链表为空；
- 使用过程中: 当Full=Empty $\Leftrightarrow$ 整个缓冲区链表为空。

■ 4. 缓冲池： 缓冲池是有多个大小相同的缓冲区组成

- 池中的缓冲区是系统公共资源，所有进程均可以共享
- 池由系统管理程序统一管理，负责分配、回收工作
- 池中每个缓冲区既可以用于输入数据，也可以用于输出数据

缓冲区数据结构



缓冲池的工作流程

■ 缓冲池的工作流程：


- (1) 当输入设备需要进行数据输入时，则从空缓冲队列的队首取下一个空缓冲区，将它作为收容输入工作缓冲区，当它被输入装满数据后，则被链接到输入缓冲队列的队尾；
- (2) 当某进程需要从缓冲池输入数据时，则从输入缓冲队列的队首取一个缓冲区作为提取输入工作缓冲区，该进程从中提取数据，取完后，则将该缓冲区链接到空缓冲区队列的队尾；
- (3) 当某进程需要输出数据到缓冲池时，则从空缓冲队列的队首取下一个空缓冲区，将它作为收容输出工作缓冲区，该进程向该缓冲区中存放数据，当它被装满数据后，则被链接到输出缓冲队列的队尾；
- (4) 当输出设备需要进行数据输出时，则从输出缓冲队列的队首取一个缓冲区作为提取输出工作缓冲区，并从中提取数据输出，取完后，则将该缓冲区链接到空缓冲区队列的队尾。

- Linux系统为了提高读写磁盘的效率，会先将数据放在一块buffer中。
- 在写磁盘时并不是立即将数据写到磁盘中，而是先写入这块buffer中了。
- 此时如果重启系统，就可能造成数据丢失。
- sync命令用来flush文件系统buffer，这样数据才会真正的写到磁盘中，并且buffer才能够释放出来。
- sync命令会强制将数据写入磁盘中，并释放该数据对应的buffer，
- 所以常常会在写磁盘后输入sync命令来将数据真正的写入磁盘。

■ 如果不去手动的输入sync命令来真正的去写磁盘，Linux系统也会有两种写磁盘的时机：

- 1) kflush内核线程周期性的去写磁盘；
- 2) buffer已满不得不写。

- SPOOL — Simultaneous Peripheral Operation On Line外部设备同时联机操作，又称假脱机操作。
- SPOOL是操作系统中采用的一项将独占设备改造成共享设备的技术。
- 实现方法：截获向某独享设备输出的数据，暂时保存到内存缓冲区或磁盘文件中，并进行排队，之后逐个输出到外设上
- 实现这一技术的软、硬件系统称为SPOOL系统，或假脱机系统，或SPOOLING系统。



SPOOLING系统的组成

输入井和输出井：

- 在磁盘上开辟出来的2个存储区域
- 输入井用于收容I/O设备的输入数据
- 输出井用于收容I/O设备的输出数据

总结一些I/O系统要完成的工作!



```
write(buf, 10);
```

OS需要提供系统调用接口

```
DMA.addr = buf;  
DMA.count = 10;
```

查一下手册就可以找到该写什么命令?该向哪里写?

.....

```
sleep_on(Disk);
```

让出CPU?

需要写中断处理程序!

```
do_write_end() //中断处理  
{  
    wakeup(Disk);  
}
```

总的感觉: 很简单

处理流程是很简单, 复杂的是
一些细节问题。

- 如何实现交互? $\Rightarrow$ 首先需要了解I/O的工作原理
- 从用户如何I/O开始 $\Rightarrow$ 用户发送一个命令(read)
- 系统调用read $\Rightarrow$ 被展开成给一些寄存器发送命令的代码
- 发送完命令以后 $\Rightarrow$ CPU轮询, 或CPU干其它事情并等中断
- 中断方案最常见 $\Rightarrow$ 相比其他设备, CPU太快了
- 实现独享设备的共享 $\Rightarrow$ 假脱机系统 (SPOOLING)

- 设备管理概述
- I/O控制方式
- 缓冲技术
- 磁盘设备

磁盘的I/O


认识一下磁盘



哈尔滨工业大学 (深圳)
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN



认识一下磁盘




盘片高速旋转产生气流非常强，足以使磁头托起，并与盘面保持一个微小的距离。

现在的水平已经达到 $0.005\mu\text{m} \sim 0.01\mu\text{m}$ ，这只是人类头发直径的千分之一。


认识一下磁盘

- 画一个示意图:



- 所以，磁盘被称为块设备!

- 看看俯视图:




扇区是磁盘的寻址单位、访问单位

- 磁盘的数据单位是扇区
- 扇区大小: 512字节
- 扇区的大小是传输时间和碎片浪费的折衷

磁盘的I/O

■ 让我们仔细想想磁盘如何读/写一个字节?



■ 分析磁盘I/O的重点在于第2步!



磁盘I/O: 缓存队列 → 控制器 → 寻道 → 旋转 → 传输!

磁盘I/O的分析

■ 我们最关心的磁盘什么时候读/写完?



磁盘访问延迟 = 队列时间 + 控制器时间 + 寻道时间 + 旋转时间 + 传输时间

前两项可以忽略!

8ms 到
12 ms

(半周): 4 ms
to 8 ms

约0.25ms

关键所在: 最小化寻道时间和旋转延迟!

■ 设一个磁盘的平均寻道时间为12ms，传输速率是200MB/s，控制器开销是0.2ms，转速为每分钟5400转。求读写一个512KB大小数据块的平均磁盘访问时间？

■ 解答：

$$\text{平均旋转延时} = 0.5 / (5400 \text{转/分}) = 0.000926 \text{秒} = 0.926 \text{ms}$$

$$\begin{aligned} \text{平均磁盘访问时间} &= \text{平均寻道时间} + \text{平均旋转延时} + \text{传输时间} + \text{控制器延时} \\ &= 12 \text{ms} + 0.926 \text{ms} + 512 \text{KB} / (200 \text{MB/s}) + 0.2 \text{ms} = (12 + 0.926 + 2.56 + 0.2) \text{ms} = 15.686 \text{ms} \end{aligned}$$

I/O过程是解开许多磁盘问题的钥匙

■ 磁盘调度:

磁盘访问延迟 = 队列时间 + 控制器时间 + 寻道时间 + 旋转时间 + 传输时间

前两项可以忽略!

8ms 到
12 ms

(半周): 4 ms
to 8 ms

约0.25ms

■ 多个磁盘访问请求出现在请求队列怎么办? 调度

■ 调度的目标是什么?

目标当然是平均访问延迟

小!

调度时主要考察什么?

寻道时间是主要矛盾!

磁盘调度: 输入多个磁道请求, 给出服务顺序!


- 先来先服务磁盘调度 First Come First Served (FCFS)
- 最短寻道时间优先磁盘调度 Shortest-Seek-Time First (SSTF)
- 扫描/电梯算法磁盘调度 SCAN
- 循环扫描/电梯算法磁盘调度 C-SCAN
- C-LOOK磁盘调度

先来先服务FCFS磁盘调度



■ 先来先服务：按请求的顺序调度


一个实例：磁头开始磁道位置=53；请求队列=98, 183, 37, 122, 14, 124, 65, 67



最短寻道时间优先磁盘调度(SSTF)

■ 最短寻道时间优先: 距离最近的请求优先

继续该实例: 磁头开始位置=53; 请求队列=98, 183, 37, 122, 14, 124, 65, 67




SSTF存在饥饿问题

扫描/电梯算法磁盘调度(SCAN)

■ SCAN调度算法 = SSTF+中途不回折：每个请求都有处理机会。根据其特
征，SCAN也被称为电梯算法！


继续该实例：磁头开始位置=53；请求队列=98, 183, 37, 122, 14, 124, 65, 67



循环扫描磁盘调度(C-SCAN)


■ C-SCAN = SCAN + 直接移到另一端：两端请求都能很快处理。

继续该实例：磁头开始位置=53；请求队列=98, 183, 37, 122, 14, 124, 65, 67



■ C-LOOK = CSCAN+向前看一看：前面没有请求就回移

继续该实例：磁头开始位置=53；请求队列=98, 183, 37, 122, 14, 124, 65, 67




■ C-LOOK是比较合理的缺省算法

操作系统中所有的算法都要因地制宜！



	优点	缺点
FCFS算法	公平、简单	平均寻道距离大，仅应用在磁盘I/O较少的场合
SSTF算法	性能比“先来先服务”好	不能保证平均寻道时间最短，可能出现“饥饿”现象
SCAN算法	寻道性能较好，可避免“饥饿”现象	不利于远离磁头一端的访问请求
C-SCAN算法	消除了对两端磁道请求的不公平	两端没有访问请求时不必要移动到头
C-LOOK算法	消除了两端不必要的移动	--

- 希捷发布Multi-Actuator多读写臂技术：提高读写性能



- 如何管理磁盘？ 首先对磁盘的扇区进行编号！
- 出厂的磁盘需要低级格式化(物理格式化)： 将连续的磁性记录材料分成物理扇区
 - 什么是磁盘的逻辑格式化？
第9章 文件系统！
- 扇区 = 头 + 数据区 + 尾
- 头、尾中包含只有磁盘控制器能识别的扇区号码和纠错码等信息


I/O过程是解开许多磁盘问题的钥匙

- 磁盘寻址：我们往往更关心存放内容的地址
- 实际上就是扇区怎么编址？
- 地址是：磁道（C） + 盘面（H） + 扇区（S）
- 寻道和旋转费时多 $\Rightarrow$ 花最少时间访问最多扇区的方案：

磁臂不动、磁盘旋转一周，访问磁头遇到的所有扇区。



➤ 扇区编址(1): CHS (Cylinder/Head/Sector)

➤ 扇区编址(2): 扇区编号 (Logical Block Addressing, LBA)



让这些扇区的编址
邻近：因为局部性！

扇区编号——现代磁盘的常见寻址方式



体现了局部性!

扇区编号, 按照 (C, H, S) 将扇区形成一维扇区数组, 数组索引就是扇区编号

某扇区 (c, h, s) 编号 $A = c * H * S + h * S + s$ 扇区总数 $= C * H * S$

已知 A , 则 $s = A \% S$; $h = [A / S] \% H$; $c = [A / (H * S)]$

■ 以前，硬盘的容量还非常小，采用与软盘类似的结构生产硬盘：

➤ CHS(Cylinder/Head/Sector)模式，以及相应的寻址方式。

✓ 也就是硬盘盘片的**每一条磁道都具有相同的扇区数**

➤ 由此产生了所谓的3D参数 (Disk Geometry)：

✓ 磁柱面数(Cylinders),

✓ 头数(Heads),

✓ 扇区数(Sectors per track)

■ CHS(Cylinder/Head/Sector)模式下磁盘的大小

- **磁头数**(Heads) 表示硬盘总共有几个磁头,也就是有几面盘片,最大为 256 (用 8 个二进制位存储);
- **柱面数**(Cylinders) 表示硬盘每一面盘片上有几条磁道,最大为 1024(用 10 个二进制位存储);
- **扇区数**(Sectors per track) 表示每一条磁道上有几个扇区,最大为63 (用 6 个二进制位存储)。

■ 每个扇区一般是 512个字节; 所以磁盘最大容量为: $256 * 1024 * 63 * 512$
 $/ 1048576 = 8064 \text{ MB}$

- CHS(Cylinder/Head/Sector)模式，这种方式会浪费很多磁盘空间 (与软盘一样)
- 为了进一步提高硬盘容量，产生了等密度结构硬盘，外圈磁道的扇区比内圈磁道多，采用这种结构后，硬盘不再具有实际的3D参数，寻址方式也改为线性寻址，即以扇区为单位进行寻址。
- 为了与使用CHS寻址的兼容 (如使用BIOS Int13H接口的软件)，在硬盘控制器内部安装了一个地址翻译器，由它负责将老式3D参数翻译成新的线性参数。

- 有一组命令寄存器组(Task File Registers), I/O的端口地址为**1F0H~1F7H**
- 1F2H 扇区计数寄存器
 - 1F3H 扇区号, 或LBA块地址0~7
 - 1F4H 柱面数低8位, 或LBA块地址8~15
 - 1F5H 柱面数高8位, 或LBA块地址16~23
 - 1F6H 驱动器/磁头, 或LBA块地址24~27
 - 1F7H 状态寄存器 命令寄存器
- CHS或LBA在磁头寄存器中指定

想一想.....磁盘驱动应如何实现？

```
do_hd = intr_addr; // do_hd 函数会在中断程序中被调用。
outb_p(hd_info[drive].ctl, HD_CMD); // 向控制寄存器输出控制字节。
port=HD_DATA; // 置 dx 为数据寄存器端口 (0x1f0)。
outb_p(hd_info[drive].wpcom>>2, ++port); // 参数：写预补偿柱面号 (需除 4)。
outb_p(nsect, ++port); // 参数：读/写扇区总数。
outb_p(sect, ++port); // 参数：起始扇区。
outb_p(cyl, ++port); // 参数：柱面号低 8 位。
outb_p(cyl>>8, ++port); // 参数：柱面号高 8 位。
outb_p(0xA0 | (drive<<4) | head, ++port); // 参数：驱动器号+磁头号。
outb(cmd, ++port); // 命令：硬盘控制命令。
```

Linux 0.11 下实现磁盘读写驱动片段

- 1) 磁盘往往不是严格按需读取，而是每次都会**预读**，即使只需要一个字节，磁盘也会从这个位置开始，顺序向后读取**一定扇区长度的数据**放入内存。
- 2) 这样做的理论依据是计算机科学中著名的**局部性原理**：当一个数据被用到时，其附近的数据也通常会马上被使用。

- 虚拟内存：按需调页与页面置换。
- 如何优化提升程序的性能？经常访问的放在一起，被换出的概率降低，从磁盘读取速度快。
- 对代码来说，紧凑的代码也往往意味着接下来执行的代码更大可能就在相同的页或相邻页。根据时间locality特性，程序80%的时间花在了20%的代码上。如果将这20%的代码尽量紧凑且排在一起，被换出的概率降低，从磁盘读取速度快。
- 对数据来说，尽量将那些会一起访问的数据放在一起。这样当访问这些数据时，因为它们在同一页或相邻页，只需要一次调页操作即可完成；反之，如果这些数据分散在多个页（更糟的情况是这些页还不相邻），那么每次对这些数据的整体访问都会引发大量的缺页错误，从而降低性能。

- 第1步：得到要访问的扇区编号；得到读盘的目标(或写盘的源)内存地址

获得编号是使
用磁盘的关键！

算法输入！


- 第2步：将扇区编号和内存地址写给DMA；然后阻塞进程

查手册、写端
口！

- 第3步：DMA处理完成后中断CPU；中断处理程序唤醒阻塞进程


编写中断处理程序！

- 第4步：进程继续...



Example hard disk layout


- 物理盘以扇区(一般为512字节)为单位进行编址，它是硬盘读写的基本单位
- 一块硬盘从逻辑上可以理解为连续的一维扇区序列



■ 整个硬盘的第1个扇区存储着“主引导记录 (MBR)”：


(1) 引导可执行代码； (2) 硬盘基本分区表最多包含4个基本分区位置信息

偏移地址	字节数	内容
00	446	启动代码
446	16	第 1 分区表项
462	16	第 2 分区表项
478	16	第 3 分区表项
494	16	第 4 分区表项
510	2	签名 (0x55 0xAA)




Example hard disk layout

- 除了第1个扇区之外，其余扇区可以划分为至多4个基本分区
- 每个分区的第1个扇区预留，可以作为引导扇区




- 每个分区除第1个扇区外的其他部分还可以看做一个硬盘，继续分区
- 这样的分区可以无限制地重复进行，直到硬盘划分完成为止



■ 概念

- 扇区 — 物理盘存储空间基本编址单位，一般为512字节
- 主引导记录MBR — 硬盘的第1个扇区的内容，含引导代码和主分区表
- 分区 — 硬盘中可以作为逻辑盘管理的一组扇区集合
- 可扩展分区 — 可以继续划分成“分区”的硬盘分区
- 引导分区 — 标记有可引导标记的硬盘分区，这种分区有引导扇区和引导文件
- 引导扇区 — 引导分区的第1个扇区
- 可扩展分区引导记录 — 可扩展分区中第2个扇区中的内容

页面置换 (Swap) ?



交换出去的页面放在哪里?

■ 交换出去的页面显然要写到磁盘上

➤ 问题的关键是写到磁盘的什么位置?



➤ 如果是代码段和数据段, 直接写到文件中?

➤ 如果是堆栈段呢? 创建一个文件吗?

变成了页面 ↔ 文件
↔ 扇区映射关系, 显然是低效的

➤ 应该是直接 “页面 ↔ 扇区”

页表条目



为提效率, 这部分磁盘不存文件, 直接用扇区号寻址。(交换分区)

这样使用的磁盘称为生磁盘(raw disk)

- 安装Linux时，需创建一硬盘分区作为交换分区

```
cst:/dev# fdisk
```

fdisk命令可以查看分区信息

```
Disk /dev/sda: 73.4 GB, 73407820800 bytes
255 heads, 63 sectors/track, 8924 cylinders
Units = cylinders of 16065 * 512 = 8225280 bytes

   Device Boot      Start   End  Blocks  Id System
/dev/sda1  *           1   8594  69031273+  83  Linux
/dev/sda2                8595   8924    2650725   5  Extended
/dev/sda5                8595   8924    2650693+  82  Linux swap
```

- 因为交换分区要和内存不断交换，所以是动态变化的

```
cst:~# cat /proc/meminfo
MemTotal:      1036564 kB
MemFree:       30584 kB
SwapTotal:     2650684 kB
SwapFree:      2650636 kB
```



swap分区的大小通常是内存大小的两倍



固态硬盘以及相关技术

固态硬盘 (SSD: Solid State Disk/Drive)

- 由NAND FLASH作为存储介质， 由一个嵌入式控制器控制NAND FLASH的操作， RAM作为buffer， 通过IDE, SATA, PCI-e等总线对外提供块接口。
- 按介质密度分为SLC、 MLC、 TLC、 QLC等。



顺序读吞吐量	550 MB/s	顺序写吞吐量	470 MB/s
随机读吞吐量	365 MB/s	随机写吞吐量	303 MB/s
平均顺序读访问时间	50 μ s	平均顺序写访问时间	60 μ s

■ 顺序访问比随机访问快

➤ 典型存储器层次结构问题

■ 随机写较慢

- 擦除块需要较长的时间($\sim 1\text{ms}$)
- 修改一页需要将块中所有页复制到新的块中
- 早期SSD 读/写速度之间的差距更大

■ 优点:

- 没有移动部件 → 更快、能耗更低、更结实


■ 缺点: 会磨损

- 闪存翻译层中的平均磨损逻辑试图通过将擦除平均分布在所有块上来最大化每个块的寿命
- 比如, Intel SSD 730 保证能经得起 128 PB (128×10^{15} 字节) 的写
- 2015年, SSD每字节比机械磁盘贵大约30倍


■ 应用:


- MP3播放器、智能手机、笔记本电脑
- 开始在台式机和服务器中应用

■ DRAM、磁盘和CPU速度之间的差距



Flash芯片内部结构





固态硬盘内部软件有两个主要模块：

1. 数据缓存管理模块
2. 闪存翻译层模块

- SSD是以硬盘的替代者的姿态出现，为了与现有系统无缝对接，SSD必须对外提供的是块接口，作为主机端，所看到的SSD是一个和HDD一样的块设备。
- 为了达到模拟块设备的目的，SSD中需要FTL作为中间层
- FTL从主机文件系统接收块级请求（LSN, size），经过FTL的处理，产生flash的各种控制命令

■ FTL由三部分组成:


- Address mapping (地址映射)
- Wear leveling (损耗平衡)
- Garbage collection (垃圾回收)

- 上层文件系统发送给SSD的任何读写命令包括两个部分 (LSN, size)
- **LSN是逻辑扇区号**，对于文件系统而言，它所看到的存储空间是一个线性的连续空间。例如，读请求 (260, 6) 表示的是需要读取从扇区号为260的逻辑扇区开始，总共6个扇区。
- 请求到达SSD后，需要经过地址转换，将**逻辑扇区转换成NAND FLASH中的物理页号**

<package, die, plane, block, page>

损耗平衡 (Wear-Leveling)

- Flash中每个块都有一定的擦写次数限制。故不能让某一个块被写次数较多，而其他块被写的次数较少。
- 需要找一种方法：使flash中每个块被擦写的次数基本相同。



■ 动态损耗平衡

- 在请求到达时，选取擦除次数较少的块作为请求的物理地址。


■ 静态损耗平衡

- 在运行一段时间后，有些块存放的数据一直没有更新（冷数据），而有些块的数据经常性的更新（热数据）。那些存放冷数据的块的擦除次数远小于存放热数据的块。将冷数据从原块取出，存放在擦除次数过多的块，原来存放冷数据的块被释放出来，接受热数据的擦写。

■ 垃圾回收的目的

SSD在使用过程中，会产生大量失效页，在SSD的容量到达一定阈值时，需要调用GC函数，清除所有失效页，以增加可用空间。

- 好的buffer策略能够提高SSD的整体性能。



- 传统的文件系统，比如EXT系列是针对磁盘介质设计的，因为磁盘是可以原地更新的，但是nand flash因为擦除太慢（擦除单元很大），为了速度只能异地更新。如果不考虑这个特性，会导致性能低下。
- F2FS主要技术：基于日志追加写，数据冷热分离、区分顺序写和随机写的数据布局等。
- F2FS的提升主要在随机读写性能中，比EXT4性能好2倍。




Figure 1: On-disk layout of F2FS.


Avoiding the Disk Bottleneck in the Data Domain Deduplication File System ----FAST-08

背景：数据去重技术

■ 数据去重（Data Deduplication）是本世纪初提出的一种文件级或者块级的压缩技术。数据去重与传统的压缩技术的本质区别是提出了数据块级或者是文件级粒度的冗余消除技术。主要包含：

➤ A. 安全指纹标识算法

➤ B. 基于内容分块算法




数据去重的基本流程：分块、哈希、索引和存储管理

提高了存储和传输的效率

(1) 极大地降低了存储空间的需求，从而减轻存储成本

(2) 极大地减少了需要网络传送的数据量，从而提高传输带宽



■ 磁盘索引瓶颈问题

- Venti使用了磁盘指纹索引方案，其系统冗余数据消除吞吐率仅仅为6.5MB/s。
- 但是高吞吐率是企业数据保护的关键指标，其备份任务通常得超过100MB/s。

问题： 指纹索引表

■ 索引表大小（使用SHA1指纹）


- 8TB 数据, 20GB 指纹库
- 800TB 数据 ,2000GB 指纹库
- 使用SHA256, SHA512呢？



太慢



太小



■ 内存开销 (SHA1) ?


➤ 1G个数据块 → 8TB数据 → BF开销1GB

■ 索引性能?


➤ 局部性+BF(布隆过滤器)

➤ 减少了99%的磁盘I/O


■ 新型的索引结构：布隆过滤器



(a) Inserting segment s1 to the Summary Vector



(b) Looking up segment s2 in the Summary Vector



Data center A backs up structured database data over the course of 31 days during the initial deployment of a deduplication system. The backup policy is to do daily full backups, where each full backup produces over 600 GB at steady state. There are two exceptions:

- During the initial seeding phase (until 6th day in this example), different data or different types of data are rolled into the backup set, as backup administrators figure out how they want to use the deduplication system. A low rate of duplicate segment identification and elimination is typically associated with the seeding phase.
- There are certain days (18th day in this example) when no backup is generated.





Figure 4: Logical/Physical Capacities at Data Center A

	Exchange data		Engineering data	
	# disk I/Os	% of total	# disk I/Os	% of total
no Summary Vector and no Locality Preserved Caching	328,613,503	100.00%	318,236,712	100.00%
Summary Vector only	274,364,788	83.49%	259,135,171	81.43%
Locality Preserved Caching only	57,725,844	17.57%	60,358,875	18.97%
Summary Vector and Locality Preserved Caching	3,477,129	1.06%	1,257,316	0.40%


- 全面取代磁带备份
- 带动了整个数据去重领域的研究
- EMC收购，仍然是最大的备份产商之一

Chunkstash speeding up inline storage deduplication using flash memory,
USENIX ATC 2010

- 磁盘的性能: IOPS大约100
- 固态硬盘性能: IOPS大约100,000
- 索引组织: cuckoo hash



- 测试结果
- 相关问题
- 最终的应用？



➤ Windows Server 8 (2012)：重复数据删除性能——通过在存储卷中来重复数据删除，以节约磁盘空间，使得存储更加高效，这个新功能可以大大提高重复删除VDI部署里数据的整体效能。附带好处是,重复删除数据技术大大提高了虚拟桌面的启动性能。

Hope you enjoyed the OS course!