



人工智能

陈科海

计算机科学与技术学院
哈尔滨工业大学（深圳）

chenkehai@hit.edu.cn



第 5 章 不确定性推理

目 录

01

5.1 概述

02

5.2 可信度推理

03

5.3 主观Bayes推理

04

5.4 证据理论推理

05

5.5 模糊推理

06

5.6 Bayesian网络

5.1.1 不确定性推理的含义

□ 什么是不确定性推理

不确定性推理是指建立在不确定性知识和证据基础上的推理。包括不完备、不精确知识的推理、模糊知识的推理等。泛指除精确推理以外的其它各种推理问题。

不确定性推理过程实际上是一种从不确定的初始证据出发，通过运用不确定性知识，最终推出具有一定不确定性但却又是合理或基本合理的结论的思维过程。

□ 三种不确定性

证据的不确定性、知识（规则）的不确定性、结论的不确定性

□ 为什么要采用不确定性推理

- (1) 所需知识不完备、不精确；
- (2) 所需知识描述模糊
- (3) 多种原因导致同一结论；
- (4) 解题方案不唯一

5.1.1 不确定性推理的含义

□ 什么是不确定性推理

不确定性推理是指建立在不确定性知识和证据基础上的推理。包括不完备、不精确知识的推理、模糊知识的推理等。泛指除精确推理以外的其它各种推理问题。

不确定性推理是指建立在不确定性知识和证据基础上的推理。包括不完备、不精确知识的推理、模糊知识的推理等。泛指除精确推理以外的其它各种推理问题。

知识, 不确定性推理: { 初始证据, 知识 } (均不确定) → 结论 (不确定但合理)

□ 三种不确定性推理: 证据的不确定性、规则(知识库)的不确定性、结论的不确定性

□ 为什么要采用不确定性推理

- (1) 所需知识不完备、不精确;
- (2) 所需知识描述模糊
- (3) 多种原因导致同一结论 ;
- (4) 解题方案不唯一

5.1.2 不确定性推理的基本问题

□ 什么是不确定性推理

- 1) 不确定性的表示
- 2) 不确定性的匹配
- 3) 组合证据不确定性的计算
- 4) 不确定性的更新
- 5) 不确定性结论的合成

5.1.2 不确定性推理的基本问题

1. 不确定性的表示

❖ 知识的不确定性的表示

考虑因素：问题的描述能力，推理中不确定性的计算

含义：知识的确定性程度，或动态强度

表示方法：用 概率， $[0,1]$ ，0接近于假，1接近于真

用可信度， $[-1,1]$ ，大于0接近于真，小于0接近于假

用隶属度，在 $[0,1]$ 区间取值，越接近于0隶属度越低，反之越高

❖ 证据不确定性的表示

证据类型：按证据组织：基本证据，组合证据

按证据来源：初始证据，中间结论

表示方法：概率，可信度，模糊集等

基本证据：常与知识表示方法一致，如概率，可信度，模糊集等

5.1.2 不确定性推理的基本问题

2. 不确定性的匹配

含义：不确定的前提条件与不确定的事实匹配

问题：前提是不确定的，事实也是不确定的

方法：设计一个计算相似程度的算法，给出相似的限度

标志：相似度落在规定限度（阈值）内为匹配，否则为不匹配

3. 组合证据不确定性的计算

当知识的前提条件是多个不确定性证据组合时，如何计算复合证据的不确定性？

证据的组合方式：析取的关系，合取的关系。

证据的不确定性计算：基于基本证据的最大/最小方法、概率方法和有界方法等。

5.1.2 不确定性推理的基本问题

4. 不确定性的更新

主要问题

- ① 如何用证据的不确定性去**更新**结论的不确定性
- ② 如何在推理中把初始证据的不确定性**传递**给最终结论

解决方法

对①，不同推理方法的解决方法不同


对②，不同推理方法的解决方法基本相同，即把当前结论及其不确定性作为新的结论放入综合数据库，依次传递，直到得出最终结论

5. 不确定性结论的合成


含义：多个不同知识推出同一结论，且不确定性程度不同

方法：视不同推理方法而定

5.1.3 不确定性推理类型



5.1.3 不确定性推理类型



目 录

01

5.1 概述

02

5.2 可信度推理

03

5.3 主观Bayes推理

04

5.4 证据理论推理

05

5.5 模糊推理

06

5.6 Bayesian网络

5.2.1 可信度推理

- 1975年肖特里菲 (E. H. Shortliffe) 等人在确定性理论 (theory of confirmation) 的基础上, 结合概率论等提出的一种不确定性推理方法。
- **可信度**: 根据经验对一个事物或现象为真的相信程度。
- **C-F (Certainty Factor) 模型**: 可信推理模型--基于可信度表示的不确定性推理的基本方法。
- 优点: 直观、简单, 且效果好。
- 缺点: 可信度带有较大的主观性和经验性, 其准确性难以把握。

5.2.1 可信度推理

1. 知识不确定性的表示

■ 产生式规则表示:

IF E THEN H ($CF(H,E)$)

$CF(H, E)$:

- 1) 可信度因子(certainty factor), 反映前提条件(E)与结论(H)的联系强度
- 2) E or H既可以是简单条件或结论, 也可以是析取或合取构成的复合条件或结论
- 3) CF就是可信度, 也即知识的静态强度

例子: IF 发热 AND 流鼻涕 THEN 感冒 (0.8)

表示当某人确实有“发烧”及“流鼻涕”症状时, 则有80%的把握是患了感冒。

5.2.1 可信度推理

1. 知识不确定性的表示

- 在CF模型中, 把 $CF(H, E)$ 定义为:

$$CF(H, E) = MB(H, E) - MD(H, E)$$

其中, MB (Measure Belief, MB)称为信任增长度

$$MB(H, E) = \begin{cases} 1 & \text{若 } P(H) = 1 \\ \frac{P(H|E) - P(H)}{1 - P(H)} & P(H|E) \geq P(H) \\ 0 & P(H|E) < P(H) \end{cases}$$

MD (Measure Disbelief, MD)称为不信任增长度

$$MD(H, E) = \begin{cases} 1, & \text{若 } P(H) = 0 \\ \frac{\min\{P(H|E), P(H)\} - P(H)}{-P(H)}, & \text{否则} \end{cases}$$

5.2.1 可信度推理

1. 知识不确定性的表示

- 在CF模型中, 把 $CF(H, E)$ 定义为:

其中,

$$CF(H, E) = \begin{cases} MB(H, E) - 0 = \frac{P(H|E) - P(H)}{1 - P(H)} & \text{若 } P(H|E) > P(H) \\ 0 & \text{若 } P(H|E) = P(H) \\ 0 - MD(H, E) = -\frac{P(H) - P(H|E)}{P(H)} & \text{若 } P(H|E) < P(H) \end{cases}$$

MD (M

$-P(H)$, 否则

1. 知识不确定性的表示

- ❖ $CF(H, E)$ 的取值范围: $[-1,1]$ 。
- ❖ 若由于相应证据的出现增加结论 H 为真的可信度, 则 $CF(H, E) > 0$, 证据的出现越是支持 H 为真, 就使 $CF(H, E)$ 的值越大。
- ❖ 反之, $CF(H, E) < 0$, 证据的出现越是支持 H 为假, $CF(H, E)$ 的值就越小。
- ❖ 若证据的出现与否与 H 无关, 则 $CF(H, E) = 0$ 。
- ❖ 对同一前提 E , 若支持若干个不同的结论 $H_i (i=1, 2, \dots, n)$, 则

$$\sum_{i=1}^n CF(H_i, E) \leq 1$$

1. 知识不确定性的表示

- ❖ 可信度的性质
- ❖ 互斥性
- ❖ 值域
- ❖ 典型值
- ❖ 对H的信任增长度等于非H的不信任增长度
- ❖ 同一证据所支持的多个不同的结论，其概率综合小于等于1

2. 证据不确定性的表示

$$CF(E) = 0.6: E \text{ 的可信度为 } 0.6$$

- ❖ 证据 E 的可信度取值范围: $[-1, 1]$ 。
- ❖ 可信度的来源: 初始证据来源于用户; 由更新算法计算而来的中间结论
- ❖ 对于初始证据, 若所有观察 S 能肯定它为真, 则 $CF(E)=1$ 。
- ❖ 若肯定它为假, 则 $CF(E) = -1$ 。
- ❖ 若以某种程度为真, 则 $0 < CF(E) < 1$ 。
- ❖ 若以某种程度为假, 则 $-1 < CF(E) < 0$ 。
- ❖ 若未获得任何相关的观察, 则 $CF(E) = 0$ 。

2. 证据不确定性的表示

- ❖ 静态强度 $CF(H, E)$: 知识的强度, 即当 E 所对应的证据为真时对 H 的影响程度。
- ❖ 动态强度 $CF(E)$: 证据 E 当前的不确定性程度。

3. 组合证据不确定性的算法

❖ 多个单一证据的合取

$$E = E_1 \wedge E_2 \wedge \dots \wedge E_n$$

则

$$CF(E) = \min\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$$

❖ 多个单一证据的析取

$$E = E_1 \vee E_2 \vee \dots \vee E_n$$

则

$$CF(E) = \max\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$$

❖ 对“非”运算

$$CF(\neg E) = -CF(E)$$

4. 不确定性的更新

❖ C-F模型中的不确定性推理

从不确定的初始证据出发，通过运用相关的不确定性知识，最终推出结论并求出结论的可信度值。结论 H 的可信度由下式计算：

$$CF(H) = CF(H, E) \times \max\{0, CF(E)\}$$

当 $CF(E) < 0$ 时，则 $CF(H) = 0$

当 $CF(E) = 1$ 时，则 $CF(H) = CF(H, E)$

5. 不确定性结论的合成

设知识: IF E_1 THEN H ($CF(H, E_1)$)

IF E_2 THEN H ($CF(H, E_2)$)

(1) 分别对每一条知识求出 $CF(H)$:

$$CF_1(H) = CF(H, E_1) \times \max\{0, CF(E_1)\} \quad CF_2(H) = CF(H, E_2) \times \max\{0, CF(E_2)\}$$

(2) 求出 E_1 与 E_2 对 H 的综合影响所形成的可信度: $CF_{1,2}(H)$

$$CF_{1,2}(H) = \begin{cases} CF_1(H) + CF_2(H) - CF_1(H)CF_2(H) & \text{若 } CF_1(H) \geq 0, \quad CF_2(H) \geq 0 \\ CF_1(H) + CF_2(H) + CF_1(H)CF_2(H) & \text{若 } CF_1(H) < 0, \quad CF_2(H) < 0 \\ \frac{CF_1(H) + CF_2(H)}{1 - \min\{|CF_1(H)|, |CF_2(H)|\}} & \text{若 } CF_1(H) \text{ 与 } CF_2(H) \text{ 异号} \end{cases}$$

5.2.2 可信度推理实例

例3.1 设有如下一组知识:

$$r_1: \quad IF \quad E_1 \quad THEN \quad H \quad (0.9)$$

$$r_2: \quad IF \quad E_2 \quad THEN \quad H \quad (0.6)$$

$$r_3: \quad IF \quad E_3 \quad THEN \quad H \quad (-0.5)$$

$$r_4: \quad IF \quad E_4 \quad AND \quad (E_5 \quad OR \quad E_6) \quad THEN \quad E_1 \quad (0.8)$$

已知: $CF(E_2)=0.8$, $CF(E_3)=0.6$, $CF(E_4)=0.5$, $CF(E_5)=0.6$, $CF(E_6)=0.7$,

求: $CF(H)$

5.2.2 可信度推理实例

解： (1) 分别对每一条知识求出 $CF(H)$

$$r_4: \quad IF \quad E_4 \quad AND \quad (E_5 \quad OR \quad E_6) \quad THEN \quad E_1 \quad (0.8)$$

由规则 r_4 得：

$$\begin{aligned} CF(E_1) &= 0.8 \times \max\{0, CF[E_4 \quad AND \quad (E_5 \quad OR \quad E_6)]\} \\ &= 0.8 \times \max\{0, \min\{CF(E_4), CF(E_5 \quad OR \quad E_6)\}\} \\ &= 0.8 \times \max\{0, \min\{CF(E_4), \max\{CF(E_5), CF(E_6)\}\}\} \\ &= 0.8 \times \max\{0, \min\{0.5, \max\{0.6, 0.7\}\}\} \\ &= 0.8 \times \max\{0, 0.5\} \\ &= 0.4 \end{aligned}$$

$$CF(E_2) = 0.8,$$

$$CF(E_3) = 0.6,$$

$$CF(E_4) = 0.5,$$

$$CF(E_5) = 0.6,$$

$$CF(E_6) = 0.7,$$

5.2.2 可信度推理实例

解： (1) 分别对每一条知识求出 $CF(H)$:

由规则 r_1 得: (r_1 : IF E_1 THEN H (0.9))

$$\begin{aligned} CF_1(H) &= 0.9 \times \max\{0, CF(E_1)\} = 0.9 \times \max\{0, 0.4\} \\ &= 0.36 \end{aligned}$$

由规则 r_2 得: (r_2 : IF E_2 THEN H (0.6))

$$\begin{aligned} CF_2(H) &= 0.6 \times \max\{0, CF(E_2)\} = 0.6 \times \max\{0, 0.8\} \\ &= 0.48 \end{aligned}$$

由规则 r_3 得: (r_3 : IF E_3 THEN H (-0.5))

$$\begin{aligned} CF_3(H) &= -0.5 \times \max\{0, CF(E_3)\} = -0.5 \times \max\{0, 0.6\} \\ &= -0.3 \end{aligned}$$

$$CF(E_2) = 0.8,$$

$$CF(E_3) = 0.6,$$

$$CF(E_4) = 0.5,$$

$$CF(E_5) = 0.6,$$

$$CF(E_6) = 0.7,$$

$$CF(E_1) = 0.4$$

5.2.2 可信度推理实例

解： (2) 求出 E_1 与 E_2 对 H 的综合影响所形成的可信度 $CF_{1,2}(H)$ ：

$$\begin{aligned} CF_{1,2}(H) &= CF_1(H) + CF_2(H) - CF_1(H) \times CF_2(H) \\ &= 0.36 + 0.48 - 0.36 \times 0.48 = 0.67 \end{aligned}$$

$$\begin{aligned} CF_{1,2,3}(H) &= \frac{CF_{1,2}(H) + CF_3(H)}{1 - \min\{|CF_{1,2}(H)|, |CF_3(H)|\}} \\ &= \frac{0.67 - 0.3}{1 - \min\{0.67, 0.3\}} = \frac{0.37}{0.7} = 0.53 \end{aligned}$$

$$CF(E_2) = 0.8,$$

$$CF(E_3) = 0.6,$$

$$CF(E_4) = 0.5,$$

$$CF(E_5) = 0.6,$$

$$CF(E_6) = 0.7,$$

$$CF(E_1) = 0.4$$

$$CF_1(H) = 0.36$$

$$CF_2(H) = 0.48$$

$$CF_3(H) = -0.3$$

$$CF_{1,2}(H) = \begin{cases} CF_1(H) + CF_2(H) - CF_1(H)CF_2(H) & \text{若 } CF_1(H) \geq 0, \quad CF_2(H) \geq 0 \\ CF_1(H) + CF_2(H) + CF_1(H)CF_2(H) & \text{若 } CF_1(H) < 0, \quad CF_2(H) < 0 \\ \frac{CF_1(H) + CF_2(H)}{1 - \min\{|CF_1(H)|, |CF_2(H)|\}} & \text{若 } CF_1(H) \text{ 与 } CF_2(H) \text{ 异号} \end{cases}$$

不确定性推理（课程回顾）

■ 可信度推理的五个基本问题

1. 知识不确定性的表示：知识（规则）
2. 证据不确定性表示：来源，静态，动态
3. 组合证据不确定性的计算：合取和析取
4. 不确定性的更新：运用规则推理过程中不确定性的传递
5. 不确定性结论的合成：多条推理路径时，结论的不确定性

5.2.2 可信度推理实例

例3.1 设有如下一组知识:

$$r_1: \quad IF \quad E_1 \quad THEN \quad H \quad (0.9)$$

$$r_2: \quad IF \quad E_2 \quad THEN \quad H \quad (0.6)$$

$$r_3: \quad IF \quad E_3 \quad THEN \quad H \quad (-0.5)$$

$$r_4: \quad IF \quad E_4 \quad AND \quad (E_5 \quad OR \quad E_6) \quad THEN \quad E_1 \quad (0.8)$$

已知: $CF(E_2)=0.8$, $CF(E_3)=0.6$, $CF(E_4)=0.5$, $CF(E_5)=0.6$, $CF(E_6)=0.7$,

求: $CF(H)$

5.2.2 可信度推理实例

解： (1) 分别对每一条知识求出 $CF(H)$

$$r_4: \quad IF \quad E_4 \quad AND \quad (E_5 \quad OR \quad E_6) \quad THEN \quad E_1 \quad (0.8)$$

由规则 r_4 得：

$$\begin{aligned} CF(E_1) &= 0.8 \times \max\{0, CF[E_4 \quad AND \quad (E_5 \quad OR \quad E_6)]\} \\ &= 0.8 \times \max\{0, \min\{CF(E_4), CF(E_5 \quad OR \quad E_6)\}\} \\ &= 0.8 \times \max\{0, \min\{CF(E_4), \max\{CF(E_5), CF(E_6)\}\}\} \\ &= 0.8 \times \max\{0, \min\{0.5, \max\{0.6, 0.7\}\}\} \\ &= 0.8 \times \max\{0, 0.5\} \\ &= 0.4 \end{aligned}$$

$$CF(E_2) = 0.8,$$

$$CF(E_3) = 0.6,$$

$$CF(E_4) = 0.5,$$

$$CF(E_5) = 0.6,$$

$$CF(E_6) = 0.7,$$

5.2.2 可信度推理实例

解： (1) 分别对每一条知识求出 $CF(H)$:

由规则 r_1 得: (r_1 : IF E_1 THEN H (0.9))

$$\begin{aligned} CF_1(H) &= 0.9 \times \max\{0, CF(E_1)\} = 0.9 \times \max\{0, 0.4\} \\ &= 0.36 \end{aligned}$$

由规则 r_2 得: (r_2 : IF E_2 THEN H (0.6))

$$\begin{aligned} CF_2(H) &= 0.6 \times \max\{0, CF(E_2)\} = 0.6 \times \max\{0, 0.8\} \\ &= 0.48 \end{aligned}$$

由规则 r_3 得: (r_3 : IF E_3 THEN H (-0.5))

$$\begin{aligned} CF_3(H) &= -0.5 \times \max\{0, CF(E_3)\} = -0.5 \times \max\{0, 0.6\} \\ &= -0.3 \end{aligned}$$

$$CF(E_2) = 0.8,$$

$$CF(E_3) = 0.6,$$

$$CF(E_4) = 0.5,$$

$$CF(E_5) = 0.6,$$

$$CF(E_6) = 0.7,$$

$$CF(E_1) = 0.4$$

5.2.2 可信度推理实例

解： (2) 求出 E_1 与 E_2 对 H 的综合影响所形成的可信度 $CF_{1,2}(H)$ ：

$$\begin{aligned} CF_{1,2}(H) &= CF_1(H) + CF_2(H) - CF_1(H) \times CF_2(H) \\ &= 0.36 + 0.48 - 0.36 \times 0.48 = 0.67 \end{aligned}$$

$$\begin{aligned} CF_{1,2,3}(H) &= \frac{CF_{1,2}(H) + CF_3(H)}{1 - \min\{|CF_{1,2}(H)|, |CF_3(H)|\}} \\ &= \frac{0.67 - 0.3}{1 - \min\{0.67, 0.3\}} = \frac{0.37}{0.7} = 0.53 \end{aligned}$$

$$CF(E_2) = 0.8,$$

$$CF(E_3) = 0.6,$$

$$CF(E_4) = 0.5,$$

$$CF(E_5) = 0.6,$$

$$CF(E_6) = 0.7,$$

$$CF(E_1) = 0.4$$

$$CF_1(H) = 0.36$$

$$CF_2(H) = 0.48$$

$$CF_3(H) = -0.3$$

$$CF_{1,2}(H) = \begin{cases} CF_1(H) + CF_2(H) - CF_1(H)CF_2(H) & \text{若 } CF_1(H) \geq 0, \quad CF_2(H) \geq 0 \\ CF_1(H) + CF_2(H) + CF_1(H)CF_2(H) & \text{若 } CF_1(H) < 0, \quad CF_2(H) < 0 \\ \frac{CF_1(H) + CF_2(H)}{1 - \min\{|CF_1(H)|, |CF_2(H)|\}} & \text{若 } CF_1(H) \text{ 与 } CF_2(H) \text{ 异号} \end{cases}$$

目 录

01

5.1 概述

02

5.2 可信度推理

03

5.3 主观Bayes推理

04

5.4 证据理论推理

05

5.5 模糊推理

06

5.6 Bayesian网络

5.3 主观Bayes

5.3.1 Bayes公式(定理)

❖ 全概率公式:

$$P(B) = \sum_{i=1}^n P(A_i) \times P(B | A_i) \quad (A_i \text{与} A_j (i \neq j) \text{互不相容})$$

❖ Bayes公式:

$$P(A_k | B) = \frac{P(A_k, B)}{P(B)} = \frac{P(A_k)P(B | A_k)}{\sum_i P(A_i)P(B | A_i)}$$

❖ 概率推理方法:

设有如下产生式表示:

IF E Then H $P(H|E)$



5.3.1 主观Bayes

例 假定病人的事实 E : 咳嗽。病因诊断结论有三种, H_1 : 支气管炎, H_2 : 肺炎, H_3 : 流感。根据病因前期检查的先验概率, 有病人患这三种病的概率 $P(H)$ 与统计所得病人在患 H_1, H_2, H_3 病的情况下咳嗽的概率 $P(E|H_i)$:

$$P(H_i) = \begin{cases} 0.3, i = 1 \\ 0.4, i = 2, \\ 0.3, i = 3 \end{cases}, \quad P(E | H_i) = \begin{cases} 0.5, i = 1 \\ 0.3, i = 2 \\ 0.4, i = 3 \end{cases}$$

求在病人出现咳嗽的症状时, 三种病因的不确定性推理表示

5.3.1 主观Bayes

解：

由Bayes公式有：

$$P(H_i | E) = \frac{P(H_i) \times P(E | H_i)}{P(E)} = \begin{cases} 0.38, i = 1 \\ 0.31, i = 2 \\ 0.31, i = 3 \end{cases}$$

当证据 E 发生时， H_1 ， H_3 病的可能性上升， H_2 的可能性下降。其不确定性推理表示如下：

$$IF \quad E \quad Then \quad H_i \begin{cases} 0.38, i = 1 \\ 0.31, i = 2, \text{可信度} \\ 0.31, i = 3 \end{cases}$$

$$P(H_i) = \begin{cases} 0.3, i = 1 \\ 0.4, i = 2, \\ 0.3, i = 3 \end{cases} \quad P(E | H_i) = \begin{cases} 0.5, i = 1 \\ 0.3, i = 2 \\ 0.4, i = 3 \end{cases}$$

5.3.1 主观Bayes

1. 知识不确定性的表示

- 产生式规则表示:

IF E THEN (LS, LN) H

(LS, LN) : 表示前提条件对结论的支持强度。

$$LS = \frac{P(E|H)}{P(E|\neg H)}$$

$$LN = \frac{P(\neg E|H)}{P(\neg E|\neg H)} = \frac{1 - P(E|H)}{1 - P(E|\neg H)}$$

1. 知识不确定性的表示

■ 几率 $O(X)$:

$$O(X) = \frac{P(X)}{1 - P(X)} \qquad O(X) = \frac{P(X)}{P(\neg X)}$$

通过几率的引入, 可以得到:

$$O(H | E) = \frac{P(E | H)}{P(E | \neg H)} O(H) = LS \times O(H)$$

$$O(H | \neg E) = \frac{P(\neg E | H)}{P(\neg E | \neg H)} O(H) = LN \times O(H)$$

$$P(H | E) = \frac{P(H | E)}{P(\neg H | E) + P(H | E)} = \frac{O(H | E)}{1 + O(H | E)}$$

5.3.1 主观Bayes

1. 知识不确定性的表示

■ *LS*的性质:

$LS > 1$	$O(H E) > O(H)$ $P(H E) > P(H)$	E 的 $\exists$ 使 H 为真的概率 $\nearrow$, $LS \nearrow \rightarrow P(H E) \nearrow$, $LS \rightarrow \infty \Rightarrow O(H E) \rightarrow \infty, P(H E) \rightarrow 1, LS$ 充分性
$LS = 1$	$O(H E) = O(H)$ $P(H E) = P(H)$	E 的 $\exists$ 与 H 无关
$LS \in (0,1)$	$O(H E) < O(H)$ $P(H E) < P(H)$	E 的 $\exists$ 使 H 为真的概率 $\searrow$, $LS \searrow \rightarrow P(H E) \searrow$
$LS = 0$	$O(H E) = 0$ $P(H E) = 0$	E 的 $\exists$ 使 H 为假

5.3.1 主观Bayes

1. 知识不确定性的表示

■ *LS*的性质:

$LS > 1$	$O(H E) > O(H)$ $P(H E) > P(H)$	E 的 $\exists$ 使 H 为真的概率 $\nearrow$, $LS \nearrow \rightarrow P(H E) \nearrow$, $LS \rightarrow \infty \Rightarrow O(H E) \rightarrow \infty, P(H E) \rightarrow 1, LS$ 充分性
$LS = 1$	$O(H E) = O(H)$ $P(H E) = P(H)$	E 的 $\exists$ 与 H 无关
$LS \in (0,1)$	$O(H E) < O(H)$ $P(H E) < P(H)$	E 的 $\exists$ 使 H 为真的概率 $\searrow$, $LS \searrow \rightarrow P(H E) \searrow$
$LS = 0$	$O(H E) = 0$ $P(H E) = 0$	E 的 $\exists$ 使 H 为假

充分性度量: *E*对*H*的支持程度

5.3.1 主观Bayes

1. 知识不确定性的表示

■ LN 的性质:

$LN > 1$	$O(H \neg E) > O(H)$ $P(H \neg E) > P(H)$	E 不 $\exists$ 使 H 为真的概率 $\nearrow$, $LN \nearrow \rightarrow P(H \neg E) \nearrow$, $LN \rightarrow \infty \Rightarrow O(H \neg E) \rightarrow \infty, P(H \neg E) \rightarrow 1$
$LN = 1$	$O(H \neg E) = O(H)$ $P(H \neg E) = P(H)$	$\neg E$ 的 $\exists$ 与 H 无关
$LN \in (0,1)$	$O(H \neg E) < O(H)$ $P(H \neg E) < P(H)$	$\neg E \exists$ 使 H 为真的概率 $\searrow$, $LN \searrow \rightarrow P(H \neg E) \searrow$ $\neg E \exists \rightarrow H$ 不为真; LN 必要性
$LN = 0$	$O(H \neg E) = 0$ $P(H \neg E) = 0$	$LN \rightarrow 0 \Rightarrow H$ 为假 $\Leftrightarrow H$ 真 $\Rightarrow E \exists$

5.3.1 主观Bayes

1. 知识不确定性的表示

■ LN 的性质:

$LN > 1$	$O(H \neg E) > O(H)$ $P(H \neg E) > P(H)$	E 不 $\exists$ 使 H 为真的概率 $\nearrow$, $LN \nearrow \rightarrow P(H \neg E) \nearrow$, $LN \rightarrow \infty \Rightarrow O(H \neg E) \rightarrow \infty, P(H \neg E) \rightarrow 1$
$LN = 1$	$O(H \neg E) = O(H)$ $P(H \neg E) = P(H)$	$\neg E$ 的 $\exists$ 与 H 无关
$LN \in (0,1)$	$O(H \neg E) < O(H)$ $P(H \neg E) < P(H)$	$\neg E \exists$ 使 H 为真的概率 $\searrow$, $LN \searrow \rightarrow P(H \neg E) \searrow$ $\neg E \exists \rightarrow H$ 不为真; LN 必要性
$LN = 0$	$O(H \neg E) = 0$ $P(H \neg E) = 0$	$LN \rightarrow 0 \Rightarrow H$ 为假 $\Leftrightarrow H$ 真 $\Rightarrow E \exists$

必要性度量: $\neg E$ 对 H 的支持程度

1. 知识不确定性的表示

■ LS 与 LN 的关系:

由于 E 和 $\neg E$ 不会同时支持或同时排斥 H , 因此只有下述三种情况存在:

- ◆ $LS > 1, LN < 1$: $P(H|E) > P(H) > P(H|\neg E)$, 说明证据 E 的存在增加了对 H 的信任度, 而 E 不存在则减少对 H 的信任度。
- ◆ $LS = LN = 1$: $P(H|E) = P(H) = P(H|\neg E)$, 说明 E 的存在与否对假设 H 无影响。
- ◆ $LS < 1, LN > 1$: $P(H|E) < P(H) < P(H|\neg E)$, 说明 E 的存在减少了对 H 的主观信任度, 而 E 不存在则增加 H 的信任度。

1. 知识不确定性的表示

■ LS 与 LN 的关系:

由于 E 和 $\neg E$ 不会同时支持或同时排斥 H , 因此只有下述三种情况存在:

- ◆ $LS > 1, LN < 1$: $P(H|E) > P(H) > P(H|\neg E)$, 说明证据 E 的存在增加了对 H 的信任度, 而 E 不存在则减少对 H 的信任度。
- ◆ $LS = LN = 1$: $P(H|E) = P(H) = P(H|\neg E)$, 说明 E 的存在与否对假设 H 无影响。
- ◆ $LS < 1, LN > 1$: $P(H|E) < P(H) < P(H|\neg E)$, 说明 E 的存在减少了对 H 的主观信任度, 而 E 不存在则增加 H 的信任度。

实际系统中, **LS 和 LN 的值均由领域专家根据经验给出的**, 而不是有 LS 和 LN 计算所得。当证据 E 越是支持 H 为真时, 则 LS 的值应该越大; 当证据 E 对 H 越是重要时, 则相应的 LN 的值应该越小。

2. 证据不确定性的表示

❖ 通常也用概率或几率表示，两者之间的关系为

$$O(E) = \frac{P(E)}{1 - P(E)} = \begin{cases} 0 & \text{当} E \text{为假时} \\ \infty & \text{当} E \text{为真时} \\ (0, \infty) & \text{当} E \text{非真也非假时} \end{cases}$$

注意：公式给出的仅是证据 E 的先验概率与先验几率之间的关系，但在某些情况下，除了需要考虑证据 E 的先验概率与先验几率外，还要考虑当前观察下证据 E 的后验概率或后验几率。以后验情况为例，对于初始证据 E ，由用户根据观察 S 给出 $P(E|S)$ ，它相当于动态强度。

3. 组合证据不确定性的算法

❖ 多个单一证据的合取

$$E = E_1 \wedge E_2 \wedge \dots \wedge E_n$$

如果已知 $P(E_1|S), P(E_2|S), \dots, P(E_n|S)$, 则:

$$P(E|S) = \min\{P(E_1|S), P(E_2|S), \dots, P(E_n|S)\}$$

❖ 多个单一证据的析取

$$E = E_1 \vee E_2 \vee \dots \vee E_n$$

如果已知 $P(E_1|S), P(E_2|S), \dots, P(E_n|S)$, 则

$$P(E|S) = \max\{P(E_1|S), P(E_2|S), \dots, P(E_n|S)\}$$


❖ 对“非”运算

$$P(\neg E|S) = 1 - P(E|S)$$

5.3.1 主观Bayes

4. 不确定性的更新

- ❖ **主观Bayes的不确定性推理**：根据证据 E 的概率 $P(E)$ 及 LS, LN 的值，把 H 的先验概率 $P(H)$ 更新为后验概率 $P(H|E)$ 或 $P(H|\neg E)$ 。这样计算的目的就是看 E 对最终结论 H 的影响，如图：



- ❖ **分以下3种情况讨论**：

1. 证据 E 肯定为真
2. 证据 E 肯定为假
3. 证据 E 既非为真也非为假（不确定）

4. 不确定性的更新

❖ 证据 E 肯定为真:

$$P(H | E) = \frac{LS \times P(H)}{(LS - 1) \times P(H) + 1}$$

❖ 证据 E 肯定为假:

$$P(H | \neg E) = \frac{LN \times P(H)}{(LN - 1) \times P(H) + 1}$$

❖ 证据 E 不确定的情况: 需要使用杜达**R.O.Doda**等人给出的公式

$$P(H | S) = P(H | E) \times P(E | S) + P(H | \neg E) \times P(\neg E | S)$$

分4种情况:

$$(1) P(E|S)=1, P(\neg E|S)=0 \quad P(H | S) = P(H | E) = \frac{LS \times P(H)}{(LS - 1) \times P(H) + 1}$$

$$(2) P(E|S)=0, P(\neg E|S)=1 \quad P(H | S) = P(H | \neg E) = \frac{LN \times P(H)}{(LN - 1) \times P(H) + 1}$$

5.3.1 主观Bayes

4. 不确定性的更新

❖ 证据 E 不确定的情况: $P(H|S) = P(H|E) \times P(E|S) + P(H|\neg E) \times P(\neg E|S)$

(3) $P(E|S)=P(E)$, E 与 S 无关


$$P(H|S) = P(H|E) \times P(E|S) + P(H|\neg E) \times P(\neg E|S)$$

(4) $P(E|S)$ 为其它值

$$= P(H|E) \times P(E) + P(H|\neg E) \times P(\neg E) = P(H)$$

$$P(H|S) = \begin{cases} P(H|\neg E) + \frac{P(H) - P(H|\neg E)}{P(E)} \times P(E|S), & \text{若 } 0 \leq P(E|S) < P(E) \\ P(H) + \frac{P(H|E) - P(H)}{1 - P(E)} \times [P(E|S) - P(E)], & \text{若 } P(E) \leq P(E|S) \leq 1 \end{cases}$$

通过对前边三种情况下的 $P(E|S)$ 上的三个特殊值: 0, $P(E)$, 1。并且分别取得了对应值 $P(H|\neg E)$ 、 $P(H)$ 及 $P(H|E)$ 。当 $P(E|S)$ 为其它值时, 通过分段线性插值可得到计算 $P(H|S)$ 的公式。



5. 不确定性结论的合成

- ❖ 假设有 n 条知识都支持同一结论 H ，并且这些知识的前提条件分别是 n 个相互独立的证据 E_1 、 E_2 、...、 E_n ，而每个证据所对应的观察又分别是 S_1 、 S_2 、...、 S_n 。在这些观察下，求 H 的后验概率的方法是：首先对每条知识分别求出 H 的后验几率 $O(H|S_i)$ ，然后利用这些后验几率并按下述公式求出在所有观察下 H 的后验几率：

$$O(H | S_1, S_2, \dots, S_n) = \frac{O(H | S_1)}{O(H)} \times \frac{O(H | S_2)}{O(H)} \times \dots \times \frac{O(H | S_n)}{O(H)} \times O(H)$$

得到 $O(H | S_1, S_2, \dots, S_n)$ 之后，通过以下公式求得： $P(H | S_1, S_2, \dots, S_n)$

$$P(H | E) = \frac{P(H | E)}{P(\neg H | E) + P(H | E)} = \frac{O(H | E)}{1 + O(H | E)}$$

5.3.2 主观Bayes举例

例 3.2 设有规则

$$r_1: IF E_1 THEN (2, 0.0001) H_1$$

$$r_2: IF E_1 AND E_2 THEN (100, 0.001) H_1$$

$$r_3: IF H_1 THEN (200, 0.01) H_2$$

$$\text{已知: } P(E_1)=P(E_2)=0.6$$


$$P(H_1)=0.091, P(H_2)=0.01$$

$$\text{用户回答: } P(E_1|S_1)=0.76, P(E_2|S_2)=0.68$$

$$\text{求: } P(H_2|S_1, S_2)=?$$

5.3.2 主观Bayes举例

解：由已有知识得到的推理网络如下图所示




5.3.2 主观Bayes举例

解: (1) 计算 $O(H_1|S_1)$

先把 $P(H_1)$ 更新为 E_1 下的后验概率 $P(H_1|E_1)$

$$P(H_1 | E_1) = \frac{LS_1 \times P(H_1)}{(LS_1 - 1) \times P(H_1) + 1} = \frac{2 \times 0.091}{(2 - 1) \times 0.091 + 1} = 0.167$$



5.3.2 主观Bayes举例

解：(1) 计算 $O(H_1|S_1)$


先把 $P(H_1)$ 更新为 E_1 下的后验概率 $P(H_1|E_1)$

$$P(H_1 | E_1) = \frac{LS_1 \times P(H_1)}{(LS_1 - 1) \times P(H_1) + 1} = \frac{2 \times 0.091}{(2 - 1) \times 0.091 + 1} = 0.167$$

由于 $P(E_1|S_1)=0.76>P(E)$ ，使用以下公式得到 $P(H_1|S_1)$ 为：

$$\begin{aligned} P(H_1 | S_1) &= P(H_1) + \frac{P(H_1 | E_1) - P(H_1)}{1 - P(E_1)} \times (P(E_1 | S_1) - P(E_1)) \\ &= 0.091 + \frac{(0.167 - 0.091)}{1 - 0.6} \times (0.76 - 0.6) \\ &= 0.121 \end{aligned}$$


$$O(H_1 | S_1) = \frac{P(H_1 | S_1)}{1 - P(H_1 | S_1)} = \frac{0.121}{1 - 0.121} = 0.138$$



5.3.2 主观Bayes举例

解: (2) 计算 $O(H_1|(S_1 \text{ AND } S_2))$

$$\begin{aligned} P(E | (S_1 \wedge S_2)) &= \min\{ P(E_1 | S_1), P(E_2 | S_2) \} \\ &= \min\{ 0.76, 0.68 \} = P(E_2 | S_2) \end{aligned}$$



5.3.2 主观Bayes举例


解：(2) 计算 $O(H_1|(S_1 \text{ AND } S_2))$

$$\begin{aligned}P(E | (S_1 \wedge S_2)) &= \min\{ P(E_1 | S_1), P(E_2 | S_2) \} \\&= \min\{ 0.76, 0.68 \} = P(E_2 | S_2)\end{aligned}$$

仅考虑 E_2 对 H_1 的影响，计算 $O(H_1|(S_1 \text{ AND } S_2))$ 转化为计算 $O(H_1|S_2)$ 。

把 H_1 的先验概率 $P(H_1)$ 更新为在 E_2 下的后验概率 $P(H_1|E_2)$

$$P(H_1 | E_2) = \frac{LS_2 \times P(H_1)}{(LS_2 - 1) \times P(H_1) + 1} = \frac{100 \times 0.091}{(100 - 1) \times 0.091 + 1} = 0.909$$



5.3.2 主观Bayes举例

解: (2) 计算 $O(H_1|(S_1 \text{ AND } S_2))$

$$\begin{aligned}P(E | (S_1 \wedge S_2)) &= \min\{ P(E_1 | S_1), P(E_2 | S_2) \} \\&= \min\{ 0.76, 0.68 \} = P(E_2 | S_2)\end{aligned}$$


仅考虑 E_2 对 H_1 的影响, 计算 $O(H_1|(S_1 \text{ AND } S_2))$ 转化为计算 $O(H_1|S_2)$ 。

把 H_1 的先验概率 $P(H_1)$ 更新为在 E_2 下的后验概率 $P(H_1|E_2)$

$$P(H_1 | E_2) = \frac{LS_2 \times P(H_1)}{(LS_2 - 1) \times P(H_1) + 1} = \frac{100 \times 0.091}{(100 - 1) \times 0.091 + 1} = 0.909$$

由于 $P(E_2|S_2)=0.68 > P(E_2)$, 使用以下公式得到 $P(H_1|S_2)$ 为:

$$\begin{aligned}P(H_1 | S_2) &= P(H_1) + \frac{P(H_1 | E_2) - P(H_1)}{1 - P(E_2)} \times (P(E_2 | S_2) - P(E_2)) \\&= 0.091 + \frac{(0.909 - 0.091)}{1 - 0.6} \times (0.68 - 0.6) = 0.255\end{aligned}$$



5.3.2 主观Bayes举例

解: (2) 计算 $O(H_1|(S_1 \text{ AND } S_2))$

$$\begin{aligned}P(E | (S_1 \wedge S_2)) &= \min\{ P(E_1 | S_1), P(E_2 | S_2) \} \\&= \min\{ 0.76, 0.68 \} = P(E_2 | S_2)\end{aligned}$$

仅考虑 E_2 对 H_1 的影响, 计算 $O(H_1|(S_1 \text{ AND } S_2))$ 转化为计算 $O(H_1|S_2)$ 。


把 H_1 的先验概率 $P(H_1)$ 更新为在 E_2 下的后验概率 $P(H_1|E_2)$

$$P(H_1 | E_2) = \frac{LS_2 \times P(H_1)}{(LS_2 - 1) \times P(H_1) + 1} = \frac{100 \times 0.091}{(100 - 1) \times 0.091 + 1} = 0.909$$

由于 $P(E_2|S_2)=0.68 > P(E_2)$, 使用以下公式得到 $P(H_1|S_2)$ 为:

$$\begin{aligned}P(H_1 | S_2) &= P(H_1) + \frac{P(H_1 | E_2) - P(H_1)}{1 - P(E_2)} \times (P(E_2 | S_2) - P(E_2)) \\&= 0.091 + \frac{(0.909 - 0.091)}{1 - 0.6} \times (0.68 - 0.6) = 0.255\end{aligned}$$

$$O(H_1 | S_2) = \frac{P(H_1 | S_2)}{1 - P(H_1 | S_2)} = \frac{0.255}{1 - 0.255} = 0.342$$




5.3.2 主观Bayes举例

解: (3) 计算 $O(H_1|S_1, S_2)$

先将 H_1 的先验概率 $P(H_1)$ 转换为先验几率

$$O(H_1) = \frac{P(H_1)}{1 - P(H_1)} = \frac{0.091}{1 - 0.091} = 0.1$$



5.3.2 主观Bayes举例


解: (3) 计算 $O(H_1|S_1, S_2)$

先将 H_1 的先验概率 $P(H_1)$ 转换为先验几率

$$O(H_1) = \frac{P(H_1)}{1 - P(H_1)} = \frac{0.091}{1 - 0.091} = 0.1$$

再根据合成公式计算 H_1 的先验几率

$$\begin{aligned} O(H_1 | S_1, S_2) &= \frac{O(H_1 | S_1)}{O(H_1)} \times \frac{O(H_1 | S_2)}{O(H_1)} \times O(H_1) \\ &= \frac{0.138}{0.1} \times \frac{0.342}{0.1} \times 0.1 = 0.472 \end{aligned}$$



5.3.2 主观Bayes举例

解: (3) 计算 $O(H_1|S_1, S_2)$

先将 H_1 的先验概率 $P(H_1)$ 转换为先验几率


$$O(H_1) = \frac{P(H_1)}{1 - P(H_1)} = \frac{0.091}{1 - 0.091} = 0.1$$

再根据合成公式计算 H_1 的先验几率

$$\begin{aligned} O(H_1 | S_1, S_2) &= \frac{O(H_1 | S_1)}{O(H_1)} \times \frac{O(H_1 | S_2)}{O(H_1)} \times O(H_1) \\ &= \frac{0.138}{0.1} \times \frac{0.342}{0.1} \times 0.1 = 0.472 \end{aligned}$$

然后再将后验几率转换为后验概率

$$P(H_1 | S_1, S_2) = \frac{O(H_1 | S_1, S_2)}{1 + O(H_1 | S_1, S_2)} = \frac{0.472}{1 + 0.472} = 0.321$$




5.3.2 主观Bayes举例

解：(4) 计算 $P(H_2|S_1, S_2)$

先将 H_2 的先验概率 $P(H_2)$ 转换为在 H_1 下的后验概率

$$P(H_2 | H_1) = \frac{LS_3 \times P(H_2)}{(LS_3 - 1) \times P(H_2) + 1} = \frac{200 \times 0.01}{(200 - 1) \times 0.01 + 1} = 0.669$$



5.3.2 主观Bayes举例


解: (4) 计算 $P(H_2|S_1, S_2)$

先将 H_2 的先验概率 $P(H_2)$ 转换为在 H_1 下的后验概率

$$P(H_2 | H_1) = \frac{LS_3 \times P(H_2)}{(LS_3 - 1) \times P(H_2) + 1} = \frac{200 \times 0.01}{(200 - 1) \times 0.01 + 1} = 0.669$$

由于 $P(H_1|S_1, S_2)=0.321 > P(H_1)$, 使用以下公式得到 $P(H_2|S_1, S_2)$ 为:

$$\begin{aligned} P(H_2|S_1, S_2) &= P(H_2) + \frac{P(H_2|H_1) - P(H_2)}{1 - P(H_1)} \times [P(H_1|S_1, S_2) - P(H_1)] \\ &= 0.1 + \frac{0.669 - 0.01}{1 - 0.091} \times (0.321 - 0.091) = 0.177 \end{aligned}$$



5.3.2 主观Bayes举例

解：(4) 计算 $P(H_2|S_1, S_2)$


先将 H_2 的先验概率 $P(H_2)$ 转换为在 H_1 下的后验概率

$$P(H_2 | H_1) = \frac{LS_3 \times P(H_2)}{(LS_3 - 1) \times P(H_2) + 1} = \frac{200 \times 0.01}{(200 - 1) \times 0.01 + 1} = 0.669$$

由于 $P(H_1|S_1, S_2)=0.321 > P(H_1)$ ，使用以下公式得到 $P(H_2|S_1, S_2)$ 为：

$$\begin{aligned} P(H_2|S_1, S_2) &= P(H_2) + \frac{P(H_2|H_1) - P(H_2)}{1 - P(H_1)} \times [P(H_1|S_1, S_2) - P(H_1)] \\ &= 0.1 + \frac{0.669 - 0.01}{1 - 0.091} \times (0.321 - 0.091) = 0.177 \end{aligned}$$

可以看出， H_2 的先验概率是0.01，通过 r_1 、 r_2 、 r_3 及初始证据进行推理，最后推出 H_2 的后验概率为0.177，相当于概率增加了16倍多。



不确定性推理 (课程回顾)

■ 主管Bayes推理的五个基本问题

1. 知识不确定性的表示: **Bayes**, 几率, **LS**, **LN**
2. 证据不确定性表示: 几率与概率
3. 组合证据不确定性的计算: 合取、析取和非运算
4. 不确定性的更新: 运用规则推理过程中不确定性的传递
5. 不确定性结论的合成: 多条推理路径时, 结论的不确定性

5.3.2 主观Bayes举例

例 3.2 设有规则

$$r_1: IF E_1 THEN (2, 0.0001) H_1$$

$$r_2: IF E_1 AND E_2 THEN (100, 0.001) H_1$$

$$r_3: IF H_1 THEN (200, 0.01) H_2$$

$$\text{已知: } P(E_1)=P(E_2)=0.6$$


$$P(H_1)=0.091, P(H_2)=0.01$$

$$\text{用户回答: } P(E_1|S_1)=0.76, P(E_2|S_2)=0.68$$

$$\text{求: } P(H_2|S_1, S_2)=?$$

5.3.2 主观Bayes举例

解：由已知知识得到的推理网络如下图所示




5.3.2 主观Bayes举例

解: (1) 计算 $O(H_1|S_1)$

先把 $P(H_1)$ 更新为 E_1 下的后验概率 $P(H_1|E_1)$

$$P(H_1 | E_1) = \frac{LS_1 \times P(H_1)}{(LS_1 - 1) \times P(H_1) + 1} = \frac{2 \times 0.091}{(2 - 1) \times 0.091 + 1} = 0.167$$



5.3.2 主观Bayes举例

解：(1) 计算 $O(H_1|S_1)$


先把 $P(H_1)$ 更新为 E_1 下的后验概率 $P(H_1|E_1)$

$$P(H_1 | E_1) = \frac{LS_1 \times P(H_1)}{(LS_1 - 1) \times P(H_1) + 1} = \frac{2 \times 0.091}{(2 - 1) \times 0.091 + 1} = 0.167$$

由于 $P(E_1|S_1)=0.76>P(E)$ ，使用以下公式得到 $P(H_1|S_1)$ 为：

$$\begin{aligned} P(H_1 | S_1) &= P(H_1) + \frac{P(H_1 | E_1) - P(H_1)}{1 - P(E_1)} \times (P(E_1 | S_1) - P(E_1)) \\ &= 0.091 + \frac{(0.167 - 0.091)}{1 - 0.6} \times (0.76 - 0.6) \\ &= 0.121 \end{aligned}$$


$$O(H_1 | S_1) = \frac{P(H_1 | S_1)}{1 - P(H_1 | S_1)} = \frac{0.121}{1 - 0.121} = 0.138$$



5.3.2 主观Bayes举例

解: (2) 计算 $O(H_1|(S_1 \text{ AND } S_2))$

$$\begin{aligned} P(E | (S_1 \wedge S_2)) &= \min\{ P(E_1 | S_1), P(E_2 | S_2) \} \\ &= \min\{ 0.76, 0.68 \} = P(E_2 | S_2) \end{aligned}$$



5.3.2 主观Bayes举例


解: (2) 计算 $O(H_1|(S_1 \text{ AND } S_2))$

$$\begin{aligned}P(E | (S_1 \wedge S_2)) &= \min\{ P(E_1 | S_1), P(E_2 | S_2) \} \\&= \min\{ 0.76, 0.68 \} = P(E_2 | S_2)\end{aligned}$$

仅考虑 E_2 对 H_1 的影响, 计算 $O(H_1|(S_1 \text{ AND } S_2))$ 转化为计算 $O(H_1|S_2)$ 。

把 H_1 的先验概率 $P(H_1)$ 更新为在 E_2 下的后验概率 $P(H_1|E_2)$

$$P(H_1 | E_2) = \frac{LS_2 \times P(H_1)}{(LS_2 - 1) \times P(H_1) + 1} = \frac{100 \times 0.091}{(100 - 1) \times 0.091 + 1} = 0.909$$



5.3.2 主观Bayes举例

解: (2) 计算 $O(H_1|(S_1 \text{ AND } S_2))$

$$\begin{aligned}P(E | (S_1 \wedge S_2)) &= \min\{ P(E_1 | S_1), P(E_2 | S_2) \} \\&= \min\{ 0.76, 0.68 \} = P(E_2 | S_2)\end{aligned}$$


仅考虑 E_2 对 H_1 的影响, 计算 $O(H_1|(S_1 \text{ AND } S_2))$ 转化为计算 $O(H_1|S_2)$ 。

把 H_1 的先验概率 $P(H_1)$ 更新为在 E_2 下的后验概率 $P(H_1|E_2)$

$$P(H_1 | E_2) = \frac{LS_2 \times P(H_1)}{(LS_2 - 1) \times P(H_1) + 1} = \frac{100 \times 0.091}{(100 - 1) \times 0.091 + 1} = 0.909$$

由于 $P(E_2|S_2)=0.68 > P(E_2)$, 使用以下公式得到 $P(H_1|S_2)$ 为:

$$\begin{aligned}P(H_1 | S_2) &= P(H_1) + \frac{P(H_1 | E_2) - P(H_1)}{1 - P(E_2)} \times (P(E_2 | S_2) - P(E_2)) \\&= 0.091 + \frac{(0.909 - 0.091)}{1 - 0.6} \times (0.68 - 0.6) = 0.255\end{aligned}$$



5.3.2 主观Bayes举例

解: (2) 计算 $O(H_1|(S_1 \text{ AND } S_2))$

$$\begin{aligned}P(E | (S_1 \wedge S_2)) &= \min\{ P(E_1 | S_1), P(E_2 | S_2) \} \\&= \min\{ 0.76, 0.68 \} = P(E_2 | S_2)\end{aligned}$$

仅考虑 E_2 对 H_1 的影响, 计算 $O(H_1|(S_1 \text{ AND } S_2))$ 转化为计算 $O(H_1|S_2)$ 。


把 H_1 的先验概率 $P(H_1)$ 更新为在 E_2 下的后验概率 $P(H_1|E_2)$

$$P(H_1 | E_2) = \frac{LS_2 \times P(H_1)}{(LS_2 - 1) \times P(H_1) + 1} = \frac{100 \times 0.091}{(100 - 1) \times 0.091 + 1} = 0.909$$

由于 $P(E_2|S_2)=0.68 > P(E_2)$, 使用以下公式得到 $P(H_1|S_2)$ 为:

$$\begin{aligned}P(H_1 | S_2) &= P(H_1) + \frac{P(H_1 | E_2) - P(H_1)}{1 - P(E_2)} \times (P(E_2 | S_2) - P(E_2)) \\&= 0.091 + \frac{(0.909 - 0.091)}{1 - 0.6} \times (0.68 - 0.6) = 0.255\end{aligned}$$

$$O(H_1 | S_2) = \frac{P(H_1 | S_2)}{1 - P(H_1 | S_2)} = \frac{0.255}{1 - 0.255} = 0.342$$




5.3.2 主观Bayes举例

解: (3) 计算 $O(H_1|S_1, S_2)$

先将 H_1 的先验概率 $P(H_1)$ 转换为先验几率

$$O(H_1) = \frac{P(H_1)}{1 - P(H_1)} = \frac{0.091}{1 - 0.091} = 0.1$$



5.3.2 主观Bayes举例


解: (3) 计算 $O(H_1|S_1, S_2)$

先将 H_1 的先验概率 $P(H_1)$ 转换为先验几率

$$O(H_1) = \frac{P(H_1)}{1 - P(H_1)} = \frac{0.091}{1 - 0.091} = 0.1$$

再根据合成公式计算 H_1 的先验几率

$$\begin{aligned} O(H_1 | S_1, S_2) &= \frac{O(H_1 | S_1)}{O(H_1)} \times \frac{O(H_1 | S_2)}{O(H_1)} \times O(H_1) \\ &= \frac{0.138}{0.1} \times \frac{0.342}{0.1} \times 0.1 = 0.472 \end{aligned}$$



5.3.2 主观Bayes举例

解: (3) 计算 $O(H_1|S_1, S_2)$

先将 H_1 的先验概率 $P(H_1)$ 转换为先验几率


$$O(H_1) = \frac{P(H_1)}{1 - P(H_1)} = \frac{0.091}{1 - 0.091} = 0.1$$

再根据合成公式计算 H_1 的先验几率

$$\begin{aligned} O(H_1 | S_1, S_2) &= \frac{O(H_1 | S_1)}{O(H_1)} \times \frac{O(H_1 | S_2)}{O(H_1)} \times O(H_1) \\ &= \frac{0.138}{0.1} \times \frac{0.342}{0.1} \times 0.1 = 0.472 \end{aligned}$$

然后再将后验几率转换为后验概率

$$P(H_1 | S_1, S_2) = \frac{O(H_1 | S_1, S_2)}{1 + O(H_1 | S_1, S_2)} = \frac{0.472}{1 + 0.472} = 0.321$$




5.3.2 主观Bayes举例

解：(4) 计算 $P(H_2|S_1, S_2)$

先将 H_2 的先验概率 $P(H_2)$ 转换为在 H_1 下的后验概率

$$P(H_2 | H_1) = \frac{LS_3 \times P(H_2)}{(LS_3 - 1) \times P(H_2) + 1} = \frac{200 \times 0.01}{(200 - 1) \times 0.01 + 1} = 0.669$$



5.3.2 主观Bayes举例


解: (4) 计算 $P(H_2|S_1, S_2)$

先将 H_2 的先验概率 $P(H_2)$ 转换为在 H_1 下的后验概率

$$P(H_2 | H_1) = \frac{LS_3 \times P(H_2)}{(LS_3 - 1) \times P(H_2) + 1} = \frac{200 \times 0.01}{(200 - 1) \times 0.01 + 1} = 0.669$$

由于 $P(H_1|S_1, S_2)=0.321 > P(H_1)$, 使用以下公式得到 $P(H_2|S_1, S_2)$ 为:

$$\begin{aligned} P(H_2|S_1, S_2) &= P(H_2) + \frac{P(H_2|H_1) - P(H_2)}{1 - P(H_1)} \times [P(H_1|S_1, S_2) - P(H_1)] \\ &= 0.1 + \frac{0.669 - 0.01}{1 - 0.091} \times (0.321 - 0.091) = 0.177 \end{aligned}$$



5.3.2 主观Bayes举例

解：(4) 计算 $P(H_2|S_1, S_2)$


先将 H_2 的先验概率 $P(H_2)$ 转换为在 H_1 下的后验概率

$$P(H_2 | H_1) = \frac{LS_3 \times P(H_2)}{(LS_3 - 1) \times P(H_2) + 1} = \frac{200 \times 0.01}{(200 - 1) \times 0.01 + 1} = 0.669$$

由于 $P(H_1|S_1, S_2)=0.321 > P(H_1)$ ，使用以下公式得到 $P(H_2|S_1, S_2)$ 为：

$$\begin{aligned} P(H_2|S_1, S_2) &= P(H_2) + \frac{P(H_2|H_1) - P(H_2)}{1 - P(H_1)} \times [P(H_1|S_1, S_2) - P(H_1)] \\ &= 0.1 + \frac{0.669 - 0.01}{1 - 0.091} \times (0.321 - 0.091) = 0.177 \end{aligned}$$

可以看出， H_2 的先验概率是0.01，通过 r_1 、 r_2 、 r_3 及初始证据进行推理，最后推出 H_2 的后验概率为0.177，相当于概率增加了16倍多。



目 录

01

5.1 概述

02

5.2 可信度推理

03

5.3 主观Bayes推理

04

5.4 证据理论推理

05

5.5 模糊推理

06

5.6 Bayesian网络

5.4 证据理论

- ❑ 证据理论(theory of evidence): 又称D-S理论, 是德普斯特 (A. P. Dempster) 首先提出, 沙佛 (G. Shafer) 进一步发展起来的一种处理不确定性的理论。
- ❑ 1981年巴纳特 (J. A. Barnett) 把该理论引入专家系统中, 同年卡威 (J. Garvey) 等人用它实现了不确定性推理。
- ❑ 目前, 在证据理论的基础上已经发展了多种不确定性推理模型。

5.4 证据理论

- ❑ 证据理论可以处理由不知道所引起的不确定性，采用信任函数而不是概率作为不确定性度量。在概率论中，当先验概率很难获得，但又要被迫给出时，用证据理论能区分不确定性和不知道的差别。
- ❑ 在D-S理论中，知识也是用产生式的形式表示的，但证据和结论都要以集合进行表示。知识的不确定性通过一个集合形式的可信度因子来表示，而证据和结论的不确定性度量则采用信任函数和似然函数来表示。

5.4.1 证据理论的形式化描述

1. 概率分配函数

定义：设样本空间 D 为一有限集，在 D 的幂集 2^D 上定义一基本概率分配 (BPA, Basic Probability Assignment) 取值为 $[0, 1]$ 的函数 $M: 2^D \rightarrow [0, 1]$ ，满足以下条件：

$$\begin{cases} m(\phi) = 0 \\ \sum_{A \subseteq D} m(A) = 1 \end{cases} \quad \begin{array}{l} m \text{ 是 } 2^D \text{ 上的概率分配函数} \\ m(A) \text{ 为 } A \text{ 的基本概率数} \end{array}$$

其中， D 的任何一个子集 A 都对应于一个关于 x 的命题，称该命题为 “ x 的值是在 A 中”

5.4.1 证据理论的形式化描述

1. 概率分配函数

定义：设样本空间 D 为一有限集，在 D 的幂集 2^D 上定义一基本概率分配 (BPA, Basic Probability Assignment) 取值为 $[0, 1]$ 的函数 $M : 2^D \rightarrow [0, 1]$ ，满足以下条件：

$$\begin{cases} m(\phi) = 0 \\ \sum_{A \subseteq D} m(A) = 1 \end{cases} \quad \begin{array}{l} m \text{ 是 } 2^D \text{ 上的概率分配函数} \\ m(A) \text{ 为 } A \text{ 的基本概率数} \end{array}$$

其中， D 的任何一个子集 A 都对应于一个关于 x 的命题，称该命题为“ x 的值是在 A 中”

>> 设 x ：所看到的颜色， $D=\{\text{红}, \text{黄}, \text{蓝}\}$ ，

则 $A=\{\text{红}\}$ ：“ x 是红色”；

$A=\{\text{红}, \text{蓝}\}$ ：“ x 或者是红色，或者是蓝色”。

5.4.1 证据理论的形式化描述

1. 概率分配函数

几点说明:

(1) 设样本空间 D 中有 n 个元素, 则 D 中子集的个数为 2^n 个。

2^D : D 的所有子集。

5.4.1 证据理论的形式化描述

1. 概率分配函数

几点说明:

(1) 设样本空间 D 中有 n 个元素, 则 D 中子集的个数为 2^n 个。

2^D : D 的所有子集.

■ 设 $D=\{\text{红}, \text{黄}, \text{白}\}$

则其子集个数 $2^3 = 8$, 具体为:

$A=\{\text{红}\}, A=\{\text{黄}\}, A=\{\text{白}\}, A=\{\text{红}, \text{黄}\},$

$A=\{\text{红}, \text{白}\}, A=\{\text{黄}, \text{白}\}, A=\{\text{红}, \text{黄}, \text{白}\}, A=\{\phi\}$

5.4.1 证据理论的形式化描述

1. 概率分配函数

几点说明:

(1) 设样本空间 D 中有 n 个元素, 则 D 中子集的个数为 2^n 个。

2^D : D 的所有子集。

(2) 概率分配函数: 把 D 的任意一个子集 A 都映射为 $[0, 1]$ 上的一个数 $m(A)$ 。

$A \subset D, A \neq D$ 时, $m(A)$: 对相应命题 A 的精确信任度。

5.4.1 证据理论的形式化描述

1. 概率分配函数

几点说明:

(1) 设样本空间 D 中有 n 个元素, 则 D 中子集的个数为 2^n 。

2^D : D 的所有子集。

(2) 概率分配函数: 把 D 的任意一个子集 A 都映射为 $[0, 1]$ 上的一个数 $m(A)$ 。

$A \subset D$, $A \neq D$ 时, $m(A)$: 对相应命题 A 的精确信任度。

- 例如, 设 $A=\{\text{红}\}$,
 $m(A)=0.3$: 命题“ x 是红色”的信任度是0.3。

5.4.1 证据理论的形式化描述

1. 概率分配函数

几点说明:

(1) 设样本空间 D 中有 n 个元素, 则 D 中子集的个数为 2^n 。

2^D : D 的所有子集。

(2) 概率分配函数: 把 D 的任意一个子集 A 都映射为 $[0, 1]$ 上的一个数 $m(A)$ 。

$A \subset D$, $A \neq D$ 时, $m(A)$: 对相应命题 A 的精确信任度。

(3) 概率分配函数与概率不同。

5.4.1 证据理论的形式化描述

1. 概率分配函数

几点说明:

(1) 设样本空间 D 中有 n 个元素, 则 D 中子集的个数为 2^n 。

2^D :
(2) 概
上的一个
 $A \subset D$

■ 设 $D=\{\text{红}, \text{黄}, \text{白}\}$
 $m(\{\text{红}\})=0.3, M(\{\text{黄}\})=0, M(\{\text{白}\})=0.1,$
 $m(\{\text{红}, \text{黄}\})=0.2, M(\{\text{红}, \text{白}\})=0.2,$
 $m(\{\text{黄}, \text{白}\})=0, M(\{\text{红}, \text{黄}, \text{白}\})=0.2, M(\Phi)=0$
但: $m(\{\text{红}\}) + m(\{\text{黄}\}) + m(\{\text{白}\}) = 0.4$

(3) 概率分配函数与概率不同。

5.4.1 证据理论的形式化描述

2. 信任函数

命题 A 的信任函数(belief function) Bel 定义:

$$2^D \rightarrow [0,1] \quad \text{且} \quad Bel(A) = \sum_{B \subseteq A} M(B) \quad \forall A \subseteq D$$

$Bel(A)$: 对命题 A 为真的总的信任程度。

5.4.1 证据理论的形式化描述

2. 信任函数

命题 A 的信任函数(belief function) Bel 定义:

$$2^D \rightarrow [0,1] \text{ 且 } Bel(A) = \sum_{B \subseteq A} m(B) \quad \forall A \subseteq D$$

$Bel(A)$: 对命题 A 为真的总的信任程度。

■ 设 $D = \{\text{红}, \text{黄}, \text{白}\}$

$m(\{\text{红}\}) = 0.3, m(\{\text{黄}\}) = 0, m(\{\text{红}, \text{黄}\}) = 0.2,$

$Bel(\{\text{红}, \text{黄}\}) = m(\{\text{红}\}) + m(\{\text{黄}\}) + m(\{\text{红}, \text{黄}\})$

$= 0.2 + 0 + 0.3 = 0.5$

5.4.1 证据理论的形式化描述

2. 信任函数

命题 A 的信任函数(belief function) Bel 定义:

$$2^D \rightarrow [0,1] \text{ 且 } Bel(A) = \sum_{B \subseteq A} m(B) \quad \forall A \subseteq D$$

$Bel(A)$: 对命题 A 为真的总的信任程度。

- 由信任函数及概率分配函数的定义推出:

$$Bel(\Phi) = m(\Phi) = 0$$

$$Bel(D) = \sum_{B \subseteq D} m(B) = 1$$

5.4.1 证据理论的形式化描述

3. 似然函数

命题 A 的似然函数(plausibility function) Pl 定义:

$$2^D \rightarrow [0,1] \quad \text{且} \quad Pl(A) = \sum_{B \cap A \neq \emptyset} m(B) = 1 - Bel(\neg A) \quad \forall A \in 2^D \subseteq D$$

$Pl(A)$: 对命题 A 为真的不可驳斥函数或上限函数。

5.4.1 证据理论的形式化描述

3. 似然函数

命题 A 的似然函数(plausibility function) Pl 定义:

$$2^D \rightarrow [0,1] \text{ 且 } Pl(A) = \sum_{B \cap A \neq \emptyset} m(B) = 1 - Bel(\neg A) \quad \forall A \in 2^D \subseteq D$$

$Pl(A)$: 对命题 A 为真的不可驳斥函数或上限函数。

■ 设 $D = \{\text{红}, \text{黄}, \text{白}\}$

$m(\{\text{红}\}) = 0.3, m(\{\text{黄}\}) = 0, m(\{\text{红}, \text{黄}\}) = 0.2,$

$$Bel(\{\text{红}, \text{黄}\}) = m(\{\text{红}\}) + m(\{\text{黄}\}) + m(\{\text{红}, \text{黄}\})$$

$$= 0.2 + 0 + 0.3 = 0.5$$

$$pl(\{\text{白}\}) = 1 - Bel(\neg\{\text{白}\}) = 1 - Bel(\{\text{红}, \text{黄}\}) = 1 - 0.5 = 0.5$$

5.4.1 证据理论的形式化描述

4. 类概率函数

命题 A 的类概率函数 f 定义:

$$f(A) = Bel(A) + \frac{|A|}{|D|} [Pl(A) - Bel(A)] \quad \forall A \in 2^D \subseteq D$$

其中, $|A|$ 与 $|D|$ 分别为 A 与 D 中的元素个数。

5.4.1 证据理论的形式化描述

4. 类概率函数

命题 A 的类概率函数 f 定义:

$$f(A) = Bel(A) + \frac{|A|}{|D|} [Pl(A) - Bel(A)] \quad \forall A \in 2^D \subseteq D$$

其中, $|A|$ 与 $|D|$ 分别为 A 与 D 中的元素个数。

类概率函数 $f(A)$ 具有如下性质:

- (1) $\sum_{i=1}^n f(\{A_i\}) = 1$, 对于 $A = \{A_1, A_2, \dots, A_n\}$
- (2) 对于任何 $A \subseteq D$, 有 $Bel(A) \leq f(A) \leq Pl(A)$
- (3) 对于任何 $A \subseteq D$, 有 $f(\neg A) = 1 - f(A)$

5.4.1 证据理论的形式化描述

5. 概率分配函数的正交和证据的组合

设 m_1 和 m_2 是两个概率分配函数；则其正交和 $m = m_1 \oplus m_2$ ：

$$m(A) = \frac{1}{K} \sum_{B \cap C = A} [m_1(B) \times m_2(C)]$$

其中，

$$K = 1 - \sum_{B \cap C = \emptyset} [m_1(B) \times m_2(C)] = \sum_{B \cap C \neq \emptyset} [m_1(B) \times m_2(C)]$$

5.4.1 证据理论的形式化描述

5. 概率分配函数的正交和证据的组合

设 m_1 和 m_2 是两个概率分配函数；则其正交和 $m = m_1 \oplus m_2$ ：

$$m(A) = \frac{1}{K} \sum_{B \cap C = A} [m_1(B) \times m_2(C)]$$

其中，

$$K = 1 - \sum_{B \cap C = \emptyset} [m_1(B) \times m_2(C)] = \sum_{B \cap C \neq \emptyset} [m_1(B) \times m_2(C)]$$

如果 $K \neq 0$ ，则正交和 m 也是一个概率分配函数；

如果 $K = 0$ ，则不存在正交和 m ，即没有可能存在概率函数，称 m_1 与 m_2 矛盾。

5.4.1 证据理论的形式化描述

例 设 $D=\{a, b, c\}$, 若基于两组不同证据而导出的基本概率分配函数分别为:

$$m_1=(\{a\}, \{a, c\}, \{a, b, c\}) = \{0.4, 0.4, 0.2\}$$

$$m_2=(\{a\}, \{a, b, c\}) = \{0.6, 0.4\}$$

将 m_1 和 m_2 合并为 $m=m_1 \oplus m_2$

5.4.1 证据理论的形式化描述

例 设 $D=\{a, b, c\}$, 若基于两组不同证据而导出的基本概率分配函数分别为:

$$m_1=(\{a\}, \{a, c\}, \{a, b, c\}) = \{0.4, 0.4, 0.2\}$$

$$m_2=(\{a\}, \{a, b, c\}) = \{0.6, 0.4\}$$

将 m_1 和 m_2 合并为 $m=m_1 \oplus m_2$

解: 先求

$$K = 1 - \sum_{B \cap C = \emptyset} [m_1(B) \times m_2(C)] = \sum_{B \cap C \neq \emptyset} [m_1(B) \times m_2(C)] = 1$$

应用正交和定义

5.4.1 证据理论的形式化描述

例 设 $D=\{a, b, c\}$, 若基于两组不同证据而导出的基本概率分配函数分别为:

$$m_1=(\{a\}, \{a, c\}, \{a, b, c\}) = \{0.4, 0.4, 0.2\}$$

$$m_2=(\{a\}, \{a, b, c\}) = \{0.6, 0.4\}$$

将 m_1 和 m_2 合并为 $m=m_1 \oplus m_2$

解: 先求

$$K = 1 - \sum_{B \cap C = \emptyset} [m_1(B) \times m_2(C)] = \sum_{B \cap C \neq \emptyset} [m_1(B) \times m_2(C)] = 1$$

应用正交和定义

$$\begin{aligned} m(\{a\}) &= m_1(\{a\})m_2(\{a\}) + m_1(\{a\})m_2(\{a, b, c\}) + m_1(\{a, c\})m_2(\{a\}) \\ &\quad + m_1(\{a, b, c\})m_2(\{a\}) = 0.76 \end{aligned}$$

5.4.1 证据理论的形式化描述

例 设 $D=\{a, b, c\}$, 若基于两组不同证据而导出的基本概率分配函数分别为:

$$m_1=(\{a\}, \{a, c\}, \{a, b, c\}) = \{0.4, 0.4, 0.2\}$$

$$m_2=(\{a\}, \{a, b, c\}) = \{0.6, 0.4\}$$

将 m_1 和 m_2 合并为 $m=m_1 \oplus m_2$

解: 先求

$$K = 1 - \sum_{B \cap C = \emptyset} [m_1(B) \times m_2(C)] = \sum_{B \cap C \neq \emptyset} [m_1(B) \times m_2(C)] = 1$$

应用正交和定义

$$\begin{aligned} m(\{a\}) &= m_1(\{a\})m_2(\{a\}) + m_1(\{a\})m_2(\{a, b, c\}) + m_1(\{a, c\})m_2(\{a\}) \\ &\quad + m_1(\{a, b, c\})m_2(\{a\}) = 0.76 \end{aligned}$$

$$m(\{a, c\}) = m_1(\{a, c\}) \times m_2(\{a, b, c\}) = 0.16$$

$$m(\{a, b, c\}) = m_1(\{a, b, c\}) \times m_2(\{a, b, c\}) = 0.08$$

5.4.1 证据理论的形式化描述

例 设 $D=\{a, b, c\}$, 若基于两组不同证据而导出的基本概率分配函数分别为:

$$m_1=(\{a\}, \{a, c\}, \{a, b, c\}) = \{0.4, 0.4, 0.2\}$$

$$m_2=(\{a\}, \{a, b, c\}) = \{0.6, 0.4\}$$

将 m_1 和 m_2 合并为 $m=m_1 \oplus m_2$

解: 先求

$$K = 1 - \sum_{B \cap C = \emptyset} [m_1(B) \times m_2(C)] = \sum_{B \cap C \neq \emptyset} [m_1(B) \times m_2(C)] = 1$$

应用正交和定义

$$\begin{aligned} m(\{a\}) &= m_1(\{a\})m_2(\{a\}) + m_1(\{a\})m_2(\{a, b, c\}) + m_1(\{a, c\})m_2(\{a\}) \\ &\quad + m_1(\{a, b, c\})m_2(\{a\}) = 0.76 \end{aligned}$$

$$m(\{a, c\}) = m_1(\{a, c\}) \times m_2(\{a, b, c\}) = 0.16 \quad m(\{a, b, c\}) = m_1(\{a, b, c\}) \times m_2(\{a, b, c\}) = 0.08$$

$$m = m_1 \oplus m_2(\{a\}, \{b\}, \{c\}, \{a, b\}, \{a, c\}, \{b, c\}, \{a, b, c\}, \emptyset) = (0.76, 0, 0, 0, 0.16, 0, 0.08, 0)$$

5.4.2 证据理论的推理模型

1. 知识不确定性的表示

DS证据理论中，不确定知识的表示形式为：

$$IF\ E\ THEN\ H = \{h_1, h_2, \dots, h_n\} \quad CF = \{c_1, c_2, \dots, c_n\}$$

其中，

- E 为前提条件，可以是简单条件或复合条件（OR与AND的合取或析取连接）
- H 为结论，是样本空间 D 中的子集， $h_1, h_2, \dots, h_n$ 为子集中的元素。
- CF 为可信度因子， c_i 对应用来表示 h_i 的可信度，且满足

$$c_i \geq 0 \quad i = 1, 2, \dots, n$$

$$\sum_{i=1}^n c_i \leq 1$$

5.4.2 证据理论的推理模型

2. 证据不确定性的表示

设 A 是规则条件部分的命题， E' 是外部输入的证据和已证实的命题，在证据 E' 的条件下，命题 A 与证据 E' 的匹配程度为：

$$MD(A|E') = \begin{cases} 1 & \text{如果 } A \text{ 的所有元素都出现在 } E' \text{ 中} \\ 0 & \text{否则} \end{cases}$$

条件部分命题 A 的确定性为：

$$CER(A) = MD(A|E') \times f(A)$$

其中， $f(A)$ 为类概率函数，由于 $f(A) \in [0, 1]$ ，有 $CER(A) \in [0, 1]$ 。

5.4.2 证据理论的推理模型

3. 组合证据不确定性的算法

❖ 组合证据: 多个单一证据的合取 $E = E_1 \wedge E_2 \wedge \dots \wedge E_n$

则: $CER(E) = \min \{ CER(E_1), CER(E_2), \dots, CER(E_n) \}$

❖ 组合证据: 多个单一证据的析取

则: $CER(E) = \max \{ CER(E_1), CER(E_2), \dots, CER(E_n) \}$

5.4.2 证据理论的推理模型

4. 不确定性的更新

设有知识 $IF\ E\ THEN\ H = \{h_1, h_2, \dots, h_n\}$ $CF = \{c_1, c_2, \dots, c_n\}$ 求结论 H 的 $CER(H)$

(1) 求出 H 的概率分配函数:

$$m(\{h_1\}, \{h_2\}, \dots, \{h_n\}) = \{CER(E) \times c_1, CER(E) \times c_2, \dots, CER(E) \times c_n\}$$

$$m(D) = 1 - \sum_{i=1}^n CER(E) \times c_i$$

若两条知识支持同一个结论集合 H , 先求出各自的 m_1 , m_2 , 再求正交和 $m_1 \oplus m_2$ 。

(2) 求出 $Bel(H)$, $Pl(H)$, $f(H)$:

$$Bel(H) = \sum_{h_i \subseteq H} M(\{h_i\}), \quad Pl(H) = 1 - Bel(\neg H) \quad f(H) = Bel(H) + \frac{|H|}{|D|} M(D)$$

5.4.2 证据理论的推理模型

4. 不确定性的更新

设有知识 $IF\ E\ THEN\ H = \{h_1, h_2, \dots, h_n\}$ $CF = \{c_1, c_2, \dots, c_n\}$ 求结论 H 的 $CER(H)$

(3) 求出 H 的不确定性的值:

$$CER(H) = MD(H | E') \times f(H)$$

$$MD(H | E') = \begin{cases} 1 & \text{如果 } H \text{ 的所有元素都出现在 } E' \text{ 中} \\ 0 & \text{否则} \end{cases}$$

5.4.3 证据理论推理实例

例3.8 设有规则

$$r_1: IF E_1 AND E_2 THEN A=\{a_1, a_2\} \quad CF=\{0.3, 0.5\}$$

$$r_2: IF E_3 THEN H=\{h_1, h_2\} \quad CF=\{0.4, 0.2\}$$

$$r_3: IF A THEN H=\{h_1, h_2\} \quad CF=\{0.1, 0.5\}$$

已知: $CER(E_1)=0.8$ $CER(E_2)=0.6$ $CER(E_3)=0.9$

并假设 D 中的元素个数为10, 求: $CER(H)=?$

5.4.3 证据理论推理实例

例3.8 设有规则

r_1 : IF E_1 AND E_2 THEN $A=\{a_1, a_2\}$ $CF=\{0.3, 0.5\}$


r_2 : IF E_3 THEN $H=\{h_1, h_2\}$ $CF=\{0.4, 0.2\}$

r_3 : IF A THEN $H=\{h_1, h_2\}$ $CF=\{0.1, 0.5\}$

已知: $CER(E_1)=0.8$ $CER(E_2)=0.6$ $CER(E_3)=0.9$

并假设 D 中的元素个数为10, 求: $CER(H)=?$

解: 由给定知识形成的推理网络如右图所示:



5.4.3 证据理论推理实例

解：(1) 求 $CER(A)$

$$CER(E_1)=0.8 \quad CER(E_2)=0.6 \quad CER(E_3)=0.9$$

由规则 r_1 得：($r_1: IF E_1 AND E_2 THEN A=\{a_1, a_2\} \quad CF=\{0.3, 0.5\}$)

$$CER(E_1 \wedge E_2) = \min\{CER(E_1), CER(E_2)\} = \min\{0.8, 0.6\} = 0.6$$


$$m(\{a_1\}, \{a_2\}) = \{0.6 \times 0.3, 0.6 \times 0.5\} = \{0.18, 0.3\}$$

$$Bel(A) = m(\{a_1\}) + m(\{a_2\}) = 0.18 + 0.3 = 0.48$$

$$Pl(A) = 1 - Bel(\neg A) = 1 - 0 = 1$$

$$\begin{aligned} f(A) &= Bel(A) + |A|/|D| \times [Pl(A) - Bel(A)] = 0.48 + 2/10 \times [1 - 0.48] \\ &= 0.584 \end{aligned}$$

故： $CER(A) = MD(A|E) \times f(A) = 0.584$




5.4.3 证据理论推理实例

解：(2) 求 $CER(H)$

由规则 r_2 得：(r_2 : IF E_3 THEN $H=\{h_1, h_2\}$ $CF=\{0.4, 0.2\}$)

$$\begin{aligned} m_1(\{h_1\}, \{h_2\}) &= \{CER(E_3) \times 0.4, CER(E_3) \times 0.2\} = \{0.9 \times 0.4, 0.9 \times 0.2\} \\ &= \{0.36, 0.18\} \end{aligned}$$

$$\begin{aligned} CER(E_1) &= 0.8 & CER(E_2) &= 0.6 & CER(E_3) &= 0.9 \\ CER(A) &= 0.584 \end{aligned}$$



5.4.3 证据理论推理实例


解：(2) 求 $CER(H)$

由规则 r_2 得：(r_2 : IF E_3 THEN $H=\{h_1, h_2\}$ $CF=\{0.4, 0.2\}$)

$$m_1(\{h_1\}, \{h_2\}) = \{CER(E_3) \times 0.4, CER(E_3) \times 0.2\} = \{0.9 \times 0.4, 0.9 \times 0.2\} \\ = \{0.36, 0.18\}$$

$$m_1(D) = 1 - [m_1(\{h_1\}) + m_1(\{h_2\})] \\ = 1 - [0.36 + 0.18] = 0.46$$

$$CER(E_1)=0.8 \quad CER(E_2)=0.6 \quad CER(E_3)=0.9 \\ CER(A)=0.584$$



5.4.3 证据理论推理实例

解：(2) 求 $CER(H)$

由规则 r_2 得：($r_2: IF E_3 THEN H=\{h_1, h_2\} CF=\{0.4, 0.2\}$)


$$m_1(\{h_1\}, \{h_2\}) = \{CER(E_3) \times 0.4, CER(E_3) \times 0.2\} = \{0.9 \times 0.4, 0.9 \times 0.2\} \\ = \{0.36, 0.18\}$$

$$m_1(D) = 1 - [m_1(\{h_1\}) + m_1(\{h_2\})] \\ = 1 - [0.36 + 0.18] = 0.46$$

$$CER(E_1)=0.8 \quad CER(E_2)=0.6 \quad CER(E_3)=0.9 \\ CER(A)=0.584$$

由规则 r_3 得：($r_3: IF A THEN H=\{h_1, h_2\} CF=\{0.1, 0.5\}$)

$$m_2(\{h_1\}, \{h_2\}) = \{CER(A) \times 0.1, CER(A) \times 0.5\} \\ = \{0.58 \times 0.1, 0.58 \times 0.5\} = \{0.06, 0.29\}$$



5.4.3 证据理论推理实例

解：(2) 求 $CER(H)$

由规则 r_2 得：(r_2 : IF E_3 THEN $H=\{h_1, h_2\}$ $CF=\{0.4, 0.2\}$)

$$\begin{aligned} m_1(\{h_1\}, \{h_2\}) &= \{CER(E_3) \times 0.4, CER(E_3) \times 0.2\} = \{0.9 \times 0.4, 0.9 \times 0.2\} \\ &= \{0.36, 0.18\} \end{aligned}$$


$$\begin{aligned} CER(E_1) &= 0.8 & CER(E_2) &= 0.6 & CER(E_3) &= 0.9 \\ CER(A) &= 0.584 \end{aligned}$$

$$\begin{aligned} m_1(D) &= 1 - [m_1(\{h_1\}) + m_1(\{h_2\})] \\ &= 1 - [0.36 + 0.18] = 0.46 \end{aligned}$$

由规则 r_3 得：(r_3 : IF A THEN $H=\{h_1, h_2\}$ $CF=\{0.1, 0.5\}$)

$$\begin{aligned} m_2(\{h_1\}, \{h_2\}) &= \{CER(A) \times 0.1, CER(A) \times 0.5\} \\ &= \{0.58 \times 0.1, 0.58 \times 0.5\} = \{0.06, 0.29\} \end{aligned}$$

$$\begin{aligned} m_2(D) &= 1 - [m_2(\{h_1\}) + m_2(\{h_2\})] \\ &= 1 - [0.06 + 0.29] = 0.65 \end{aligned}$$




5.4.3 证据理论推理实例

解：(2) 求 $CER(H)$

由规则 r_2 得： $m_1(\{h_1\}, \{h_2\}, D) = \{0.36, 0.18, 0.46\}$

由规则 r_3 得： $m_2(\{h_1\}, \{h_2\}, D) = \{0.06, 0.29, 0.65\}$



5.4.3 证据理论推理实例


解：(2) 求 $CER(H)$

由规则 r_2 得： $m_1(\{h_1\}, \{h_2\}, D) = \{0.36, 0.18, 0.46\}$

由规则 r_3 得： $m_2(\{h_1\}, \{h_2\}, D) = \{0.06, 0.29, 0.65\}$

求正交和 $m = m_1 \oplus m_2$

$$\begin{aligned} K &= 1 - \sum_{B \cap C = \emptyset} [m_1(B) \times m_2(C)] = \sum_{B \cap C \neq \emptyset} [m_1(B) \times m_2(C)] \\ &= 0.36 \times 0.06 + 0.36 \times 0.65 + 0.18 \times 0.29 + 0.18 \times 0.65 \\ &\quad + 0.46 \times 0.06 + 0.46 \times 0.29 + 0.46 \times 0.65 = 0.88 \end{aligned}$$



5.4.3 证据理论推理实例

解：(2) 求 $CER(H)$


由规则 r_2 得： $m_1(\{h_1\}, \{h_2\}, D) = \{0.36, 0.18, 0.46\}$

由规则 r_3 得： $m_2(\{h_1\}, \{h_2\}, D) = \{0.06, 0.29, 0.65\}$

求正交和 $m = m_1 \oplus m_2$

$$\begin{aligned} K &= 1 - \sum_{B \cap C = \emptyset} [m_1(B) \times m_2(C)] = \sum_{B \cap C \neq \emptyset} [m_1(B) \times m_2(C)] \\ &= 0.36 \times 0.06 + 0.36 \times 0.65 + 0.18 \times 0.29 + 0.18 \times 0.65 \\ &\quad + 0.46 \times 0.06 + 0.46 \times 0.29 + 0.46 \times 0.65 = 0.88 \end{aligned}$$

$$\begin{aligned} m(h_1) &= \frac{1}{K} \sum_{B \cap C = A} [m_1(B) \times m_2(C)] \\ &= \frac{1}{0.88} (0.36 \times 0.06 + 0.36 \times 0.65 + 0.46 \times 0.06) = 0.32 \end{aligned}$$



5.4.3 证据理论推理实例


解：(2) 求 $CER(H)$

求正交和 $m=m_1 \oplus m_2$

$$m(h_2) = \frac{1}{K} \sum_{B \cap C = A} [m_1(B) \times m_2(C)]$$

$$= \frac{1}{0.88} (0.18 \times 0.29 + 0.18 \times 0.65 + 0.46 \times 0.29) = 0.34$$

$$m(\{h_1\}, \{h_2\}, D) = \{0.32, 0.34, 0.34\}$$



5.4.3 证据理论推理实例

解：(2) 求 $CER(H)$

求正交和 $m=m_1\oplus m_2$

$$\begin{aligned} m(h_2) &= \frac{1}{K} \sum_{B \cap C = A} [m_1(B) \times m_2(C)] \\ &= \frac{1}{0.88} (0.18 \times 0.29 + 0.18 \times 0.65 + 0.46 \times 0.29) = 0.34 \end{aligned}$$


$$m(\{h_1\}, \{h_2\}, D) = \{0.32, 0.34, 0.34\}$$

再根据 m 求

$$Bel(H) = m(\{h_1\}) + m(\{h_2\}) = 0.32 + 0.34 = 0.66$$

$$Pl(H) = 1 - Bel(\neg H) = 1$$

$$f(H) = Bel(H) + \frac{H}{D} \times [Pl(H) - Bel(H)] = 0.66 + \frac{2}{10} \times (1 - 0.66) = 0.73$$



5.4.3 证据理论推理实例

解：(2) 求 $CER(H)$

求正交和 $m=m_1 \oplus m_2$

$$\begin{aligned} m(h_2) &= \frac{1}{K} \sum_{B \cap C = A} [m_1(B) \times m_2(C)] \\ &= \frac{1}{0.88} (0.18 \times 0.29 + 0.18 \times 0.65 + 0.46 \times 0.29) = 0.34 \end{aligned}$$

$$m(\{h_1\}, \{h_2\}, D) = \{0.32, 0.34, 0.34\}$$


再根据 m 求

$$Bel(H) = m(\{h_1\}) + m(\{h_2\}) = 0.32 + 0.34 = 0.66$$

$$Pl(H) = 1 - Bel(\neg H) = 1$$

$$f(H) = Bel(H) + \frac{H}{D} \times [Pl(H) - Bel(H)] = 0.66 + \frac{2}{10} \times (1 - 0.66) = 0.73$$

$$CER(H) = MD(H|E') \times f(H) = 0.73$$



目 录

01

5.1 概述

02

5.2 可信度推理

03

5.3 主观Bayes推理

04

5.4 证据理论推理

05


5.5 模糊推理

06

5.6 Bayesian网络

5.5 模糊推理

- ❑ 1965年，美国L. A. Zadeh发表了“fuzzy set”的论文，首先提出了模糊理论。
- ❑ 模糊推理，实际上是建立在知识的模糊逻辑表示及其模糊集合理论基础上的一种软计算。



Lotfi A. Zadeh



5.5 模糊推理

- ❖ 模糊集及其运算
- ❖ 模糊关系及其运算
- ❖ 模糊知识表示
- ❖ 模糊概念的匹配
- ❖ 模糊推理的方法

5.5.1 模糊集及其运算

1. 模糊集的定义

- ❖ **论域**: 所讨论的全体对象, 用 U 等表示。
- ❖ **元素**: 论域中的每个对象, 常用 a, b, c, x, y, z 表示。
- ❖ **集合**: 论域中具有某种相同属性的确定的、可以彼此区分的元素的整体, 常用 A, B 等表示。
- ❖ **元素 a 和集合 A 的关系**: a 属于 A 或 a 不属于 A , 即只有两个真值“真”和“假”。
- ❖ **隶属度与隶属函数**: 模糊逻辑给集合中每一个元素赋予一个介于0和1之间的实数, 描述其属于一个集合的强度, 该实数称为元素属于一个集合的**隶属度**。集合中所有元素的隶属度全体构成集合的**隶属函数**。

5.5.1 模糊集及其运算

1. 模糊集的定义

设 U 是给定论域， $\mu_F(u)$ 是把任意 $u \in U$ 映射为 $[0, 1]$ 上某个实值的函数：


$$\mu_F(u) : U \rightarrow [0, 1]$$

$$u \rightarrow \mu(u)$$

则称 $\mu_F(u)$ 为定义在 U 上的一个**隶属函数**，由 $\mu_F(u)$ 对所有 $u \in U$ 所构成的集合 $F = \{ \mu_F(u) \mid u \in U \}$ ，则称为 U 上的一个**模糊集**， $\mu_F(u)$ 称为 u 对 F 的隶属度。



“成年人” 特征函数图



“成年人” 隶属度函数图

5.5.1 模糊集及其运算

2. 模糊集表示方法

(1) Zadeh表示法

❖ 论域是离散且元素数目有限:

$$A = \mu_A(x_1)/x_1 + \mu_A(x_2)/x_2 + \cdots + \mu_A(x_n)/x_n = \sum_{i=1}^n \mu_A(x_i)/x_i$$

或

$$A = \{\mu_A(x_1)/x_1, \mu_A(x_2)/x_2, \cdots, \mu_A(x_n)/x_n\}$$

❖ 论域是连续的, 或者元素数目无限:

$$A = \int_{x \in U} \mu_A(x)/x$$

5.5.1 模糊集及其运算

2. 模糊集表示方法

(1) Zadeh表示法

❖ 论域是离散且元素数目有限:

$$A = \mu_A(x_1)/x_1 + \mu_A(x_2)/x_2 + \cdots + \mu_A(x_n)/x_n = \sum_{i=1}^n \mu_A(x_i)/x_i$$

或

$$A = \{\mu_A(x_1)/x_1, \mu_A(x_2)/x_2, \cdots, \mu_A(x_n)/x_n\}$$

❖ 论域是连续的, 或者元素数目无限:

$$A = \int_{x \in U} \mu_A(x)/x$$

“ $\mu_F(x_2)/x_i$ ”不是相除关系, 只是一个记号; “+”也不是算术意义上的加, 只是一个连接符号。[不是积分符号, 只是表示论域中各元素与其隶属度对应关系的总括。

5.5.1 模糊集及其运算

2. 模糊集的代表方法

(2) 序偶表示法

论域是离散且元素数目有限:

$$A = \{(\mu_A(x_1), x_1), (\mu_A(x_2), x_2), \dots, (\mu_A(x_n), x_n)\}$$

(3) 向量表示法

论域是离散且元素数目有限:

$$A = \{\mu_A(x_1), \mu_A(x_2), \dots, \mu_A(x_n)\}$$

5.5.1 模糊集及其运算

3. 隶属函数

- ❖ 常见的隶属函数：正态分布、三角分布、梯形分布等。
- ❖ 隶属函数确定方法：模糊统计法、专家经验法、二元对比排序法、基本概念扩充法等。

以年龄作论域，取 $U = [0, 200]$ ，扎德给出了“年老” O 与“年青” Y 两个模糊集合的隶属函数为

$$\mu_O(u) = \begin{cases} 0 & 0 \leq u \leq 50 \\ \left[1 + \left(\frac{5}{u-50}\right)^2\right]^{-1} & 50 < u \leq 200 \end{cases} \quad \mu_Y(u) = \begin{cases} 1 & 0 \leq u \leq 25 \\ \left[1 + \left(\frac{u-25}{5}\right)^2\right]^{-1} & 25 < u \leq 200 \end{cases}$$

采用Zadeh表示法:

$$O = \int_{50 < u \leq 200} \left[1 + \left(\frac{u-50}{5}\right)^2\right]^{-1} / u \quad Y = \int_{0 < u \leq 25} 1/u + \int_{25 < u \leq 200} \left[1 + \left(\frac{u-25}{5}\right)^2\right]^{-1} / u$$

5.5.1 模糊集及其运算

4. 模糊集的运算

(1) 模糊集合的**包含**关系: 若 $\mu_A(x) \geq \mu_B(x)$, 则 $A \supseteq B$

(2) 模糊集合的**相等**关系: 若 $\mu_A(x) = \mu_B(x)$, 则 $A = B$

(3) 模糊集合的**交并补**运算

① 交运算(intersection) $A \cap B$

$$\mu_{A \cap B}(x) = \min \{ \mu_A(x), \mu_B(x) \} = \mu_A(x) \wedge \mu_B(x)$$

② 并运算(union) $A \cup B$

$$\mu_{A \cup B}(x) = \max \{ \mu_A(x), \mu_B(x) \} = \mu_A(x) \vee \mu_B(x)$$

③ 补运算(complement) $\bar{A}$ 或者 A^c

$$\mu_{\bar{A}}(x) = 1 - \mu_A(x)$$

5.5.1 模糊集及其运算

例3.10 设 $U=\{1,2,3\}$, F 和 G 分别是 U 上的两个模糊集, 即

$$F=\text{小}=1/1+0.6/2+0.1/3$$

$$G=\text{大}=0.1/1+0.6/2+1/3$$

则 $F \cup G = (1 \vee 0.1)/1 + (0.6 \vee 0.6)/2 + (0.1 \vee 1)/3 = 1/1 + 0.6/2 + 1/3$

$$F \cap G = (1 \wedge 0.1)/1 + (0.6 \wedge 0.6)/2 + (0.1 \wedge 1)/3 = 0.1/1 + 0.6/2 + 0.1/3$$

$$\neg F = (1-1)/1 + (1-0.6)/2 + (1-0.1)/3 = 0.4/2 + 0.9/3$$

5.5.1 模糊集及其运算

例3.10 设 $U=\{1,2,3\}$, F 和 G 分别是 U 上的两个模糊集, 即

$$F=\text{小}=1/1+0.6/2+0.1/3$$

$$G=\text{大}=0.1/1+0.6/2+1/3$$

则 $F \cup G = (1 \vee 0.1)/1 + (0.6 \vee 0.6)/2 + (0.1 \vee 1)/3 = 1/1 + 0.6/2 + 1/3$

$$F \cap G = (1 \wedge 0.1)/1 + (0.6 \wedge 0.6)/2 + (0.1 \wedge 1)/3 = 0.1/1 + 0.6/2 + 0.1/3$$

$$\neg F = (1-1)/1 + (1-0.6)/2 + (1-0.1)/3 = 0.4/2 + 0.9/3$$

小结: 两个模糊集之间的运算实际上就是逐点对隶属函数作相应的运算。

5.5.2 模糊关系及其运算

1. 模糊关系的定义

设 F_i 是 $U_i(i=1,2,\dots,n)$ 上的模糊集, 则称

$$R = F_1 \times F_2 \times \cdots \times F_n = \int_{u_1 \times u_2 \times \cdots \times u_n} (\mu_{F_1}(u_1) \wedge \mu_{F_2}(u_2) \wedge \cdots \wedge \mu_{F_n}(u_n)) / (u_1, u_2, \cdots, u_n)$$

为 $F_1, F_2, \dots, F_n$ 的笛卡尔乘积, 它是 $U_1 \times U_2 \times \cdots \times U_n$ 上的一个模糊关系(R_c , 由麦姆德尼(Mamdani)提出)。

由扎德(Zadeh)提出的一种模糊关系

$$R_m = \int_{U \times V} (\mu_F(u) \wedge \mu_G(v)) \vee (1 - \mu_F(u)) / (u, v)$$

由米祖莫托(Mizumoto)提出的一种模糊关系

$$R_g = \int_{U \times V} (\mu_F(u) \rightarrow \mu_G(v)) / (u, v) \quad \mu_F(u) \rightarrow \mu_G(v) = \begin{cases} 1 & \text{当 } \mu_F(u) \leq \mu_G(v) \text{ 时} \\ \mu_G(v) & \text{当 } \mu_F(u) > \mu_G(v) \text{ 时} \end{cases}$$

5.5.2 模糊关系及其运算

1. 模糊关系的定义

已知输入的模糊集合 A 和输出的模糊集合 B :

$$A = 1.0 / a_1 + 0.8 / a_2 + 0.5 / a_3 + 0.2 / a_4 + 0.0 / a_5$$

$$B = 0.7 / b_1 + 1.0 / b_2 + 0.6 / b_3 + 0.0 / b_4$$

求 A 到 B 的模糊关系 R 。

$$R = A \times B = \mu_A^T \circ \mu_B = \begin{bmatrix} 1.0 \\ 0.8 \\ 0.5 \\ 0.2 \\ 0.0 \end{bmatrix} \circ [0.7 \quad 1.0 \quad 0.6 \quad 0.0]$$

5.5.2 模糊关系及其运算

1. 模糊关系的定义

已知输入的模糊集合 A 和输出的模糊集合 B :

求 A 到 B

$$R = \begin{bmatrix} 1.0 \wedge 0.7 & 1.0 \wedge 1.0 & 1.0 \wedge 0.6 & 1.0 \wedge 0.0 \\ 0.8 \wedge 0.7 & 0.8 \wedge 1.0 & 0.8 \wedge 0.6 & 0.8 \wedge 0.0 \\ 0.5 \wedge 0.7 & 0.5 \wedge 1.0 & 0.5 \wedge 0.6 & 0.5 \wedge 0.0 \\ 0.2 \wedge 0.7 & 0.2 \wedge 1.0 & 0.2 \wedge 0.6 & 0.2 \wedge 0.0 \\ 0.0 \wedge 0.7 & 0.0 \wedge 1.0 & 0.0 \wedge 0.6 & 0.0 \wedge 0.0 \end{bmatrix} = \begin{bmatrix} 0.7 & 1.0 & 0.6 & 0.0 \\ 0.7 & 0.8 & 0.6 & 0.0 \\ 0.5 & 0.5 & 0.5 & 0.0 \\ 0.2 & 0.2 & 0.2 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 \end{bmatrix}$$

$[0.0]$

5.5.2 模糊关系及其运算

2. 模糊关系的合成

设 R_1 与 R_2 分别是 $U \times V$ 与 $V \times W$ 上的两个模糊关系，则 R_1 与 R_2 的合成是从 U 到 W 的一个模糊关系，记为 $R_1 \circ R_2$ 。其隶属函数为

$$\mu_{R_1 \circ R_2}(u, w) = \vee \{ \mu_{R_1}(u, v) \wedge \mu_{R_2}(v, w) \}$$

其中， $\wedge$ 和 $\vee$ 分别表示取最小和取最大。

设有以下两个模糊关系

$$R_1 = \begin{bmatrix} 0.4 & 0.5 & 0.6 \\ 0.8 & 0.3 & 0.7 \end{bmatrix} \quad R_2 = \begin{bmatrix} 0.7 & 0.9 \\ 0.2 & 0.8 \\ 0.5 & 0.3 \end{bmatrix}$$

则 R_1 与 R_2 的合成是

$$R = R_1 \circ R_2 = \begin{bmatrix} 0.5 & 0.5 \\ 0.7 & 0.8 \end{bmatrix} \quad R(1,1) = (0.4 \wedge 0.7) \vee (0.5 \wedge 0.2) \vee (0.6 \wedge 0.5) = 0.5$$

5.5.3 模糊知识表示

1. 模糊命题的描述

设 $x \in U$, F 为模糊谓词, 则模糊命题可表示为

$$x \text{ is } F$$

其中, 模糊谓词可以是**大、小、年轻、年老、冷、暖、长、短**等。

设 $x \in U$, m 为模糊修饰语, F 为模糊谓词, 则模糊命题可表示为

$$x \text{ is } mF$$

其中, 模糊修饰语也称为**程度词**, 常用的程度词有“**很**”、“**非常**”、“**有些**”、“**绝对**”等, 可以进行**求补、集中、扩展、加强对比**运算。

更一般的模糊命题描述: “大多数成绩非常好的学生”

其中, “大多数”是模糊量词, “非常”是模糊修饰词, “成绩好”是模糊谓词。

5.5.3 模糊知识表示

2. 模糊知识的表示方式

在扎德的推理模型中，产生式规则的表示形式是

$IF\ x\ is\ F\ THEN\ y\ is\ G$

其中， x 和 y 是变量（对象）； F 和 G 分别是论域 U 和 V 上的模糊集（概念）。

说明：

(1) 条件部分可以是多个“ $x_i\ is\ A_i$ ”的逻辑组合，此时，隶属函数间的运算按模糊集的模糊逻辑运算进行。

(2) 模糊推理中所用证据是用模糊命题表示的。

“成绩好的学生都很刻苦”

IF “成绩好的学生” THEN “学生很刻苦”

5.5.4 模糊概念匹配

1. 语义距离

语义距离用于刻划两个模糊概念之间的差异

设 A 与 B 分别是论域 $U = \{x_1, x_2, \dots, x_n\}$ 上的表示两个模糊概念的模糊集, 则它们之间的海明距离定义为:

$$d_h(A, B) = \frac{1}{n} \times \sum_{i=1}^n |\mu_A(x_i) - \mu_B(x_i)|$$

欧几里德距离定义为:

$$d_o(A, B) = \frac{1}{\sqrt{n}} \times \sqrt{\sum_{i=1}^n (\mu_A(x_i) - \mu_B(x_i))^2}$$

明可夫斯基距离定义为($q \geq 1$):

$$d_m(A, B) = \left[\frac{1}{n} \times \sum_{i=1}^n |\mu_A(x_i) - \mu_B(x_i)|^q \right]^{1/q}$$

切比雪夫距离定义为:

$$d_q(A, B) = \max_{1 \leq i \leq n} |\mu_A(x_i) - \mu_B(x_i)|$$

2. 贴程度

贴程度是指两个概念的接近程度，可以直接用于模糊概念的匹配

设 A 与 B 分别是论域 $U = \{x_1, x_2, \dots, x_n\}$ 上的表示两个模糊概念的模糊集，则它们之间的贴程度定义为：

$$(A, B) = [A \cdot B + (1 - A \odot B)]$$

其中， $A \cdot B$ 称为 A 与 B 的内积， $A \odot B$ 称为 A 与 B 的外积，分别为：

$$A \cdot B = (u_A(x_i) \wedge u_B(x_i))$$

$$A \odot B = A(u_A(x_i) \vee u_B(x_i))$$

若贴程度大于等于规则指定的阈值时，就认为规则的模糊条件与证据匹配。

5.5.5 模糊推理方法

1. 模糊假言推理

规则: IF x is F , THEN y is G

证据: x is F' ,

结论: y is G'

2. 模糊拒取式推理

规则: IF x is F , THEN y is G

事实: y is G'

结论: x is F'

2. 模糊假言三段式

规则 1: IF x is F , THEN y is G

规则 2: IF y is G , THEN z is H

结论 (规则 3): IF x is F , THEN z is H

5.5.5 模糊推理方法

1. 模糊假言推理

规则: IF x is F , THEN y is G

证据: x is F' ,

结论: y is G'

2. 模糊拒取式推理

规则: IF x is F , THEN y is G

事实: y is G'

结论: x is F'

2. 模糊假言三段式

规则 1: IF x is F , THEN y is G

规则 2: IF y is G , THEN z is H

结论 (规则 3): IF x is F , THEN z is G

模糊推理实际上是按照给定的推理模式，通过模糊集合与模糊关系的合成来实现的。

5.5.5 模糊推理方法

例3.18 设 $U=\{1,2,3\}$, F 和 G 分别是 U 上的两个模糊集, 即

$$F=\text{小}=1/1+0.6/2+0.1/3$$

$$G=\text{大}=0.1/1+0.6/2+1/3$$

并设“较小”的模糊集为: $F'=\text{较小}=1/1+0.7/2+0.2/3$, 求在此证据下的模糊结论

5.5.5 模糊推理方法

例3.18 设 $U=\{1,2,3\}$, F 和 G 分别是 U 上的两个模糊集, 即

$$F=\text{小}=1/1+0.6/2+0.1/3$$

$$G=\text{大}=0.1/1+0.6/2+1/3$$

并设“较小”的模糊集为: $F'=\text{较小}=1/1+0.7/2+0.2/3$, 求在此证据下的模糊结论

$$G' = F' \circ R_c = [1 \quad 0.7 \quad 0.2] \circ \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 0.6 & 0.6 \\ 0.1 & 0.1 & 0.1 \end{bmatrix} = [0.1 \quad 0.6 \quad 1]$$

$$R_c = \begin{bmatrix} 1 \\ 0.6 \\ 0.1 \end{bmatrix} \circ [0.1 \quad 0.6 \quad 1] = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 0.6 & 0.6 \\ 0.1 & 0.1 & 0.1 \end{bmatrix}$$

$$R = F_1 \times F_2 \times \cdots \times F_n = \int (\mu_{F_1}(u_1) \wedge \mu_{F_2}(u_2) \wedge \cdots \wedge \mu_{F_n}(u_n)) / (u_1, u_2, \cdots, u_n)$$

$u_1 \times u_2 \times \cdots \times u_n$

5.5.5 模糊推理方法

例3.19 设 $U=\{1,2,3\}$, F 和 G 分别是 U 上的两个模糊集, 即

$$F=\text{小}=1/1+0.6/2+0.1/3$$

$$G=\text{大}=0.1/1+0.6/2+1/3$$

并设“较大”的模糊集为: $F'=\text{较小}=0.2/1+0.7/2+1/3$, 求事实与 G 匹配的模糊证据

5.5.5 模糊推理方法

例3.19 设 $U=\{1,2,3\}$, F 和 G 分别是 U 上的两个模糊集, 即

$$F=\text{小}=1/1+0.6/2+0.1/3$$

$$G=\text{大}=0.1/1+0.6/2+1/3$$

并设“较大”的模糊集为: $F'=\text{较小}=0.2/1+0.7/2+1/3$, 求事实与 G 匹配的模糊证据

$$F' = R_c \circ G' = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 0.6 & 0.6 \\ 0.1 & 0.1 & 0.1 \end{bmatrix} \circ \begin{bmatrix} 0.2 \\ 0.7 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0.6 \\ 0.1 \end{bmatrix}$$

$$R_c = \begin{bmatrix} 1 \\ 0.6 \\ 0.1 \end{bmatrix} \circ [0.1 \quad 0.6 \quad 1] = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 0.6 & 0.6 \\ 0.1 & 0.1 & 0.1 \end{bmatrix}$$

$$R = F_1 \times F_2 \times \cdots \times F_n = \int_{u_1 \times u_2 \times \cdots \times u_n} (\mu_{F_1}(u_1) \wedge \mu_{F_2}(u_2) \wedge \cdots \wedge \mu_{F_n}(u_n)) / (u_1, u_2, \cdots, u_n)$$

5.5.5 模糊推理方法

例3.20 设 $U=\{1,2,3\}$, E 、 F 和 G 分别是 U 上的三个模糊集, 即

$$E=1/1+0.6/2+0.2/3, \quad F=0.8/1+0.5+0.1/3$$

$$G=0.2/1+0.6+1/3$$

按 R_g 求 $E \times F \times G$ 上的关系 R 。

5.5.5 模糊推理方法

例3.20 设 $U=\{1,2,3\}$, E 、 F 和 G 分别是 U 上的三个模糊集, 即

$$E=1/1+0.6/2+0.2/3, \quad F=0.8/1+0.5+0.1/3$$

$$G=0.2/1+0.6+1/3$$

按 R_g 求 $E \times F \times G$ 上的关系 R 。

$$R_1 = E \times F = \begin{bmatrix} 0.8 & 0.5 & 0.1 \\ 1 & 0.5 & 0.1 \\ 1 & 1 & 0.1 \end{bmatrix} \quad R_2 = F \times G = \begin{bmatrix} 0.2 & 0.6 & 1 \\ 0.2 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

$$R = E \times F \times G = R_1 \circ R_2 = \begin{bmatrix} 0.2 & 0.6 & 0.8 \\ 0.2 & 0.6 & 1 \\ 0.2 & 1 & 1 \end{bmatrix}$$

$$R_g = \int_{U \times V} (\mu_F(u) \rightarrow \mu_G(v)) / (u, v)$$

$$\mu_F(u) \rightarrow \mu_G(v) = \begin{cases} 1 & \text{当 } \mu_F(u) \leq \mu_G(v) \text{ 时} \\ \mu_G(v) & \text{当 } \mu_F(u) > \mu_G(v) \text{ 时} \end{cases}$$

目 录

01

5.1 概述

02

5.2 可信度推理

03

5.3 主观Bayes推理

04

5.4 证据理论推理

05

5.5 模糊推理

06


5.6 Bayesian网络

5.6 Bayes网络

■ 1985年，贝叶斯网络是由美国加州大学的珀尔（J.Pearl）于1985年首先提出的一种模拟人类推理过程中因果关系的不确定性处理模型。它是概率论与图论的结合，其拓扑结构是一个有向无环图。

贝叶斯网络的别名

- 信念网(Belief Network)
- 概率网络(Probability Network)
- 因果网络(Causal Network)
- 知识图(Knowledge Map)
- 图模型(Graphical Model)或概率图模型(PGM)
- 决策网络(Decision Network)
- 影响图(Influence Diagram)



5.6.1 贝叶斯网络的概念及理论

1. 贝叶斯网络的定义

三种概率：

联合概率： $P(a, b)$

边缘概率： $P(a) = \sum_b P(a, b)$

条件概率： $P(a|b) = \frac{P(a,b)}{P(b)}$

一般性推理问题：

给定特定事件 e ($e \in$ 证据变量 (Evidence variable) 集 E)，包含隐变量集 (Hidden variable) Y ，求查询变量 x 发生的概率 ($x \in$ 查询变量集 X)

$$P(X|e) = \frac{P(X, e)}{P(e)} = \frac{\sum_y P(X, y, e)}{Z = \sum_x P(X, e)} = \frac{\sum_y P(X, y, e)}{\sum_{x,y} P(x, y, e)}$$

可以用全联合概率求解，但计算复杂性太大，利用变量之间的独立性和条件独立性可大大减少为了定义全联合概率分布所需的概率数目。

5.6.1 贝叶斯网络的概念及理论

1. 贝叶斯网络的定义


设 $X=\{X_1, X_2, \dots, X_n\}$ 是任何随机变量集，其上的贝叶斯网络可定义为 $BN=(B_S, B_P)$ 。其中：

- ① B_S 是贝叶斯网络的结构，是一个有向无环图(DAG)
- ② B_P 为贝叶斯网络的条件概率集合：每节点 X_i 都有一个条件概率分布表： $P(X_i|Parents(X_i))$ ，量化其父节点对该节点的影响

5.6.1 贝叶斯网络的概念及理论

1. 贝叶斯网络的定义

例 假设“出现盗贼”和“地震”会“启动报警”，而“启动报警”之后，John和Mary会给房屋主人打电话。可以用下图所示的贝叶斯网络来描述。




5.6.1 贝叶斯网络的概念及理论

2. 贝叶斯网络的全联合概率分布表示

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | x_{i-1}, x_{i-2}, \dots, x_1) = \prod_{i=1}^n P(x_i | \text{parent}(x_i))$$

试计算：报警器响了，但既没有盗贼闯入，也没有发生地震，同时John和Mary都给你打电话的概率 $P(j, m, a, \neg b, \neg e)$




5.6.1 贝叶斯网络的概念及理论

2. 贝叶斯网络的全联合概率分布表示

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | x_{i-1}, x_{i-2}, \dots, x_1) = \prod_{i=1}^n P(x_i | \text{parent}(x_i))$$

试计算：报警器响了，但既没有盗贼闯入，也没有发生地震，同时John和Mary都给你打电话的概率
 $P(j, m, a, \neg b, \neg e)$

$$\begin{aligned} &= P(j|a)P(m|a)P(a|\neg b, \neg e) P(\neg b) P(\neg e) \\ &= 0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998 \\ &= 0.00062 = 0.062\% \end{aligned}$$



5.6.1 贝叶斯网络的概念及理论


3. 贝叶斯网络的条件独立关系

- 给定父节点，一个节点与它的非后代节点是条件独立的
- 给定一个节点的父节点、子节点以及子节点的父节点——马尔科夫覆盖 (Markov blanket)，这个节点和网络中的所有其它节点是条件独立的

5.6.1 贝叶斯网络的概念及理论

3. 贝叶斯网络的条件独立关系

- 给定父节点，一个节点与它的非后代节点是条件独立的




给定节点 X 的父节点 $U_1, \dots, U_m$,
节点 X 与它的非后代节点 (即
 Z_{ij}) 是条件独立的。

5.6.1 贝叶斯网络的概念及理论

3. 贝叶斯网络的条件独立关系

- 给定一个节点的父节点、子节点以及子节点的父节点——**马尔科夫覆盖** (Markov blanket), 这个节点和网络中的**所有其它节点**是条件独立的



给定**马尔科夫覆盖**（两圆圈之间的区域），节点 X 和网络中**所有其它节点**都是条件独立的。

5.6.1 贝叶斯网络的概念及理论

4. 贝叶斯网络的构造

构造原则:

- 两节点间的有向边的取舍原则: 更高精度概率的重要性与指定额外信息的代价的折衷
- “因果模型”比“诊断模型”需要更少的数据, 且这些数据也更容易得到

构造过程:

- 首先, 添加“**根本原因**”节点
- 然后, 加入受它们**直接影响的变量**
- 依次类推, 直到**叶节点**, 即对其它变量没有直接因果影响的节点
- 对每个根节点, 给出其先验概率; 对其他节点, 给出其条件概率表

5.6.2 贝叶斯网络的推理

1. 贝叶斯网络的精确推理

$$P(X|e) = \frac{P(X,e)}{P(e)} = \frac{\sum_y P(X,y,e)}{Z = \sum_x P(X,e)} = \frac{\sum_y P(X,y,e)}{\sum_{x,y} P(x,y,e)}$$

一般性推理问题:

给定特定事件 e ($e \in$ 证据变量 (Evidence variable) 集 E), 包含隐变量集 (Hidden variable) Y , 求查询变量 x 发生的概率 ($x \in$ 查询变量集 X)

直接利用

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | x_{i-1}, x_{i-2}, \dots, x_1) = \prod_{i=1}^n P(x_i | \text{parent}(x_i))$$

进行求解。


5.6.2 贝叶斯网络的推理

例 已知, 一个事件 $e = \{JohnCalls = true, \text{ and } MaryCalls = true\}$, 试问出现盗贼的概率是多少?

$$\text{解: } P(X|e) = \frac{1}{Z = \sum_x P(X,e)} P(X, e) = aP(X,e) = a \sum_y P(X,e,y)$$

$P(\text{Burgary} \mid \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true})$ 简写为:

$$\begin{aligned} P(B \mid j, m) &= aP(B, j, m) = a \sum_e \sum_a P(B, e, a, j, m) \\ &= a \sum_e \sum_a P(B)P(e)P(a|B,e)P(j|a)P(m|a) \end{aligned}$$





5.6.2 贝叶斯网络的推理

例 已知, 一个事件 $e = \{JohnCalls = true, \text{ and } MaryCalls = true\}$, 试问出现盗贼的概率是多少?

解:

$$\begin{aligned}P(b | j, m) &= \alpha P(b, j, m) = \alpha \sum_e \sum_a P(b, e, a, j, m) \\&= \alpha \sum_e \sum_a P(b)P(e)P(a|b,e)P(j|a)P(m|a) \\&= \alpha \times 0.0059224\end{aligned}$$





$P(b | j, m)$ 的自顶向下的计算过程

5.6.2 贝叶斯网络的推理

例 已知, 一个事件 $e = \{JohnCalls = true, \text{ and } MaryCalls = true\}$, 试问出现盗贼的概率是多少?

解:

$$\begin{aligned} P(\neg b | j, m) &= a P(\neg b, j, m) = a \sum_e \sum_a P(\neg b, e, a, j, m) \\ &= a \sum_e \sum_a P(\neg b) P(e) P(a | \neg b, e) P(j | a) P(m | a) \\ &= a \times 0.0014919 \end{aligned}$$



$P(\neg b | j, m)$ 的自顶向下的计算过程



5.6.2 贝叶斯网络的推理

例 已知, 一个事件 $e = \{JohnCalls = true, \text{ and } MaryCalls = true\}$, 试问出现盗贼的概率是多少?

解:

$$\begin{aligned} P(\neg b | j, m) &= a P(\neg b, j, m) = a \sum_e \sum_a P(\neg b, e, a, j, m) \\ &= a \sum_e \text{因此, } P(B|j, m) = a \langle 0.0059224, 0.0014919 \rangle \\ &= a \times 0 \approx \langle 0.799, 0.201 \rangle \end{aligned}$$

即在John和Mary都打电话的条件下, 出现盗贼的概率约为80%



$P(\neg b | j, m)$ 的自顶向下的计算过程

5.6.2 贝叶斯网络的推理

1. 贝叶斯网络的精确推理-变量消元

- 消除重复计算，提高枚举算法的效率
- 保存中间结果，以备多次使用
- 从右到左（在树结构中为自底向上）的次序计算 BN 的计算公式

$$\begin{aligned}P(B \mid j, m) &= \alpha P(B, j, m) = \alpha \sum_e \sum_a P(B, e, a, j, m) \\&= \alpha \sum_e \sum_a P(B)P(e)P(a|B,e)P(j|a)P(m|a) \\&= \alpha P(B) \sum_e P(e) \sum_a P(a|B,e)P(j|a)P(m|a)\end{aligned}$$

5.6.2 贝叶斯网络的推理

2. 贝叶斯网络的近似推理

- 大规模多连通BN的精确推理是不可操作的，必须通过近似推理来解决。
- 后验概率计算的主要采样方法
 - 直接采样方法：
 - ✓ 直接采样算法
 - ✓ 拒绝采样(Rejection sampling)算法
 - ✓ 似然加权(Likelihood weighting)算法
 - 马尔科夫链蒙特卡罗 (MCMC) 方法
 - 变分法(Variational method)
 - 环传播(Loopy propagation)方法

5.6.2 贝叶斯网络的推理

2. 贝叶斯网络的近似推理

- 大规模多连通BN的精确推理是不可操作的，必须通过近似推理来解决。
- 后验概率计算的主要采样方法
 - 直接采样方法：
 - ✓ 直接采样算法
 - ✓ 拒绝采样(Rejection sampling)算法
 - ✓ 似然加权(Likelihood weighting)算法
 - 马尔科夫链蒙特卡罗 (MCMC) 方法
 - 变分法(Variational method)
 - 环传播(Loopy propagation)方法

5.6.2 贝叶斯网络的推理


2. 贝叶斯网络的近似推理—马尔科夫链蒙特卡洛 (MCMC) 方法

思想:

- 后验概率计算的主要采样方法对前一个事件进行随机改变而生成事件样本
- BN 为每个变量指定了一个特定的当前状态
- 下一个状态是通过对某个非证据变量 X_i 进行采样来产生, 取决于 X_i 的马尔可夫覆盖中的变量当前值
- MCMC 方法可视为: 在状态空间中 (所有可能的完整赋值空间) 的随机走动 (每次改变一个变量), 但是证据变量的值固定不变。

5.6.2 贝叶斯网络的推理

MCMC算法执行过程示例




【要求】： 查询 $P(\text{Rain} \mid \text{Sprinkler} = \text{true}, \text{WetGrass} = \text{true})$ 的概率

5.6.2 贝叶斯网络的推理

MCMC算法执行步骤:

- 证据变量Sprinkler, WetGrass固定为true
- 隐变量Cloudy和查询变量Rain随机初始化, 例如, Cloudy = true, Rain = false, 初始状态为: **[C=true, S=true, R=false, W=true]**
- 反复执行如下步骤:
 - ① 根据Cloudy的马尔科夫覆盖(MB)变量 (Sprinkler和Rain) 的当前值, **对Cloudy采样**, 即根据 $P(\text{Cloudy} | \text{Sprinkler} = \text{true}, \text{Rain} = \text{false})$ (即转移概率) 来采样。即:

$$P(C|S, \neg R) = \frac{P(C, S, \neg R)}{P(S, \neg R)} = \frac{P(C)P(S|C)P(\neg R|C)}{P(C)P(S|C)P(\neg R|C) + P(\neg C)P(S|\neg C)P(\neg R|\neg C)}$$
$$= (0.5 \times 0.1 \times 0.2) / [0.5 \times 0.1 \times 0.2 + 0.5 \times 0.5 \times 0.8] = 0.04762$$



5.6.2 贝叶斯网络的推理

MCMC算法执行步骤:

由计算机生成一个随机数 $q \in [0, 1]$ (可参照《概率统计》中的随机数生成方法)。比较转移概率值与随机数 q 的大小, 以决定是继续停留在原状态, 还是转移到下一个新的状态。判别方法如下:

*if $q < P(C|S, \neg R)$ then 转移到下一个新状态;
otherwise 停留在原状态.*

对于本例子, 假设生成的随机数 $q=0.0389$, 可知, 转移概率
 $P(\text{Cloudy}|\text{Sprinkler}=\text{true}, \text{Rain}=\text{false})=0.04762 > q=0.0389$, 所以,
Cloudy由true状态转移到新状态false, 即采样结果为: Cloudy = false。故
新的当前状态为:

[C=false, S=true, R=false, W=true]

5.6.2 贝叶斯网络的推理

MCMC算法执行步骤:

- ② 根据Rain节点的马尔可夫覆盖(MB)变量 (Cloudy、Sprinkler和WetGrass) 的当前值, **对Rain采样**, 即根据 $P(\text{Rain} \mid \text{Cloudy} = \text{false}, \text{Sprinkler} = \text{true}, \text{WetGrass} = \text{true})$ 来采样。假设采样结果为: $\text{Rain} = \text{true}$ 。故新的当前状态为: **C=false, S=true, R=true, W=true**

【注】上述过程中所访问的每一个状态都是一个样本, 能对查询变量Rain的估计有贡献。


- ③ 重复上述步骤, 直到所要求的访问次数 N 。
若为true, false的次数分别为 n_1, n_2 , 则查询解为:

$$\text{Normalize}(\langle n_1, n_2 \rangle) = \langle n_1 / N, n_2 / N \rangle$$

若上述过程访问了20个 $\text{Rain} = \text{true}$ 的状态和60个 $\text{Rain} = \text{false}$ 的状态, 则所求查询的解为 $\langle 0.25, 0.75 \rangle$ 。

5.6.2 贝叶斯网络的推理

MCMC算法执行步骤:



5.6.2 贝叶斯网络的推理

MCMC算法描述:

```
function MCMC-Ask( $X, e, BN, N$ ) return  $P(X | e)$ 
  local variables:  $N[X]$ , //关于查询变量 $X$ 的向量计数, 初值0
   $Z$ , // $BN$ 中的非证据变量集
   $x$ , //  $BN$ 的当前状态
  利用 $Z$ 中变量的随机值来初始化 $x$ ;
  for  $j = 1$  to  $N$  do
     $N(x) \leftarrow N(x) + 1$ ; // $x$ 是当前状态 $x$ 中的查询变量 $X$ 的值
    for each  $Z_i$  in  $Z$  do
      给出 $Z_i$ 的马尔可夫覆盖 $MB(Z_i)$ , 并根据 $P(Z_i | MB(Z_i))$  来采样的 $Z_i$ 值;
  return Normalize( $N[X]$ ) //对 $N[X]$ 进行归一化
```