



人工智能

陈科海

计算机科学与技术学院

哈尔滨工业大学（深圳）

chenkehai@hit.edu.cn



第 6 章 机器学习

目录

6.1 概述

6.2 线性回归

6.3 决策树学习

6.4 支持向量机

6.5 集成学习

6.1 概述

□ 学习和机器学习的概念

➤ 什么是学习

学习是一个有特定目的的知识获取和能力增长过程

其内在行为是获得知识、积累经验、发现规律等

其外部表现是改进性能、适应环境、实现自我完善等

6.1 概述

□ 学习和机器学习的概念

➤ 什么是学习

学习是一个有特定目的的**知识获取和能力增长过程**

其内在行为是**获得知识、积累经验、发现规律等**

其外部表现是**改进性能、适应环境、实现自我完善等**



➤ 什么是机器学习

机器学习就是让机器（计算机）来模拟和实现人类的学习功能。

简单来讲，就是**让机器（计算机）从数据中学习知识（即自动获取知识）**


6.1 概述

□ 学习和机器学习的概念




6.1 概述

□ 学习和机器学习的概念



图像数据

类别分类




文本数据

情感分类

1. 原始数据中提取特征
2. 学习映射函数 f
3. 通过映射函数 f 将原始数据映射到语义空间，即寻找数据和任务目标之间的关系

6.1 概述

机器学习发展历史



6.1 概述

□ 机器学习的分类

- 按学习策略分为：记忆学习、传授学习、演绎学习、归纳学习等。归纳学习又可分为示例学习、观察发现学习等。
- 按学习方式分为：有导师学习（监督学习）、无导师学习（非监督学习）和强化学习（增强学习）

6.1 概述

机器学习分类

- 按学习策略分为：记忆学习、传授学习、演绎学习、归纳学习等。归纳学习又可分为示例学习、观察发现学习等。
- 按学习方式分为：有导师学习（监督学习）、无导师学习（非监督学习）和强化学习（增强学习）

监督学习(supervised learning)

数据有标签、一般为回归或分类等任务

无监督学习(un-supervised learning)

数据无标签、一般为聚类或若干降维任务

强化学习(reinforcement learning)

序列数据决策学习，一般为与从环境交互中学习

半监督学习
(semi-supervised learning)

6.1 概述

机器学习中的分类问题

人员	数学好	身体好	会编程	嗓门大
程序员A	Yes	No	Yes	Yes
作家A	No	No	Yes	No
程序员B	Yes	Yes	No	No
...	...	...	...	...
医生A	Yes	Yes	Yes	Yes
程序员C	Yes	Yes	Yes	Yes
程序员D	Yes	Yes	Yes	No

标签数据

6.1 概述

机器学习中的分类问题

人员	数学好	身体好	会编程	嗓门大
程序员A	Yes	No	Yes	Yes
作家A	No	No	Yes	No
程序员B	Yes	Yes	No	No
...	...	...	...	...
医生A	Yes	Yes	Yes	Yes
程序员C	Yes	Yes	Yes	Yes
程序员D	Yes	Yes	Yes	No

标签数据

从数据
中学习

映射函数

模式

f

(数学好 = Yes, 会编程 = Yes, 身体好 = ?, 嗓门大 = ?)

→ 程序员

类别

6.1 概述

机器学习中的分类问题

人员	数学好	身体好	会编程	嗓门大
程序员A	Yes	No	Yes	Yes
作家A	No			
程序员B	Yes			
...	...			
医生A	Yes			
程序员C	Yes	Yes	Yes	Yes
程序员D	Yes	Yes	Yes	No

标签数据

映射函数

监督学习的三要素

- 标注数据：标识了类别信息的数据
- 学习模型：如何学习得到映射模型
- 损失函数：如何对学习结果进行度量


类别

嗓门大 = ?)

6.1 概述


□ 监督学习的标注数据

从训练数据集学习
得到映射函数 f




训练数据集
 $(x_i, y_i), i = 1, \dots, n$

在测试数据集
测试映射函数 f



测试数据集
 $(x_i', y_i'), i = 1, \dots, m$

未知数据集
上测试映射函数 f



6.1 概述

□ 监督学习的学习模型

监督学习方法又可以分为**生成（式）方法**(generative approach)和**判别（式）方法**(discriminative approach)。所学到的模型分别称为**生成（式）模型**(generative model)和**判别（式）模型**(discriminative model)。

6.1 概述

□ 监督学习的学习模型

监督学习方法又可以分为**生成（式）方法**(generative approach)和**判别（式）方法**(discriminative approach)。所学到的模型分别称为**生成（式）模型**(generative model)和**判别（式）模型**(discriminative model)。

- 判别方法直接学习判别函数 $f(X)$ 或者条件概率分布 $P(Y|X)$ 作为预测的模型，即判别模型。
- 判别模型关心在给定输入数据下，预测该数据的输出是什么。
- 典型判别模型包括回归模型、决策模型、**神经网络**、支持向量机和集成模型等。

$$f(\text{人脸}) \longrightarrow \text{人脸}$$

$$P(\text{人脸} | \text{人脸}) = 0.99$$

6.1 概述

□ 监督学习的学习模型

监督学习方法又可以分为**生成（式）方法**(generative approach)和**判别（式）方法**(discriminative approach)。所学到的模型分别称为**生成（式）模型**(generative model)和**判别（式）模型**(discriminative model)。

- 生成模型从数据中学习联合概率分布 $P(X, Y)$ （通过似然概率 $P(X|Y)$ 和类概率 $P(Y)$ 的乘积来求取）

$$P(Y|X) = \frac{P(X, Y)}{P(X)} \quad \text{或者} \quad P(Y|X) = \frac{P(X|Y) \times P(Y)}{P(X)}$$

- 典型方法为贝叶斯方法、隐马尔可夫链
- 授之于鱼、不如授之于“渔”
- 联合分布概率 $P(X, Y)$ 或似然概率 $P(X|Y)$ 求取很困难

似然概率：计算
导致样本 X 出现的
模型参数值

$$P(Y|X) = \frac{P(X|Y) \times P(Y)}{P(X)}$$

6.1 概述

□ 监督学习的学习模型

● 生成式模型

优点:

- 信息丰富
- 单类问题灵活性强
- 增量学习
- 合成缺失数据

缺点:

- 学习过程复杂
- 为分布牺牲分类性能




● 判别式模型

优点:

- 类间差异清晰
- 分类边界灵活
- 学习简单
- 性能较好

缺点:

- 不能反应数据特性
- 需要全部数据进行学习




由生成模型可以得到判别模型，
但由判别模型得不到生成模型。

6.1 概述

□ 监督学习的损失函数

训练映射函数 f

使得 $f(x_i)$ 预测结果尽量等于 y_i



训练数据集

$(x_i, y_i), i = 1, \dots, n$


- ❖ 训练集中一共有 n 个标注数据，第 i 个标注数据记为 (x_i, y_i) ，其中第 i 个样本数据为 x_i ， y_i 是 x_i 的标注信息。

6.1 概述

□ 监督学习的损失函数

训练映射函数 f

使得 $f(x_i)$ 预测结果尽量等于 y_i



训练数据集

$(x_i, y_i), i = 1, \dots, n$


- ❖ 训练集中一共有 n 个标注数据，第 i 个标注数据记为 (x_i, y_i) ，其中第 i 个样本数据为 x_i ， y_i 是 x_i 的标注信息。
- ❖ 从训练数据中学习得到的映射函数记为 f ， f 对 x_i 的预测结果记为 $f(x_i)$ 。损失函数就是用来计算 x_i 真实值 y_i 与预测值 $f(x_i)$ 之间差值的函数。

6.1 概述

□ 监督学习的损失函数

训练映射函数 f

使得 $f(x_i)$ 预测结果尽量等于 y_i



训练数据集

$(x_i, y_i), i = 1, \dots, n$


- ❖ 训练集中一共有 n 个标注数据，第 i 个标注数据记为 (x_i, y_i) ，其中第 i 个样本数据为 x_i ， y_i 是 x_i 的标注信息。
- ❖ 从训练数据中学习得到的映射函数记为 f ， f 对 x_i 的预测结果记为 $f(x_i)$ 。损失函数就是用来计算 x_i 真实值 y_i 与预测值 $f(x_i)$ 之间差值的函数。
- ❖ 很显然，在训练过程中希望映射函数在训练数据集上得到“损失”之和最小，即 $\min \sum_{i=1}^n \text{Loss}(f(x_i), y_i)$ 。

6.1 概述

□ 监督学习的损失函数

训练映射函数 f

使得 $f(x_i)$ 预测结果尽量等于 y_i



训练数据集

$(x_i, y_i), i = 1, \dots, n$

损失函数名称	损失函数定义
0-1损失函数	$Loss(y_i, f(x_i)) = \begin{cases} 1, & f(x_i) \neq y_i \\ 0, & f(x_i) = y_i \end{cases}$
平方损失函数	$Loss(y_i, f(x_i)) = (y_i - f(x_i))^2$
绝对损失函数	$Loss(y_i, f(x_i)) = y_i - f(x_i) $
对数损失函数/对数似然损失函数	$Loss(y_i, P(y_i x_i)) = -\log P(y_i x_i)$

典型的损失函数


6.1 概述

□ 监督学习的损失函数—经验风险与期望风险

映射函数训练目标：**经验风险**最小化(empirical risk minimization, ERM)

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

选取一个使得训练集所有数据损失平均值最小的映射函数。这样的考虑是否够？



训练数据集

$(x_i, y_i), i = 1, \dots, n$


6.1 概述

□ 监督学习的损失函数—经验风险与期望风险

映射函数训练目标: **经验风险**最小化(empirical risk minimization, ERM)

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

选取一个使得训练集所有数据损失平均值最小的映射函数。这样的考虑是否够?



训练数据集

$(x_i, y_i), i = 1, \dots, n$

映射函数训练目标: **期望风险**最小化(expected risk minimization)

$$\min_{f \in \Phi} \int_{x \times y} \text{Loss}(y, f(x)) P(x, y) dx dy$$



测试数据集数据无穷多

$(x_i', y_i'), i = 1, \dots, \infty$


6.1 概述

□ 监督学习的损失函数—经验风险与期望风险

映射函数训练目标: **经验风险**最小化(empirical risk minimization, ERM)

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

选取一个使得训练集所有数据损失平均值最小的映射函数。这样的考虑是否够?



训练数据集
 $(x_i, y_i), i = 1, \dots, n$

映射函数训练目标: **期望风险**最小化(expected risk minimization)

$$\min_{f \in \Phi} \int_{x \times y} \text{Loss}(y, f(x)) P(x, y) dx dy$$



测试数据集数据无穷多
 $(x_i', y_i'), i = 1, \dots, \infty$

- 期望风险是模型关于联合分布期望损失, 经验风险是模型关于训练样本集平均损失。
- 根据大数定律, 当样本容量趋于无穷时, 经验风险趋于期望风险。所以实际上用经验风险来估计期望风险。
- 由于现实中训练样本数目有限, 用经验风险估计期望风险并不理想, 要对经验风险进行一定的约束。

6.1 概述

□ 监督学习的损失函数—过学习（过拟合）与欠学习（欠拟合）

经验风险最小化

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

期望风险最小化

$$\min_{f \in \Phi} \int_{x \times y} \text{Loss}(y, f(x)) P(x, y) dx dy$$

经验风险小 (训练集上表现好)	期望风险小 (测试集上表现好)	泛化能力强
经验风险小 (训练集上表现好)	期望风险大 (测试集上表现不好)	
经验风险大 (训练集上表现不好)	期望风险大 (测试集上表现不好)	
经验风险大 (训练集上表现不好)	期望风险小 (测试集上表现好)	

6.1 概述

□ 监督学习的损失函数—过学习（过拟合）与欠学习（欠拟合）

经验风险最小化

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

期望风险最小化

$$\min_{f \in \Phi} \int_{x \times y} \text{Loss}(y, f(x)) P(x, y) dx dy$$

经验风险小 (训练集上表现好)	期望风险小 (测试集上表现好)	泛化能力强
经验风险小 (训练集上表现好)	期望风险大 (测试集上表现不好)	过度学习 (模型过于复杂)
经验风险大 (训练集上表现不好)	期望风险大 (测试集上表现不好)	
经验风险大 (训练集上表现不好)	期望风险小 (测试集上表现好)	

6.1 概述

□ 监督学习的损失函数—过学习（过拟合）与欠学习（欠拟合）

经验风险最小化

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

期望风险最小化

$$\min_{f \in \Phi} \int_{x \times y} \text{Loss}(y, f(x)) P(x, y) dx dy$$

经验风险小 (训练集上表现好)	期望风险小 (测试集上表现好)	泛化能力强
经验风险小 (训练集上表现好)	期望风险大 (测试集上表现不好)	过度学习 (模型过于复杂)
经验风险大 (训练集上表现不好)	期望风险大 (测试集上表现不好)	欠学习
经验风险大 (训练集上表现不好)	期望风险小 (测试集上表现好)	

6.1 概述

□ 监督学习的损失函数—过学习（过拟合）与欠学习（欠拟合）

经验风险最小化

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

期望风险最小化

$$\min_{f \in \Phi} \int_{x \times y} \text{Loss}(y, f(x)) P(x, y) dx dy$$

经验风险小 (训练集上表现好)	期望风险小 (测试集上表现好)	泛化能力强
经验风险小 (训练集上表现好)	期望风险大 (测试集上表现不好)	过度学习 (模型过于复杂)
经验风险大 (训练集上表现不好)	期望风险大 (测试集上表现不好)	欠学习
经验风险大 (训练集上表现不好)	期望风险小 (测试集上表现好)	“神仙算法” 或“黄粱美梦”

6.1 概述

□ 监督学习的损失函数—结构风险最小

经验风险最小化：仅反映了局部数据

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

期望风险最小化：无法得到全量数据

$$\min_{f \in \Phi} \int_{x \times y} \text{Loss}(y, f(x)) P(x, y) dx dy$$

6.1 概述

□ 监督学习的损失函数—结构风险最小

经验风险最小化：仅反映了局部数据

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i))$$

期望风险最小化：无法得到全量数据

$$\min_{f \in \Phi} \int_{x \times y} \text{Loss}(y, f(x)) P(x, y) dx dy$$

结构风险最小化(structural risk minimization):

为了防止过拟合，在经验风险上加上表示模型复杂度的正则化项(regulatizer)或惩罚项

(penalty term) :


$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i)) + \lambda J(f)$$

经验风险 模型复杂度

在最小化经验风险与降低模型复杂度
之间寻找平衡

6.1 概述

□ 监督学习小结



结构风险最小化(structural risk minimization):

为了防止过拟合，在经验风险上加上表示模型复杂度的正则化项(regulatizer)或惩罚项 (penalty term) :

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, f(x_i)) + \lambda J(f)$$

经验风险 模型复杂度

在最小化经验风险与降低模型复杂度之间寻找平衡

目录

6.1 概述

6.2 线性回归

6.3 决策树学习

6.4 支持向量机

6.5 集成学习

6.2 线性回归

- 在现实生活中，往往需要分析若干变量之间的关系，如碳排放量与气候变暖之间的关系、某一商品广告投入量与该商品销售量之间的关系等，这种分析不同变量之间存在关系的研究叫**回归分析**，刻画不同变量之间关系的模型被称为**回归模型**。如果这个模型是线性的，则称为**线性回归模型**。
- 一旦确定了回归模型，就可以进行预测等分析工作，如从碳排放量预测气候变化程度、从广告投入量预测商品销售量等。


6.2 线性回归

$$y = 33.73(\text{英寸}) + 0.516x$$

y: 子女平均身高

x: 父母平均身高

- 父母平均身高每增加一个单位, 其成年子女平均身高只增加0.516个单位, 它反映了这种“衰退 (regression)”效应 (“回归”到正常人平均身高)。
- 虽然x和y之间并不总是具有“衰退” (回归) 关系, 但是“线性回归”这一名称就保留下来了。



英国著名生物学家
兼统计学家高尔顿
Sir Francis Galton
(1822-1911)

6.2 线性回归


$$y = 33.73(\text{英寸}) + 0.516x$$

y: 子女平均身高

x: 父母平均身高

- 父母平均身高每增加一个单位, 其成年子女平均身高只增加0.516个单位, 它反映了这种“衰退 (regression)”效应 (“回归”到正常人平均身高)。
- 虽然x和y之间并不总是具有“衰退” (回归) 关系, 但是“线性回归”这一名称就保留下来了。

- 给出任意一对父母平均身高, 则可根据上述方程, 计算得到其子女平均身高
- 从父母平均身高来预测其子女平均身高
- 如何求取上述线性方程 (预测方程) 的参数?



英国著名生物学家
兼统计学家高尔顿
Sir Francis Galton
(1822-1911)

6.2 线性回归

$$y = 33.73(\text{英寸}) + 0.516x$$

y: 子女平均身高


x: 父母平均身高

- 父母平均身高每增加一个单位, 其成年子女平均身高只增加0.516个单位, 它反映了这种“衰退 (regression)”效应 (“回归”到正常人平均身高)。
- 虽然x和y之间并不总是具有“衰退” (回归) 关系, 但是“线性回归”这一名称就保留下来了。

- 给出任意一对父母平均身高, 则可根据上述方程, 计算得到其子女平均身高
- 从父母平均身高来预测其子女平均身高
- 如何求取上述线性方程 (预测方程) 的参数?

该回归模型中两个
参数

需要从标注数据中
学习得到
(监督学习)



英国著名生物学家
兼统计学家高尔顿
Sir Francis Galton
(1822-1911)

6.2 线性回归

例子：下表给出了芒提兹尼欧（Montesinho）地区发生森林火灾的部分历史数据，表中列举了每次发生森林火灾时的气温温度取值 x 和受到火灾影响的森林面积 y 。


气温温度 x	5.1	8.2	11.5	13.9	15.1	16.2	19.6	23.3
火灾影响面积 y	2.14	4.62	8.24	11.24	13.99	16.33	19.23	28.74

可否对气温温度与火灾所影响的森林面积之间关系进行建模呢？初步观察之后，可以使用简单的线性模型构建两者之间关系，即气温温度 x 与火灾所影响的森林面积 y 之间存在 $y = ax + b$ 形式的关系。

6.2 线性回归


回归模型: $y = ax + b$

求取: 最佳回归模型是最小化残差平方和的均值, 即要求 8 组 (x, y) 数据得到的残差平均值 $\frac{1}{N} \sum (y - \tilde{y})^2$ 最小。残差平均值最小只与参数 a 和 b 有关, 最优解即是使得残差最小所对应的 a 和 b 的值。



气温温度取值和受到火灾影响森林面积之间的一元线性回归模型 (实线为最佳回归模型)

6.2 线性回归



气温取值和受到火灾影响森林面积之间的一元线性回归模型（实线为最佳回归模型）

回归模型： $y = ax + b$

求取： 最佳回归模型是最小化残差平方和的均值，即要求 8 组 (x, y) 数据得到的残差平均值 $\frac{1}{N} \sum (y - \tilde{y})^2$ 最小。残差平均值最小只与参数 a 和 b 有关，最优解即是使得残差最小所对应的 a 和 b 的值。

- 记在当前参数下第 i 个训练样本 x_i 的预测值为 $\hat{y}_i$
- x_i 的标注值（实际值） y_i 与预测值 $\hat{y}_i$ 之差记为 $(y_i - \hat{y}_i)^2$
- 训练集中 n 个样本所产生误差总和(即损失函数)为：

$$L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$$

- **目标：** 寻找一组 a 和 b ，使得误差总和 $L(a, b)$ 最小。

在线性回归中，解决此目标的方法叫最小二乘法。

一般而言，要使函数具有最小值，对 $L(a, b)$ 参数 a 和 b 分别求导，令其导数为零，再求取参数 a 和 b 的取值。

6.2 线性回归

回归模型: $y = ax + b$

损失函数: $L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$

6.2 线性回归

回归模型: $y = ax + b$

损失函数: $L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$

$$\frac{\partial L(a, b)}{\partial a} = \sum_{i=1}^n 2(y_i - ax_i - b)(-x_i) = 0$$

将 $b = \bar{y} - a\bar{x}$ ($\bar{y} = \frac{\sum_{i=1}^n y_i}{n}$, $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$) 代入上式

6.2 线性回归

回归模型: $y = ax + b$

损失函数: $L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$

$$\frac{\partial L(a, b)}{\partial a} = \sum_{i=1}^n 2(y_i - ax_i - b)(-x_i) = 0$$

将 $b = \bar{y} - a\bar{x}$ ($\bar{y} = \frac{\sum_{i=1}^n y_i}{n}$, $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$) 代入上式

$$\Rightarrow \sum_{i=1}^n (y_i - ax_i - \bar{y} + a\bar{x})(x_i) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i x_i - ax_i x_i - \bar{y} x_i + a\bar{x} x_i) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i x_i - \bar{y} x_i) - a \sum_{i=1}^n (x_i x_i - \bar{x} x_i) = 0$$

6.2 线性回归

回归模型: $y = ax + b$

损失函数: $L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$

$$\frac{\partial L(a, b)}{\partial a} = \sum_{i=1}^n 2(y_i - ax_i - b)(-x_i) = 0$$

将 $b = \bar{y} - a\bar{x}$ ($\bar{y} = \frac{\sum_{i=1}^n y_i}{n}$, $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$) 代入上式


$$\Rightarrow \sum_{i=1}^n (y_i - ax_i - \bar{y} + a\bar{x})(x_i) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i x_i - ax_i x_i - \bar{y} x_i + a\bar{x} x_i) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i x_i - \bar{y} x_i) - a \sum_{i=1}^n (x_i x_i - \bar{x} x_i) = 0$$

$$\min_{a, b} L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$$

$$\Rightarrow \left(\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} \right) - a \left(\sum_{i=1}^n x_i x_i - n\bar{x}^2 \right) = 0$$


$$a = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i x_i - n\bar{x}^2}$$

6.2 线性回归

回归模型: $y = ax + b$

损失函数: $L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$

$$\frac{\partial L(a, b)}{\partial b} = \sum_{i=1}^n 2(y_i - ax_i - b)(-1) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i - ax_i - b) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i) - a \sum_{i=1}^n x_i - \sum_{i=1}^n b = 0$$

$$\Rightarrow n\bar{y} - an\bar{x} - nb = 0$$

$$\Rightarrow b = \bar{y} - a\bar{x}$$



$$a = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$$

$$\min_{a,b} L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$$

6.2 线性回归

回归模型: $y = ax + b$

损失函数: $L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$

$$\frac{\partial L(a, b)}{\partial b} = \sum_{i=1}^n 2(y_i - ax_i - b)(-1) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i - ax_i - b) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i) - a \sum_{i=1}^n x_i - \sum_{i=1}^n b = 0$$

$$\Rightarrow n\bar{y} - an\bar{x} - nb = 0$$

$$\Rightarrow b = \bar{y} - a\bar{x}$$



$$a = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$$

$$\min_{a,b} L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$$

可以看出：只要给出了训练样本 $(x_i, y_i) (i = 1, \dots, n)$ ，我们就可以从训练样本出发，建立一个线性回归方程，使得对训练样本数据而言，该线性回归方程预测的结果与样本标注结果之间的差值和最小。

6.2 线性回归

回归模型: $y = ax + b$

$$\min_{a,b} L(a,b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$$

$$a = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

$$b = \bar{y} - a \bar{x}$$

$$a = \frac{x_1 y_1 + x_2 y_2 + \dots + x_8 y_8 - 8 \bar{x} \bar{y}}{x_1^2 + x_2^2 + \dots + x_8^2 - 8 \bar{x}^2} = 1.428$$

$$b = \bar{y} - a \bar{x} = -7.09$$

即预测芒提兹尼欧地区火灾所影响森林面积与气温温度之间的一元线性回归模型为

“火灾所影响的森林面积 = $1.428 \times$ 气温温度 $- 7.09$ ”，即 $y = 1.428x - 7.09$

目录

6.1 概述

6.2 线性回归

6.3 决策树学习

6.4 支持向量机

6.5 集成学习

6.3 决策树

□ 决策树是一种由节点和边构成的用来描述分类过程的层次数据结构。

- ① 根节点：表示分类的开始
- ② 叶节点：表示一个实例的结束
- ③ 中间节点：表示相应实例中的某一属性
- ④ 边代表：某一属性可能的属性值
- ⑤ 路径：从根节点到叶节点的每一条路径都代表一个具体的实例，并且同一路径上的所有属性之间为合取关系，不同路径（即一个属性的不同属性值）之间为析取关系。
- ⑥ 决策树的分类过程：从树的根接点开始，按照给定的事例的属性值去测试对应的树枝，并依次下移，直至到达某个叶节点为止。

□ 常用算法ID3 (Iterative Dichotomic version3)、C4.5、C5.0和随机森林

6.3 决策树





图5.4 一个简单的鸟类识别决策树



IF 鸟类会飞 AND 是家养的 THEN 可能是和平鸽
IF 鸟类会飞 AND 不是家养的 THEN 可能是信天翁
IF 鸟类不会飞 AND 会游泳 THEN 可能是企鹅
IF 鸟类不会飞 AND 不会游泳 THEN 可能是鸵鸟

决策树学习过程实际上是一个构造决策树的过程。当学习完成后，就可以利用这棵决策树对未知事物进行分类。

6.3 决策树

- ❑ ID3 (Iterative Dichotomic version 3) 算法的学习过程是一个以整个样本集为根节点，以信息增益最大为原则，选择条件属性进行扩展，逐步构造出决策树的过程。
- ❑ ID3算法是J.R.Quinlan于1983年提出的一种在国际上有很大影响的示例学习方法，它的前身是Hunt、Marin和Stone于1966年提出的概念学习系统 (Concept Learning System, CLS) 。

6.3 决策树

1.ID3算法

若假设 $S=\{s_1, s_2, \dots, s_n\}$ 为整个样本集, $X=\{x_1, x_2, \dots, x_m\}$ 为全体属性 (特征) 集, $Y=\{y_1, y_2, \dots, y_k\}$ 为样本类别。则ID3算法描述如下:

- (1) 从根节点(S, X)开始, 计算所有可能的属性 (特征) 的信息增益, 选择信息增益最大的属性 (特征) 作为节点的划分特征;
- (2) 由该属性 (特征) 的不同取值建立子节点;
- (3) 再对子节点递归1-2步, 构建决策树;
- (4) 直到没有特征可以选择或类别完全相同为止, 得到最终的决策树。

6.3 决策树

2.ID3算法—信息熵与信息增益

若假设 $S=\{s_1, s_2, \dots, s_n\}$ 为整个样本集, $X=\{x_1, x_2, \dots, x_m\}$ 为全体属性 (特征) 集, $Y=\{y_1, y_2, \dots, y_k\}$ 为样本类别。

□ **信息熵**: 对信息源整体不确定性的度量

$$Entropy(S) = H(S) = - \sum_{i=1}^k P_i \log P_i$$

其中 P_i 表示第 i 类样本在样本集 S 中所占比例

□ **信息增益**: 两个信息量之间的差的度量, 描述的是信息的确定性

$$\begin{aligned} Gain(S, A) &= Entropy(S) - \sum_{i=1}^n \frac{|S_i|}{|S|} Entropy(S_i) \\ &= Entropy(S) - Entropy(S | A_i) = H(S) - H(S | A_i) \end{aligned}$$

6.3 决策树

3.ID3算法—实例

序号	属性值 (X)			决策方案 (Y)
	x_1 (层次)	x_2 (专业)	x_3 (学否)	
s_1	1	1	1	y_3
s_2	1	1	2	y_1
s_3	1	2	1	y_3
s_4	1	2	2	y_2
s_5	2	1	1	y_3
s_6	2	1	2	y_2
s_7	2	2	1	y_3
s_8	2	2	2	y_3

y_1 : 必修AI

y_2 : 选修AI

y_3 : 不修AI

x_1 : 学历层次 {1-研究生, 2-本科}

x_2 : 专业类别 {1-电信类, $x_2=2$ -机电类}

x_3 : 学习基础 {1-修过AI, 2-未修AI}

用ID3算法完成下述学生选课的例子

6.3 决策树

3.ID3算法—实例

序号	属性值 (X)			决策方案 (Y)
	x_1 (层次)	x_2 (专业)	x_3 (学否)	
s_1	1	1	1	y_3
s_2	1	1	2	y_1
s_3	1	2	1	y_3
s_4	1	2	2	y_2
s_5	2	1	1	y_3
s_6	2	1	2	y_2
s_7	2	2	1	y_3
s_8	2	2	2	y_3

用ID3算法完成下述学生选课的例子

以(S,X)为根节点，按照信息熵下降最大的原则来构造决策树。计算根节点的信息熵：

$$\begin{aligned} Entropy(S) &= H(S) = - \sum_{i=1}^3 P_i \log_2 P_i \\ &= -\frac{1}{8} \log_2 \left(\frac{1}{8}\right) - \frac{2}{8} \log_2 \left(\frac{2}{8}\right) - \frac{5}{8} \log_2 \left(\frac{5}{8}\right) \\ &= 1.2988 \end{aligned}$$

计算根节点(S,X)关于每个属性(特征) 的加权信息熵：

$$Entropy \quad (S \mid x_t) = H \left(S \mid x_t \right) = \sum \frac{\mid S_{x_t} \mid}{\mid S \mid} Entropy \quad (S_{x_t})$$

6.3 决策树

3.ID3算法—实例

序号	属性值 (X)			决策方案 (Y)
	x_1 (层次)	x_2 (专业)	x_3 (学否)	
s_1	1	1	1	y_3
s_2	1	1	2	y_1
s_3	1	2	1	y_3
s_4	1	2	2	y_2
s_5	2	1	1	y_3
s_6	2	1	2	y_2
s_7	2	2	1	y_3
s_8	2	2	2	y_3

$$Entropy(S) = H(S) = 1.2988$$

计算根节点(S,X)关于每个属性
(特征) 的加权信息熵:

$$Entropy(S | x_t) = H(S | x_t) = \sum \frac{|S_{x_t}|}{|S|} Entropy(S_{x_t})$$

$$Entropy(S | x_1) = H(S | x_1) = \sum \frac{|S_{x_1}|}{|S|} Entropy(S_{x_1})$$

$$= \frac{4}{8} \times \left(-\frac{1}{4} \log_2 \left(\frac{1}{4} \right) - \frac{1}{4} \log_2 \left(\frac{1}{4} \right) - \frac{2}{4} \log_2 \left(\frac{2}{4} \right) \right)$$

$$+ \frac{4}{8} \times \left(-\frac{0}{4} \log_2 \left(\frac{0}{4} \right) - \frac{1}{4} \log_2 \left(\frac{1}{4} \right) - \frac{3}{4} \log_2 \left(\frac{3}{4} \right) \right)$$

$$= \frac{4}{8} \times 1.5 + \frac{4}{8} \times 0.8113 = 1.1557$$

用ID3算法完成下述学生选课的例子

6.3 决策树

3.ID3算法—实例

序号	属性值 (X)			决策方案 (Y)
	x_1 (层次)	x_2 (专业)	x_3 (学否)	
s_1	1	1	1	y_3
s_2	1	1	2	y_1
s_3	1	2	1	y_3
s_4	1	2	2	y_2
s_5	2	1	1	y_3
s_6	2	1	2	y_2
s_7	2	2	1	y_3
s_8	2	2	2	y_3

$$Entropy(S) = H(S) = 1.2988$$

计算根节点(S,X)关于每个属性
(特征) 的加权信息熵:

$$Entropy(S | x_t) = H(S | x_t) = \sum \frac{|S_{x_t}|}{|S|} Entropy(S_{x_t})$$

$$Entropy(S | x_1) = H(S | x_1) = 1.1557$$

$$Entropy(S | x_2) = H(S | x_2) = 1.1557$$

$$Entropy(S | x_3) = H(S | x_3) = 0.75$$

$$Gain(S, x_1) = H(S) - H(S | x_1) = 1.2988 - 1.1557 = 0.1431$$

$$Gain(S, x_2) = H(S) - H(S | x_2) = 1.2988 - 1.1557 = 0.1431$$

$$Gain(S, x_3) = H(S) - H(S | x_3) = 1.2988 - 0.75 = 0.5488 \quad \checkmark$$

用ID3算法完成下述学生选课的例子

6.3 决策树

3.ID3算法—实例

序号	属性值 (X)			决策方案 (Y)
	x_1 (层次)	x_2 (专业)	x_3 (学否)	
s_1	1	1	1	y_3
s_2	1	1	2	y_1
s_3	1	2	1	y_3
s_4	1	2	2	y_2
s_5	2	1	1	y_3
s_6	2	1	2	y_2
s_7	2	2	1	y_3
s_8	2	2	2	y_3

用ID3算法完成下述学生选课的例子




图5.5 扩展根节点后的部分决策树

- (1) S_1' 类别完全相同, y_3 是叶子节点
- (2) 删除属性 x_3
- (3) 递归处理 (S_2', X_1)

6.3 决策树

3.ID3算法—实例 (例5.1)




图5.7 最终得到的完整决策树

用ID3算法完成学生选课的例子

如果属性集为空，将该节点标记为叶节点，并根据各个类别的样本数量，按照少数服从多数的原则，将该叶节点的类别标记为样本数最多的那个类别。

目录

6.1 概述

6.2 线性回归

6.3 决策树学习

6.4 支持向量机

6.5 集成学习

6.4 支持向量机

- 支持向量机（即SVM）利用最大间隔算法去近似地实现结构风险最小化原理，是一种基于统计学习理论的新型通用机器学习方法。该方法不仅可以很好地解决线性可分问题，而且可以利用核函数有效地解决线性不可分问题。

6.4 支持向量机

□ 支持向量机（即SVM）利用最大间隔算法去近似地实现结构风险最小化原理，是一种基于统计学习理论的新型通用机器学习方法。该方法不仅可以很好地解决线性可分问题，而且可以利用核函数有效地解决线性不可分问题。

1. 线性可分与最优分类超平面

线性可分问题分类是SVM学习方法的基础，SVM是通过最优分类超平面来实现其分类的。

2. 非线性可分与核函数

对非线性可分问题，SVM采用特征空间映射方式，即将非线性可分的样本集映射到高维空间，使其在高维空间中被转变为线性可分。即采用核函数的方法。

6.4 支持向量机

1. 线性可分与最优分类超平面

假设有以下 n 个独立、同分布且线性可分的训练样本 $S=\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, $Y=\{-1, +1\}$ 为样本类别。SVM学习的目标就是要找到一个最优超平面

$$w \cdot x + b = 0$$


将两类不同的样本完全分开。其中, w 是权重向量, “ $\cdot$ ”是向量的点积, x 是输入向量, b 是一个阈值。

1. 线性可分与最优分类超平面

假设有以下 n 个独立、同分布且线性可分的训练样本 $S=\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, $Y=\{-1, +1\}$ 为样本类别。SVM学习的目标就是要找到一个最优超平面

$$w \cdot x + b = 0$$

将两类不同的样本完全分开。其中， w 是权重向量，“ $\cdot$ ”是向量的点积， x 是输入向量， b 是一个阈值。



- (1) H 为分类超平面， H_1 和 H_2 分别为两个不同类的边界分割平面， H_1 和 H_2 均与 H 平行，且 H_1 和 H_2 分别通过相应类中离 H 最近的样本点。
- (2) 对 H ，若能满足 H 与两个类边界分割平面 H_1 和 H_2 等距，且能使 H_1 和 H_2 之间的间隔最大，则称该分类超平面为**最优分类超平面**。
- (3) 最优分类超平面仅与分布在 H_1 和 H_2 上的样本点有关，这些样本点被称为**支持向量**

1. 线性可分与最优分类超平面—最优分类超平面的分类间隔

对线性分类问题，其分类超平面方程的一般形式为

$$w \cdot x + b = 0$$

分类判别函数的一般形式为

$$g(x) = w \cdot x + b$$

对于所有样本有

$$y_i = \begin{cases} +1 & w \cdot x_i + b \geq 0 \\ -1 & w \cdot x_i + b < 0 \end{cases}$$

一个样本点到分类超平面的距离为


$$\frac{|w \cdot x + b|}{\|w\|} = \frac{y_i(w \cdot x + b)}{\|w\|} \xrightarrow{\text{线性可分}} \frac{y_i(w \cdot x + b)}{\|w\|} \geq D$$

我们希望 D 越大越好，改变 w ，可以得到 D 的无穷多个解。为能够得到其唯一解，我们约定 $D\|w\|=1$ 或 $D=1/\|w\|$ 。此时，要使 D 最大化，则需 $\|w\|$ 最小化。

1. 线性可分与最优分类超平面—求解最优分类超平面


SVM优化目标转化成

$$\min \frac{1}{2} \|w\|^2 \quad \text{st. } y_i (w \bullet x_i + b) \geq 1, \quad i=1,2,\dots,n$$



拉格朗日乘数法

$$L(w, b, a) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n a_i (y_i (w \bullet x_i + b) - 1) \quad (a_i \geq 0)$$



对 w 和 b 的偏导数为0

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^n a_i y_i x_i = 0 \quad \frac{\partial L}{\partial b} = \sum_{i=1}^n a_i y_i = 0$$

$$\max W(a) = \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i,j=1}^n a_i a_j y_i y_j (x_i \bullet x_j)$$

$$\text{st. } \sum_{i=1}^n a_i y_i = 0, a_i \geq 0, i=1,2,\dots,n \quad \Rightarrow \text{支持向量} \Rightarrow \frac{1}{m} \sum_{i=1}^m (y_i - w \bullet x_i)$$


$$f(x) = \text{sgn}(w \bullet x + b)$$

$$= \text{sgn}\left(\sum_{i=1}^m a_i y_i (x_i \bullet x) + b\right)$$

2.非线性可分与核函数

SVM优化目标转化成

$$\max W(a) = \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i,j=1}^n a_i a_j y_i y_j (x_i \bullet x_j)$$



高维空间

$$\max W(a) = \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i,j=1}^n a_i a_j y_i y_j K(x_i \bullet x_j)$$

高维空间上的分类判别函数

$$\begin{aligned} f(x) &= \text{sgn}(w \bullet x + b) \\ &= \text{sgn}\left(\sum_{i=1}^m a_i y_i K(x_i \bullet x) + b\right) \end{aligned}$$

$$\begin{aligned} f(x) &= \text{sgn}(w \bullet x + b) \\ &= \text{sgn}\left(\sum_{i=1}^m a_i y_i (x_i \bullet x) + b\right) \end{aligned}$$

常用核函数

核函数名称	损失函数定义
多项式核函数	$K(x, x_i) = [(x \cdot x_i) + 1]^d$
径向基核函数	$K(x, x_i) = \exp\left(-\frac{\ x - x_i\ ^2}{\sigma^2}\right)$
S型核函数	$K(x, x_i) = \tanh(v(x \cdot x_i) + C)$

目录

6.1 概述

6.2 线性回归

6.3 决策树学习

6.4 支持向量机

6.5 集成学习

6.5 集成学习

- 集成学习是指为解决同一问题，先训练出一系列个体学习器（或称弱学习器），然后再根据某种规则把这些个体学习器的学习结果整合到一起，得到比单个个体学习器更好的学习效果。
- 包括两大基本问题：（1）个体学习器的构造；（2）个体学习器的合成




图5.11 集成学习的基本结构

6.5 集成学习

□ 集成学习的两种方式

(1) **同质集成 (狭义集成学习)**：构造个体学习器时使用**相同类型**的学习方法，个体学习器称为基学习器，所用的学习算法称为基学习算法。

(2) **异质集成 (广义集成学习)**：构造个体学习器时可以使用**不同类型**的学习方法

□ 1996年，弗罗因德 (Freund) 和史皮尔 (Schapire) 提出了著名的 AdaBoost (adaptive Boost) 算法，布雷曼 (Breiman) 提出了著名的 Bagging 算法。奠定了集成学习的理论基础，形成了集成学习的基本构架，标志着集成学习的真正形成。

□ Boosting方法

- ① 为每个训练样本平均分配初始权重，并训练出弱学习器1；
- ② 通过提高错误率高的训练样本的权重，降低错误率低的训练样本的权重，得到训练样本的新的权重分布，并在该权重分布上训练出弱学习器2；
- ③ 重复①和②，直到到达最大迭代轮数
- ④ 将训练出来的这些弱学习器合成到一起，形成最终的强学习器。

□ Boosting方法

- ① 为每个训练样本平均分配初始权重，并训练出弱学习器1；
- ② 通过提高错误率高的训练样本的权重，降低错误率低的训练样本的权重，得到训练样本的新的权重分布，并在该权重分布上训练出弱学习器2；
- ③ 重复①和②，直到到达最大迭代轮数
- ④ 将训练出来的这些弱学习器合成到一起，形成最终的强学习器。

□ Bagging方法

- ① 从初始训练集中使用可重采样的随机抽样方法产生出本轮的训练子集，利用选定的弱学习算法训练出本轮迭代的弱学习器；
- ② 重复①，直到到达最大迭代轮数
- ③ 按照某种方式将训练出来的这些弱学习器合成到一起，形成最终的强学习器。

Boosting方法

① 为每个训练样本平均分配初始权重，并训练出弱学习器1；

② 通过训练，得到

③ 重

④ 将

Bagging


① 从，利用

② 重


③ 按照某种方式将训练出来的这些弱学习器合成到一起，形成最终的强学习器。

弱学习器的合成方法		定义
代数合成法	平均法	$H_{final}(X) = \operatorname{argmax}_j \frac{1}{T} \sum_{t=1}^T h_{t,j}(X)$
	加权平均法	$H_{final}(X) = \operatorname{argmax}_j \frac{1}{T} \sum_{t=1}^T w_t h_{t,j}(X)$
投票法		$H_{final}(X) = \operatorname{argmax}_{j \in Y} \frac{1}{T} \sum_{t=1}^T I(h_{t,j}(X) = y)$

6.5.1 AdaBoost算法



6.5.1 AdaBoost算法



6.5.2 Bagging方法

