



哈爾濱工業大學(深圳)
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

计算机科学与技术学院

2025 年 (春) 季 自然语言处理课程报告

姓名: 章晨冉 学号: 220110514

姓名: 金正达 学号: 220110515

姓名: 官佳文 学号: 220110309

2025 年 6 月 24 日

目录

1. 介绍	1
2. 模型方法	1
2.1 整体结构	1
2.2 模型细节	2
3. 实验结果	4
3.1 实验设置	4
3.2 评估指标	5
3.3 实验结果	6
4. 结论	7
参考文献	7

1. 介绍

细粒度中文仇恨言论识别要求我们构建一个能够深入理解文本内部结构的模型，从而以结构化的形式解析出仇恨言论的各个构成要素。

具体来说，我们的模型需要从给定的社交媒体评论文本中，抽取出所有相关的仇恨言论四元组。一个完整的四元组包含四个关键元素：

- 评论对象：这是指评论内容直接评述或指向的个体或群体。我们需要从原文中精确地抽取出这个实体，例如在“老黑我是真的讨厌”中，评论对象就是“老黑”。如果一条评论没有明确的指向性，例如“保持安全！”，则此项应被标记为 NULL。
- 论点：这是针对上述“评论对象”所发表的核心观点或信息片段。它概括了评论者对评论对象的具体看法。例如，在“你可真是头蠢驴”中，论点就是“蠢驴”。
- 目标群体：此元素要求我们判断上述“评论对象-论点”的组合具体指向了哪一类社会群体。任务预设了五个分类标签供我们选择，分别是：“地域”、“种族”、“性别”、“LGBTQ”、“其他”。
- 是否仇恨：这是一个二元分类标签，用于最终判定“评论对象-论点”这对组合是否构成了仇恨言论。即便是对于非仇恨的文本，我们也需要完整抽取其四元组，并将此项标记为“non-hate”。

此项任务的一大挑战在于，单条输入文本可能包含多个评论对象和论点，因此可能需要抽取出多个四元组。我们的模型必须具备识别并分割这些不同四元组的能力。

任务的输入为社交媒体文本，输出为仇恨四元组，顺序依次为 Target、Argument、Targeted Group、Hateful。每个四元组中各元素之间用“|”分割，并利用[END]结尾；如果一条样本中包含多个四元组，不同四元组之间利用[SEP]分割。

2. 模型方法

2.1 整体结构


我们提出一种基于自反思学习和记忆检索的增强型框架，旨在提升大语言模型在细粒度中文仇恨言论识别任务中的性能。传统的微调方法虽然能够将任务知识注入模型，但在面对复杂、隐晦或不断变化的语言表达时，往往表现出泛化能力的不足。为了解决这一挑战，本框架引入了一个动态的“经验池”机制，模拟人类“举一反三”的学习过程。该框架的核心思想是，模型在处理每个训练样本时，不仅仅是进行一次性的预测，而是将每次的预测结果与真实标签进行对比，并对二者间的差异进行“反思”。这种反思过程会生成一段结构化的“经验”文本，总结本次预测的得失、关键点的遗漏以及未来应注意的事项。这些宝贵的经验被向量化后存入一个专门的经验池中。

在处理新的文本时，模型会首先查询经验池，检索出与当前输入最相关的历史经验。这些经验将被动态地整合进当前的推理提示中，作为一种“先验知识”或“过往案例”来引导模型，从而生成更准确、更鲁棒的预测结果。

通过这种“学习-反思-检索-应用”的闭环，模型得以在持续的训练过程中积累并利用解决特定问题的元认知能力，实现性能的动态演进与自我完善。

2.2 模型细节

本框架主要由两大核心模块构成：经验池模块和反思性推理与学习模块。下图展示了框架的整体工作流程：



2.2.1 经验池模块

经验池是本框架的记忆中枢，其核心功能是高效地存储、索引和检索从过往任务中提炼出的经验。该模块的设计确保了模型能够快速定位到与当前问题最相似的历史情境，从而获得有效的决策支持。

“经验”在本框架中被定义为对一次具体预测任务的反思总结。它并非简单的原始数据对，而是经过模型深度分析后生成的、具有指导意义的元知识。每条经验都与生成它时所依据的原始输入文本相关联。

为了实现高效检索，经验的存储与索引是分离的。所有经验的文本内容被存储在一个字典结构中，通过唯一的 ID 进行标识。而用于检索的关键，输入文本，则通过一个强大的文本编码器转换为高维向量。这种设计使得文本的语义信息得以在向量空间中被量化和度量。

为了从海量经验中快速检索，本模块采用了 FAISS 库。FAISS 是一个专为稠密向量相似性搜索和聚类而设计的库，能够支持亿万级别的向量索引。具体而言，所有输入文本的向量表示被添加到一个基于 L2 距离的 IndexFlatL2 索引中。当处理新的输入文本时，该文本同样被编码为查询向量。随后，FAISS 索引会根据查询向量与索引中所有向量的欧氏距离，快速返回最相似的 top-k 个向量索引。通过这些索引，系统便能回溯到原始的经验文本。为了更直观地衡量相关性，L2 距离会被转换为余弦相似度分数，并可设置一个阈值以过滤掉相关性不足的经验，确保检索到的经验具有足够的参考价值。

2.2.2 反思性推理与学习模块

该模块是框架的执行核心，负责驱动整个“推理-反思-学习”的闭环。它围绕一个核心智能体展开，该智能体协调大语言模型、经验池以及数据流，完成模型的训练和评估过程。

经验驱动的推理：

在进行预测时，无论是训练还是评估阶段，模型并非直接处理原始输入。首先，系统会利用当前输入文本作为查询，向经验池模块发起检索请求，获取最相关的 k 条历史经验。

这些检索到的经验文本会被整合到一个精心设计的提示模板中：

任务的输入为社交媒体文本，输出为仇恨四元组，
顺序依次为Target、Argument、Targeted Group、Hateful。

四元组介绍：

- 评论对象 (Target)：帖子的评述对象，如一个人或一个群体，目标只能从实例中提取。
- 论点 (Argument)：评论中目标关键论点的主要信息片段，不要太长。
- 目标群体 (Targeted Group)：指包含仇恨信息的评论对象-论点对涉及的目标群体。标注的目标群体包括“Region”、“Racism”、“Sexism”、“LGBTQ”、“others”共5类。
- 是否仇恨 (Hateful)：评论对象-论点对是否构成了对某些群体的仇恨言论。结果为hate或者non-hate。

注意：

1. 如果是否仇恨标记为non-hate，则目标群体标记为non-hate；
2. 每个四元组中各元素之间用“|”分割，并利用[END]结尾；
3. 如果一条样本中包含多个主要评述对象，不同四元组之间利用[SEP]分割。只有在必要的时候使用多个，不要盲目使用；
4. 请严格按照顺序和格式输出，不能省略空格，只输出四元组内容。

下面是之前一些经验：

{experience_text}

示例：

输入：把中国当成他们的殖民地。

输出：他们|把中国当成他们的殖民地|Racism|hate[END]

重要：按照下面的格式给出答案，严格按照要求进行回复，利用之前的经验进行输出的生成：

输入：{input_text}

输出：

该模板不仅包含了任务的详细指令、输入/输出格式要求，还专门开辟了一个“过往经验”区域。这样，当大语言模型接收到最终的提示时，它不仅知道“要做什么”和“要处理什么”，还能参考“过去类似问题是如何解决的”，从而显著提高其解决复杂问题的能力。如果没有检索到相关经验，该区域将提示“没有相关经验”，避免无效信息的干扰。

自我反思与经验生成：

自我反思是本框架实现自我演化的关键机制，仅在训练阶段被激活。当模型根据经验驱动的提示生成一个输出后，系统并不会就此结束。它会将模型的输出与标准答案进行对比。

如果二者不一致，或者即便是形式上一致但需要进一步确认，系统会启动一次“反思”调用。它会向大语言模型发送一个特定的反思提示：

请对以下仇恨言论识别任务的预测结果进行分析和反思：

模型输出：{model_output}

正确答案：{label}

请从以下几个方面进行反思分析：

1. 对于评论对象 (Target)、论点 (Argument)、目标群体 (Targeted Group) 的分类、仇恨程度 (Hateful) 的判断是否准确？
2. 这类错误的可能原因是什么？针对这类问题，应该注意哪些关键点？

请总结出具体的经验教训，用于指导后续类似文本的分析。格式要求：

- 简洁明了，突出重点
- 包含具体的识别要点和注意事项
- 可以作为经验指导应用到类似案例中

反思总结 (**不超过5句话**) :

该提示包含了模型的输出和正确答案，并要求模型扮演“反思专家”的角色，从多个维度（如实体识别准确性、关系判断逻辑等）分析差异，并总结出可泛化的经验教训。这段由模型自己生成的反思总结，就构成了一条全新的、宝贵的经验。

经验的沉淀与循环：

新生成的经验并不会被丢弃，而是连同其对应的原始输入文本，被立即送入经验池模块进行存储和索引。

随着训练的进行，经验池会不断丰富和扩充。后续的训练样本将能够检索到这些新生成的经验，从而在一个动态更新的知识库支持下进行学习。这个过程形成了一个优雅的自举循环：解决问题 → 反思错误 → 形成经验 → 利用经验解决新问题。这一机制使得模型不再是一个被动的信息接收者，而是一个能够主动从错误中学习并不断积累智慧的主体。

3. 实验结果

3.1 实验设置

基础模型的选择上，我们使用了 deepseek-chat 模型 API。

经验池的超参数中，搜索相似度阈值为 0.8，确保搜索到的经验足够相关，搜索经验个数为 3，既能提供足够的经验参考，又避免了过多噪声信息的引入。

经验池的文本编码器使用了 Bge-m3 模型，能够有效捕获文本的深层语义信息，生成合适的文本编码。

3.2 评估指标

我们模型的最终得分，并非由单一的 F1 分数决定，而是由硬匹配（Hard Match）和软匹配（Soft Match）两种策略下 F1 分数的平均分来评定。这意味着我们的模型必须在两个不同维度的准确性上都表现出色。

以下是我们对这两种评分标准的理解：

硬匹配：

这是最严格的评分标准。

若要在此项得分，我们模型预测出的一个四元组，其内部的“评论对象”、“论点”、“目标群体”和“是否仇恨”这全部四个元素，都必须与标准答案中的对应元素在字符串层面完全一致，不能有任何字符的差别。这要求我们的模型具备极高的预测精度。

软匹配：

此标准为我们的文本抽取部分提供了一定的容错空间。

要获得一个“软匹配”的正确计分，我们预测的四元组必须同时满足两个条件：分类标签必须精准：“目标群体”和“是否仇恨”这两个分类性质的元素，必须与标准答案完全一致。

文本片段可有偏差：“评论对象”和“论点”这两个从原文中抽取的文本片段，与标准答案的字符串匹配度需超过 50%。

官方指定的字符串匹配度计算方式，与 Python difflib 库中的 SequenceMatcher 函数一致。其具体计算公式为：

$$Similarity = \frac{M \times 2}{len_{pred} + len_{gold}}$$

其中，M 是我们预测的字符串和标准答案之间的最长公共子序列长度（这要求字符不仅要匹配，顺序也要正确），而 len_{pred} 和 len_{gold} 分别是我们预测的字符串和标准答案的长度。

综上所述，我们的模型策略必须兼顾两个层面：既要追求用词和分类的绝对精确以在“硬匹配”中得分，又要具备理解和抽取核心语义的能力，以应对“软匹配”中对文本表达多样性的包容。最终的排名将取决于我们的模型在这两种要求下的综合表现。

3.3 实验结果

队名 (sz+组长学号)	组长姓名	组长学号	组员1姓名	组员1学号	组员2姓名	组员2学号	Rank	Score
sz220110103	方烨	220110103	陈智伟	220110102	王家豪	220110427	1	0.3665
sz220110609	李子韬	220110609	胡巍瀚	220110613	张佳瑾	220110215	2	0.3321
sz220110330	陈竣发	220110330	郭金炜	220110331	董佳鹏	220110323	3	0.3232
sz220110407	朱双羽	220110407	田淳皓	220110411	林涵	220110409	4	0.3211
sz220110123	陈铭瑜	220110123	徐锦锐	220111026	李怡君	220110313	5	0.3176
sz220110430	吴梓滔	220110430	陈单青	220110431	梅皓然	220110325	6	0.3173
sz220110321	陈志荣	220110321	廖云峰	220110304	谌令涵	220110306	7	0.317
sz220110828	李建杭	220110828	卢家谦	220110809	彭相儒	220110922	8	0.3152
sz220111024	黄煜聪	220111024	段伊樊	220110919	粟芷瑄	220111009	9	0.308
sz220110514	章晨冉	220110514	金正达	220110515	官佳文	220110309	10	0.3023
sz220310324	陈然	220310324	刘嘉铭诚	220110315	曾元昊	220110328	11	0.2865
sz220110918	李卓	220110918	岳亮	220110921	曾立荣	220110903	12	0.2852
sz220110801	杨霄	220110801	尤欣宇	220110820	李红橘	220110815	13	0.2702
sz220110326	谭名超	220110326	郭睿勉	220110312	黎俊	220110924	14	0.2669
sz220110724	陈彦至	220110724	谭皓文	220110623	谢诚豪	220110620	15	0.2654
sz220110930	杨越州	220110930	黄宇浩	220110415	刘子淇	220110923	16	0.2501
sz220110223	黄子洋	220110223	陶槿劼	220110929	唐潇萌	220110916	17	0.2483
sz220110805	林泳帆	220110805	闵睿凡	220110822	陈德毅	220110806	18	0.2209
sz220110214	朱泽恩	220110214	宋国豪	220110228	文飞扬	220110206	19	0.2082
sz220110722	蔡易轩	220110722	陈哲恺	220110731			20	0.1988
sz220110211	黄俊杰	220110211	何嘉峻	220110220	马浩帆	220110209	21	0.1976
sz220110728	张子晗	220110728	潘俊	220110829	陈宜登	220110524	22	0.1766
sz220111022	卢家鼎		张震华		刘宇浩		23	0.1537

在本次细粒度中文仇恨言论识别任务中，我们基于自反思学习和记忆检索的增强型框架取得了 0.3023 的最终得分。

根据最终排名，这一成绩在所有参赛队伍中位列第 10 名。

这一结果验证了我们提出的结合“经验池”与大语言模型进行动态学习的框架具有可行性。模型在处理复杂的、多维度的仇恨言论四元组抽取任务时，展现了一定的性能。0.3023 的分数是通过硬匹配和软匹配两种策略下的 F1 分数平均得出的，这表明我们的模型在实现分类标签（目标群体、是否仇恨）的准确判断和文本元素（评论对象、论点）的精确抽取方面，达到了一定的综合水平。

从排名上看，我们的模型与顶尖水平尚有差距，这表明该框架仍有较大的优化空间。分析其原因，可能在于：

- 经验的质量与泛化能力：虽然模型能够生成反思经验，但这些经验的质量和泛化能力可能还不够高，有时可能生成了针对性过强或不够深刻的总结，导致其在指导新案例时的效果有限。
- 检索机制的有效性：尽管采用了 Bge-m3 编码和 FAISS 进行相似度检索，但在复杂的语义场景下，检索到的经验与当前问题的实际关联度可能存在偏差，从而引入噪声或提供了错误的引导。
- 基础模型的限制：我们使用的 deepseek-chat 模型 API 本身的能力是框架性能的上限。尽管其表现优异，但在处理高度隐晦、反讽或包含复杂网络用语的仇恨言论时，仍可能出现理解偏差。

实验结果初步证明了我们框架的创新价值，但同时也为未来需要深入研究和改进的方向。

4. 结论

我们成功设计并实现了一个基于自反思学习和记忆检索的增强型框架，旨在提升大语言模型在细粒度中文仇恨言论识别任务上的表现。该框架通过引入动态“经验池”机制，模拟人类“举一反三”的学习过程，使模型能够在持续的训练中进行“学习-反思-检索-应用”的闭环，从而积累元认知能力并实现自我完善。

实验结果显示，我们的模型最终取得了 0.3023 分的成绩，位列第 10 名。这一成绩肯定了该方法的有效性，证明了通过检索历史经验来辅助推理的思路，能够帮助模型更好地应对复杂的四元组抽取任务，尤其是在兼顾严格的“硬匹配”与有一定容错空间的“软匹配”评估标准下。

尽管如此，实验结果也揭示了模型仍有广阔的改进空间。一个关键的优化方向在于提升“经验”本身的质量与深度。当前框架依赖大语言模型自我反思生成经验教训，未来的工作可以探索如何引导模型生成更具泛化能力、更为深刻的元知识，而不仅仅是针对单个错误样本的修正总结。这可能需要设计更复杂的反思提示，或者引入一个审核机制来过滤掉低质量、重复或过于具体的经验，确保沉淀到经验池中的是真正具有普适指导价值的智慧。

与之并行，经验检索机制的精准性也值得深入研究。目前系统采用基于文本向量相似度的方法来检索历史经验，但在面对语义模糊或结构独特的仇恨言论时，这种方式可能无法保证检索到的案例总能切中要害。可以探索更加精细化的检索策略，例如，将文本的结构特征、错误类型等信息也纳入索引，实现多维度的情境匹配，从而为模型提供关联性更强、更具参考价值的“先验知识”。

此外，整个框架的性能上限受到所选用的基础大语言模型能力的制约。将此框架迁移并适配到更前沿、规模更大的基础模型上，是提升性能最直接的路径之一。一个拥有更强语言理解、逻辑推理和知识储备的基础模型，不仅能提升初始预测的准确率，还能在自我反思环节产生更高质量的分析与总结，从而驱动整个“学习-反思-检索-应用”的闭环进入一个更高层次的良性循环，从根本上增强模型处理复杂、隐晦仇恨言论的能力。

总的来说，我们设计的框架为解决细粒度仇恨言论识别问题提供了一种富有前景的思路，通过赋予模型从自身错误中学习并积累经验的能力，增强了其在复杂推理任务中的准确性和鲁棒性。

参考文献

- [1]. Liu A, Feng B, Xue B, et al. Deepseek-v3 technical report[J]. arXiv preprint arXiv:2412.19437, 2024. Construction and Applications of Open Business Knowledge Graph. Shumin Deng, Hui Chen, Zhoubo Li, Feiyu Xiong, Qiang Chen, Mosha Chen, Xiangwen Liu, Jiaoyan Chen, Jeff Z. Pan, Huajun Chen and Ningyu Zhang.
- [2]. Xu W, Mei K, Gao H, et al. A-mem: Agentic memory for llm agents[J]. arXiv preprint arXiv:2502.12110, 2025.

自然语言处理

细粒度中文仇恨言论识别

——基于自反思学习和记忆检索的 增强型框架

成员：章晨冉、金正达、官佳文

hate speech

share

post

threat

CONTENTS

细粒度中文仇恨言论识别要求我们构建一个能够深入理解文本内部结构的模型，从而以结构化的形式解析出仇恨言论的各个构成要素。模型需要从给定的社交媒体评论文本中，抽取出所有相关的仇恨言论四元组。

目录

Part1 模型结构

Part2 模型细节

Part3 实验结果

Part4 结论

PART 01

模型结构


An Enhanced Framework for Self-Reflective Learning and Memory Retrieval

Model Structure

模型结构

基于自反思学习和记忆检索的增强型框架

本框架引入“经验池”机制，模拟“举一反三”学习过程。模型处理样本时，对比预测结果与真实标签进行反思，生成结构化经验文本，向量化后存入经验池。处理新文本时，查询经验池，检索相关经验整合进推理提示，引导模型生成更准确预测。这种“学习-反思-检索-应用”闭环，使模型积累元认知能力，实现性能动态演进与自我完善。



PART 02

模型细节

The Details of the Model

模型细节

经验池模块

高效地存储、索引和检索从过往任务中提炼出的经验。该模块的设计确保了模型能够快速定位到与当前问题最相似的历史情境，从而获得有效的决策支持。




1

2

经验驱动的推理

利用当前输入文本作为查询，向经验池模块发起检索请求，获取最相关的 k 条历史经验。



3

自我反思与经验生成

当模型根据经验驱动的提示生成一个输出后，系统并不会就此结束。它会将模型的输出与标准答案进行对比。



经验的沉淀与循环

新生成的经验并不会被丢弃，而是连同其对应的原始输入文本，被立即送入经验池模块进行存储和索引。




4

模型细节

经验池模块

经验池是本框架记忆中枢，高效存储、索引和检索过往经验。经验是预测任务反思总结，非原始数据对，是指导性元知识，与原始输入文本关联。存储与索引分离，经验文本存于字典结构，通过唯一ID标识，输入文本经文本编码器转为高维向量。

本文采用FAISS库实现快速检索，输入文本向量存于IndexFlatL2索引，新输入文本编码为查询向量，FAISS快速返回最相似top-k向量索引，回溯原始经验文本，L2距离转余弦相似度分数，设阈值过滤低相关性经验。



模型细节

经验驱动的推理

在进行预测时，无论是训练还是评估阶段，模型并非直接处理原始输入。首先，系统会利用当前输入文本作为查询，向经验池模块发起检索请求，获取最相关的 k 条历史经验。这些检索到的经验文本会被整合到一个精心设计的提示模板中。

该模板不仅包含了任务的详细指令、输入/输出格式要求，还专门开辟了一个“过往经验”区域。这样，当大语言模型接收到最终的提示时，它不仅知道“要做什么”和“要处理什么”，还能参考“过去类似问题是 如何解决的”，从而显著提高其解决复杂问题的能力。如果没有检索到相关经验，该区域将提示“没有相关经验”，避免无效信息的干扰。

任务的输入为社交媒体文本，输出为仇恨四元组，顺序依次为Target、Argument、Targeted Group、Hateful。

四元组介绍：

- 评论对象 (Target)：帖子的评述对象，如一个人或一个群体，目标只能从实例中提取。
- 论点 (Argument)：评论中目标关键论点的主要信息片段，不要太长。
- 目标群体 (Targeted Group)：指包含仇恨信息的评论对象-论点对涉及的目标群体。标注的目标群体包括“Region”、“Racism”、“Sexism”、“LGBTQ”、“others”共5类。
- 是否仇恨 (Hateful)：评论对象-论点对是否构成了对某些群体的仇恨言论。结果为hate或者non-hate。

注意：

1. 如果是否仇恨标记为non-hate，则目标群体标记为non-hate；
2. 每个四元组中各元素之间用“|”分割，并利用[END]结尾；
3. 如果一条样本中包含多个主要评述对象，不同四元组之间利用[SEP]分割。只有在必要的时候使用多个，不要盲目使用；
4. 请严格按照顺序和格式输出，不能省略空格，只输出四元组内容。

下面是之前一些经验：

{experience_text}

示例：

输入：把中国当成他们的殖民地。

输出：他们 | 把中国当成他们的殖民地 | Racism | hate [END]

重要：按照下面的格式给出答案，严格按照要求进行回复，利用之前的经验进行输出的生成：

输入：{input_text}

输出：

自我反思与经验生成

自我反思是本框架实现自我演化的关键机制，仅在训练阶段被激活。当模型根据经验驱动的提示生成一个输出后，系统并不会就此结束。它会将模型的输出与标准答案进行对比。如果二者不一致，或者即便是形式上一致但需要进一步确认，系统会启动一次“反思”调用。它会向大语言模型发送一个特定的反思提示。

该提示包含了模型的输出和正确答案，并要求模型扮演“反思专家”的角色，从多个维度（如实体识别准确性、关系判断逻辑等）分析差异，并总结出可泛化的经验教训。这段由模型自己生成的反思总结，就构成了一条全新的、宝贵的经验。

请对以下仇恨言论识别任务的预测结果进行分析和反思：

模型输出：{model_output}

正确答案：{label}

请从以下几个方面进行反思分析：

1. 对于评论对象 (Target)、论点 (Argument)、目标群体 (Targeted Group) 的分类、仇恨程度 (Hateful) 的判断是否准确？
2. 这类错误的可能原因是什么？针对这类问题，应该注意哪些关键点？

请总结出具体经验教训，用于指导后续类似文本的分析。格式要求：

- 简洁明了，突出重点
- 包含具体的识别要点和注意事项
- 可以作为经验指导应用到类似案例中

反思总结 (**不超过5句话**)：

经验的沉淀与循环

新生成的经验并不会被丢弃，而是连同其对应的原始输入文本，被立即送入经验池模块进行存储和索引。

随着训练的进行，经验池会不断丰富和扩充。后续的训练样本将能够检索到这些新生成的经验，从而在一个动态更新的知识库支持下进行学习。这个过程形成了一个优雅的自举循环：解决问题 → 反思错误 → 形成经验 → 利用经验解决新问题。这一机制使得模型不再是一个被动的信息接收者，而是一个能够主动从错误中学习并不断积累智慧的主体。



PART 03

实验结果

实验结果

实验设置

基础模型的选择上，我们使用了 deepseek-chat 模型 API。经验池的超参数中，搜索相似度阈值为 0.8，确保搜索到的经验足够相关，搜索经验个数为 3，既能提供足够的经验参考，又避免了过多噪声信息的引入。经验池的文本编码器使用了 Bge-m3 模型，能够有效捕获文本的深层语义信息，生成合适的文本编码。

结果

在本次细粒度中文仇恨言论识别任务中，我们基于自反思学习和记忆检索的增强型框架取得了0.3023的最终得分。

队名（sz+组长学号）	组长姓名	组长学号	组员1姓名	组员1学号	组员2姓名	组员2学号	Rank	Score
sz220110103	方烨	220110103	陈智伟	220110102	王家豪	220110427	1	0.3665
sz220110609	李子韬	220110609	胡巍瀚	220110613	张佳瑾	220110215	2	0.3321
sz220110330	陈竣发	220110330	郭金炜	220110331	董佳鹏	220110323	3	0.3232
sz220110407	朱双羽	220110407	田淳皓	220110411	林涵	220110409	4	0.3211
sz220110123	陈铭瑜	220110123	徐锦锐	220111026	李怡君	220110313	5	0.3176
sz220110430	吴梓滔	220110430	陈单青	220110431	梅皓然	220110325	6	0.3173
sz220110321	陈志荣	220110321	廖云峰	220110304	湛令涵	220110306	7	0.317
sz220110828	李建杭	220110828	卢家谦	220110809	彭相儒	220110922	8	0.3152
sz220111024	黄煜聪	220111024	段伊樊	220110919	栗芷瑄	220111009	9	0.308
sz220110514	章晨冉	220110514	金正达	220110515	官佳文	220110309	10	0.3023
sz220310324	陈然	220310324	刘嘉谔诚	220110315	曾元昊	220110328	11	0.2865
sz220110918	李卓	220110918	岳亮	220110921	曾立荣	220110903	12	0.2852
sz220110801	杨霄	220110801	尤欣宇	220110820	李红橘	220110815	13	0.2702
sz220110326	谭名超	220110326	郭睿勉	220110312	黎俊	220110924	14	0.2669
sz220110724	陈彦至	220110724	谭皓文	220110623	谢诚豪	220110620	15	0.2654
sz220110930	杨越州	220110930	黄宇浩	220110415	刘子淇	220110923	16	0.2501
sz220110223	黄子洋	220110223	陶韬劼	220110929	唐潇萌	220110916	17	0.2483
sz220110805	林泳帆	220110805	闵睿凡	220110822	陈德毅	220110806	18	0.2209
sz220110214	朱泽恩	220110214	宋国豪	220110228	文飞扬	220110206	19	0.2082
sz220110722	蔡易轩	220110722	陈哲恺	220110731			20	0.1988
sz220110211	黄俊杰	220110211	何嘉峻	220110220	马浩钊	220110209	21	0.1976
sz220110728	张子晗	220110728	潘俊	220110829	陈宜登	220110524	22	0.1766
sz220111022	卢家鼎		张宸华		刘宇浩		23	0.1537

PART 04

结论

结论



优点

结果验证了我们提出的结合“经验池”与大语言模型进行动态学习的框架具有可行性。模型在处理复杂的、多维度的仇恨言论四元组抽取任务时，展现了一定的性能。

缺点

虽然模型能够生成反思经验，但这些经验的质量和泛化能力可能还不够高，有时可能生成了针对性过强或不够深刻的总结，导致其在指导新案例时的效果有限。

反思

在复杂的语义场景下，检索到的经验与当前问题的实际关联度可能存在偏差，从而引入噪声或提供了错误的引导。我们使用的deepseek-chat模型API本身的能力是框架性能的上限。尽管其表现优异，但在处理高度隐晦、反讽或包含复杂网络用语的仇恨言论时，仍可能出现理解偏差。

可能的优化

一个关键的优化方向在于提升“经验”本身的质量与深度。当前框架依赖大语言模型自我反思生成经验教训，未来的工作可以探索如何引导模型生成更具泛化能力、更为深刻的元知识，而不仅仅是针对单个错误样本的修正总结。这可能需要设计更复杂的反思提示，或者引入一个审核机制来过滤掉低质量、重复或过于具体的经验，确保沉淀到经验池中的是真正具有普适指导价值的智慧。

学习-反思-检索-应用

基础大语言模型能力

经验检索机制的精准性

提升“经验”本身的质量与深度

与之并行，经验检索机制的精准性也值得深入研究。目前系统采用基于文本向量相似度的方法来检索历史经验，但在面对语义模糊或结构独特的仇恨言论时，这种方式可能无法保证检索到的案例总能切中要害。可以探索更加精细化的检索策略，例如，将文本的结构特征、错误类型等信息也纳入索引，实现多维度的情境匹配，从而为模型提供关联性更强、更具参考价值的“先验知识”。



哈爾濱工業大學
HARBIN INSTITUTE OF TECHNOLOGY

2025年

感谢观看！
