



均方误差的分解

将预测模型 $\hat{f}(x)$ 的均方误差分解为偏差 (Bias) 的平方、方差 (Variance) 和噪声 (Noise) 三个部分。

$$\begin{aligned}
 MSE &= E[(y - \hat{f}(x))^2] \\
 &= E[(f(x) + \epsilon - \hat{f}(x))^2] \\
 &= E[((f(x) - \hat{f}(x)) + \epsilon)^2] \\
 &= E[(f(x) - \hat{f}(x))^2 + 2\epsilon(f(x) - \hat{f}(x)) + \epsilon^2] \\
 &= E[(f(x) - \hat{f}(x))^2] + 2E[\epsilon(f(x) - \hat{f}(x))] + E[\epsilon^2]
 \end{aligned}$$

由于 ϵ 与 $\hat{f}(x)$ 相互独立, 且 $E[\epsilon] = 0$, 因此 $2E[\epsilon(f(x) - \hat{f}(x))] = 2E[\epsilon]E[f(x) - \hat{f}(x)] = 2 \cdot 0 \cdot E[f(x) - \hat{f}(x)] = 0$ 。同时, $E[\epsilon^2] = \sigma^2$ 。

所以,

$$MSE = E[(f(x) - \hat{f}(x))^2] + \sigma^2$$

接下来, 对 $E[(f(x) - \hat{f}(x))^2]$ 这一项进行进一步分解。在其中引入 $E_D[\hat{f}(x)]$ (预测模型的期望值):

$$\begin{aligned}
 E[(f(x) - \hat{f}(x))^2] &= E[(f(x) - E_D[\hat{f}(x)] + E_D[\hat{f}(x)] - \hat{f}(x))^2] \\
 &= E[((f(x) - E_D[\hat{f}(x)])) + (E_D[\hat{f}(x)] - \hat{f}(x))]^2] \\
 &= E[(f(x) - E_D[\hat{f}(x)])^2 + 2(f(x) - E_D[\hat{f}(x)])(E_D[\hat{f}(x)] - \hat{f}(x)) + (E_D[\hat{f}(x)] - \hat{f}(x))^2] \\
 &= E[(f(x) - E_D[\hat{f}(x)])^2] + 2E[(f(x) - E_D[\hat{f}(x)])(E_D[\hat{f}(x)] - \hat{f}(x))] + E[(E_D[\hat{f}(x)] - \hat{f}(x))^2]
 \end{aligned}$$

由于 $f(x)$ 和 $E_D[\hat{f}(x)]$ 是确定的值 (对于给定的 x) , 它们可以从期望中提取出来。因此, 中间项为:

$$2(f(x) - E_D[\hat{f}(x)])E[E_D[\hat{f}(x)] - \hat{f}(x)] = 2(f(x) - E_D[\hat{f}(x)])(E_D[\hat{f}(x)] - E_D[\hat{f}(x)]) = 0$$

所以,

$$E[(f(x) - \hat{f}(x))^2] = (f(x) - E_D[\hat{f}(x)])^2 + E[(E_D[\hat{f}(x)] - \hat{f}(x))^2]$$

偏差 (Bias): $Bias(\hat{f}(x)) = E_D[\hat{f}(x)] - f(x)$

方差 (Variance): $Var[\hat{f}(x)] = E_D[(\hat{f}(x) - E_D[\hat{f}(x)])^2]$

将上述结果代回 MSE 的表达式，得到：

$$\begin{aligned} MSE &= (f(x) - E_D[\hat{f}(x)])^2 + E[(E_D[\hat{f}(x)] - \hat{f}(x))^2] + \sigma^2 \\ &= Bias(\hat{f}(x))^2 + Var[\hat{f}(x)] + \sigma^2 \end{aligned}$$

三层神经网络反向传播算法推导

$O_i = x_i$: 输入层第 i 个节点的输出等于输入特征 x_i ，其中 $i = 1, 2, \dots, n$ ， n 为输入特征的数量。

$I_j = \sum_{i=1}^n w_{ji}x_i$: 隐藏层第 j 个节点的输入是所有输入层节点输出的加权和，其中 w_{ji} 是输入层第 i 个节点到隐藏层第 j 个节点的权重， $j = 1, 2, \dots, m$ ， m 为隐藏层节点的数量。

$O_j = f(I_j)$: 隐藏层第 j 个节点的输出是其输入的激活函数 f 的结果。这里 f 是 sigmoid 函数， $f(x) = \frac{1}{1+e^{-x}}$ 。

$I_k = \sum_{j=1}^m w_{kj}O_j$: 输出层第 k 个节点的输入是所有隐藏层节点输出的加权和，其中 w_{kj} 是隐藏层第 j 个节点到输出层第 k 个节点的权重， $k = 1, 2, \dots, l$ ， l 为输出层节点的数量。

$O_k = f(I_k)$: 输出层第 k 个节点的输出是其输入的激活函数 f 的结果。

标函数 (损失函数):

对于单个样本，假设期望输出为 d_k ，实际输出为 $y_k (= O_k)$:

$$E = \frac{1}{2} \sum_k (d_k - y_k)^2$$

通过梯度下降法更新权重，使得损失函数最小化。对于输出层权重 w_{jk} ，其更新规则为：

$$w_{jk}(t+1) = w_{jk}(t) + \Delta w_{jk}$$

其中， $\Delta w_{jk} = -\eta \frac{\partial E}{\partial w_{jk}}$ ， η 是学习率。

计算梯度 $\frac{\partial E}{\partial w_{jk}}$:

$$\begin{aligned}
\frac{\partial E}{\partial w_{jk}} &= \frac{\partial E}{\partial O_k} \frac{\partial O_k}{\partial I_k} \frac{\partial I_k}{\partial w_{jk}} \\
&= -(d_k - y_k) \cdot f'(I_k) \cdot O_j \\
&= -\delta_k O_j
\end{aligned}$$

其中, $\delta_k = (d_k - y_k)f'(I_k)$ 是输出层第 k 个节点的误差项。

因此, 输出层权重的更新规则为:

$$w_{jk}(t+1) = w_{jk}(t) + \eta \delta_k O_j$$

将 $f'(I_k) = f(I_k)(1 - f(I_k)) = y_k(1 - y_k)$ 代入 δ_k , 得到:

$$\delta_k = (d_k - y_k)y_k(1 - y_k)$$

最终的输出层权重更新规则为:

$$w_{jk}(t+1) = w_{jk}(t) + \eta(d_k - y_k)y_k(1 - y_k)O_j$$

对于隐藏层权重 w_{ij} (输入层第 i 个节点到隐藏层第 j 个节点的权重), 其更新规则为:

$$w_{ij}(t+1) = w_{ij}(t) + \Delta w_{ij}$$

其中, $\Delta w_{ij} = -\eta \frac{\partial E}{\partial w_{ij}}$ 。

计算梯度 $\frac{\partial E}{\partial w_{ij}}$:

$$\frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial O_j} \frac{\partial O_j}{\partial I_j} \frac{\partial I_j}{\partial w_{ij}}$$

需要计算 $\frac{\partial E}{\partial O_j}$:

$$\begin{aligned}
\frac{\partial E}{\partial O_j} &= \sum_k \frac{\partial E}{\partial I_k} \frac{\partial I_k}{\partial O_j} \\
&= \sum_k \frac{\partial}{\partial I_k} \left(\frac{1}{2} (d_k - f(I_k))^2 \right) \frac{\partial}{\partial O_j} \left(\sum_{j'} w_{kj'} O_{j'} \right) \\
&= \sum_k -(d_k - y_k) f'(I_k) w_{kj} \\
&= \sum_k \delta_k w_{kj}
\end{aligned}$$

接下来计算 $\frac{\partial O_j}{\partial I_j}$ 和 $\frac{\partial I_j}{\partial w_{ij}}$:

$$\begin{aligned}
\frac{\partial O_j}{\partial I_j} &= f'(I_j) \\
\frac{\partial I_j}{\partial w_{ij}} &= \frac{\partial}{\partial w_{ij}} \left(\sum_{i'} w_{ji'} x_{i'} \right) = x_i = O_i
\end{aligned}$$

因此,

$$\begin{aligned}
\frac{\partial E}{\partial w_{ij}} &= \left(\sum_k \delta_k w_{kj} \right) f'(I_j) O_i \\
&= \delta_j O_i
\end{aligned}$$

其中, $\delta_j = f'(I_j) \sum_k \delta_k w_{kj} = O_j(1 - O_j) \sum_k \delta_k w_{kj}$ 是隐藏层第 j 个节点的误差项。

最终的隐藏层权重更新规则为:

$$\begin{aligned}
w_{ij}(t+1) &= w_{ij}(t) + \eta \delta_j O_i \\
&= w_{ij}(t) + \eta O_j(1 - O_j) \left(\sum_k \delta_k w_{kj} \right) O_i
\end{aligned}$$