

Lecture 8: Face Detection

Harbin Institute of Technology (Shenzhen)

Jingyong Su

sujingyong@hit.edu.cn



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Outline

1. Introduction

2. Face Detection Algorithm

- *PCA (Eigen Face)*
- *LDA (Fisher Face)*



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Face Detection



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Simple Approach

- Recognize faces (mug shots) using gray levels (appearance).
- Each image is mapped to a long vector of gray levels.
- Several views of each person are collected in the database during training.



Simple Approach

- During recognition a vector corresponding to an unknown face is compared with all vectors in the database.
- The face from database, which is closest to the unknown face is declared as a recognized face.



Problems and Solution

- Problems:
 - Dimensionality of each face vector will be very large (250,000 for a 512 X 512 image!)
 - Raw gray levels are sensitive to noise, and lighting conditions.



Problems and Solution

- Solution:
 - Reduce dimensionality of face space by finding principal components (Eigen vectors) to span the face space
 - Only a few most significant eigen vectors can be used to represent a face, thus reducing the dimensionality.



Outline

1. Introduction

2. Face Detection Algorithm

- **PCA (Eigen Face)**
- **LDA (Fisher Face)**

Belhumeur P N, Hespanha J P, Kriegman D J. Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997, 19(7): 711-720.



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN



PCA



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

动机

- 许多系统是多要素的复杂系统，多变量问题是经常会遇到的。变量太多，无疑会增加分析问题的难度与复杂性，而且在许多实际问题中，多个变量之间是具有一定的相性的。
- 人们会很自然地想到，能否在相关分析的基础上，用较少的新变量代替原来较多的旧变量，而且使这些较少的新变量尽可能多地保留原来变量所反映的信息？



背景

- 主成分分析(Principal Component Analysis, 简称PCA)是一种常用的基于变量协方差矩阵对信息进行处理、压缩和抽提的无监督学习方法。
- 主成分概念首先由 Karl Parson在1901年首先提出，当时只是对非随机变量来讨论的。1933年Hotelling将这个概念推广到随机变量，作了进一步发展。




简介

- 利用正交变换把由线性相关变量表示的观测数据转换为少数几个由线性无关变量表示的数据，线性无关的变量称为主成分。
- 主成分的个数通常小于原始变量的个数，所以主成分分析属于降维方法。
- 主成分分析主要用于发现数据中的基本结构，即数据中变量之间的关系。




举例

- 如果主成分分析只取第一主成分，即新坐标系的 y_1 轴，那么等价于将数据投影在椭圆长轴上，用这个主轴表示数据，将二维空间的数据压缩到一维空间中。



举例

- 假设有两个变量 x_1 和 x_2 ，三个样本点 A 、 B 、 C ，分布在由 x_1 和 x_2 轴组成的坐标系中
- 对坐标系进行旋转变换，得到新的坐标轴 y_1 （新的变量）
- 三个样本点在 y_1 轴上投影，得到 y_1 轴的坐标值 A' 、 B' 、 C'



举例

- $OA'^2 + OB'^2 + OC'^2$ 表示样本在变量 y_1 上的方差和
- 主成分分析旨在选取正交变换中 **方差最大** 的变量，作为第一主成分，也就是旋转变换中坐标值的平方和最大的轴
- $OA'^2 + OB'^2 + OC'^2$ 最大等价于样本点到 y_1 轴的距离的平方和 $AA'^2 + BB'^2 + CC'^2$ 最小
- 主成分分析在旋转变换中选取离样本点的距离平方和最小的轴，作为第一主成分。第二主成分等的选取，在 **保证与已选坐标轴正交的条件下**，类似地进行



主要性质

设 x 是 m 维随机变量, Σ 是 x 的协方差矩阵, Σ 的特征值分别是 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m \geq 0$, 特征值对应的单位特征向量分别是 $\alpha_1, \alpha_2, \dots, \alpha_m$, 则 x 的第 k 主成分是

$$y_k = \alpha_k^T x = \alpha_{1k}x_1 + \alpha_{2k}x_2 + \dots + \alpha_{mk}x_m, \quad k = 1, 2, \dots, m$$

x 的第 k 主成分的方差是

$$\text{var}(y_k) = \alpha_k^T \Sigma \alpha_k = \lambda_k, \quad k = 1, 2, \dots, m$$

即协方差矩阵 Σ 的第 k 个特征值



主成分的个数

- 第 k 主成分 y_k 的方差贡献率定义为 y_k 的方差与所有方差之和的比，记作 η_k

$$\eta_k = \frac{\lambda_k}{\sum_{i=1}^m \lambda_i}$$

- k 个主成分 $y_1, y_2, \dots, y_k$ 的累计方差贡献率定义为 k 个方差之和与所有方差之和的比

$$\sum_{i=1}^k \eta_i = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^m \lambda_i}$$

- 累计方差贡献率反映了主成分保留信息的比例，通常取 k 使得累计方差贡献率达到规定的百分比以上。



应用：人脸识别

数据集：CMU-PIE-face



训练集：8个人，每人12张照片（160*140）

测试集：8个人，每人12张照片



哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

应用：人脸识别-训练阶段

- **第一步**：训练集有96个样本，由灰度图组成，每个样本大小为 $M * N = 160 * 140 = 22400$ ，训练样本矩阵：

$$x = (x_1, x_2, \dots, x_{96})^T$$

- **第二步**：计算训练图片的平均脸

$$\Psi = \frac{1}{96} \sum_{i=1}^{i=96} x_i$$



应用：人脸识别-训练阶段

- **第三步**：计算差值脸，计算每一张人脸与平均脸的差值

$$d_i = x_i - \Psi, i = 1, 2, \dots, 96$$

- **第四步**：构建协方差矩阵

$$C = \frac{1}{96} \sum_{i=1}^{96} d_i d_i^T = \frac{1}{96} A A^T$$

$$A = (d_1, d_2, \dots, d_{96})$$



应用：人脸识别-训练阶段

- **第五步**：求协方差矩阵的特征值和特征向量，构造特征脸空间。根据特征值的贡献率选取前 p 个最大特征向量及其对应的特征向量。则“特征脸”空间为：

$$w = (u_1, u_2, \dots, u_p)$$

- **第六步**：将每一幅人脸与平均脸的差值脸矢量投影到特征脸空间，

$$\Omega_i = w^T d_i (i = 1, 2, \dots, 96)$$



应用：人脸识别-分类阶段


确定测试样本与哪一类的训练样本最近

- **第一步**：将待识别的人脸图像 Γ 与平均脸的差值脸投影到特征空间，得到其特征向量表示： $\Omega^\Gamma = w^T(\Gamma - \Psi)$
- **第二步**：将每一训练样本按照第一步的方式进行投影，求出每一类样本的平均脸
- **第三步**：找出距离待识别的人脸图像最近的类平均脸，将该平均脸的类别作为待识别的人脸图像的类别



应用：人脸识别-实验结果

分类准确率为71.9%



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN



KPCA






哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

背景：PCA的缺陷

PCA只适用于线性可分的数据集，对于非线性可分的效果较差。



Solution：将数据通过某个函数 ϕ 映射到高维空间，使得其线性可分，进而可使用PCA进行降维。



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

背景：PCA的缺陷

新的问题：映射到几维空间？怎样找到函数 ϕ ？

核函数可以解决这些问题



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

背景：KPCA的提出

- 核主成分分析 (Kernel Principal Component Analysis, KPCA) 于2002年由Ming-Hsuan Yang首次提出，通过利用核函数来解决人脸识别问题中的非线性可分的问题。

Ming-Hsuan Yang. Kernel Eigenfaces vs. Kernel Fisherfaces: Face recognition using kernel methods[C]// IEEE International Conference on Automatic Face & Gesture Recognition, 2002.



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

算法

核函数：可以直接得到低维数据映射到高维空间后的内积，而忽略具体的 ϕ

$$k(x, y) = \langle \phi(x), \phi(y) \rangle$$

常见核函数：

1. 线性核

$$k(x, y) = x^T y + c$$

2. 多项式核

$$k(x, y) = (ax^T y + c)^d$$

3. 高斯核

$$k(x, y) = \exp\left(-\frac{\|x-y\|^2}{2\sigma^2}\right)$$



算法

假设共有 n 个数据，每个数据维度为 m （数据已标准化）：

$$X = [x^{(1)}, x^{(2)}, \dots x^{(n)}]$$

经过函数 ϕ 映射后： $\phi(X) = [\phi(x^{(1)}), \phi(x^{(2)}), \dots \phi(x^{(n)})]$

则利用PCA时，需要计算的协方差矩阵为：

$$\frac{1}{n} \phi(X) \phi(X)^T$$

特征方程：

$$\frac{1}{n} \phi(X) \phi(X)^T \omega = \lambda \omega$$



算法

由于任一向量都可以由该空间中的所有样本线性表示：

$$\omega = \sum_{k=1}^n \alpha_k \phi(x^{(k)}) = \phi(X)\alpha, \text{ 其中 } \alpha = [\alpha_1, \alpha_2, \dots, \alpha_n]^T$$

则特征方程变为： $\frac{1}{n} \phi(X) \phi(X)^T \phi(X) \alpha = \lambda \phi(X) \alpha$

左乘 $\phi(X)^T$ ： $\frac{1}{n} \phi(X)^T \phi(X) \phi(X)^T \phi(X) \alpha = \lambda \phi(X)^T \phi(X) \alpha$

令 $K = \phi(X)^T \phi(X)$ ，则上式变为： $\frac{1}{n} K^2 \alpha = \lambda K \alpha$

即

$$K^2 \alpha = \lambda n K \alpha \quad \equiv \quad K \alpha = \lambda n \alpha$$

可以看出，该式为矩阵 K 对应的特征方程。



算法

矩阵 K 对应的特征方程： $K\alpha = \lambda n\alpha$


得到矩阵 K 以后，可以求出其对应的特征向量 α 。

继而可以直接得到原数据在经过 ω 的投影后的坐标值

$$\begin{aligned}\omega^T \phi(x^{(i)}) &= (\phi(X) \cdot \alpha)^T \phi(x^{(i)}) = \alpha^T \phi(X)^T \phi(x^{(i)}) \\ &= \alpha^T \begin{bmatrix} \phi(x^{(1)})^T \phi(x^{(i)}) \\ \phi(x^{(2)})^T \phi(x^{(i)}) \\ \vdots \\ \phi(x^{(n)})^T \phi(x^{(i)}) \end{bmatrix} = \alpha^T \begin{bmatrix} k(x^{(1)}, x^{(i)}) \\ k(x^{(2)}, x^{(i)}) \\ \vdots \\ k(x^{(n)}, x^{(i)}) \end{bmatrix}\end{aligned}$$



应用1：在非线性可分的数据上的降维效果




非线性可分的原始数据



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

应用1：在非线性可分的数据上的降维效果




经过PCA转换后的数据：两个类别无法区分



哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

应用1：在非线性可分的数据上的降维效果



经过KPCA转换后的数据：有较好的区分性



哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

应用2：人脸识别


数据集：Gpr13

训练集：41个人，每人8张照片 (70*80)

测试集：41个人，每个人2张照片 (70*80)

KPCA的准确率为95.1%

PCA的准确率为93.9%



哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LDA



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

背景

- 线性判别分析 (Linear Discriminant Analysis, LDA) , 于1936年由Ronald Fisher首次提出 , 因此也叫做Fisher线性判别 (Fisher Linear Discriminant, FLD) , 或者Fisher Discriminant Analysis (FDA)。
- 1997年由Belhumeur引入模式识别和人工智能领域。

[1] Fisher R A. The use of multiple measurements in taxonomic problems[J]. Annals of Eugenics, 1936.

[2] Belhumeur P N, Hespanha J P, Kriegman D J. Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection[J]. IEEE TPAMI, 1997.



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN



背景

- 将高维的模式样本投影到最佳鉴别矢量空间，以达到抽取分类信息和压缩特征空间维数的效果。
- 投影后保证模式样本在新的子空间有最大的类间距离和最小的类内距离，即模式在该空间中有最佳的可分离性。
- 因此，它是一种有效的特征抽取方法。使用这种方法能够使投影后模式样本的类间散布矩阵最大，并且同时类内散布矩阵最小。



算法

以二分类为例，LDA的目标是：投影到了一条直线之后，能够使得数据点尽量地按类别区分开（最大的类间距离和最小的类内距离）。



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

算法

PCA是一种**无监督**的降维方法；
主要是从特征的协方差角度，将数据投影到
方差最大的几个相互正交的方向上。



PCA

LDA是一种**有监督**的降维方法；
希望投影后不同类别之间数据点的距离更大，
同一类别的数据点更紧凑。



LDA



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

算法

- 数据： d 维样本，2个类别
- 用来区分二分类的直线（投影函数）为： $y = w^T x$
- 类别均值： $m_i = \frac{1}{n_i} \sum_{x \in D_i} x$
- 投影后的类别均值： $\tilde{m}_i = w^T m_i$
- 投影后，每个类别内数据样本之间的分散程度（方差）：

$$\tilde{s}_i^2 = \sum_{y \in Y_i} (y - \tilde{m}_i)^2$$



算法

- 目标：最大的类间距离和最小的类内距离
- 则有优化函数：

$$J(w) = \frac{|\tilde{m}_1 - \tilde{m}_2|^2}{\tilde{s}_1^2 + \tilde{s}_2^2}$$

- **分母**表示每一个类别内的方差之和，方差越小表示一个类别内的点越集中。（最小的类内距离）
- **分子**为两个类别各自的中心点的距离的平方，值越大表示两个类别越远。（最大的类间距离）



算法

- 定义计算各类别分散程度的 S_i : $S_i = \sum_{x \in D_i} (x - m_i)(x - m_i)^T$
- 则 $J(w)$ 分母化为 :

$$\tilde{s}_i^2 = \sum_{x \in D_i} (w^T x - w^T m_i)^2 = \sum_{x \in D_i} w^T (x - m_i)(x - m_i)^T w = w^T S_i w$$

$$\tilde{s}_1^2 + \tilde{s}_2^2 = w^T (S_1 + S_2) w = w^T S_W w$$

- S_W 为类内散度矩阵 : $S_W = S_1 + S_2$
- 分子化为 : $|\tilde{m}_1 - \tilde{m}_2|^2 = w^T (m_1 - m_2)(m_1 - m_2)^T w = w^T S_B w$
- S_B 为类间散度矩阵 : $S_B = (m_1 - m_2)(m_1 - m_2)^T$



算法

- 则有优化函数： $J(w) = \frac{w^T S_B w}{w^T S_W w}$
- 由拉格朗日乘子法：

$$c(w) = w^T S_B w - \lambda(w^T S_W w - 1)$$

$$\Rightarrow \frac{dc}{dw} = 2S_B w - 2\lambda S_W w = 0$$

$$\Rightarrow S_B w = \lambda S_W w$$

$$S_W^{-1} S_B w = \lambda w \quad \text{注：} w \text{ 的大小并不影响结果}$$



算法

$$S_W^{-1} S_B w = \lambda w$$

w 是矩阵 $S_W^{-1} S_B$ 的特征向量

又因为 $S_B w = (m_1 - m_2)(m_1 - m_2)^T w$,

$(m_1 - m_2)^T w$ 是一个标量

所以, $S_B w$ 与 $(m_1 - m_2)$ 同方向

令 $S_B w = \lambda_1 (m_1 - m_2)$, 且有 $S_B w = \lambda S_W w$, 则

$$w = S_W^{-1} (m_1 - m_2)$$

只要有散度矩阵和均值即可求出最优解



应用：人脸识别

数据集：CMU-PIE-face



训练集：8个人，每人12张照片 160*140

测试集：8个人，每个人12张照片，分类准确率达到100%




哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

应用：人脸识别

数据集2：CMU-PIE-face



训练集：9个人，每人15张照片 64*64

测试集：9个人，每个人15张照片，分类准确率达99.3%



哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN