

Lecture 10

Convolutional Neural Networks

Harbin Institute of Technology (Shenzhen)

Jingyong Su

sujingyong@hit.edu.cn



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

目录

- 一. CNN引入
- 二. CNN结构
- 三. CNN训练
- 四. CNN案例



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

全连接神经网络处理大尺寸图像具有三个明显的缺点：

- (1) 首先将图像展开为向量会丢失空间信息；
- (2) 其次参数过多效率低下，训练困难；
- (3) 同时大量的参数也很快会导致网络过拟合。





哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN



局部连接

- 输入： 1000×1000 的图像
- 全连接：如果隐藏层数目与输入层一样，那么输入层到隐含层的权值参数为 $1000 \times 1000 \times 10^6 = 10^{12}$ ，如此数目巨大的参数几乎难以训练；
- 局部连接：隐藏层的每个神经元仅与图像中 10×10 的局部图像相连接，权值参数数量为 $10 \times 10 \times 10^6 = 10^8$ ，将直接减少4个数量级。



权值共享

- 图像的一部分的统计特性与其他部分是一样的。意味着这一部分学习的特征也能用在另一部分上，所以对于这个图像上的所有位置，都能使用同样的学习特征。
- 隐藏层的每一个神经元连接的是一个 10×10 的局部图像，因此有 10×10 个权值参数，将这 10×10 个权值参数共享给剩下的神经元，也就是说隐藏层中 10^6 个神经元的权值参数相同，那么此时不管隐藏层神经元的数目是多少，需要训练的参数就是这 10×10 个权值参数（也就是卷积核(也称滤波器)的大小）。



卷积神经网络(Convolutional Neural Networks), 简称CNN。

- 属于一种特殊的多层神经网络
- 是一种前馈神经网络

卷积神经网络的核心思想是：

- 感受野(receptive field)
- 权值共享
- 下采样/降采样

三种结合起来获得了某种程度的位移、尺度、形变不变性。



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

目录

- 一. CNN引入
- 二. CNN结构
- 三. CNN训练
- 四. CNN案例



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

CNN 由3部分组成

卷积层


提取图像特征

池化层

降维、防止过拟合

全连接层

输出结果



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

卷积层 (Convolutional layer)

卷积神经网络中每层卷积层由若干卷积核(卷积单元)组成，每个卷积单元的参数都是通过反向传播算法优化得到的。

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0


Image

4		

Convolved
Feature



卷积层 (Convolutional layer)




哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

卷积层 (Convolutional layer)

多通道卷积核




哈尔滨工业大学(深圳)


HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

池化层 (Pooling layer)

通常在卷积层之后会得到维度很大的特征，为了进一步降低网络训练参数及模型的过拟合程度，将特征切成几个区域，取其最大值 (Max-Pooling) 或平均值 (Mean-Pooling)，得到新的、维度较小的特征。



Convolved
feature




Pooled
feature



池化层 (Pooling layer)

常用的池化操作



Feature Map

6	6	6	6
4	5	5	4
2	4	4	2
2	4	4	2

Max
Pooling

Average
Pooling

Sum
Pooling




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

全连接层-输出结果

经过卷积层和池化层降维过的数据，全连接层才能“跑得快”，不然数据量太大，计算成本高，效率低下。




哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet-5卷积神经网络模型

Yann LeCun在1998年设计的用于手写数字识别的卷积神经网络，是早期卷积神经网络中最有代表性的实验系统之一，共7层（不包括输入层）。



卷积层 - 池化层 - 卷积层 - 池化层 - 卷积层 - 全连接层



哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

目录

- 一. CNN引入
- 二. CNN结构
- 三. CNN训练
- 四. CNN案例



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

CNN参数优化—误差反向传播推导

与多层神经网络（DNN）不同

- 1) 池化层没有激活函数，可以令池化层的激活函数为 $\sigma(z)=z$ ，即激活后就是自己本身。这样池化层激活函数的导数为1。
- 2) 池化层在前向传播的时候，对输入进行了压缩，那么现在需要向前反向推导 δ^{l-1} ，这个推导方法和DNN完全不同。
- 3) 卷积层是若干个矩阵卷积求和而得的当前层的输出，这和DNN很不相同，DNN的全连接层是直接进行矩阵乘法得到当前层的输出。这样在卷积层反向传播的时候，上一层的 δ^{l-1} 递推计算方法肯定有所不同。
- 4) 对于卷积层，由于 W 使用的运算是卷积，那么从 δ^l 推导出该层的所有卷积核的 W, b 的方式也不同。



池化层误差反向传播

已知池化层的 δ^l ，推导出上一隐藏层的 δ^{l-1}

- 如果是**Max**，则把 δ^l 的各个池化局域的值放在之前做前向传播算法得到最大值的位置。
- 如果是**Average**，则把 δ^l 的各个池化局域的值取平均后放在还原后的子矩阵位置。这个过程一般叫做上采样（upsample）。

假设池化区域大小是2x2， δ^l 的第 k 个子矩阵为：

$$\delta_k^l = \begin{pmatrix} 2 & 8 \\ 4 & 6 \end{pmatrix}$$



池化层误差反向传播

- 如果是Max，假设之前在前向传播时记录的最大值位置分别是左上，右下，右上，左下，则转换后的矩阵为：

$$\begin{pmatrix} 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 8 \\ 0 & 4 & 0 & 0 \\ 0 & 0 & 6 & 0 \end{pmatrix}$$

- 如果是Average，则进行平均，转换后的矩阵为：

$$\begin{pmatrix} 0.5 & 0.5 & 2 & 2 \\ 0.5 & 0.5 & 2 & 2 \\ 1 & 1 & 1.5 & 1.5 \\ 1 & 1 & 1.5 & 1.5 \end{pmatrix}$$

- 由 $a^l = \sigma(z^l)$ ，得到 δ_k^{l-1} ：

$$\delta_k^{l-1} = \left(\frac{\partial a_k^{l-1}}{\partial z_k^{l-1}} \right)^T \frac{\partial J(W, b)}{\partial a_k^{l-1}} = \text{upsample}(\delta_k^l) \odot \sigma'(z_k^{l-1})$$

$$\delta^{l-1} = \text{upsample}(\delta^l) \odot \sigma'(z^{l-1})$$



卷积层误差反向传播

已知卷积层的 δ^l ，推导出上一隐藏层的 δ^{l-1}

卷积层的前向传播公式：

$$a^l = \sigma(z^l) = \sigma(a^{l-1} * W^l + b^l)$$

我们知道 δ^{l+1} 和 δ^l 的递推关系为：

$$\delta^l = \frac{\partial J(W, b)}{\partial z^l} = \left(\frac{\partial z^{l+1}}{\partial z^l} \right)^T \frac{\partial J(W, b)}{\partial z^{l+1}} = \left(\frac{\partial z^{l+1}}{\partial z^l} \right)^T \delta^{l+1}$$

注意到 z^l 和 z^{l-1} 的关系为：

$$z^l = a^{l-1} * W^l + b^l = \sigma(z^{l-1}) * W^l + b^l$$

因此有

$$\delta^{l-1} = \left(\frac{\partial z^l}{\partial z^{l-1}} \right)^T \delta^l = \delta^l * \text{rot180}(W^l) \odot \sigma'(z^{l-1})$$



卷积层误差反向传播

式子中的 $rot180()$ 表示卷积核被旋转了180度。而在DNN中只是矩阵的转置。

那么为什么呢？以一个简单的例子来说明。

假设我们 $l-1$ 层的输出 a^{l-1} 是一个 3×3 矩阵，第 l 层的卷积核 W^l 是一个 2×2 矩阵，采用1像素的步幅，则输出 z^l 是一个 2×2 的矩阵。我们简化 b^l 都是0，则有

$$a^{l-1} * W^l = z^l$$

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} * \begin{pmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{pmatrix} = \begin{pmatrix} z_{11} & z_{12} \\ z_{21} & z_{22} \end{pmatrix}$$

$$z_{11} = a_{11}w_{11} + a_{12}w_{12} + a_{21}w_{21} + a_{22}w_{22}$$

$$z_{12} = a_{12}w_{11} + a_{13}w_{12} + a_{22}w_{21} + a_{23}w_{22}$$

$$z_{21} = a_{21}w_{11} + a_{22}w_{12} + a_{31}w_{21} + a_{32}w_{22}$$

$$z_{22} = a_{22}w_{11} + a_{23}w_{12} + a_{32}w_{21} + a_{33}w_{22}$$

模拟反向求导有

$$\nabla a^{l-1} = \frac{\partial J(W, b)}{\partial a^{l-1}} = \left(\frac{\partial z^l}{\partial a^{l-1}} \right)^T \frac{\partial J(W, b)}{\partial z^l} = \left(\frac{\partial z^l}{\partial a^{l-1}} \right)^T \delta^l$$



卷积层误差反向传播

$$\nabla a^{l-1} = \frac{\partial J(W, b)}{\partial a^{l-1}} = \left(\frac{\partial z^l}{\partial a^{l-1}} \right)^T \frac{\partial J(W, b)}{\partial z^l} = \left(\frac{\partial z^l}{\partial a^{l-1}} \right)^T \delta^l$$

$$z_{11} = a_{11}w_{11} + a_{12}w_{12} + a_{21}w_{21} + a_{22}w_{22}$$

$$z_{12} = a_{12}w_{11} + a_{13}w_{12} + a_{22}w_{21} + a_{23}w_{22}$$

$$z_{21} = a_{21}w_{11} + a_{22}w_{12} + a_{31}w_{21} + a_{32}w_{22}$$

$$z_{22} = a_{22}w_{11} + a_{23}w_{12} + a_{32}w_{21} + a_{33}w_{22}$$

假设 z 矩阵对应的反向传播误差是 $\delta_{11}, \delta_{12}, \delta_{21}, \delta_{22}$ 组成的 2×2 矩阵，则可以分别写出 ∇a_{l-1} 的9个标量的梯度。

- 比如对于 a_{11} 的梯度，由于在4个等式中 a_{11} 只和 z_{11} 有乘积关系，从而有：

$$\nabla a_{11} = \delta_{11} w_{11}$$

- 对于 a_{12} 的梯度，由于在4个等式中 a_{12} 和 z_{12}, z_{11} 有乘积关系，从而有：

$$\nabla a_{12} = \delta_{11} w_{12} + \delta_{12} w_{11}$$



卷积层误差反向传播

同样的道理得到：

$$\nabla a_{13} = \delta_{12} w_{12}$$

$$\nabla a_{21} = \delta_{11} w_{21} + \delta_{21} w_{11}$$

$$\nabla a_{22} = \delta_{11} w_{22} + \delta_{12} w_{21} + \delta_{21} w_{12} + \delta_{22} w_{11}$$

$$\nabla a_{23} = \delta_{12} w_{22} + \delta_{22} w_{12}$$

$$\nabla a_{31} = \delta_{21} w_{21}$$

$$\nabla a_{32} = \delta_{21} w_{22} + \delta_{22} w_{21}$$

$$\nabla a_{33} = \delta_{22} w_{22}$$

用一个矩阵卷积的形式表示，即

$$\begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & \delta_{11} & \delta_{12} & 0 \\ 0 & \delta_{21} & \delta_{22} & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} * \begin{pmatrix} w_{22} & w_{21} \\ w_{12} & w_{11} \end{pmatrix} = \begin{pmatrix} \nabla a_{11} & \nabla a_{12} & \nabla a_{13} \\ \nabla a_{21} & \nabla a_{22} & \nabla a_{23} \\ \nabla a_{31} & \nabla a_{32} & \nabla a_{33} \end{pmatrix}$$

这个例子直观的介绍为什么对含有卷积的式子反向传播时，卷积核要翻转180度的原因。



CNN参数优化—梯度推导

现在已经可以递推出每一层的梯度误差 δ^l

- 对于全连接层，可以按DNN的反向传播算法求该层 W, b 的梯度
- 而池化层并没有 W, b , 也不用求梯度
- 只有卷积层的 W, b 需要求出



CNN参数优化—梯度推导

已知卷积层的 δ^l ，推导该层的 W, b 的梯度

- 卷积层 z 和 W, b 的关系为：

$$z^l = a^{l-1} * W^l + b$$

- 因此有：

$$\frac{\partial J(W, b)}{\partial W^l} = a^{l-1} * \delta^l$$

对于 b ，则稍微有些特殊，因为 δ^l 是高维张量，而 b 只是一个向量，不能像DNN那样直接和 δ^l 相等。通常的做法是将 δ^l 的各个子矩阵的项分别求和，得到一个误差向量，即为 b 的梯度：

$$\frac{\partial J(W, b)}{\partial b^l} = \sum_{u,v} (\delta^l)_{u,v}$$



目录

- 一. CNN引入
- 二. CNN结构
- 三. CNN训练
- 四. CNN案例




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Neocognitron, 1979

- root of CNN
- sliding-window features
- composing basic modules
- no backprop




Kunihiko Fukushima, "Neocognitron: A Self-organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position", 1980



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet, 1989





“Backpropagation applied to handwritten zip code recognition”, LeCun et al. 1989, “Gradient-based learning applied to document recognition”, LeCun et al. 1998



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet, 1989





“Backpropagation applied to handwritten zip code recognition”, LeCun et al. 1989, “Gradient-based learning applied to document recognition”, LeCun et al. 1998



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet, 1989





"Backpropagation applied to handwritten zip code recognition", LeCun et al. 1989, "Gradient-based learning applied to document recognition", LeCun et al. 1998



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet, 1989





"Backpropagation applied to handwritten zip code recognition", LeCun et al. 1989, "Gradient-based learning applied to document recognition", LeCun et al. 1998



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet, 1989





"Backpropagation applied to handwritten zip code recognition", LeCun et al. 1989, "Gradient-based learning applied to document recognition", LeCun et al. 1998



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet, 1989





“Backpropagation applied to handwritten zip code recognition”, LeCun et al. 1989, “Gradient-based learning applied to document recognition”, LeCun et al. 1998



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet, 1989



“Backpropagation applied to handwritten zip code recognition”, LeCun et al. 1989, “Gradient-based learning applied to document recognition”, LeCun et al. 1998



哈爾濱工業大學(深圳)


HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

AlexNet, 2012

The Deep Learning Revolution

Scaling up CNN

- data scaling
 - ImageNet, 1.28 million images, 1000 classes
- model scaling
 - “60 million parameters and 650,000 neurons”
- reducing overfitting
 - data augmentation
 - dropout
- GPU implementation



“ImageNet Classification with Deep Convolutional Neural Networks”, Krizhevsky, Sutskever, Hinton. NeurIPS 2012



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet vs. AlexNet

- deeper (more layers)
- wider (more channels)
- ReLU (not sigmoid)




figure inspired by: <https://en.wikipedia.org/wiki/LeNet>



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet vs. AlexNet

- deeper (more layers)
- wider (more channels)
- ReLU (not sigmoid)




figure inspired by: <https://en.wikipedia.org/wiki/LeNet>



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet vs. AlexNet

- deeper (more layers)
- **wider (more channels)**
- ReLU (not sigmoid)





figure inspired by: <https://en.wikipedia.org/wiki/LeNet>



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LeNet vs. AlexNet

- deeper (more layers)
- wider (more channels)
- **ReLU (not sigmoid)**




figure inspired by: <https://en.wikipedia.org/wiki/LeNet>



哈爾濱工業大學(深圳)


HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

VGG nets, 2014

Very deep CNN

- stack the same modules
 - conv: all 3x3
- very deep
 - 16 or 19 layers
- clear evidence: deeper is better
- **Composing basic operations into complex functions**

AlexNet vs. VGG-16



“Very Deep Convolutional Networks for Large-Scale Image Recognition”, Simonyan & Zisserman. ICLR 2015



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN