

Lecture 11

Sequence Modeling

Harbin Institute of Technology (Shenzhen)

Jingyong Su

sujingyong@hit.edu.cn



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Sequence Problems in Vision



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Video: Sequence of Images

- Video counterparts of 2D problems
 - classification, detection, segmentation, ...
- Video-specific problems
 - tracking, temporal reasoning, structure-from-motion, ...



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Vision-Language Problems

- pixels in, language out
 - captioning, visual question answering (VQA), reasoning, referring...




figure credit: https://github.com/yunjey/pytorch-tutorial/tree/master/tutorials/03-advanced/image_captioning



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Vision-Language Problems

- language in, pixels out
 - text-to-image, text-to-video, text-to-3D generation




figure credit: DALL-E




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Image as a Sequence

- Sequence of pixels (iGPT)



Chen et al., Generative Pretraining from Pixels, 2020




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Image as a Sequence

- Sequence of patches (ViT)



Dosovitskiy, et al., An Image is Worth 16x16 Words- Transformers for Image Recognition at Scale, arXiv 2020, ICLR 2021



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Seq2Seq Everywhere

one to one




image
classification

one to many






image captioning
object detection

many to one




video
classification

many to many



visual question answering, visual dialog
text-to-image, text-to-video generation, ...

many to many



<http://karpathy.github.io/2015/05/21/rnn-effectiveness/>



哈爾濱工業大學(深圳)


HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

目录

- 一. RNN
- 二. Encoder-Decoder机制
- 三. LSTM
- 四. Attention机制



序列数据：



例：自然语言处理很常见的问题-命名实体识别。

- I like eating apple.
- Apple is a tech company.

全连接的神经网络无法给apple做正确的分类，因为**没有结合上下文**去训练模型，而是单独的在训练apple这个单词的标签。




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

单层网络

在学习RNN（Recurrent Neural Network）之前，首先了解一下最基本的单层网络




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

经典的RNN结构 (N vs N)

为了建模序列问题，RNN引入了隐状态 h (hidden state) 的概念， h 可以对序列数据提取特征，接着再转换为输出。

- 先从 h_1 的计算开始看：




注：一个箭头就表示对该向量做一次变换。 h_0 和 x_1 分别有一个箭头连接，就表示对 h_0 和 x_1 各做了一次变换。




经典的RNN结构 (N vs N)

- h_2 的计算和 h_1 类似。要注意的是，在计算时，每一步使用的参数 U 、 W 、 b 都是一样的，也就是说每个步骤的参数都是共享的，这是RNN的重要特点。




经典的RNN结构 (N vs N)

- 依次计算剩下下来的 (使用相同的参数U、W、b)




经典的RNN结构 (N vs N)

- 目前的RNN还没有输出，输出可直接通过h进行计算



经典的RNN结构 (N vs N)

- 剩下的输出类似进行（使用和 y_1 同样的参数 V 和 c ）




最经典的RNN结构，其输入和输出序列必须要是等长的，
缺点是适用范围较小。



RNN结构 (N vs 1)



- 通常用来处理序列分类问题。如输入一段文字判别它所属的类别，输入一个句子判断其情感倾向，输入一段视频并判断它的类别等等。



RNN结构 (1 vs N)

- 从图像生成文字 (image caption)
- 从类别生成语音或音乐等

另一种结构是把X作为每个阶段的输入



RNN结构

- N vs N
- N vs 1
- 1 vs N
- N vs M?



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

目录

- 一. RNN
- 二. Encoder-Decoder模型
- 三. LSTM
- 四. Attention机制



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

RNN结构 (N vs M)


RNN最重要的一个变种：N vs M。这种结构又叫 Encoder-Decoder模型，也称为Seq2Seq模型，应用非常广泛。

- 机器翻译。Encoder-Decoder的最经典应用，事实上这一结构就是在机器翻译领域最先提出的。
- 文本摘要。输入是一段文本序列，输出是这段文本序列的摘要序列。
- 阅读理解。将输入的文章和问题分别编码，再对其进行解码得到问题的答案。
- 语音识别。输入是语音信号序列，输出是文字序列。
-



RNN结构 (N vs M)

Encoder-Decoder结构先将输入数据编码成一个上下文向量 c



得到 c 有多种方式

$$c = h_4$$

$$c = f(h_4)$$

$$c = f(h_1, h_2, h_3, h_4)$$




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN


RNN结构 (N vs M)

拿到 c 之后，就用另一个RNN网络对其进行解码，这部分被称为Decoder。具体做法就是将 c 当做之前的初始状态 h_0 输入到Decoder中。



RNN结构 (N vs M)

还有一种做法是将 c 当做每一步的输入



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

目录


- 一. RNN
- 二. Encoder-Decoder模型
- 三. LSTM
- 四. Attention机制



LSTM (Long Short Term Memory)

经典RNN：每一时刻的隐藏状态都不仅由该时刻的输入决定，还取决于上一时刻的隐藏层的值。如果一个句子很长，到句子末尾时，它将记不住这个句子的开头的内容详细内容。

(“长期依赖”)



LSTM通过它的“门控装置”有效的缓解了这个问题。




哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LSTM

RNN什么信息它都存下来，因为它没有挑选的能力



RNN单元




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LSTM

LSTM会选择性的存储信息，多了三个门

输入门，遗忘门，输出门



LSTM单元




哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LSTM


- 每个黄色方框表示一个神经网络层，由权值，偏置以及激活函数组成；
- 每个粉色圆圈表示元素级别操作；
- 箭头表示向量流向；相交的箭头表示向量的拼接；分叉的箭头表示向量的复制。



LSTM单元状态

LSTM的核心部分是最上边类似于传送带的部分，这一部分叫做单元状态 (cell state)，它自始至终存在于LSTM的整个链式系统中。


$$C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t$$



LSTM遗忘门 f_t

遗忘（保留）部分先前信息

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$



哈爾濱工業大學(深圳)


HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LSTM输入门 i_t

生成当前时刻新增信息

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LSTM输入门 i_t

结合两部分信息得到新记忆信息

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

LSTM输出门 o_t

$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$
$$h_t = o_t * \tanh(C_t)$$




目录

- 一. RNN
- 二. Encoder-Decoder模型
- 三. LSTM
- 四. Attention机制




Not feedforward:

step at time t must wait for all steps at time $< t$ to complete.
(not parallelism-friendly)




CNN

- limited context
- feedforward



RNN

- long context
- not feedforward



Attention

- long context
- feedforward



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Attention机制




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Attention机制

- 视觉系统就是一种Attention机制，将有限的注意力集中在重点信息上，从而节省资源，快速获得最有效的信息。




- 在听到一句话时，我们会不自觉的捕获关键信息。
比如：“**我**吃了**100**个**包子**”



Attention机制

Attention最早应用于计算机视觉，真正发扬光大是在自然语言处理，因为2018年BERT和GPT的效果出奇的好而走红。自此Transformer和Attention开始被重点关注。




哈尔滨工业大学(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Attention机制

- 在Encoder-Decoder结构中，Encoder把所有的输入序列都编码成一个统一的语义特征 c 再解码，因此， c 中必须包含原始序列中的所有信息，它的长度就成了限制模型性能的瓶颈。如机器翻译问题，当要翻译的句子较长时，一个 c 可能存不下那么多信息，就会造成翻译精度的下降。




- Attention机制通过在每个时间输入不同的 c 来解决这个问题。



Attention机制

- 带有Attention机制的Decoder




- 每一个c会自动去选取与当前输出最合适的上下文信息






Attention机制

- 具体来说，我们用 a_{ij} 衡量Encoder中第 j 阶段的 h_j 和解码时第 i 阶段的相关性，最终Decoder中第 i 阶段的输入的上下文信息 c_i 就来自于所有 h_j 对 a_{ij} 的加权和。以机器翻译为例（将中文翻译成英文）




Attention机制

- 这些权重 a_{ij} 是怎么来的？
- 从模型中学的，它实际和Decoder的第 $i-1$ 阶段的隐状态、Encoder第 j 个阶段的隐状态有关。



Self-Attention


不是输入和输出之间的Attention机制，而是输入内部元素之间或者输出内部元素之间发生的。



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Self-Attention




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

Self-Attention

Encoding




哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN


Sequence Modeling

Not feedforward:
step at time t must wait for
all steps at time $< t$ to
complete.
(not parallelism-friendly)




CNN

- limited context
- feedforward



RNN

- long context
- not feedforward



Attention

- long context
- feedforward