

机器学习

第二章 概念学习和一般到特殊序 Concept Learning and The General- to-specific Ordering

主要内容

- 概念及概念学习
- 假设、假设空间、实例空间定义
- 假设空间中的一般到特殊偏序结构
- 变型空间和候选消除算法
- 归纳偏置及无偏学习的无用性

2.1 简介

- 概念

- 每个概念可被看作对象或事件的集合，它是一个大集合子集，或者是在这个大集合中定义的布尔函数
- IsBird(animal)

- 概念学习

- 概念学习是指从有关某个布尔函数的训练样例中推断出该布尔函数

2.2 概念学习任务

- 示例
 - 目标概念: “Aldo进行水上运动的日子”
 - EnjoySport(day)
 - 任务: 基于某日的天气属性, 预测该天EnjoySport的值

表2-1 目标概念EnjoySport的正例和反例

Example	Sky	AirTemp	Humidity	Wind	Water	Forecast	EnjoySport
1	Sunny	Warm	Normal	Strong	Warm	Same	Yes
2	Sunny	Warm	High	Strong	Warm	Same	Yes
3	Rainy	Cold	High	Strong	Warm	Change	No
4	Sunny	Warm	High	Strong	Cool	Change	Yes

Sky有三个属性值，其余属性有两个属性值

• 假设 (Hypothesis)

– 理解假设

- 假设是问题的一个可能解，是基于输入数据进行预测的函数或数学模型，它是对输入（特征）和输出（目标）之间关系的猜测。
- 机器学习算法会尝试不同的假设，直到找到最适合训练数据的假设。
- 本章指概念, 布尔函数

– 假设的表示

- 一般表示为函数
- 本章：实例的各属性约束的合取式 (conjunction) (偏置?)
- 约束取值（属性值）可以是：
 - 特定值：例如 $Water=Warm$
 - 接受任意值：例如 $Water=?$
 - 不接受任何值：例如 $Water=\emptyset$

– 假设示例: h (布尔函数)

Sky	Temp	Humid	Wind	Water	Forecast
< Sunny	?	?	Strong	?	Same >

<?, ?, ?, ?, ?, ?> // 每一天都是正例

< ϕ , ϕ , ϕ , ϕ , ϕ , ϕ > // 每一天都是反例

语法不同, 语义相同的假设:

< ϕ , warm, high, weak, cool, same>

< ϕ , ϕ , high, weak, cool, same>

<sunny, cold, normal, strong, warm, ϕ >

EnjoySport概念学习任务

已知:

- 实例集 **X**: 日子集合, 由 *Sky, Temp, Humidity, Wind, Water, Forecast* 六个属性描述每个日子
- 假设集 **H**: 每一个 **h** 定义为六个属性的值约束的合取, 例如
 < Sunny ? ? Strong ? Same >
- 训练样例集 **D**: 目标函数的正例和反例: $(x_1, c(x_1)), \dots, (x_n, c(x_n))$
- 目标概念 **c**: **EnjoySport** $X \rightarrow \{0, 1\}$

求解:

- H 中的一个假设 **h**, 使对于 X 中任意 **x**, $h(x) = c(x)$

2.2.1 术语定义

- 实例: x
- 实例集合: X
- 目标概念: c
- 训练样例: x
- 训练样例集合: D
- 正例: $c(x)=1$
- 反例: $c(x)=0$
- 假设: h
- 所有可能假设的集合: H

目标：寻找一个假设 h ，使对于 X 中的所有 x , $h(x)=c(x)$


2.2.2 归纳学习假设

- 归纳学习
 - 从样例中获取普遍规律
 - 只保证输出假设在训练数据上符合目标概念
- 归纳学习假设（Assumption 假定）
 - 任一假设如果在足够大的训练样例集中很好地逼近目标函数，它也能在未见实例中很好地逼近目标函数

2.3 作为搜索的概念学习

- 概念学习可以看作是一个搜索的过程
 - 搜索空间：由假设表示所定义的所有假设组成的空间
例：< Sunny,?,?,Strong,?,?> , < Sunny,?,?,?,?,?,?>⋯..
 - 目标：寻找能最好地拟合训练样例的假设
 - 让尽可能多的训练实例 x 满足, $h(x)=c(x)$

- 理解假设的空间，实例空间和学习程序之间的关系
 - EnjoySport的假设空间：所有可能的函数集合
 - 实例空间：全部样本集合
 - 假设空间与实例空间关系：
 - 一个假设对应一个实例子集，使得 $h(x)=1$
 - 不同的实例： $3*2*2*2*2*2 = 96$
 - Sky: Sunny, Cloudy, Rainy
 - AirTemp: Warm, Cold
 - Humidity: Normal, High
 - Wind: Strong, Weak
 - Water: Warm, Cold
 - Forecast: Same, Change
- 不同的假设(概念): 依实例空间定义有 2^{96}
- 依本章假设表示，假设空间中语法不同的假设: $5*4*4*4*4*4=5120$
- 假设空间中语义不同的假设: $1+4*3*3*3*3*3=973$
- 学习程序：对假设空间进行搜索，找到一个或多个 h ，使得 $h(x)=c(x)$, x 为训练样本



2.3.1 假设的一般到特殊序


- 考虑以下两个假设:
 - $h_1 = \langle \text{Sunny}, ?, ?, \text{Strong}, ?, ? \rangle$
 - $h_2 = \langle \text{Sunny}, ?, ?, ?, ?, ? \rangle$
 - 哪些实例可被 h_1 、 h_2 分类为正例呢?
 - h_2 包含的实例约束较少，它分类出的正例也较多 ($h(x)=1$)

- 偏序关系 **more_general_than_or_equal_to**
 - 满足(satisfy):
 - 对任意实例x和假设h, 当且仅当 $h(x) = 1$ 时x满足h
 - $x=(\text{sunny, cold, high, weak, cold, change})$ 满足 $h_2=< \text{Sunny},?, ?, ?, ?, ?>$
 - 偏序关系**more_general_than_or_equal_to**的定义:
 - 令 h_j 和 h_k 为在 X 上定义的布尔函数, 称 h_j 是**more general than or equal to** h_k , 当且仅当
$$\forall x \in X : [(h_k(x) = 1) \rightarrow (h_j(x) = 1)]$$
 - 记作 h_j **more_general_than_or_equal_to** h_k , 或者 $h_j \geq_g h_k$


- “ $\geq$ ” 这个关系定义了假设空间H上的一个偏序
(偏序: 自反, 反对称, 传递)
- more_general_than(严格一般)定义:
 - $h_j >_g h_k$, 当且仅当, $(h_j \geq_g h_k) \wedge \neg (h_k \geq_g h_j)$
- More_specific_than
 - $h_j \leq_g h_k$, 当且仅当, $h_k \geq_g h_j$

more_general_than 示例

实例空间



假设空间



特殊



一般

$x_1 = (\text{Sunny}, \text{Warm}, \text{High}, \text{Strong}, \text{Cool}, \text{Same})$

$x_2 = (\text{Sunny}, \text{Warm}, \text{High}, \text{Light}, \text{Warm}, \text{Same})$

$h_2 \geq h_1$

$h_2 \geq h_3$

$h_1 = \langle \text{Sunny}, ?, ?, \text{Strong}, ?, ? \rangle$

$h_2 = \langle \text{Sunny}, ?, ?, ?, ?, ? \rangle$

$h_3 = \langle \text{Sunny}, ?, ?, ?, \text{Cool}, ? \rangle$

2.4 Find-S: 寻找极大特殊假设


- 原理
 - 使用 `more_general_than` 偏序关系，搜索与训练样例相一致的假设
 - 从H中最特殊假设开始，当该假设覆盖正例失败时将其一般化（泛化）
 - 最特殊的假设是哪个？
 - $= \langle \emptyset, \emptyset, \emptyset, \emptyset, \emptyset, \emptyset, \rangle$
 - 为什么Find-S 输出的是极大特殊假设？
 - 最初所有实例都为反例，只针对正例进行最小泛化，所以覆盖的正例范围最小

Find-S 算法


1. 将h初始化为H中最特殊假设
2. 对每个正例 x
 - 对h的每个属性约束 a_i
 - 如果 x 满足 a_i
 - 那么 不做任何处理
 - 否则 将h中 a_i 替换为满足 x 的下一个更一般 (the next more general) 约束
3. 输出假设 h
 - 注意：对反例， h 不做任何改变 （为什么？）
 - 最初所有实例都为反例，只针对正例进行最小泛化，只要训练数据正确， h 会与所有训练反例一致

Find-S的假设空间搜索


实例空间



假设空间(假设空间具有层次结构)



特殊



一般

$x_1 = (\text{Sunny}, \text{Warm}, \text{Normal}, \text{Strong}, \text{Warm}, \text{Same}) +$

$x_2 = (\text{Sunny}, \text{Warm}, \text{High}, \text{Strong}, \text{Warm}, \text{Same}) +$

$x_3 = (\text{Rainy}, \text{Cold}, \text{High}, \text{Strong}, \text{Warm}, \text{Change}) -$

$x_4 = (\text{Sunny}, \text{Warm}, \text{High}, \text{Strong}, \text{Cool}, \text{Change}) +$

$h_0 = \langle \emptyset, \emptyset, \emptyset, \emptyset, \emptyset, \emptyset, \rangle$

$h_1 = \langle \text{Sunny}, \text{Warm}, \text{Normal}, \text{Strong}, \text{Warm}, \text{Same} \rangle$

$h_{2,3} = \langle \text{Sunny}, \text{Warm}, ?, \text{Strong}, \text{Warm}, \text{Same} \rangle$

$h_4 = \langle \text{Sunny}, \text{Warm}, ?, \text{Strong}, ?, ? \rangle$

Find-S的特点

- 假设空间为属性约束的合取式
- Find-S 保证输出H中与正例一致的最特殊的假设
- 只要目标概念包含在H中，并且训练数据都是正确的，最终的假设也与所有反例一致

Find-S 的问题

- 学习是否收敛到了正确的目标概念
 - 没办法确定它是否找到了唯一合适的假设，或者说是否还有其他可能的假设
- 训练样例是否相互一致（忽略了所有反例）
- 为什么要用最特殊的假设？
- 如果有多个极大特殊假设怎么办？



2.5 变型空间和候选消除算法

Version Spaces and the Candidate-Elimination Algorithm

- 候选消除算法 (Candidate-Elimination Algorithm) VS Find-S
 - **Find-S** 输出的假设只是H中能够拟合训练数据的一个假设
 - **候选消除算法**输出的是与训练样例一致的所有假设的集合
 - **候选消除算法**在描述这一集合时不需要明确列举其**所有成员**
 - 这归功于 `more_general_than` 偏序结构
 - **Find-S** 和**候选消除算法** 对噪声数据敏感



2.5.1 变型空间表示

- 一致的定义 (Consistent)
 - 一个假设 h 与训练样例集合 D 一致，当且仅当对 D 中每一个样例 $\langle x, c(x) \rangle$ 都有 $h(x) = c(x)$
$$\text{Consistent}(h, D) \Leftrightarrow (\forall \langle x, c(x) \rangle \in D) \quad h(x) = c(x)$$
 - 一致和满足的区别
- 变型空间 (Version Space)
 - 与训练样例一致的所有假设构成的集合
 - 包含了目标概念的所有合理的变型
 - 定义:
 - 关于假设空间 H 和训练样例集 D 的变型空间，标记为 $VS_{H,D}$ ，是 H 中与训练样例集 D 一致的所有假设构成的子集

$$VS_{H,D} = \{h \in H \mid \text{Consistent}(h, D)\}$$


2.5.2 列表后消除算法

- 列表后消除算法：枚举出所有与训练样本一致的假设来表示 VS
 1. 变型空间 $\leftarrow H$ 中所有假设
 2. 对每个训练样例 $(x, c(x))$
从变型空间中移除所有 $h(x) \neq c(x)$ 的假设 h
 3. 输出变型空间中的假设列表
- 优点
 - 保证得到所有与训练数据一致的假设
- 缺点
 - 要求枚举出 H 中所有假设

2.5.3 变型空间的更简洁表示

- 一种更简洁的表示
 - 变型空间用极大一般和极大特殊假设表示
 - 这些假设形成了一般和特殊边界，这些边界在整个偏序结构中划分出变型空间
 - EnjoySport 的例子

变型空间示例



$x_1 = (\text{Sunny Warm Normal Strong Warm Same}) +$
 $x_2 = (\text{Sunny Warm High Strong Warm Same}) +$
 $x_3 = (\text{Rainy Cold High Strong Warm Change}) -$
 $x_4 = (\text{Sunny Warm High Strong Cool Change}) +$

- 一般边界, G , 是在 H 中与 D 相一致的极大一般成员的集合

$$G = \{g \in H \mid \text{Consist}(g, D) \text{ and } (\neg \exists g' \in H) [(\exists g' > g) \text{ and } \text{Consist}(g', D)]\}$$

- 特殊边界, S , 是在 H 中与 D 相一致的极大特殊成员的集合

$$S = \{s \in H \mid \text{Consist}(s, D) \text{ and } (\neg \exists s' \in H) [(\exists s > s') \text{ and } \text{Consist}(s', D)]\}$$

- 变型空间表示定理

– 每一个变型空间内的成员都在这两个边界之间

$$VS_{H,D} = \{h \in H \mid (\exists s \in S) (\exists g \in G) (g \geq h \geq s)\}$$

$x \geq y$ 表示 x 比 y 更一般

– (证明)

- (1) 每一个满足上式的 h 都在 $VS_{H,D}$ 中
- (2) $VS_{H,D}$ 的每个成员都满足等式 (反证)

2.5.4 候选消除学习算法

$G \leftarrow H$ 中最一般的假设

$S \leftarrow H$ 中最特殊的假设

对每个训练样例 $d=(x,c(x))$

如果 d 是一正例

从 G 中移去所有与 d 不一致的假设

对 S 中每个与 d 不一致的假设 s

- 从 S 中移去 s
- 把 s 的所有极小泛化式 h 加入到 S 中，其中 h 满足
 - h 与 d 一致，而且 G 的某个成员比 h 更一般
- 从 S 中移去所有这样的假设：它比 S 中另一假设更一般


如果d是一个反例

从S中移去所有与d不一致的假设


对G中每个与d不一致的假设g

- 从G中移去g
- 把g的所有的极小特殊化式h加入到G中，其中h满足
 - h与d一致，而且S的某个成员比h更特殊
- 从G中移去所有这样的假设：它比G中另一假设更特殊

- g 的极小特殊化（从实例空间分析）



- s 的极小一般化（从实例空间分析）



2.5.5 算法的举例

S: ~~$\{\langle \emptyset, \emptyset, \emptyset, \emptyset, \emptyset, \emptyset \rangle\}$~~

G: $\{\langle ?, ?, ?, ?, ?, ? \rangle\}$

$x_1 = (\text{Sunny Warm Normal Strong Warm Same}) +$

S: ~~$\{\langle \text{Sunny Warm Normal Strong Warm Same} \rangle\}$~~

G: $\{\langle ?, ?, ?, ?, ?, ? \rangle\}$

$x_2 = (\text{Sunny Warm High Strong Warm Same}) +$

S: $\{\langle \text{Sunny Warm ? Strong Warm Same} \rangle\}$

G: $\{\langle ?, ?, ?, ?, ?, ? \rangle\}$

算法的举例

S: {< Sunny Warm ? Strong Warm Same >}

G: {<?, ?, ?, ?, ?, ?>}

$x_3 = (\text{Rainy Cold High Strong Warm Change}) -$

S: {< Sunny Warm ? Strong Warm Same >}

G: {<Sunny,?, ?, ?, ?, ?, ?>, <?, Warm, ?, ?, ?, ?>, <?, ?, ?, ?, ? Same>}

$x_4 = (\text{Sunny Warm High Strong Cool Change}) +$


S: {< Sunny Warm ? Strong ? ? >}

G: {<Sunny,?, ?, ?, ?, ?, ?>, <?, Warm, ?, ?, ?, ?> }

2.6 关于变型空间和候选消除算法的说明

- 候选消除算法是否会收敛到正确的假设?
 - 在训练样例中没有错误
 - H 包含目标概念（目标假设 c ）
- 如果训练数据中包含错误
 - 如果给定足够的训练数据，最终，我们会发现 S 和 G 的边界收敛得到一个空的变型空间
- 目标概念不能由假设表示方式所描述
 - 类似

- 需要什么样的训练样例？
 - 每个新样例使变型空间的大小減半，目标概念只用 $\log_2|VS|$ 次训练后得到



$x_1 = (\text{Sunny Warm Normal Light Warm Same})$

- 怎样使用不完全学习概念
 - 目标概念虽未完全学习到，但可对新样例进行可信度分类
 - 例子 2.6

A = (Sunny Warm Normal Strong Cool Change) +
B = (Rainy Cold Normal Light Warm Same) -
C = (Sunny Warm Normal Light Warm Same) +-
D = (Sunny Cold Normal Strong Warm Same) 2+4-

2.7 归纳偏置

- 候选消除算法的问题
 - 如果目标概念不在假设空间中怎么办
 - 是否可设计一个包含**所有**假设的空间来解决
 - 假设空间的大小对于算法**推广到**未见实例的能力有什么影响
 - 假设空间的大小**对所需训练样例的数量**有什么影响

2.7.1 一个有偏的假设空间

- 前述假设空间不能表示析取形式的目标概念:

$$(\text{Sky}=\text{Sunny}) \vee (\text{Sky}=\text{Cloudy})$$

$x_1 = (\text{Sunny Warm Normal Strong Cool Change}) +$

$x_2 = (\text{Cloudy Warm Normal Strong Cool Change}) +$

$S : \{ \langle ?, \text{Warm}, \text{Normal}, \text{Strong}, \text{Cool}, \text{Change} \rangle \}$

$x_3 = (\text{Rainy Warm Normal Strong Cool Change}) -$



$S : \{ \}$

2.7.2 无偏的学习器

- Idea: H能表达所有可教授的概念, 换言之, 它能够表达实例集X的所有可能的子集, 称之为X的幂集(the power set $P(X)$)
 - $|X|=96$, $|P(X)|=2^{96} \sim 10^{28}$ 不同的概念
 - H 包含析取, 合取和否定式
 - 例如 <Sunny Warm Normal ? ? ?> or <Sunny or cloudy ? ? ? ? Change>
 - H 肯定包含目标概念

- 会学习到怎样的S和G?
 - 假定三个正例 (x_1, x_2, x_3) 和 两个负例 (x_4, x_5)
 - $S : \{ \langle x_1 \vee x_2 \vee x_3 \rangle \}$, $G : \{ \neg \langle x_4 \vee x_5 \rangle \}$
 - 唯一可被分类的样例就是训练样例本身. (为什么?)
 - 每一个未见实例都会被变型空间中刚好半数的假设划分为正例, 而被另一半划分为反例
 - 想要学得目标概念, 就必须提供X中所有的实例作为训练样例

在实例空间分析无偏学习



- EnjoySport : 用无偏假设空间学习
 - 无法泛化到未见样例
 - 为了收敛到一个单一的、最终的目标概念，
必须将 X 中的每一个实例作为一个训练样例

2.7.3 无偏学习的无用性

- 归纳推理的基本属性:

学习器如果不对目标概念的形式做预先的假定，它从根本上无法对未见实例进行分类

- 归纳学习需要某种形式的预先假定，称为归纳偏置（非精确定义）

- 归纳推理
 - $(D_c \wedge x_i) \rightarrow L(x_i, D_c)$
 - $L(x_i, D_c)$ 结果的正确性无法证明
 - 如何证明(演绎派生, $\vdash$):引入附加前提, 即归纳偏置

- 归纳偏置的精确定义:

已知:

- 概念学习算法 L
- 实例 X , 目标概念 c
- 训练样例 $D_c = \{ \langle x, c(x) \rangle \}$
- 让 $L(x_i, D_c)$ 表示 L 赋予实例 x_i 的分类



定义:

L 的归纳偏置是最小断言集合 B , 它使任意目标概念 c 和相应的训练样例 D_c 满足

$$(\forall x_i \in X)[B \wedge D_c \wedge x_i] \vdash L(x_i, D_c)$$

这里 $y \vdash z$ 代表 z 从 y 演绎派生.

归纳系统和等价演绎系统



- 候选消除算法的归纳偏置
 - $\{c \in H\}$ (为什么? 证明 $L(x_i, D_c) = c(x_i)$)
- 三种有不同偏置的学习算法
 - 机械式学习器(Rote learner): 存储样例, 当且仅当它与先前观察到的示例匹配时, 对 x 进行分类。
 - 没有偏置
 - 候选消除算法
 - 偏置: 假设空间包含目标概念
 - Find-S
 - 偏置: 假设空间包含目标概念, 任何实例, 除非它的逆实例可由其他知识逻辑推出, 否则它为反例

- 算法有偏性越强，它的归纳能力越强，可以分类更多的未见实例
- 不同形式的归纳偏置：
 - 对类别的假定，以确定目标概念的范围
 - 对假设进行排序，以描述偏好程度
 - 隐含在学习器中不可更改

- 作业： 2.6