

机器学习


第三章 决策树学习

主要内容

- 决策树的定义与表示
- ID3算法
- 决策树学习的归纳偏置
- 决策树的扩展与优化

3.1 简介

- 决策树学习简介
 - 逼近离散值函数的一种方法
 - 可以用if-then 规则进行表示
 - 广泛的应用到许多领域




3.2 决策树的表示

• 决策树

- 通过从根节点到叶节点对实例进行排序从而实现分类
- 叶子节点提供分类
- 每个节点指定一种属性
- 每个分支都对应一个属性值
- 决策树可以表示对属性约束的合取的析取

打网球的决策树例子




- Fig. 3.1: 属性约束的合取的析取

$(\text{Outlook}=\text{Sunny} \wedge \text{Humidity}=\text{Normal})$


✓ $(\text{Outlook}=\text{Overcast})$

✓ $(\text{Outlook}=\text{Rain} \wedge \text{Wind}=\text{Weak})$




决策树的合取

Outlook=Sunny $\wedge$ Wind=Weak




决策树的析取

Outlook=Sunny $\vee$ Wind=Weak




决策树的异或

Outlook=Sunny XOR Wind=Weak



3.3 决策树学习的适用问题

- 具有以下特征的问题
 - 实例由属性-值对表示
 - 目标函数具有离散输出值
 - 可能需要析取描述
 - 训练数据可能包含错误
 - 训练数据可能包含缺失的属性值
- 分类问题：把实例识别为离散的可能类别
 - 疾病分类
 - 信用卡风险分析
 - 设备故障分类



3.4 决策树学习算法

- 大多数算法都是一个核心算法的变体
- 采用自顶向下的贪婪搜索遍历搜索空间
- ID3(Quinlan 1986) C4.5(Quinlan 1993)

- ID3

自顶向下构造决策树

使用统计测试评估每个属性，以确定它单独分类训练示例的能力

选择最好的属性作为树的根节点

为该属性的每个可能值创建一个分支

训练样例按属性值分流到后续节点

重复以上过程

ID3 算法


ID3(Examples, Target_attribute, Attributes)

- 创建树的根节点Root
- 如果Examples都是正例，则返回label=+的单节点树Root
- 如果Examples都是反例，则返回label=-的单节点树Root
- 如果Attributes为空，则返回单节点树Root，label= Examples中最普遍的Target_attribute值
- 否则 开始
 - $A \leftarrow$ Attributes中分类Examples能力最好的属性
 - Root的决策属性 $\leftarrow A$
 - 对A的每一个可能属性值 v_i
 - 在Root下面添加一个新的分支，对应测试 $A=v_i$
 - 令 $Examples_{v_i}$ 为Examples中满足A属性值为 v_i 的子集
 - 如果 $Examples_{v_i}$ 为空
 - 在这个新分支下加一个叶子结点，结点的label= Examples中最普遍的Target_attribute值
 - 否则在新分支下添加子树
ID3 ($Examples_{v_i}$, Target_attribute, Attributes- $\{A\}$)
- 结束
- 返回Root

3.4.1 哪些属性是最佳的分类属性

- 信息增益
 - 度量某个属性分类训练样例的能力
 - ID3使用信息增益从候选属性中选择属性

- 熵度量样例的均一性
 - 描述样例集合的纯度
 - 集合S对布尔型分类的熵:



$$\text{Entropy}(S) = -(p^+) \log_2(p^+) - (p^-) \log_2(p^-)$$

- 一般来说，如果目标属性有c个不同的值

$$\text{Entropy}(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

- 从信息理论角度理解熵:
 - 确定了编码S中任意成员的类别所需的最小位数
 - Entropy(S)=对S中随机抽取的成员类别(在最优、最短长度码下)进行编码所需的期望比特数


为什么?

- 信息论最优长度编码:
 - $(-\log_2 p)$ 比特, p 为S中成员类别出现的概率
 - S中的随机抽取的成员的类别(c类)编码期望比特数:

$$\text{Entropy}(s) = \sum_{i=1}^c -p_i \log_2 p_i$$

Example

choice_i	p_i	encoding
"A"	1/3	11
"B"	1/2	0
"C"	1/12	100
"D"	1/12	101



High probability,
Less information

Low probability,
More information

010011011101
B C A B A D

Entropy: $H(X) = 1.626$ bits


Expected length of this encoding:

$$(2)(1/3) + (1)(1/2) + (3)(1/12)(2) = 1.667 \text{ bits}$$


- **信息增益**是根据某属性对样本集合进行划分所导致的期望熵降低

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

- **Gain(S,A)**是用属性**A**的值划分**S**所引起的期望熵的降低




Low information gain High entropy



High information gain Low entropy

信息增益计算实例



$$\begin{aligned}\text{Entropy}([29+, 35-]) &= -29/64 \log_2 29/64 - 35/64 \log_2 35/64 \\ &= 0.99\end{aligned}$$



信息增益计算实例

- $\text{Entropy}([21+, 5-]) = 0.71$
- $\text{Entropy}([8+, 30-]) = 0.74$
- $\text{Gain}(S, A_1) = \text{Entropy}(S)$
- $-26/64 * \text{Entropy}([21+, 5-])$
- $-38/64 * \text{Entropy}([8+, 30-])$
- $= 0.27$


$$\begin{aligned} \text{Entropy}([18+, 33-]) &= 0.94 \\ \text{Entropy}([11+, 2-]) &= 0.62 \\ \text{Gain}(S, A_2) &= \text{Entropy}(S) \\ &\quad - 51/64 * \text{Entropy}([18+, 33-]) \\ &\quad - 13/64 * \text{Entropy}([11+, 2-]) \\ &= 0.12 \end{aligned}$$




Play Tennis 训练样例

Day	Outlook	Temp.	Humidity	Wind	Play Tennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Weak	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cold	Normal	Weak	Yes
D10	Rain	Mild	Normal	Strong	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Play tennis 决策树属性节点选择




$$\begin{aligned}\text{Gain}(S, \text{Humidity}) &= 0.940 - (7/14) * 0.985 \\ &\quad - (7/14) * 0.592 \\ &= 0.151\end{aligned}$$




$$\begin{aligned}\text{Gain}(S, \text{Wind}) &= 0.940 - (8/14) * 0.811 \\ &\quad - (6/14) * 1.0 \\ &= 0.048\end{aligned}$$

Play tennis决策树属性节点选择



$$\begin{aligned}
 &\text{Gain}(S, \text{Outlook}) \\
 &= 0.940 - (5/14) * 0.971 \\
 &\quad - (4/14) * 0.0 - (5/14) * 0.971 \\
 &= 0.247
 \end{aligned}$$

ID3 算法构建play tennis 决策树




$$\text{Gain}(S_{\text{sunny}}, \text{Humidity}) = 0.970 - (3/5)0.0 - 2/5(0.0) = 0.970$$

$$\text{Gain}(S_{\text{sunny}}, \text{Temp.}) = 0.970 - (2/5)0.0 - 2/5(1.0) - (1/5)0.0 = 0.570$$

$$\text{Gain}(S_{\text{sunny}}, \text{Wind}) = 0.970 - (2/5)1.0 - 3/5(0.918) = 0.019$$

ID3 算法构建play tennis 决策树



ID3 算法


ID3(**Examples**, **Target_attribute**, **Attributes**)

- 创建树的根节点Root
- 如果**Examples**都是正例，则返回label=+的单节点树Root
- 如果**Examples**都是反例，则返回label=-的单节点树Root
- 如果**Attributes**为空，则返回单节点树Root，label= **Examples**中最普遍的**Target_attribute**值
- 否则 开始
 - $A \leftarrow$ **Attributes**中分类**Examples**能力最好的属性
 - Root的决策属性 $\leftarrow A$
 - 对A的每一个可能属性值 v_i
 - 在Root下面添加一个新的分支，对应测试 $A=v_i$
 - 令 $Examples_{v_i}$ 为**Examples**中满足A属性值为 v_i 的子集
 - 如果 $Examples_{v_i}$ 为空
 - 在这个新分支下加一个叶子结点，结点的label= **Examples**中最普遍的**Target_attribute**值
 - 否则在新分支下添加子树
ID3 ($Examples_{v_i}$, **Target_attribute**, **Attributes**-{A})
- 结束
- 返回Root

3.5 决策树学习的假设空间搜索

• ID3的优势和不足

- H 是有限离散值函数的完整空间
- ID3只维护一个当前假设 h
- 在搜索过程中没有回溯
- 收敛到局部最优解
- 在每个步骤中，使用当前所有训练样例做基于统计的决定
 - 对训练样例中的错误数据不太敏感



3.6 决策树学习的归纳偏置

- ID3搜索策略
 - 优先选择短树而不是长树
 - 选择信息增益高的属性离根较近的树
- ID3的近似归纳偏置
 - 短树较长树优先
 - BFS-ID3寻找最短的决策树
- 更接近ID3的归纳偏置
 - 短树比长树优先
 - 高信息增益属性更靠近根结点的树优先

3.6.1 限定偏置和优选偏置


- ID3 vs. 候选消除算法
 - ID3搜索一个完整的假设空间，但不完全搜索这个空间。
 - C-E搜索一个不完整的H，但它完全地搜索这个空间
 - ID3的归纳偏置是搜索策略排序假设的结果
 - C-E的归纳偏置是假设表示的表达能力的结果

- 优选偏置
 - 对某些假设胜过其它假设的一种优选，对假设没有硬性限制
 - 如短树优先
- 限定偏置
 - 对目标假设的一种限定
 - 候选消除算法预先假定：假设为属性的合取
- 优选偏置和限定偏置的结合
 - Chapter 1 中下棋案例：线性函数+梯度下降搜索
- 一般来说，优选偏置比限定偏置更可取
 - 使用完全的假设空间

3.6.2 为什么短假设优先

- ID3的归纳偏置的哲学基础
 - 奥卡姆剃刀：
 - 选择最简单的符合数据的假设
- 论据支持
 - 对行星运动的简单解释胜于复杂的解释
 - 短假设比长假设少
 - 一个符合数据的简短假设不太可能是巧合
 - 一个符合数据的长假设可能只是一个巧合
 - 复杂h常常不能正确地泛化到后续数据

Occam's Razor



"When faced with two equally good hypotheses, always choose the simpler."

3.6.2 为什么短假设优先

- 奥卡姆剃刀的困难1:
 - 可构造一些特殊的小树，数目更少(17个叶子节点，11个非叶子节点)，偶然一致性更小
 - 这些小树大多晦涩难解
 - 为什么短描述的决策树组成的小假设集合比其他众多小假设集合更相关
- 奥卡姆剃刀的困难2:
 - h 的大小由学习器内部使用的特定表示决定
 - 两个学习器使用不同的内部表示得到不同的 h ，两者都用奥卡姆剃刀原则，会得到相互矛盾的结论
 - 从进化和自然选择的角度进行分析
 - 归纳偏置决定假设的内部表示

3.7 决策树学习的常见问题

- DT学习的实际问题
 - 决策树要长多深
 - 处理连续属性
 - 选择适当的属性筛选度量标准
 - 处理缺少属性值的训练数据
 - 处理具有不同代价的属性
 - 提高计算效率
- 为了解决这些问题，ID3被扩展到C4.5

3.7.1 避免过度拟合数据


- 考虑假设 h 的错误率
 - 训练数据: $\text{error}_{\text{train}}(h)$
 - 整体数据 D : $\text{error}_D(h)$

假设 $h \in H$ **过拟合** 训练数据,
如果存在其它假设 $h' \in H$ 满足


$\text{error}_{\text{train}}(h) < \text{error}_{\text{train}}(h')$ 并且

$\text{error}_D(h) > \text{error}_D(h')$


- 示例图3.6 (下页)



过拟合





- 什么导致了过拟合
 - 训练案例中的随机噪声
 - 少数示例与叶节点相关联
 - 发生巧合的规则性,(尽管属性与实际目标函数无关, 但恰好能很好区分样例)



• 如何避免过度拟合？

- 在对训练数据进行完美分类之前，终止树增长
- 后修剪法，允许树过度拟合数据，之后再修剪

stop when the leaf nodes get less than m training instances. Here is an example for $m = 5$.




• 注意

- 第一种方法似乎更直接，但估计何时停止树增长很难
- 第二种方法在实践中更为成功

- 避免过拟合的关键问题
 - 定义一个准则评估正确的最终树的规模
- 解决方法:
 - 使用独立的样例集评估修剪方法的效用
 - 使用所有可用的数据进行训练，但应用统计测试来评估扩展特定节点是否可能改善在训练集外实例上的性能
 - 使用明确的标准衡量训练示例和决策树的编码复杂度，当编码长度最小时停止增长

- 注意
 - 第一种是最常见的(训练和验证集方法)
 - 一个训练集，学习假设
 - 验证集，评估假设的精度




- 动机:

- 学习器可能会被训练集内的随机错误所误导，但是验证集不太可能出现相同的随机错误
- 验证集应该足够大，以提供具有统计意义的实例样本
- 通常验证集为样例的三分之一

3.7.1.1 错误率降低修剪


- 修剪步骤
 - 修剪
 - 删除以该节点为根的子树，使其成为叶节点
 - 指定叶子节点的类别
 - 最常见的训练样例的类别
 - 删除节点
 - 如果修剪后的树在验证集上的性能不比原始树差
 - 重复这一步骤，直到进一步修剪有害为止
- 可用数据被划分为3个子集
 - 训练样本集合
 - 评估修剪树的验证集合
 - 用于估计实际精度的测试样例集合
 - 这种方法需要大量的数据





3.7.1.2 规则后修剪

- 步骤:
 - (1)从训练集合推导出决策树
 - 尽可能地拟合训练数据，并允许发生过拟合。
 - (2)将树转换成等价的规则集
 - 为每个路径创建一条规则
 - (3) 规则修剪
 - 删除可以提高规则估计精度的前件
 - (4)对修剪后的规则进行排序
 - 根据规则的估计精度进行排序
 - 按照这个顺序对后续实例进行分类




- 示例:图3.1中的决策树

- 树的最左边的路径

- If (outlook=sunny) $\wedge$ (Humidity=High) then PlayTennis=No

- 考虑移除(outlook=sunny) 与 (Humidity=High)


- 选择对规则精度提高最大的剪枝步骤



IF (Outlook = Sunny) & (Humidity = High)
THEN PlayTennis = No
IF (Outlook = Sunny) & (Humidity = Normal)
THEN PlayTennis = Yes
.....

- 估计规则的精度
 - 使用验证集
 - 基于训练集本身
 - 使用悲观估计
 - 弥补了训练数据有利于当前规则的估计偏置
 - 估计过程($Accuracy_s$ 样本精度, $Accuracy_D$ 估计精度, binomial distribution)
 - 计算规则的样本精度 $Accuracy_s$
 - 计算二项分布下的标准差(假设 $Accuracy_s$ 服从二项式分布)
 - 对于给定的置信水平, 采用下限估计作为规则估计精度 $Accuracy_D$
 - 注意
 - 对于大数据集, 悲观估计非常接近观察精度
 - 在统计上是无效的, 但在实践中是有用的

- 为什么在修剪前要把DT转换成规则
 - 区分决策节点使用的不同上下文
 - 对每个节点可以进行不同的修剪
 - 消除发生在树的根附近的属性测试和发生在叶子附近的属性测试之间的区别
 - 避免凌乱记录问题
 - 提高其可读性



3.7.2 合并连续值属性

- ID3对属性值的限制
 - 目标属性为离散值
 - 在决策节点中测试的属性是离散值
- 属性为连续值如何处理？
 - 动态定义新的离散值属性

- 案例:
 - Temperature = 24.50C
 - (Temperature > 20.00C) = {true, false}
 - 閾值应该设置在哪里?

Temperature	40°C	48°C	60°C	72°C	80°C	90°C
PlayTennis	No	No	Yes	Yes	Yes	No

- 定义基于阈值的布尔属性
 - 选择具有最大信息增益的阈值**C**
 - 根据**A**对样例进行排序
 - 找到目标属性不同的相邻样例
 - 在**A**值对应区间创建一组候选阈值(取中间值)
 - 可以证明, 使信息增益最大的**C**位于该边界(Fayyad1991)
 - 计算各阈值的信息增益

Temperature	40°C	48°C	60°C	72°C	80°C	90°C
PlayTennis	No	No	Yes	Yes	Yes	No


- 方法扩展
 - 将连续属性分割成多个区间

3.7.3 属性选择的其他度量标准

- 信息增益的偏置
 - 偏袒具有较多值的属性
- 增益比率 (GainRatio)
 - 引入惩罚项，分裂信息项
 - 分裂信息项用于衡量属性分裂数据的广度和均匀性
 - 增益比率阻碍选择均匀分布的属性

$$\text{SplitInformation}(S, A) = - \sum_{i=1}^c \frac{|S_i|}{|S|} \log_2 \frac{|S_i|}{|S|}$$

$$\text{GainRatio}(S, A) = \frac{\text{Gain}(S, A)}{\text{SplitInformation}(S, A)}$$



all subsets perfectly pure => optimal split

Won't work for new data: D15 Rain High Weak

1	Temperature	Humidity	Wind	PlayTennis
2	Hot	High	Weak	No
3	Hot	High	Strong	No
4	Mild	High	Weak	Yes
5	Cool	Normal	Weak	Yes
6	Cool	Normal	Strong	No

$\text{SplitInfo}(\text{Temperature}) = - (2/5) * \log_2(2/5) - (1/5) * \log_2(1/5) - (2/5) * \log_2(2/5) = 0.918$


- 问题：
 - 当 $S_i \approx S$ ，分母很小或接近零，导致增益比率非常大
 - 增益比率应用于那些增益高于平均增益的属性

- 基于距离的度量
 - 定义数据划分之间的距离度量
 - 属性的评估基于它创建的数据划分与完美划分之间的距离
 - 选择划分最接近完美划分的属性
 - Lopez de Mantaras(1991)证明了它并不偏向具有大量值的属性
- Mingers (1989a) 实验
 - 不同的属性选择度量对最终精度的影响小于后修剪对最终精度的影响

3.7.4 处理缺少属性值的训练样例


- 处理属性缺失样例
 - 如何根据该属性已知值，估计缺失的属性值
 - $\langle x, c(x) \rangle$ 是 S 中的一个训练样例，值 $A(x)$ 未知
 - 如何计算信息增益 $\text{Gain}(S, A)$

- 处理缺失属性值
 - 将节点相关的训练样例集中最常见的值赋给它
 - 取节点相关训练集中同类别样例中最常见的值
 - 给A的每个可能值赋一个概率



3.7.5 处理不同代价的属性

- 实例属性与代价相关
 - 尽可能选择使用低成本属性的决策树
 - 仅在需要产生可靠的分类时才依赖高成本属性
- 通过在属性选择度量中引入代价项，对属性进行选择



- Tan and Schlimmer(1990) and Tan(1993),
Nunez(1988)(1991)

小结和补充读物

- 决策树学习为概念学习和其他离散值函数的学习提供了一种实用的方法
- ID3
 - 贪心搜索
 - 由根向下生长
 - 搜索的假设空间H完整
 - 归纳偏置，短树优先
 - 过拟合问题

- C4.5是对基本ID3算法的扩展:

方法	属性度量	属性类型	丢失属性处理	剪枝策略	属性代价处理
ID3	信息增益	离散值	无	无	无
C4.5	增益比率	离散值、 连续值	有	错误率降低修剪 规则后修剪	有

- 作业: 3.3,3.2

- Hunt
- Quinlan
- Mingers