

机器学习

第6章：贝叶斯学习

内容

- 介绍贝叶斯定理
- 定义极大似然假设和最大后验概率假设
- 分析前面章节的相关问题和学习算法
- 介绍几种直接操纵概率的学习算法
 - 贝叶斯最优分类器
 - Gibbs算法
 - 朴素贝叶斯分类器
 - 贝叶斯信念网络

6.1 简介

- 为什么要把贝叶斯学习引入机器学习
 - 贝叶斯推理为推理提供了一种概率手段
 - 基于待考察量遵循的概率分布，做出最优决策
 - 可定量衡量假设的置信度
 - 可计算显式的假设成立概率，例如朴素贝叶斯分类器
 - 为未直接操作概率数据的学习算法提供理论分析基础
 - Find-S
 - 候选消除算法
 - 神经网络
 - 决策树的归纳偏置
 - 最小描述长度原则

贝叶斯学习的特点

- 先验知识可以与观察数据一起决定假设成立的最终概率
 - 先验知识:
 - 先验概率 $P(h)$
 - 每个可能假设在可观察数据上的概率分布, $P(D/h)$
- 每个样例可以增量地降低或者升高某假设(成立)的估计概率
- 允许假设做出不确定性的预测
- 结合多个假设的预测进行分类
 - 按其概率加权
- 做为最优的决策标准可用来衡量其他方法的性能

实践中应用贝叶斯方法的难度

- 需要许多概率的初始知识.
 - 如果不知道, 则应进行估算
- 贝叶斯最优假设的计算代价比较大

6.2 贝叶斯法则

- 机器学习的任务：根据观察到的训练数据 D ，找到最佳假设
 - 最佳(best)假设:在给定数据 D 以及 H 中各假设的先验概率，最可能(成立或正确)的假设
 - 贝叶斯定理基于训练数据和先验知识计算假设成立的概率

先验概率和后验概率

- $P(h)$ (假设 h 的先验概率): 在观察数据被观测到之前, h 成立的概率
 - 反映 h 是可能正确假设的背景知识
 - 无法获取假设先验概率, 可假定每个 h 的先验概率相同
- $P(D)$: 观察数据 D 的先验概率
- $P(D|h)$: 假设 h 成立的情况下, 观测到观察数据 D 的概率。
- $P(h|D)$ (后验概率): 给定观察数据 D 时, 假设 h 成立的概率。


贝叶斯公式

- 提供一种从先验概率 $P(h)$ 计算后验概率 $P(h | D)$ 的方法

$$P(h | D) = \frac{P(D | h)P(h)}{P(D)}$$

- $P(h | D)$ 随 $P(h)$ 和 $P(D | h)$ 增大
- 随 $P(D)$ 的增加而减小。

• 为什么？



Is it a cat or a dog in the box?

Problem Statement:

Initial Belief: 50/50 chances

→ $P(\text{Cat}) = 0.5$

→ $P(\text{Dog}) = 0.5$

We have a CLUE: Pet is quiet

→ $P(\text{Quiet} | \text{Cat}) = 80\% \text{ or } 0.8$

→ $P(\text{Quiet} | \text{Dog}) = 30\% \text{ or } 0.3$

The Pet is very Quiet

From Bayes Theorem probability that pet is a cat given it is quiet is:

$P(\text{Cat} | \text{Quiet}): \frac{P(\text{Quiet} | \text{Cat}) \times P(\text{Cat})}{P(\text{Quiet})}$

基本概率公式总结


- 乘法规则: $P(A \wedge B) = P(A|B)P(B) = P(B|A)P(A)$
- 加法规则: $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$
- 贝叶斯法则: $P(h|D) = P(D|h)P(h)/P(D)$
- 全概率法则:
 - 如果事件 $A_1 \dots A_n$ **互斥**且

$$\sum_{i=1}^n P(A_i) = 1 \qquad P(B) = \sum_{i=1}^n P(B | A_i)P(A_i)$$

贝叶斯公式证明

- $P(h|D)=P(h \wedge D)/ P(D)$ 乘法法则
- $P(h \wedge D)= P(D|h) P(h)$ 乘法法则
- $h_1, h_2, \dots, h_n$ 互斥, 且 $\sum_{k=0}^n P(h_k) = 1$

$$\begin{aligned} P(h|D) &= P(D|h)P(h) / P(D) \\ &= P(D|h)P(h) / \sum_{k=0}^n P(h_k) P(D|h_k) \end{aligned} \quad \text{全概公式}$$



极大后验假设

- 学习器在观测到数据D后，找到的具有最大可能性的假设h
 - 极大后验假设（maximum a posteriori MAP假设）：

$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} \frac{P(D | h)P(h)}{P(D)} \\ &= \arg \max_{h \in H} P(D | h)P(h) \end{aligned}$$

极大似然假设

- 假定每个假设都具有相同的先验概率($P(h_i) = P(h_j)$)
 - $P(D | h)$: 给定 h 时,观察到数据 D 的似然度
- 使 $P(D|h)$ 最大的假设被称为 极大似然假设(maximum likelihood, ML)

$$h_{ML} = \arg \max_{h \in H} P(D | h)$$

6.2.1 举例

- 两个假设：
 - 病人有某种类型的癌症: $h_1 = \text{cancer}$
 - 病人无癌症: $h_2 = \neg \text{cancer}$
- 实验测试有两种可能输出: + 、 -
- 先验知识: 所有人口中只有0.008的人患有该病.
- 该测试对确实有病的患者有98%的可能性返回 +
- 该测试对无病患者有97%的可能性返回 -
- 概率描述:
- $P(\text{cancer})=0.008$, $P(\neg \text{cancer})=0.992$
 $P(+|\text{cancer})=0.98$, $P(-|\text{cancer})=0.02$
 $P(+|\neg \text{cancer})=0.03$, $P(-|\neg \text{cancer})=0.97$

- 问题：测试返回阳性结果的患者有没有癌症？

$$\arg \max_{h \in H} P(D | h)P(h)$$



- 计算极大后验假设
 - $P(h_1 = \text{cancer} | +)$: $P(+ | \text{cancer})P(\text{cancer}) = 0.0078$
 - $P(h_2 = \neg \text{cancer} | +)$: $P(+ | \neg \text{cancer})P(\neg \text{cancer}) = 0.0298$
 - $h_{\text{MAP}} = h_2 = \neg \text{cancer}$
 - $P(D)$?
- 贝叶斯推理在很大程度上取决于先验概率
- 假设没有被完全接受或拒绝

6.3 贝叶斯法则和概念学习

- Brute-force 贝叶斯概念学习
- 对第2章提到的概念学习问题进行分析
 - 证明概念学习输出极大后验假设

6.3.1 Brute-Force 贝叶斯概念学习

- **概念学习问题**: 对于有限的假设空间 H , 学习某个目标概念 $c: X \rightarrow (0,1)$
- **Brute-Force MAP 学习算法**
 - 对于 H 中的每个 h , 计算后验概率
$$P(h | D) = \frac{P(D | h)P(h)}{P(D)}$$
 - 输出 h_{MAP}
$$h_{MAP} = \arg \max_{h \in H} P(h | D)$$
 - 需要大量的计算
 - 对于大的假设空间不切实际, 但是它提供了一个标准, 我们可以据此判断其他概念学习算法的性能

Brute-force MAP 学习算法的概率设置

- 概念学习的假定条件:
 - 训练数据D是无噪声的(i.e., $d_i=c(x_i)$)
 - 目标概念包含在假设空间H中
 - 没有任何理由认为某假设比其他假设的可能性大

- 则有:

$$P(h) = \frac{1}{|H|}$$

$$P(D | h) = \begin{cases} 1 & \forall d_i, d_i = h(x_i) \\ 0 & otherwise \end{cases}$$

- Brute-Force MAP的第一步

- h 与训练数据不一致, $P(h | D) = \frac{0 \cdot P(h)}{P(D)} = 0$

- h与D一致, $P(h | D) = \frac{1 \cdot \frac{1}{|H|}}{P(D)} = \frac{\frac{1}{|H|}}{\frac{|VS_{H,D}|}{|H|}} = \frac{1}{|VS_{H,D}|}$


$VS_{H,D}$ 是H中与D一致的假设子集

- 从全概率公式推导出P(D)

$$\begin{aligned} P(D) &= \sum_{h_i \in H} P(D | h_i) P(h_i) \\ &= \sum_{h_i \in VS_{H,D}} 1 \times \frac{1}{|H|} + \sum_{h_i \notin VS_{H,D}} 0 \times \frac{1}{|H|} \\ &= \sum_{h_i \in VS_{H,D}} 1 \times \frac{1}{|H|} \\ &= \frac{|VS_{H,D}|}{|H|} \end{aligned}$$

- 假设的概率演化情况如图6-1所示(下一页)

从贝叶斯法角度分析概念学习的学习过程



结论：每一个一致假设都是MAP 假设


6.3.2 MAP 假设和一致学习器

- 一致学习器:
 - 输出的假设在训练样例上有零错误率
- 任意一致学习器输出一个MAP 假设
 - 假定 H 上有均匀的先验概率
 - 假定训练数据是确定性的($P(D|h), 0, 1$ 概率)和无噪声的

- 分析Find-S
 - 在上述概率分布下输出MAP假设
 - 先验概率偏袒于更特殊假设的任何概率分布，Find-S输出MAP假设
 - 如果 h_i 比 h_j 更特殊， $p(h_i) > p(h_j)$.

- 贝叶斯框架提出了一种分析学习算法行为的方法
 - 通过定义 $P(h)$ 和 $P(D | h)$ ，分析算法是否输出最优假设
- $P(h)$ 和 $P(D|h)$ 可以看作是算法表现最优时的隐含假定
 - $P(h)$, H 上的先验概率
 - $P(D|h)$, 数据拒绝或接受假设的强度
- 实际上, $P(h)$ 和 $P(D | h)$ 也是学习器的归纳偏置
 - 在第二章中, 我们将归纳偏置定义为断言集合 B 。

- 通过定义 $P(h)$ 和 $P(D|h)$ ，可以基于贝叶斯定理将归纳推理方法建模为等价的概率推理
 - 基于贝叶斯定理的概率推理系统将表现出与这些算法等效的输入-输出行为




6.4 极大似然和最小误差平方假设

- 贝叶斯分析表明
 - 在某些特定前提下，使输出的假设和训练数据之间的误差平方最小化的学习算法会输出极大似然假设
 - 意义
 - 为ANN和其他曲线拟合方法提供了基于贝叶斯的解释

- 问题设定:
 - 学习器 $L(X, H, D)$
 - 实例空间 X
 - 假设空间 H (real-valued functions)
 - D : 给定 m 个训练样例的集合, 每个训练样例的目标值被某随机样例干扰, 随机噪声服从正态分布。
 - $\langle x_i, d_i \rangle$, 其中 $d_i = f(x_i) + e_i$
 - $f(x_i)$: 目标函数的无噪声值
 - e_i 是随机噪声, 独立抽取, 服从均值为 0 的正态分布
 - 学习器的任务
 - 输出一个极大似然假设
 - 或者, 等价的 MAP 假设 (假定所有假设有相等的先验概率)

— 例如：一个线性目标函数 f ，如图：



— 定义概率密度函数：

$$p(x_0) = \lim_{\varepsilon \rightarrow 0} \frac{1}{\varepsilon} P(x_0 \leq x < x_0 + \varepsilon)$$

证明


- 定义 h_{ML}

- 假定训练样例之间相互独立
- $P(D|h)$ = 各 $p(d_i|h)$ 的乘积

$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m p(d_i | h)$$

- 定义数据分布

- 噪音 e_i 服从 $N(0, \sigma)$
- d_i 服从 $N(f(x_i), \sigma)$
- $p(d_i|h)$ 概率密度为 $N(f(x_i), \sigma)$ (如下图, 见下一页)



A Normal distribution (also called a Gaussian distribution) is a bell-shaped distribution defined by the probability density function

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

A Normal distribution is fully determined by two parameters in the above formula: μ and σ .

If the random variable X follows a normal distribution, then:

- The probability that X will fall into the interval (a, b) is given by

$$\int_a^b p(x)dx$$

- The expected, or mean value of X , $E[X]$, is

$$E[X] = \mu$$

- The variance of X , $Var(X)$, is

$$Var(X) = \sigma^2$$

- The standard deviation of X , σ_X , is

$$\sigma_X = \sigma$$

The Central Limit Theorem (Section 5.4.1) states that the sum of a large number of independent, identically distributed random variables follows a distribution that is approximately Normal.

- 替换 $\mu=f(x_i)=h(x_i)$,
得到:

$$\begin{aligned}h_{ML} &= \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(d_i - \mu)^2} \\&= \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(d_i - h(x_i))^2} \\&= \arg \max_{h \in H} \sum_{i=1}^m \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2}(d_i - h(x_i))^2 \\&= \arg \max_{h \in H} \sum_{i=1}^m -\frac{1}{2\sigma^2}(d_i - h(x_i))^2 \\&= \arg \min_{h \in H} \sum_{i=1}^m (d_i - h(x_i))^2\end{aligned}$$

- 证明极大似然假设是使 d_i 与 $h(x_i)$ 之间的平方误差之和最小的假设
 - 约束条件:
 - 通过将随机噪声添加到真实目标值来生成 d_i
 - 这种随机噪声服从零均值的正态分布

为什么选择正态分布来描述噪声？

- 数学计算的简洁性
- 它是物理系统中许多类型噪声的良好近似值
- 中心极限定理显示
 - 足够多的独立同分布的随机变量之和服从正态分布