

机器学习

第六章 贝叶斯学习

6.5 用于预测概率的极大似然假设

- 学习一个不确定性函数
 - 为什么?
 - 确定性函数 $f: X \rightarrow \{0,1\}$
 - 不可预测性来源于不能观察到数据的所有特征
 - f 是输入的概率函数
 - 任务：学习目标函数
 - $f' : X \rightarrow [0,1]$, 使得 $f' = P(f(x)=1)$

两种方法

- 蛮力方法（Brute-Force way）
 - 收集对 x 的每个可能值观察到的1和0的频率
 - 训练神经网络，对每个 x 输出目标概率
- 直接从 f 的训练样例中训练神经网络，而且仍能学习到 f' 的极大似然假设

优化准则（误差函数, 二分类交叉熵损失函数）推导

– $D = \{ \langle x_1, d_1 \rangle, \dots, \langle x_m, d_m \rangle \}$

– $P(D | h) = \prod_{i=1}^m P(x_i, d_i | h) = \prod_{i=1}^m P(d_i | h, x_i) P(x_i | h) = \prod_{i=1}^m P(d_i | h, x_i) P(x_i)$ (假设 x_i 独立于 h)

– 注意:
$$P(d_i | h, x_i) = \begin{cases} h(x_i) & d_i = 1 \\ 1 - h(x_i) & d_i = 0 \end{cases} = h(x_i)^{d_i} (1 - h(x_i))^{1-d_i}$$

$$P(D | h) = \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} P(x_i)$$

$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} p(x_i)$$

$$= \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i}$$

$$= \arg \max_{h \in H} \sum_{i=1}^m d_i \ln h(x_i) + (1 - d_i) \ln(1 - h(x_i)) \quad (6.13)$$

– 注意式子(6.13)与熵函数的一般式（在第三章中讨论过）的相似性

$$\sum_{i=1}^m d_i \ln h(x_i) + (1 - d_i) \ln(1 - h(x_i))$$

$$\sum - \quad \blacklozenge$$

- 式(6.13)的负值被称为交叉熵（cross entropy）
 - 衡量实际分布与目标分布的相似性


6.5.1 在神经网络中梯度搜索以达到似然最大化

- 使式(6.13) 最大化可得到极大似然假设
– 基于(6.13)推导神经网络权值训练法则

$$\begin{aligned}\frac{\partial G(h, D)}{\partial w_{jk}} &= \sum_{i=1}^m \frac{\partial G(h, D)}{\partial h(x_i)} \frac{\partial h(x_i)}{\partial w_{jk}} \\ &= \sum_{i=1}^m \frac{\partial (d_i \ln h(x_i) + (1 - d_i) \ln(1 - h(x_i)))}{\partial h(x_i)} \frac{\partial h(x_i)}{\partial w_{jk}} \\ &= \sum_{i=1}^m \frac{d_i - h(x_i)}{h(x_i)(1 - h(x_i))} \frac{\partial h(x_i)}{\partial w_{jk}}\end{aligned}$$

– 假定神经网络是一个单层的sigmoid单元。我们有

$$\frac{\partial h(x_i)}{\partial w_{jk}} = \sigma'(x_i) x_{ijk} = h(x_i)(1 - h(x_i)) x_{ijk}$$



– 最大化 $P(D|h)$, 使用梯度上升

$$\frac{\partial G(h, D)}{\partial w_{jk}} = \sum_{i=1}^m (d_i - h(x_i)) x_{ijk}$$

$$\Delta w_{jk} = \eta \sum_{i=1}^m (d_i - h(x_i)) x_{ijk}$$

$$w_{jk} \leftarrow w_{jk} + \Delta w_{jk}$$

- BP算法可使用不同的误差函数，学习到对应的极大似然假设
 - 最小化误差平方和的假设是极大似然假设：
 - 前提条件： $\langle x_i, d_i \rangle$ ，其中 $d_i = f(x_i) + e_i$
 - 最小化交叉熵的假设也是极大似然假设：
 - 前提条件：观察到的布尔值，为输入实例的概率函数
 - 误差平方和损失多用于回归学习，交叉熵损失用于二分类

6.7 贝叶斯最优分类器

- 两个问题
 - “给定训练数据，最可能的假设 h 是什么？”
 - 学习到一个假设
 - “给定训练数据，对新实例的最可能分类是什么？”
 - 类别
 - 能不能用最可能的 h 直接分类新实例？

- 例子
 - 三个假设, h_1, h_2, h_3 .
 - $P(h_1|D)=0.4, P(h_2|D)=0.3, P(h_3|D)=0.3$
 - h_1 是MAP 假设
 - 对一个新实例 x , $h_1(x)=1, h_2(x)=0, h_3(x)=0$
 - 任务: x 的类别?
 - MAP 假设: $h_1(x)=1$
 - 考虑所有假设, $p(x=1)=0.4$, and $p(x=0)=0.6$
 - 我们发现最可能的分类和 h_{MAP} 给出的不同

- 如何得到最可能的分类
 - 合并所有假设的预测，用后验概率来加权
 - $P(v_j|D)$ 是将新实例划分为 v_j 的概率。
 - 新实例的**最优**分类为使 $P(v_j|D)$ 最大的 v_j ：

$$= \sum_{\in}$$

$$v_{optimal} = \arg \max_{v_j \in V} \sum_{h_i \in H} P(v_j | h_i) P(h_i | D)$$

- 例子

- 条件

- 可能的分类集合 $V=\{+,-\}$
 - $P(h_1|D)=0.4$, (后验) $P(-|h_1)=0$, $P(+|h_1)=1$
 - $P(h_2|D)=0.3$, $P(-|h_2)=1$, $P(+|h_2)=0$
 - $P(h_3|D)=0.3$, $P(-|h_3)=1$, $P(+|h_2)=0$

- 因此

- $\sum_{h_i \in H} P(+ | h_i) P(h_i | D) = 0.4$
 - $\sum_{h_i \in H} P(- | h_i) P(h_i | D) = 0.6$
 - $\arg \max_{v_j \in \{+,-\}, h_i \in H} \sum_{h_i \in H} P(v_j | h_i) P(h_i | D) = 0.6$

- 总结
 - 贝叶斯最优分类器使新实例被正确分类的可能性达到最大
 - 一个有趣的属性是，最优分类可以对应于 H 中不存在的假设
 - 搜索假设空间 H'
 - 在 H 中多个假设的线性组合所作的预测中进行比较

6.8 Gibbs 算法

- 贝叶斯最优分类器的问题
 - 获得最好性能
 - 开销很大
- Gibbs算法一个替代的，非最优的方法
 - 按照H上的后验概率分布，从H 中随机选择假设h
 - 使用h来预测新实例x的分类
- 分类错误率
 - 最差为贝叶斯分类器错误率期望值的两倍

$$E[\text{error}_{\text{Gibbs}}] \leq 2 \times E[\text{error}_{\text{BayesOptimal}}]$$

6.9 朴素贝叶斯分类器

- 学习任务:
 - 每个实例 x 可由属性值对描述 (结构化数据)
 - 目标函数 $f(x)$ 从某个有限集合 V 中取值(离散函数)
 - 预测新实例的目标值

- 学习方法

- 给定描述实例的属性值 $\langle a_1, \dots, a_n \rangle$ ，计算最可能的目标值 v_{MAP}

$$v_{MAP} = \arg \max_{v_j} P(v_j | a_1, \dots, a_n)$$

- 使用贝叶斯公式将此表达式重写

$$\begin{aligned} v_{MAP} &= \arg \max_{v_j \in V} \frac{P(a_1, \dots, a_n | v_j) P(v_j)}{P(a_1, \dots, a_n)} \\ &= \arg \max_{v_j \in V} P(a_1, \dots, a_n | v_j) P(v_j) \end{aligned}$$

- 估计贝叶斯方程中两个数据项的值
 - $P(v_j)$: 目标值 v_j 出现在训练数据中的频率
 - $P(a_1, \dots, a_n | v_j)$:
 - 需要十分大的训练数据
 - 简单的假定: 在给定目标值时, 属性值之间相互条件独立

$$P(a_1, \dots, a_n | v_j) = \prod_i P(a_i | v_j)$$

- 朴素贝叶斯分类器:

$$v_{NB} = \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i | v_j)$$

- 注意: $P(a_i|v_j)$, $P(a_1, \dots, a_n|v_j)$ 的数量
- 只有当条件独立性被满足时, 朴素贝叶斯分类 v_{NB} 等于 MAP 分类
- 与其他学习方法的差别?
 - 没有明确的搜索假设空间的过程

- 例子

- 第3章的表3.2提供了目标PlayTennis的14个训练样例,其中每一天由属性(sunny, cool, high, strong)来描述

- $$v_{NB} = \arg \max_{v_j \in \{yes, no\}} P(v_j) \prod_i P(a_i | v_j)$$

$$= \arg \max_{v_j \in \{yes, no\}} P(v_j) P(sunny | v_j) P(cool | v_j) P(high | v_j) P(strong | v_j)$$

- 计算不同目标值的概率

- $P(yes) = 9/14 = 0.64$
- $P(no) = 5/14 = 0.36$
- $P(strong|yes) = 3/9 = 0.33$
- $P(strong|no) = 3/5 = 0.60$
- ...

- 计算 v_{NB}

- $P(yes)P(sunny|yes)P(cool|yes)P(high|yes)P(strong|yes) = 0.0053$
- $P(no)P(sunny|no)P(cool|no)P(high|no)P(strong|no) = 0.0206$
- $v_{NB} = no$

Play Tennis 训练样例

Day	Outlook	Temp.	Humidity	Wind	Play Tennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Weak	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cold	Normal	Weak	Yes
D10	Rain	Mild	Normal	Strong	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

- m-估计

- 当样本数据很小，我们使用m-估计

$$\frac{n_c + mp}{n + m}$$

- p: 先验估计
 - m: 为等效样本大小的常量

- 在缺少其他信息时，可假定均匀的先验概率

- 如果一个属性有k个值， $p=1/k$

- m被称为等效样本大小


- 将n个实际观察到的样本扩大，加上m个属性值按p分布的虚拟样本

6.10 实例：学习分类文本

- 学习问题：
 - 我感兴趣的电子新闻稿
 - 讨论机器学习的网页
- 朴素贝叶斯算法遵循一下的问题框架：
 - 实例空间 X 包含了所有的文本文档
 - 训练集
 - 目标函数 $f(x)$
 - 目标值集合 $V(V=\{\text{like}, \text{dislike}\})$

- 文本分类要解决的两个主要问题
 - 怎样将任意文档表示为属性值的形式
 - 如何估计朴素贝叶斯分类器所需的概率
- 文本文档表示
 - 为每个单词位置定义一个属性
 - 属性值为在此位置上找到的英文单词

Text Classification using naive bayes



- 文本分类例子
 - 700个被分类为dislike的文档
 - 300个被分类为like
 - 任务：分类以下新文档
 - 文档: This is an example document for the naive Bayes classifier. This document contains only one paragraph, or two sentences.
- 朴素贝叶斯分类器计算：

$$\begin{aligned}v_{NB} &= \arg \max_{v_j \in \{like, dislike\}} P(v_j) \prod_{i=1}^{19} P(a_i | v_j) \\&= \arg \max_{v_j \in \{like, dislike\}} P(v_j) P(a_1 = "this" | v_j) \dots P(a_{19} = "sentences" | v_j)\end{aligned}$$

- 注意： 在这个问题中，在一个位置上出现某单词的概率独立于另外一个位置的单词吗？ 即朴素贝叶斯分类器的属性独立是否成立。
 - 我们别无选择，必须作此假定
 - 没有这个假定，要计算的概率项将极为庞大
 - 在实践中朴素贝叶斯学习器在许多文本分类问题中性能非常好

- 估计 $P(v_i)$ 和 $P(a_i=w_k|v_i)$.

- $P(v_i)$

- $P(a_i=w_k|v_i)$, 我们需要估计大约 $2 \times 5000 \times 19$ 个项吗?

- 假定遇到一个单词的概率独立于单词所在位置

$$P(a_i=w_k|v_i)=P(w_k|v_j)$$

- 优点：使可用于估计每个概率的样例数增加了，因此增加了估计的可靠程度
 - 本质上朴素贝叶斯分类将文本表示为词的集合，即词袋(word bag)

- 采纳 m-估计?

$$= \frac{\quad +}{+ \quad \blacklozenge \quad \blacklozenge \quad \blacklozenge \quad \blacklozenge \quad \blacklozenge}$$

- Learn_Naive_Bayes_Text(Examples, V)

学习 $P(w_k|v_j)$ 和 $P(v_j)$

- 收集单词

- Vocabulary $\leftarrow$ 收集Examples中所有单词、标点符号及其他记号

- 计算 $P(v_j)$ 及 $P(w_k|v_j)$

- 对V中每个目标值 v_j
 - docs_j $\leftarrow$ Examples中目标值为 v_j 的文档子集
 - $P(v_j) \leftarrow |docs_j| / |Examples|$
 - Text_j $\leftarrow$ 将docs_j中所有成员连接起来建立的单个文档
 - n $\leftarrow$ 在Text_j中不同单词位置的总数
 - 对Vocabulary中每个单词 w_k
 - » $n_k \leftarrow$ 单词 w_k 出现在Text_j中的次数
 - » $P(w_k|v_j) \leftarrow (n_k + 1) / (n + |Vocabulary|)$

- Classify_Naive_Bayes_Text(Doc)

对文档Doc返回其估计的目标值

- a_i 代表在Doc中的第*i*个位置上出现的单词
- positions←在Doc中的所有单词位置
- 返回 v_{NB} ，其中

$$v_{NB} = \arg \max_{v_j \in V} P(v_j) \prod_{i \in positions} P(a_i | v_j)$$

6.10 实验结果

- Joachims用其分类新闻组的文章
 - 每一文章的分类是该文章所属的新闻组名称
 - 20个电子新闻组，每个组中有1000篇文章
 - 3/2作为训练样例，其余作为测试数据
 - 100个最常见的单词及任何出现少于3次的单词被移去
 - 精度: 89%
- Lang 将其应用到学习目标概念“我感兴趣的新闻组文章”
 - NewsWeeder系统
 - 推荐的文章集合中用户感兴趣的文章比通常高3-4倍

作业

- 6.1, 6.2