

第9章：线性分类器

引言

- 贝叶斯定理提供了从先验概率 $P(h)$ 、 $P(D)$ 以及 $P(D|h)$ 计算后验概率 $P(h|D)$ 的方法

类标记 h 相对于样本 D 的“类条件概率”或“似然”

“证据” (evidence) 因子与类标记无关

先验概率
样本空间中各类样本所占的比例，可通过各类样本出现的频率估计


$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} P(D | h) P(h) \\ &= \arg \max_{h \in H} P(D | h) P(h) \end{aligned}$$

- 某些情况下，可以假定 H 中每一个假设都有相同的先验，即 $P(h_i)=P(h_j)$ ，则：

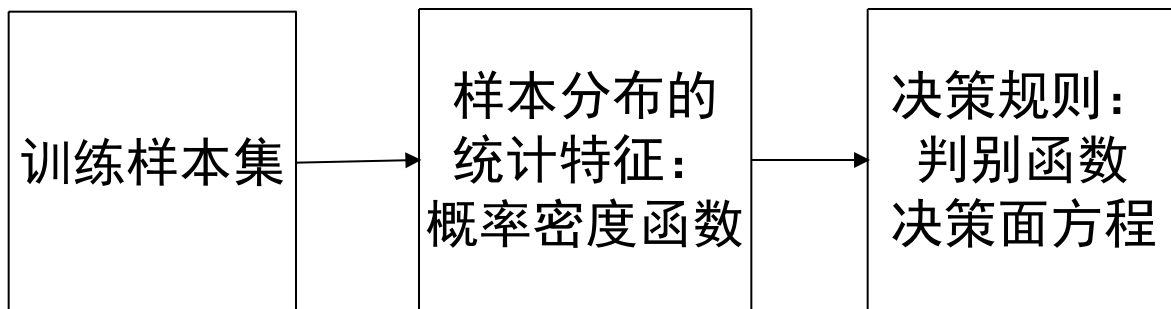
$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h | D) \\ &= \arg \max_{h \in H} P(D | h) \end{aligned}$$

引言

分类器 功能结构



基于样本的Bayes分类器：
通过估计类条件概率密度函数，设计相应的判别函数



获取统计分布及其参数很困难，实际问题中并不一定具备获取准确统计分布的条件。

引言

存在的问题：


- (a) 在实际应用中，样本空间的类条件概率密度**很难确定**；
- (b) 利用非参数估计方法**需要大量的样本**且随着特征空间维数的增加所需样本数量急剧增加，在实际的应用中可行性差。

解决的办法：

利用样本集直接设计分类器，给定某个判别函数类，利用样本集确定判别函数中的未知参数，最后用参数确定的判别函数进行分类。

判别函数形式：

- **线性函数：简单、实用、经济**



本章研究 $g(x)$ 为线性函数时，分类器参数的估计问题。

引言

相比贝叶斯分类器，线性判别函数的特点：

- 采用线性判别函数导致的错误率或风险可能比贝叶斯分类器大
- 但是，线性函数是最简单的函数，**计算量小，容易实现**。因此，线性判别函数是统计模式识别的基本方法之一
- 线性判别函数是“次优”，只是相对于错误率或风险而言的，**而对所提的准则函数来讲，则是最好**

本章内容

一、线性判别函数

二、最小距离准则

三、感知器函数准则

四、最小平方误差准则

一、线性判别函数

- 基于判别函数的分类器学习概要：
 - 直接假设判别函数 $g(x)$ 具有某种形式, 然后利用样本集确定出判别函数中的未知参数
 - $g(x)$ 的具体形式需根据样本集在模式空间中的分布情况或相关领域的专业知识来确定
 - 本章研究 $g(x)$ 为线性函数时, 分类器参数的估计问题
 - 学习判别函数的参数

一、线性判别函数

基于样本的判别函数学习：

三要素

- 确定分类器，也就是判别函数的类型（线性？）
- 确定分类器设计的目标或者准则
- 设计算法利用数据搜索得到最优的判别函数参数

形式化

判别函数类 $\{g(\alpha), \alpha \in \Omega\}$, α : 未定参数

准则函数 $L(\alpha)$

求: α^* : $L(\alpha^*) = \min L(\alpha)$




一、线性判别函数

- 如何估计判别函数的未知参数？
 - 给出分类器的设计要求
 - ✓ 应针对不同的实际情况，提出不同的设计要求，使得所设计的分类器尽可能好地满足这些要求
 - ✓ 由于所提要求不同，结果也相各异，这说明上述“尽可能好”是相对于所提要求而言的
 - 这种设计要求，往往用某个特定的函数来表达，称之为**准则函数**，“尽可能好”的结果对应于准则函数取最优值
 - **分类器设计问题**就转化为**求准则函数极值的问题**了，因此就可以利用**最优化技术**求解未知参数


一、线性判别函数

线性可分情况



一、线性判别函数

线性不可分情况



一、线性判别函数

定义线性判别函数

设模式 x 是 d 维的, $x = (x_1, x_2, \dots, x_d)^T$, 类别数 $m = 2$

设线性判别函数的一般形式为

第 i 个输入 $g(x) = w^T x + w_0$

■ $x = (x_1, x_2, \dots, x_d)^T$: 特征矢量

■ $w = (w_1, w_2, \dots, w_d)^T$: 权矢量

■ w_0 : 偏置(bias)或阈值

第 i 个输入上的权值

一、线性判别函数

| 定义线性判别函数的增广形式

$$g(x) = w^T x \quad \text{齐次形式}$$

■ $\mathbf{x} = (1, x_1, x_2, \dots, x_d)^T$: 增广的特征矢量;

■ $\mathbf{w} = (w_0, w_1, w_2, \dots, w_d)^T$: 增广的权矢量;

下标从0开始




一、线性判别函数

I 两类问题的决策规则

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 \begin{cases} > 0, & \mathbf{x} \in C_1 \\ < 0, & \mathbf{x} \in C_2 \\ = 0, & \text{拒} \end{cases}$$

相当于把 w_0 作为阈值



Farkas定理：不等式组 $A\mathbf{w} < 0, \mathbf{c}^T \mathbf{w} > 0$ 有解的充要条件是： $A^T \mathbf{y} = \mathbf{c}, \mathbf{y} \geq 0$ 无解。


一、线性判别函数

I 决策面(超平面) H分析

它将 C_1 类与 C_2 类的样本分开

决策面H的方向(法向量) w

一般来说, 决策面将特征空间分成两个半空间, 分别对应于 C_1 类与 C_2 类的决策域 C_1, C_2 。



由于当 $x \in C_1$ 时, $g(x) > 0$ 所以决策面的方向指向 C_1

决策面H的正侧 C_1 所在的侧

决策面H的负侧 C_2 所在的侧

总之, 决策面的方向由 w 确定, 位置由阈值 w_0 确定。

一、线性判别函数


决策面的几何意义

- 决策面(decision boundary) H 方程: $g(x)=0$
- 向量 w 是决策面 H 的法向量
- $g(x)$ 是点 x 到决策面 H 的距离的一种代数度量


$$g(x)=w^T x + w_0$$

$x = x_p + r \frac{w}{\|w\|}$, 且 $g(x) = r \|w\|$
到 H 上的投影
 x_p 是 x 在 H 上的投影

线性判别函数可看作是模式 x 到决策面 H 的距离的函数。



一、线性判别函数



- $g(X)$ 是 d 维空间任一点 x 到决策面 H 的距离的代数度量
- w_0 体现该决策面在特征空间中的位置
 - 1) $w_0=0$ 时, 该决策面过特征空间坐标系原点, $g(0) = w_0$
 - 2) 否则, $r_0 = w_0 / \|w\|$ 表示坐标原点到决策面的距离

一、线性判别函数

线性判别分界总结

- 线性分类界面 H 是 d 维空间中的一个超平面；
- 分类界面将 d 维空间分成两部分， C_1 、 C_2 分别属于两个类别；
- 判别函数的权矢量 w 是一个垂直于分类界面 H 的矢量，其方向指向区域 C_1 ；
- 偏置 w_0 与原点 to 分类界面 H 的距离有关：
$$r_0 = \frac{w_0}{\|w\|}$$

总之，利用线性判别函数进行决策，就是用一个超平面把特征空间分割成两个决策区域。

判别函数 $g(x)$ 正比于 x 点到超平面的有向距离。

一、线性判别函数

线性分类器设计的主要步骤

所谓设计线性分类器，就是利用训练样本集建立线性判别函数。

- 估计其中未知参数 w 和 w_0 ，即寻找最好参数的过程。
- 最好的参数往往是准则函数的极值点。
- 转化为利用训练样本集寻找准则函数的极值点 w 和 w_0 的问题。

$$g(x) = w^T x + w_0$$

一、线性判别函数

具体过程

- ① 获取训练样本集，即一组具有类别标志的样本集：

$$X = \{x_1, x_2, \dots, x_n\}$$

X 可看作确定性样本集，也可看作随机样本集。

- ② 确定一个准则函数 $J(X, w, w_0)$

J 值反映分类器的性能，其极值解对应于“最好”的决策。


- ③ 用最优化方法求出准则函数的极值解 w^* 和 w_0^* 。

$$\{w^*, w_0^*\} = \arg \min_{w, w_0} J(X, w, w_0)$$

4. 对未知样本 x ，只要计算 $g(x)$ ，然后根据决策规则判定 x 所属类别。

一、理解线性判别函数

- 训练和测试过程分开，不同的样本集
- 训练过程中有模型选择问题



一、线性判别函数

分类决策问题（二分类及多分类）

1. 分类的基本原理

不同模式对应的特征点散布在不同的区域中。运用已知类别的训练样本进行学习，产生若干个代数界面 $g(x)=0$ ，将特征空间划分成一些互不重叠的子区域。

2. 判别函数

表示判别边界的函数 $g(x)$ 称为判别函数（Discriminant Function）。

一、线性判别函数




多类决策问题

➤ 线性可分性

- 假设已知一组容量为 n 的样本集，如果有一个线性分类器能把每个样本正确分类，则称这组样本集为**线性可分的**；否则称为**线性不可分的**。
- 反过来，如果样本集是线性可分的，则必然存在一个线性分类器能把每个样本正确分类。
- 假设样本集是线性可分的，在多类情况下，比如 m 类，往往需要定义多个线性判别函数，通常有三种方案。

一、线性判别函数

多分类分类边界及线性可分示例：



两类分类问题，分界线
是一个判别函数

两类问题中线性不可
分的实例

三类分类问题，边
界线也是一个判别
函数

一、线性判别函数

多类决策问题

- 前面讲到的大都是二分类学习任务，现实应用中常常会遇到多分类学习任务
- 多分类学习方法
 - 二分类学习方法推广到多类
 - 利用二分类学习器解决多分类问题（常用）
 - ✓ 对问题进行拆分，为拆出的每个二分类任务训练一个分类器
 - ✓ 对每个分类器的预测结果进行集成以获得最优的多分类结果
- 拆分策略
 - 一对其余（One vs. Rest, 0vR）
 - 一对一（One vs. One, 0v0）
 - 多对多（Many vs. Many, MvM）

一、线性判别函数


方案一：一对其余

线性判别函数将属于 ω_i 类的模式与其余不属于 ω_i 类的模式分开， m 类分类问题转换成 $m-1$ 个两类问题。 m 类问题要有 m 个判别函数 d_i , $i = 1, 2, \dots, m$ 。

判别规则为:
$$\begin{cases} d_i(x) > 0 \\ d_j(x) \leq 0 \end{cases} \quad \forall j \neq i, \text{ 判 } x \text{ 属于 } \omega_i \text{ 类。}$$


比如对图的三类问题，如果对于任一模式 如果它的

则该模式属于 ω_1 类。



一、线性判别函数

如果某个 x 使二个以上的判别函数 $d_i > 0$ 。则此模式 x 就无法作出确切的判决。如图



另一种情况是IR2区域，判别函数都为负值。IR1，IR2，IR3，IR4，都为不确定区域。

一、线性判别函数

例子：已知三类 w_1 , w_2 , w_3 的判别函数分别为：

$$\begin{cases} d_1(\vec{x}) = -x_1 + x_2 \\ d_2(\vec{x}) = x_1 + x_2 - 5 \\ d_3(\vec{x}) = -x_2 + 1 \end{cases}$$

求：当 $\vec{x} = (x_1, x_2)' = (6, 5)'$ 时，属于哪一类？

解：三个判别边界分别为：

将 $\vec{x} = (x_1, x_2)' = (6, 5)'$ 代入方程组：

$$\begin{cases} d_1(\vec{x}) = -x_1 + x_2 \\ d_2(\vec{x}) = x_1 + x_2 - 5 \\ d_3(\vec{x}) = -x_2 + 1 \end{cases}$$

得：

$$d_1(\vec{x}) = -1, d_2(\vec{x}) = 6, d_3(\vec{x}) = -4.$$

结论：因为 $d_1(x) < 0, d_2(x) > 0, d_3(x) < 0$ 所以它属于 ω_2 类。

一、线性判别函数

方案二：一对一

对 m 类中的任意两类 ω_i 和 ω_j 都分别建立一个判别函数，这个判别函数将属于 ω_i 类与 ω_j 类的模式区分开，此函数对其他分类不提供信息，因此， m 类问题需要建立

$m(m-1)/2$ 个判别函数 d_{ij} , $i = 1, 2, \dots, m$


判别规则为：

若 $d_{ij}(x) > 0, j \neq i$

$j = 1, 2, \dots, m$

则判 x 属于 ω_i 类。

采用这种方案，判别空间中同样可能存在不确定区域，如图中的斜线区域。不确定区域中的模式无法确定其类别。



一、线性判别函数

例：设有一个二维三类问题，三个判别函数为：

$$d_{12}(\vec{x}) = -x_1 - x_2 + 5 \quad d_{13}(\vec{x}) = -x_1 + 3 \quad d_{23}(\vec{x}) = -x_1 + x_2$$

求模式 $\vec{x} = (4, 3)'$ 属于哪一类？

解：将模式 $\vec{x} = (4, 3)'$ 代入 $d_{ij}(\vec{x})$ 有：

$$d_{12}(\vec{x}) = -2 \Rightarrow \vec{x} \notin \omega_1$$

$$d_{23}(\vec{x}) = -1 \Rightarrow \vec{x} \notin \omega_2$$

$$d_{13}(\vec{x}) = -1 \Rightarrow \vec{x} \notin \omega_1$$

上面三式等效为： $d_{21}(\vec{x}) = 2 \quad d_{31}(\vec{x}) = 1 \quad d_{32}(\vec{x}) = 1$

由于 $d_{3j}(\vec{x}) > 0 \quad (j = 1, 2)$ ，所以判 $\vec{x} \in \omega_3$

一、线性判别函数

方案三：多对多

m 类问题定义 m 个判别函数 d_i , $i=1, 2, \dots, m$ 。


判别规则为: 若 $d_i(x) > d_j(x)$, $j \neq i$; $i, j=1, 2, \dots, m$
则判 x 属于 ω_i 类。

决策面 H_{ij} 方程为

$$d_i(x) = d_j(x)$$

$j \neq i$; $i, j=1, 2, \dots, m$

采用这种方案，决策空间中**不存在不确定区域**，处理多类问题时通常采用这种方案。



一、线性判别函数

例：设有一个二维三类问题，三个判别函数为：

$$d_1(\vec{x}) = -x_1 + x_2 \quad d_2(\vec{x}) = x_1 + x_2 - 1 \quad d_3(\vec{x}) = -x_2$$

求模式 $\vec{x} = (1, 1)'$ 属于哪一类？

解：将模式 $\vec{x} = (1, 1)'$ 代入上面各式得：

$$d_1(\vec{x}) = 0 \quad d_2(\vec{x}) = 1 \quad d_3(\vec{x}) = -1$$

$$\text{由于} \quad \begin{cases} d_2(\vec{x}) > d_3(\vec{x}) \\ d_2(\vec{x}) > d_1(\vec{x}) \end{cases} \quad \text{所以} \quad \vec{x} \in \omega_2$$

一、线性判别函数

上述三种方法小结:


当 $n > 2$ 时, 法比 法需要更多的判别函数式
这是一个缺点。

但是 法是将 类与其余的 类区分开, 而
法是将 类和 类分开, 显然 法使模式更
更容易线性可分, 这是它的优点。

方法(3)判别函数的数目和方法(1)相同, 但没有不确定区,
分析简单, 是最常用的一种方法。

一、线性判别函数

多类问题线性分类器



二、最小距离准则

最小欧氏距离准则

d 维空间中两个向量之间的欧氏距离

设 $x = (x_1, x_2, \dots, x_d)^T, y = (y_1, y_2, \dots, y_d)^T$

则 x, y 之间的欧氏距离 d 为 $d^2 = (x-y)^T(x-y)$

同类模式在模式空间中应相互靠近, 根据这一特点, 我们可利用**距离最小准则**来设计分类器。

设有 m 类已知类别的模式(样本)集。计算 ω_i 类中所有样本的均值 μ_i , 记样本 x 到 ω_i 类的距离为

$$d_i(x) = (x - \mu_i)^T (x - \mu_i), i = 1, 2, \dots, m$$

二、最小距离准则

按最小距离分类原理，决策规则为

若 $D_i(x) < D_j(x)$, $j \neq i$; $i, j = 1, 2, \dots, m$

则判 x 属于 ω_i 类


如图，各类的中心用黑点表示

★ 表示待判样本

$$\begin{aligned} d_i(x) &= (x - \mu_i)^T (x - \mu_i) \\ &= x^T x - 2\mu_i^T x + \mu_i^T \mu_i \end{aligned}$$

记 $g_i(x) = 2\mu_i^T x - \mu_i^T \mu_i$

显然, $g_i(x)$ 为线性函数



决策规则为：若 $g_i(x) > g_j(x)$, $j \neq i$; $i, j = 1, 2, \dots, m$

则判 x 属于 ω_i 类。

二、最小距离准则

从以上分析可知，最小欧氏距离分类器的判别函数可用线性函数代替，

$$g_i(x) = 2\mu_i^T x - \mu_i^T \mu_i = w^T x + w_0$$

$$\Rightarrow w = 2\mu_i^T, w_0 = -\mu_i^T \mu_i$$

所以最小距离分类器实质上是线性分类器。

最小欧氏距离分类器构造简便，使用方便，但是分类效果常常不理想。

分类效果不好的原因在于判别函数的权向量及阈值仅仅利用了各类样本的均值信息，而没有充分利用样本的其它信息。

二、最小距离准则

1. 欧氏距离
2. 曼哈顿距离
3. 切比雪夫距离
4. 闵可夫斯基距离
5. 标准化欧氏距离
6. 马氏距离
7. 夹角余弦
8. 汉明距离
9. 杰卡德距离 & 杰卡德相似系数
10. 相关系数 & 相关距离
11. 信息熵

三、感知器准则

1. 几个基本概念
2. 感知器准则函数
3. 梯度下降算法

三、感知器准则

几个基本概念

(1) 线性可分性及其概率

假设已知一组容量为 n 的样本集 $y_1, y_2, \dots, y_n$ ，其中 y_i 为 d' 维增广样本向量，分别来自 ω_1 类和 ω_2 类。如果存在一个权向量 w ，使得对于任何 $y \in \omega_1$ ，都有 $w^T y > 0$ ，而对于任何 $y \in \omega_2$ ，都有 $w^T y < 0$ ，则称这组样本集为线性可分的，否则为线性不可分。

反过来，如果样本集是线性可分的，则必存在一个权向量 w ，能将这个样本集正确的分类。

三、感知器准则

(2) 样本的规范化

如果样本集 $y_1, y_2, \dots, y_n$ 是线性可分的, 则必存在某个或某些权向量 w , 使得:

$$\begin{cases} w^T y_i > 0, & y_i \in \omega_1 \\ w^T y_j < 0, & y_j \in \omega_2 \end{cases}$$

如果在来自 ω_2 类的样本 y_j 前面加上一个负号, 即令 $y'_j = -y_j$, 其中 $y_j \in \omega_2$, 则有 $w^T y'_j > 0$ 。因此, 令

$$y'_n = \begin{cases} y_i, & \text{对于 } y_i \in \omega_1 \\ -y_j, & \text{对于 } y_j \in \omega_2 \end{cases}$$



上述过程称为**样本的规范化**, y'_n 叫做**规范化增广样本向量**。

三、感知器准则

(3)解向量和解区

在线性可分情况下，满足 $w^T y_i > 0, i=1,2,\dots,n$ 的权向量 w 称为解向量


方程 $w^T y_i = y_i^T w = 0$ 确定了一个以 y_i 为法向量的超平面， n 个样本将产生 n 个超平面，每个超平面把权空间分为两个半空间，且 w 位于正半空间。解向量若存在，必在 n 个正半空间的交迭区，且该区任意向量都是解向量 w 。可见解向量往往不只一个，而是无穷多个解向量组成的区域，称之为解区。



三、感知器准则

(4)对解区的限制

- 对解区加以限制的目的在于使解向量 w 更可靠。通常认为，越靠近解区中心的解向量，似乎越能对新的样本正确分类。
- 因此，引入余量 $b > 0$ ，并寻找满足 $w^T y_i \geq b$ 的解向量。显然，由 $w^T y_i \geq b > 0$ 所产生的正半空间的交迭区(即新解区)位于原解区之中。
- 它的边界离开原解区边界的距离为 $b / \|y_i\|$ 。如图所示。
- 引入余量的目的是使解向量 w 不在解区的边界点上。



三、感知器准则

● 感知器准则函数

➤ 设有一组样本， $\mathbf{y}_1, \dots, \mathbf{y}_n$ ，其中 $\mathbf{y}_i$ 是规范化增广样本向量，我们要找一个解向量 $\mathbf{w}$ ，使得 $\mathbf{w}^T \mathbf{y}_i > 0, i = 1, 2, \dots, n$ 。显然，对于线性可分情况，问题才有解。为此这里首先考虑处理线性可分问题的算法。

➤ 构造准则函数： $J^P(\mathbf{w}) = \sum_{\mathbf{y} \in Y^e} (-\mathbf{w}^T \mathbf{y})$ 使 $J^P(\mathbf{w})$ 最小

□ 恒有 $J^P(\mathbf{w}) \geq 0$ ， Y^e 是被权向量 $\mathbf{w}$ 错分类的样本集合

□ 当 $\mathbf{y}$ 被错分类时 $\mathbf{w}^T \mathbf{y} \leq 0$, 则 $-\mathbf{w}^T \mathbf{y} \geq 0$

➤ 因此， $J^P(\mathbf{w})$ 总是大于等于0，仅当 $\mathbf{w}$ 为解向量 $\mathbf{w}^*$ 在解区边界上时， $J^P(\mathbf{w})$ 才为0。这一准则函数称为感知器准则函数。

三、感知器准则

● 梯度下降算法

- 我们采用梯度下降法求解，使 $J_P(w)$ 达到极小值的解向量
- 先将准则函数对 w 求梯度：

$$\nabla J^P(w) = \frac{\partial J^P(w)}{\partial w} = \sum_{y \in Y^e} (-y)$$

- 梯度下降法的迭代公式为： $w^{k+1} = w^k - \rho^k \nabla J$


- 由上两式可得： $w^{k+1} = w^k + \rho^k \sum_{y \in Y^e} y$

- **梯度下降法**可以简单叙述为，任意给定初始权向量 w^1 ，第 $k+1$ 次迭代的权向量 w^{k+1} 等于第 k 次的权向量加上被 w^k 错分的样本之和乘以某个系数 ρ_k

三、感知器准则


➤ 批修正法

- 在迭代过程中，每次都用到所有错分的样本



三、感知器准则

下图以**二维**为例，对 $w^1 = 0$, $\rho_k = 1$ 的情况，说明算法是如何在有限步内找到一个解向量 w^* 。




三、感知器准则

➤ 单样本修正法

□ 样本集看作一个不断重复出现的序列而逐个加以考虑。


□ 对于任意权向量 w^k ，如果它把某个样本分错了，则对 w^k 做一次修正




三、感知器准则

➤ 固定增量法

把 ρ_k 看作不随 k 而变化的常数，
特定地取 $\rho_k = 1$



三、感知器准则



w^k 收敛到解区域

四、最小平方误差准则

- 最小平方误差准则函数
- MSE准则函数的算法

四、最小平方误差准则

- 由于感知器准则及其梯度下降算法只适用于线性可分情况，对于线性不可分情况，迭代过程永远不会终结，即算法不收敛，实际问题事先无法确定是否线性可分。
- 希望得到一种对两种情况都可适用的线性判别算法：
 - 对线性可分问题，可得到一个如感知器准则函数那样的解向量；
 - 对线性不可分问题，能够得到一个使某种度量误差（或损失）的准则函数达到最小值的解向量。

四、最小平方误差准则

● 最小平方误差准则函数

- 设 $\mathbf{y}_i$ ($i = 1, 2, \dots, n$) 为规范化增广样本, $\mathbf{w}$ 为增广权向量, 对两类线性可分问题, 有

$$\mathbf{w}^T \mathbf{y}_i = b_i > 0, \quad i = 1, 2, \dots, n$$

- 写成向量形式 $\mathbf{Y}\mathbf{w} = \mathbf{b}$, 其中 $\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^T \\ \mathbf{y}_2^T \\ \dots \\ \mathbf{y}_n^T \end{bmatrix}$, $\mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \dots \\ b_n \end{bmatrix}$
- $\mathbf{b}$ 是事先给定的常数, 与样本集无关

四、最小平方误差准则

- 但我们可以定义一个误差向量 $\mathbf{e} = \mathbf{Y}\mathbf{w} - \mathbf{b}$
- 并定义平方误差准则函数

$$J(\mathbf{w}) = \|\mathbf{e}\|^2 = \|\mathbf{Y}\mathbf{w} - \mathbf{b}\|^2 = \sum_{k=1}^n (\mathbf{w}^T \mathbf{y}_k - b^k)^2$$

- 然后找一个使 $J(\mathbf{w})$ 极小化的 $\mathbf{w}$ 作为问题的解, 此解是方程组的最小二乘法近似解, 也称为伪逆解或称为MSE解

- 令 $\nabla J(\mathbf{w}) = \sum_{k=1}^n 2(\mathbf{w}^T \mathbf{y}_k - b^k) \mathbf{y}_k = 2\mathbf{Y}^T(\mathbf{Y}\mathbf{w} - \mathbf{b}) = 0$

- 得 $\mathbf{Y}^T \mathbf{Y} \mathbf{w} = \mathbf{Y}^T \mathbf{b} \Rightarrow \mathbf{w} = (\mathbf{Y}^T \mathbf{Y})^{-1} \mathbf{Y}^T \mathbf{b} \triangleq \mathbf{Y}^+ \mathbf{b}$

- $\mathbf{Y}^+$ 是 $\mathbf{Y}$ 的左逆矩阵, $\mathbf{w}$ 就是MSE解

四、最小平方误差准则

- MSE准则函数的算法

- 利用最小二乘法求得的MSE解 w 需要计算矩阵 Y 的左逆 $Y^+ = (Y^T Y)^{-1} Y^T$ 由此带来两个问题:

- 要 $Y^T Y$ 求矩阵可逆,若 $Y^T Y$ 不可逆,将得不到解

- 计算量大,同时可能引入较大的计算误差

- 实际应用中,往往不用这样得解析方法求MSE解,而是用梯度下降算法等最优化技术来求解

四、最小平方误差准则

- Widrow-Hoff算法

➤ $J(\mathbf{w})$ 的梯度为 $\nabla J(\mathbf{w}) = 2\mathbf{Y}^T(\mathbf{Y}\mathbf{w} - \mathbf{b})$

➤ 则梯度算法可写成:
$$\begin{cases} \mathbf{w}^1 = \text{任意值} \\ \mathbf{w}^{k+1} = \mathbf{w}^k - \rho^k \mathbf{Y}^T(\mathbf{Y}\mathbf{w} - \mathbf{b}) \end{cases}$$

➤ 可以证明,如果选择 $\rho^k = \rho_1/k, \rho_1$ 取任意值, 则该算法得到的权向量序列 $\mathbf{w}^k$ 收敛于 $\mathbf{w}$,使 $\nabla J(\mathbf{w}) = 0$

➤ 无论矩阵是否可逆,该算法总能产生一个有用的权向量,且计算量小的多

小结

- 线性判别函数
 - 基本概念
 - 几何意义
 - 线性判别函数可看作是模式 x 到决策面 H 的距离的函数
 - 设计步骤
 - 分类决策问题
 - 一对其余 & 一对一 & 多对多
- 最小距离准则
- 感知器准则
- 最小平方误差准则