


深度神经网络 I

Deep Neural Networks



内容


动机

—

—

Why


Deep



动机——Why Deep Learning?

深度学习

深度学习是机器学习的分支，以多层神经网络为架构，从数据中自动学习特征表示，并进行预测或决策。深度学习的“深度”指的是神经网络的层数较多，能够学习到数据的多层次抽象表示。



生物学启示


■ 人脑视觉机理

■ “视觉系统的信息处理”：可视皮层是分级的

- 大脑皮层包括V1, V2, V4, PMC, PFC等区域
- 每一部分功能不同,

■ 神经-中枢-大脑的工作过程，或许是一个不断迭代、不断抽象的过程。



- 从原始信号，做低级抽象，逐渐向高级抽象迭代。人类的逻辑思维，经常使用高度抽象的概念。



生物学启示

■ 视觉信息的层次化抽象示例

1. 视网膜（**Retina**）获取图像的像素点
2. 低级的**V1**区提取边缘特征
3. V2区获取基本形状或目标的局部
4. 高层**V4**得到整个目标（如判定为一张人脸）
5. 更高层的**PFC**（前额叶皮层）进行分类判断等。



脑的深层结构

生物学启示

- 深度学习就是基于大脑的分层结构，设计出的多层神经网络系统，可以自动学习数据的不同抽象层次的特征
 - 2006年，加拿大多伦多大学教授Geoffrey Hinton和他的学生在《科学》上发表了一篇文章，开启了深度学习在学术界和工业界的浪潮。
 - A fast learning algorithm for deep belief nets
 - 这篇文章证实了多隐层的人工神经网络具有优异的特征学习能力，学习得到的特征对数据有更本质的刻画，从而有利于数据的识别与分类

传统机器学习


解决问题的思路




能不能自动地学习一些特征呢？

能！ Deep Learning





Computer Vision Features



Audio Features




频谱图



CC


梅尔频率倒谱系数

Deep Learning




Flux

谱通量



ZCR

零交叉率



Rolloff

谱滚降点

Deep Learning 基本思想

如何获取多层次特征

- 假设有

Deep Learning 基本思想

“深度模型”是手段，“特征

Deep Learning 基本思想

深度模型的特征学习能力

传统神经网络模型存在的问题

- 需要带标签训练数据

- 实际中几乎所有的数据是无标签的
- 人脑可以从无标签数据中学习


- 网络训练

- 采用BP算法
- BP算法存在梯度消失或膨胀问题，很难扩展到多层

- 梯度消失/爆炸问题：

随着网络层数增加，反向传播过程中，损失函数相对于权重的梯度可能会变得非常小。使得后面的层难以学习任何有意义的模式，因为权重的更新可以忽略。

相反，某些情况下，反向传播过程中的梯度可能会变得非常大，使得权重更新量过大，导致训练不稳定，使优化过程难以控制。



传统神经网络模型存在的问题

■ BP算法梯度消失 或膨胀分析

■ 各层神经元误差项的 ϑ_s 的推导

$$\Delta \omega_{ji} = -\eta x_{ji} y_i (1 - y_i) (y_i - d_i) = -\eta x_{ji} \vartheta_j \quad (\text{输出层})$$

ϑ_j 为输出层(t)单元误差项

$$\begin{aligned} \Delta \omega_{kj} &= -\eta x_k y_j (1 - y_j) \sum_{i=1}^n \omega_{ji} y_i (1 - y_i) (y_i - d_i) = -\eta x_k \sum_{i=1}^n \omega_{ji} y_j (1 - y_j) \vartheta_j \\ &= -\eta x_k \vartheta_k \end{aligned}$$

最后一个隐藏层(t-1)梯度变化量

ϑ_k 最后一个隐藏层(t-1)梯度变化量

以此代入，隐藏层t-q的单元误差项：

$$\vartheta_i(t-q) = \sum_{l_{t-q+1}=1}^n \cdots \sum_{l_t=1}^n \prod_{m=1}^q w_{l_m l_{m-1}} y'_{l_m}(t-m) \cdot \vartheta_k(t) \quad \vartheta_k(t) \text{ 输出层误差项}$$

$y'_{l_m}(t-m)$ 为隐藏层(t-m)中第 l_m 个神经元的输出

l_{t-q+1} 表示的是第 $t-q+1$ 层中神经元的下标 (即第 $t-q+1$ 层第 l_{t-q+1} 个神经元) , l_t 表示第 t 层的下标。

$m=0$ 对应输出层, $m=q$ 对应第 $t-q$ 层。

传统神经网络模型存在的问题

- BP算法梯度消失 或膨胀分析
 - 梯度分析

$$\vartheta_i(t-q) = \sum_{l_{t-q+1}=1}^n \cdots \sum_{l_t=1}^n \prod_{m=1}^q w_{l_m l_{m-1}} y'_{l_m}(t-m) \cdot \vartheta_k(t) \quad \vartheta_k(t) \text{ 输出层误差项}$$

在上面的式子中, 如果对于所有的 m 有

$$|w_{l_m l_{m-1}} y'_{l_m}(t-m)| > 1.0$$

则梯度会随着反向传播层数的增加而呈指数增长, 导致梯度爆炸。

如果对于所有的 m 有


$$|w_{l_m l_{m-1}} y'_{l_m}(t-m)| < 1.0$$

则在经过多层的传播后, 梯度会趋向于0, 导致梯度消失。

传统神经网络模型存在的问题


- BP算法梯度消失 或膨胀分析

- 简单理解：随着迭代次数的增加越来越多的神经元进入饱和区，阻止了梯度的传播



$$\sigma = \frac{1}{1+e^{-x}}$$

$$\sigma'(x) = \sigma(x) \cdot (1 - \sigma(x))$$



训练深度神经网络


■ 如何训练深度神经网络

- 预训练：建立产生输入的生成式模型，调整参数使得生成式模型的概率最大
 - 学习 $p(\text{input data})$ ，而不是 $p(\text{label} \mid \text{input data})$
 - 通过“逐层初始化” (layer-wise pre-training) 来有效克服梯度消失或膨胀问题
 - 自下向上的非监督学习 (greedy layer-wise training)
- 微调：通过整体微调适配具体任务
 - 自顶向下的监督学习
 - 就是通过带标签的数据去训练，误差自顶向下传输，对网络进行微调
 - 微调特征（中间层），使得与问题更相关。

训练深度神经网络

■ 预训练（pre-training）


- 使用一种贪婪的、逐层训练
- 使用无监督学习，每次训练一层
- 固定先前隐藏层的参数，再训练下一层
- 先前的层可以被视为特征提取



训练深度神经网络

■ 微调

- 添加输出层
- 使用监督学习训练整个网络
- 监督学习的执行方式与常规网络相同
 - 前向传播、反向传播和更新
- 我们将这一个阶段称为微调
 - 所有参数都针对目标任务进行“调整”
 - 学习到更具辨别力特征表示



传统机器学习与深度学习对比



特征	机器学习	深度学习
数据要求	适用于较小的结构化数据	需要大量非结构化数据
特征工程	手动完成	由模型自动完成
计算能力	要求较低	需要高性能计算
训练时间	相对较短	更长
可解释性	相对较好	通常被称为“黑匣子”
适合的问题	简单或中等复杂的任务	涉及图像、音频或自然语言的高度复杂任务

Deep Learning的常用模型

——AutoEncoder自动编码器

AutoEncoder自动编码器


- **AutoEncoder**是多层神经网络的一种非监督式学习算法，其架构可解析为**Encoder**（编码器）和**Decoder**（解码器）两个部分，它们分别做压缩与解压缩的动作，让输出值和输入值相同
- 通常**AE**的隐藏层节点数少于输入层节点数，通过重建输入，编码器会建立隐藏层（一个或多个层）对输入信息的低维表示。




AutoEncoder自动编码器

- 其它不同形式的AutoEncoder
 - 变分自编码器
 - 降噪自编码
 - 稀疏自编码器
 - 栈式自编码器（重点）


Auto Encoder (AE)



Variational AE (VAE)



Denoising AE (DAE)




Sparse AE (SAE)



AutoEncoder自动编码器

- 变分自编码器 (VAE)


- 用于图像生成
- 编码器经训练学习到输入图像数据的概率分布，即正态分布的均值和方差，从该分布进行采样，经解码器生成富有变化的图像



AutoEncoder自动编码器

- 降噪自编码器（Denoising AE）


- 去掉输入数据的噪声，恢复其原始表示
- 实现：在输入中加入随机噪声，之后输出原始无噪声的数据，使模型学会去噪的能力。



AutoEncoder自动编码器


■ 稀疏自编码器（Sparse AE）

- 稀疏AE是在AutoEncoder的基础上加上L1 正则化，使得编码器将每个输入表示为少量节点的组合，只有一部分节点非零值，称为活动节点。
- 特征稀疏化可以过滤掉无用的信息，因此稀疏AE可以给出比原始数据更好的特征描述。




Stacked AutoEncoder 栈式自编码器

- 最基本的一种深度学习方法
- 利用多层神经网络学习不同层次的抽象特征
 - 给定一个神经网络，令其输出与输入是相同的，训练调整其参数，得到每一层的权重
 - 每一层的输出就代表一种特征表示
- 自动编码器就是一种尽可能复现输入信号的神经网络。
 - 为了实现这种复现，自动编码器就必须捕捉可以代表输入数据的最重要的因素



Stacked AutoEncoder 栈式自编码器


从
无
标
签
数
据
学
习
数



之前的前向神经网络中，如左图，输入的样本是有标签的，即（input, target），这样根据当前输出和target（label）之间的差去改变前面各层的参数，直到收敛。

但现在我们只有无标签数据，也就是右边的图。那么这个误差怎么得到呢？

Stacked AutoEncoder 栈式自编码器



- 采用无监督学习
 - 因为是无标签数据，所以误差就是重构后的输出数据与原输入数据的差值
- 通过调整encoder和decoder的参数，使得重构误差最小，这样就得到输入信号的一个特征表示，即图中code。

Stacked AutoEncoder 栈式自编码器

- Deep结构——逐层训练

- 自编码器“栈化”
- 通过编码器产生特征，依次训练下一层。

得到第一层的code，重构误差最小，让我们相信这个code就是原输入信号的良好表达，或者说，它和原信号代表的是同一个东西，只是表达不一样。

第二层和第一层的训练方式类似，将第一层输出的code当成第二层的输入信号，同样最小化重构误差，就会得到第二层的参数，并且得到第二层输入的code，也就是原输入信息的第二个特征表达。

其他层也以同样的方法进行。



Stacked AutoEncoder 栈式自编码器


- Deep 网络，每一

Stacked AutoEncoder 栈式自编码器

最后、只调整分类器



层的
2、通过有标签样本，
微调整个系统：（如
果有足够多的数据）

code



两隐层自编码网络MNIST手写数字识别


训练一个包含两个隐含层的栈



两隐层自编码网络MNIST手写数字识别


固定上一层网络参数；

把上一层的



两隐层自编码网络MNIST手写数字识别


将二阶特征作为 softmax



4

两隐层自编码网络MNIST手写数字识别

将这三层结合起来构成一个栈式



栈式自编码器神经网络总结

■ 栈式自编码器神经网络具有强大的表达能

栈式自编码器神经网络总结

