



面向领域的计算机系统设计与实践

课题报告

题目：认知双过程驱动的多模态立场检测

姓名：金正达

学号：220110515

日期：2025.12.17

1. 课题背景

随着支持图文等多种形式内容的社交媒体平台的普及，多模态立场检测（Multimodal Stance Detection, MSD）已成为理解公众意见的关键任务。多模态立场检测旨在通过综合分析文本与图像两种信息，识别出用户对于特定目标的所表达的态度，相较于仅依赖文本的分析方法，这种综合性的分析能够提供更全面的视角。因此，该任务在政治话语分析、虚假信息检测和公共卫生传播等领域具有广泛的应用价值，是解码复杂在线互动的重要工具。

当前，已有的多模态立场检测方法主要致力于提升模型提取多模态特征的能力。然而，这些方法大多倾向于简单地融合来自不同模态的信息来学习立场表达，却忽略了一个关键问题：在不同的样本中，不同模态（文本或图像）对最终立场决策的贡献度是动态变化的。




现有研究在这一方面存在两点主要局限。首先，单个模态的信息价值高度依赖于上下文，如上图中的(a)和(b)所示——某个模态在孤立状态下可能具有模糊性或无关性，难以为立场检测提供有效的证据支持。因此，若模型无法准确判定模态贡献度，就容易受到此类低质量输入数据的干扰。其次，模态间的语义关系并非固定不变，而是动态演变的，如上图中的(c)和(d)所展示的互补性与矛盾性共存的现象。简单的特征对齐方法难以驾驭这种微妙的交互关系。因此，当模型遇到贡献度不一的模态信息时，现有方法倾向于不加区分地将低质量信息与高置信度的判断相融合，从而污染整个检测过程，影响最终结果的准确性。

2. 框架设计

(1) 框架总览

本课题提出一种基于双重推理机制的多模态立场检测框架——ReMoD（Rethinking Modality Contribution of stance expression through a Dual-reasoning paradigm），以实现模态贡献的动态再思考与自适应优化，使模型能够在不同话题、不同风格以及跨域迁移场景中稳定工作。



如图所示，ReMoD 框架的设计理念借鉴了认知心理学中的“双过程理论”，即人类决策中的“直觉式推理系统（System1）”与“反思式推理系统（System2）”。模型通过模拟两种推理模式的协同工作，实现从经

验驱动的快速判断到理性审视的自我修正，从而增强立场推断的鲁棒性与可解释性。研究工作以人类双过程认知理论为方法论支点，将依赖经验的直觉判断与可追溯的反思性推理植入到统一的多模态管线之中，形成由知识感知、经验检索与直觉预测、反思生成与经验演化、立场推断等环节耦合而成的整体方案。通过在文本与图像两个模态层面同时进行知识获取与证据对齐，结合跨模态可检索的经验记忆池，实现对复杂舆情样本的细粒度理解与稳健推断。

（2）多模态感知模块

多模态知识感知模块是整个框架的基石，其目标是最大限度地从原始输入中提取结构化的语义信息，为后续的推理提供高质量的原料。这个过程分为两个并行的分支：

在文本处理上，首先对输入文本进行命名实体识别，再利用这些实体作为索引，从外部知识库中检索相关的背景知识和详细描述。最后，将原始文本和检索到的背景知识融合，通过大型语言模型提炼成一份精炼的、包含核心信息的“文本知识摘要”。

在视觉处理上，使用先进的 VLM 为图像生成详细的标题，再识别出图像中的所有关键视觉实体，随后和文本处理一样，提取出“图像知识摘要”。此外，还会利用 SAM 模型，对识别出的视觉实体进行精确的像素级分割，获取细粒度视觉信号。

（3）经验驱动的直觉推理模块

经验驱动的直觉推理模块旨在模拟人类基于经验的“系统 1”快速反应。此阶段的核心是利用历史经验，迅速对当前的多模态信息形成一个初步的判断。

本框架中包含两个核心的经验池，其中模态经验池存储了关于“如何权衡不同模态”的经验；语义经验池存储了关于“如何理解特定语义”的经验。当接收到新的图文输入时，会进行模态协同检索，即获取文本和图像的加权向量嵌入，从两个经验池中检索最相关的历史经验片段。

智能体最后将当前感知到的知识（来自多模态感知模块）与检索到的经验（来自经验池）相结合，并被要求从三个独立的角度进行快速评估，生成包含预测和理由的“初始假设”，并将其传递给模块三进行深入反思。

（4）深思熟虑的反思推理模块

深思熟虑的反思推理模块是模拟“系统 2”的关键，它负责对“系统 1”提出的直觉假设进行批判性的审查、验证和优化。这一过程通过两种思维链反思机制来实现：模态思维链负责评估不同模态在形成初始判断时的贡献和可靠性，智能体反思获得的新见解随后被用来更新模态经验池；语义思维链则负责深入挖掘图文之间的复杂语义关系和上下文逻辑，智能体的反思会提炼出对特定“语义模式”的深刻理解，并用来更新语义经验池。

通过这两个思维链过程，系统不仅得出了一个经过深思熟虑的最终结论，更重要的是，它将反思中学到的经验反哺回经验池，形成了一个持续学习和自我优化的闭环。

3. 实验结果

（1）实验设置

本课题选择使用 MMSD 数据集测试该框架的性能。该数据集包含五个不同的领域：

- Multi-modal COVID-CQ (MCCQ)
- Multi-modal Russo-Ukrainian Conflict (MRUC)
- Multi-modal Taiwan Question (MTWQ)
- Multi-modal Twitter Stance Election 2020 (MTSE)
- Multi-modal Will-They-Won't-They (MWTWT)

遵循数据集论文中的评测方法，采用 Macro-F1 作为主要指标进行评测。

(2) 实验结果

In Target 场景下的结果如下所示：

MODALITY	METHOD	MTSE		MCCQ		MWTWT					MRUC		MTWQ	
		DT	JB	CQ	CA	CE	AC	AH	DF		RUS	UKR	MOC	TOC
Text-only	BERT	48.25	52.04	66.57	75.62	60.85	63.05	59.24	81.53	41.25	46.80	57.77	45.91	
	RoBERTa	58.39	60.79	66.57	69.56	65.03	69.74	67.99	79.21	39.52	57.66	55.22	48.88	
	KEBERT	64.50	69.81	66.84	71.67	67.56	69.29	69.74	80.57	41.55	59.01	58.15	47.75	
	LLaMA2	53.23	52.67	47.40	34.89	41.95	49.09	44.32	30.21	38.84	38.54	55.31	46.51	
Vision-only	GPT4	68.74	66.39	65.84	63.14	65.12	69.93	71.62	52.69	41.64	53.76	58.05	49.81	
	ResNet	37.89	38.59	47.16	39.89	42.20	43.52	37.05	50.34	35.10	40.00	42.02	33.94	
	ViT	40.48	40.42	46.64	46.63	50.00	40.16	46.32	50.86	33.31	39.87	38.63	35.53	
	SwinT	39.89	40.43	48.80	46.30	46.99	41.02	47.39	51.32	35.01	40.89	35.03	35.47	
Multimodal	BERT+ViT	41.86	45.82	61.32	63.20	44.71	56.45	46.85	73.71	39.28	48.41	47.47	40.86	
	ViLT	35.32	48.24	47.85	62.70	56.44	58.06	60.22	73.66	34.62	42.41	44.43	59.51	
	CLIP	53.22	65.83	63.65	70.93	67.17	67.43	70.86	79.06	44.99	59.86	55.29	40.98	
	TMPT	55.41	61.61	67.67	76.60	63.19	67.25	62.92	81.19	43.56	59.24	55.68	46.82	
	TMPT+CoT	66.61	68.75	71.79	74.40	69.96	68.43	63.00	82.71	45.04	60.52	68.95	59.87	
	Qwen-VL	43.31	45.13	50.51	43.06	45.49	49.79	46.04	27.73	36.50	40.78	42.14	39.34	
	MiMo	66.21	65.89	61.54	45.32	42.19	50.69	42.36	40.26	39.30	58.95	60.07	52.39	
	LLaVa	49.48	45.80	60.30	20.48	28.48	33.83	38.94	31.57	36.53	47.47	50.45	47.07	
	Qwen2.5-VL	64.90	69.29	63.33	51.27	52.30	60.40	58.21	48.95	41.04	51.34	61.18	51.71	
	GPT4-Vision	70.46	72.82	61.63	44.59	47.07	57.47	57.90	37.61	44.83	56.40	66.72	56.90	
Backbones	ReMoD	68.93↑	70.33↑	72.90↑	58.85↑	56.61↑	69.98↑	60.22↑	65.54↑	50.81↑	62.42↑	64.57↑	56.78↑	
	- w/ Qwen-VL	65.14↑	63.84↑	53.51↑	51.07↑	55.01↑	62.13↑	57.15↑	54.91↑	39.96↑	49.30↑	57.36↑	42.80↑	
	- w/ MiMo	66.43↑	69.91↑	70.84↑	59.25↑	53.34↑	61.26↑	56.35↑	58.18↑	42.52↑	60.22↑	61.29↑	54.82↑	
	- w/ LLaVa	58.26↑	51.61↑	62.38↑	24.86↑	28.88↑	40.67↑	43.14↑	35.77↑	36.79↑	50.15↑	51.81↑	48.04↑	

如图所示，ReMoD 在大多数基准测试中都取得了具有竞争力的性能，甚至在多种场景下超过了像 GPT4 和 GPT4-Vision 这样强大的大型语言模型。虽然 TMPT+CoT 在某些目标上表现出更强的结果，但它依赖于使用 GPT4 生成的 CoT 示例进行训练。相反，ReMoD 通过利用积累的经验对自适应模态贡献进行重新思考，凸显了其无需训练的优势。

对基准性能的深入分析揭示了多模态融合中的复杂挑战。纯文本模型始终优于纯视觉模型，这证实了文本是立场确定的主要模态。然而，像 GPT4-Vision 这样的先进多模态模型相较于其纯文本变体的优越性能，验证了视觉线索的补充价值，强调了跨模态整合的必要性。值得注意的是，不同融合方法的性能提升不一致，再加上像 CLIP 和 TMPT 这样较简单的框架所面临的困境，凸显了一个关键缺陷：这些模型无法根据每个样本处理每种模态的不同贡献，使得有噪声或不相关的视觉数据降低了整体性能。相比之下，ReMoD 利用其双重推理范式动态地重新思考模态贡献，从而提高了其最终的预测准确性。

Zero Shot 场景下的结果如下所示：

MODALITY	METHOD	MTSE		MWTWT					MRUC		MTWQ	
		DT	JB	CA	CE	AC	AH		RUS	UKR	MOC	TOC
Text-only	BERT	32.52	29.97	63.55	61.30	59.18	52.89	22.01	15.45	28.04	9.57	
	RoBERTa	26.60	32.21	59.22	59.22	64.86	57.46	27.10	19.98	30.62	15.84	
	KEBERT	26.17	31.81	59.70	62.56	63.92	55.53	24.68	28.18	29.17	19.80	
	LLaMA2	53.57	53.92	32.47	38.37	48.08	46.13	31.86	36.34	51.46	44.10	
Vision-only	GPT4	70.78	68.83	57.19	60.56	65.63	69.01	40.22	49.18	62.10	52.12	
	ResNet	25.52	29.70	23.01	24.11	25.21	25.27	23.88	25.57	27.59	24.88	
	ViT	28.63	29.70	24.59	28.18	34.06	33.40	27.26	28.51	29.37	23.69	
	SwinT	28.54	30.85	28.53	28.50	35.87	34.33	25.44	24.54	27.90	19.69	
Multimodal	BERT+ViT	26.70	31.57	59.21	59.30	65.04	59.28	23.33	15.21	24.76	11.70	
	ViLT	28.08	29.74	38.33	46.00	55.01	48.55	21.56	23.96	23.54	19.18	
	CLIP	28.21	28.99	61.08	55.67	63.80	60.06	25.62	27.40	27.21	15.69	
	TMPT	31.69	32.65	66.36	66.39	66.32	61.56	23.87	24.71	32.18	26.48	
	TMPT+CoT	54.30	58.46	67.28	63.73	64.87	54.26	48.99	51.75	45.32	43.70	
	Qwen-VL	47.62	46.14	38.57	43.36	47.82	41.01	36.95	41.39	44.32	44.08	
	MiMo	66.58	66.01	38.11	40.10	44.20	39.05	44.85	50.24	64.65	46.25	
	LLaVa	50.26	46.74	26.53	30.77	34.96	36.57	40.67	38.69	48.97	39.80	
	Qwen2.5-VL	68.11	67.02	47.59	49.78	62.52	50.95	48.22	45.82	67.08	47.03	
	GPT4-Vision	72.68	71.28	42.23	45.92	54.59	53.19	42.09	47.00	65.00	52.36	
Backbones	ReMoD	72.96↑	71.74↑	50.91↑	58.05↑	67.82↑	61.77↑	50.07↑	52.57↑	69.77↑	52.70↑	
	- w/ Qwen-VL	59.48↑	56.47↑	42.65↑	50.18↑	61.74↑	55.22↑	44.12↑	42.42↑	60.16↑	45.79↑	
	- w/ MiMo	67.44↑	66.09↑	44.70↑	40.12↑	45.59↑	41.27↑	46.62↑	52.23↑	65.57↑	46.47↑	
	- w/ LLaVa	53.10↑	49.52↑	27.21↑	30.42	44.13↑	38.25↑	42.43↑	40.64↑	50.63↑	45.76↑	

如图所示，该结果揭示了依赖领域内训练的模型所固有的脆弱性。像 BERT 和 RoBERTa 这样的小型架构性能急剧下降，而即便是 GPT-4 和 GPT-4V 这样强大的大型语言模型，在面对未见过的目标时也表现出显著的性能波动。这凸显了当前范式的一个根本性局限：真正的零样本泛化仍然是一项艰巨且在很大程度上尚未解决的挑战。在这种高要求的场景下，ReMoD 树立了稳健性和适应性的新标准。它在大多数被评估的数据集上都取得了最先进的结果。这种稳定性，尤其是与领先的基于大型语言模型的基线模型不

稳定的输出相比，为其更优越的泛化能力提供了令人信服的证据。

（3）消融实验

METHOD	MTSE	MCCQ	MWTWT	MRUC	MTWQ
<i>in-target setting</i>					
ReMoD	70.88	72.90	63.24	71.41	69.76
-w/o MEP	69.04	68.38	60.37	70.33	68.45
-w/o SEP	70.65	69.56	57.18	67.05	69.11
-w/o CoT	70.78	67.92	59.13	65.45	69.17
<i>zero-shot setting</i>					
ReMoD	71.19	-	65.42	70.74	71.39
-w/o MEP	66.95	-	55.26	65.71	68.55
-w/o SEP	64.47	-	56.18	68.74	70.41
-w/o CoT	70.85	-	56.29	69.11	71.22

为了评估 ReMoD 中每个组件的影响，我们进行了一项消融研究，结果报告于图中。研究结果明确表明所有模块具有协同重要性，因为完整的 ReMoD 模型在目标内和零样本设置下始终优于任何消融版本。其中最关键的组件是经验池。不使用模态经验（w/o MEP）会导致最显著的性能下降，尤其是在零样本场景中，这凸显了评估跨样本模态贡献对于实现稳健泛化的不可或缺的作用。

（4）样例分析

为了进一步凸显 ReMoD 双重推理的优势，我们通过对比直接 CoT 与 ReMoD 的结果，分析了图中的两个示例。在示例（a）中，直接 CoT 从字面上将文本中的“stan Putin”解读为支持，却忽略了“cringe”这一负面语境。ReMoD 的模态经验强调通过语境判断对文本证据进行加权，能够借助“cringe”和“stan”之间的矛盾识别出隐含的讽刺，从而避免被孤立的显性词汇误导。其语义经验阐明该讽刺是在批评与俄罗斯相关的现象，进而将文本与反对俄罗斯这一目标立场联系起来。

对于示例（b），直接 CoT 根据文本中印度解除出口禁令以及图像中领导人合作等表面信息，推断出对该药物的支持态度。相比之下，ReMoD 的模态经验强调要优先考虑跨模态的显性立场信息，进行平等加权并默认持中立态度，同时其语义经验通过常识和地缘政治背景加深理解，揭示出文本描述的是国际博弈中的客观政策调整，而非作者主观上认可该药物的疗效。通过抑制对表面信息的误读，并利用背景知识校准推理，ReMoD 准确捕捉到了中立立场。

