

哈尔滨工业大学深圳校区

毕业论文中期报告

题 目 认知双过程驱动的
 多模态立场检测

姓 名 金正达

学 号 220110515

学 院 计算机科学与技术学院

专 业 计算机科学与技术

指 导 教 师 徐睿峰教授

日 期 2026 年 3 月 17 日

目 录

1 课题主要研究内容及进度	1
1.1 课题主要研究内容	1
1.2 进度介绍	1
1.2.1 大语言模型在立场检测中的应用	1
1.2.2 多模态立场检测的研究现状与挑战	2
1.2.3 人类认知的双过程理论的探索	2
2 已完成的研究工作及结果	3
2.1 ReMoD 核心框架的设计	3
2.1.1 多模态知识感知模块设计	4
2.1.2 经验驱动的直觉推理（系统 1）模块设计	5
2.1.3 元认知反思推理（系统 2）模块设计	6
2.2 初步实验	7
2.2.1 实验设置	7
2.2.2 基线方法	8
2.2.3 主要结果	8
2.3 阶段性学术成果	10
3 后期拟完成的研究工作及进度安排	11
3.1 后期拟完成的研究工作	11
3.2 进度安排	11
4 存在的困难及解决方案	12
4.1 存在的困难	12
4.2 解决方案	12
5 论文按时完成的可能性	14

1 课题主要研究内容及进度

1.1 课题主要研究内容

本课题以多模态立场检测 (Multi-modal Stance Detection, MSD) 为核心研究方向, 旨在构建一种具备动态模态理解与自适应推理能力的检测框架, 以提升社交媒体文本分析的准确性与可解释性。现有多模态立场检测模型大多依赖固定或简单的模态融合策略, 难以充分捕捉不同模态在具体语境下的差异化贡献。静态融合方式往往导致语义偏差、模态冗余及噪声放大等问题, 限制了模型在复杂现实场景中的泛化性能。针对这些不足, 本研究提出一种基于双重推理机制的多模态立场检测框架 ReMoD (**Rethinking Modality Contribution of stance expression through a Dual-reasoning paradigm**), 以实现模态贡献的动态再思考与自适应优化, 使模型能够在不同话题、不同风格以及跨域迁移场景中稳定工作。

ReMoD 框架的设计理念借鉴了认知心理学中的“双过程理论”, 即人类决策中的“直觉式推理系统 (System 1)”与“反思式推理系统 (System 2)”。模型通过模拟两种推理模式的协同工作, 实现从经验驱动的快速判断到理性审视的自我修正, 从而增强立场推断的鲁棒性与可解释性。研究工作以人类双过程认知理论为方法论支点, 将依赖经验的直觉判断与可追溯的反思性推理植入到统一的多模态管线之中, 形成由知识感知、经验检索与直觉预测、反思生成与经验演化、立场推断等环节耦合而成的整体方案。通过在文本与图像两个模态层面同时进行知识获取与证据对齐, 结合跨模态可检索的经验记忆池, 实现对复杂舆情样本的细粒度理解与稳健推断。

1.2 进度介绍

1.2.1 大语言模型在立场检测中的应用

基于大语言模型 (Large Language Model, LLM) 的立场检测是近年来的研究热点。相较于早期依赖大量人工特征的范式, 现有工作广泛利用了 LLM 固有的零样本和少样本泛化优势。通过精心设计的提示词和思维链 (Chain of Thought, CoT) 逐步推理策略, 模型在缺乏大规模高质量标注的情况下仍能给出相对稳定的判断。此外, 引入外部知识与多智能体“分工—辩证—仲裁”机制, 进一步增强了复杂场景下的论证能力与可解释性。然而, 本课题在前期调研与实验中发现, 当前纯文本 LLM 范式在应对社交媒体日益丰富的图文数据时存在先天不足, 且传统的思维

链容易受表面信息误导。基于这一现状，本课题在后续模型设计中，不仅继承了 LLM 的推理优势，还针对性地开发了模态思维链（Modality-CoT）与语义思维链（Semantic-CoT），以增强生成理由的可靠性与跨模态验证能力。

1.2.2 多模态立场检测的研究现状与挑战

随着社交媒体生态的发展，多模态立场检测的核心在于处理文本与图像之间的互补、互动乃至冲突关系。近年来，依托 Transformer 的跨模态注意力机制，多模态融合策略得到了持续演进。尽管在少样本与噪声鲁棒学习上取得了一定进展，但本课题在深入分析后指出，现有方法绝大多数仍受限于“学习融合”的底层范式。这类方法擅长评估特征权重，但缺乏显式的推理过程来辨析模态间的动态关系。在面临“语义陷阱”（如跨模态的反讽、隐喻或逻辑谬误）时，仅靠特征融合极易产生误判。因此，本课题明确了由“学习融合”向“学习推理”转变的研究主线，以此作为框架架构的核心动机。

1.2.3 人类认知的双过程理论的探索

为了打破上述多模态融合的瓶颈，本课题将目光投向了认知心理学中的双过程理论（快慢思考机制）。该理论指出人类认知包含依赖直觉与经验的“系统 1”和进行深度分析验证的“系统 2”。近年来，这一机制在 LLM 领域展现出巨大潜力，许多框架均通过模拟认知动态有效提升了复杂任务的推理准确性与效率。受此启发，本课题目前已成功设计并实现了 ReMoD 框架。在中期阶段，本课题已将该理论落地为两套核心代码模块：一是模拟“系统 1”的经验驱动直觉推理模块，通过查询模态与语义经验池快速生成初始假设；二是模拟“系统 2”的元认知反思推理模块，对初始判断进行深度审查并实现经验池的自我进化与更新。

2 已完成的研究工作及结果

2.1 ReMoD 核心框架的设计

本节详细介绍针对多模态立场检测（MSD）提出的新型 ReMoD 框架。本框架受人类认知的双过程理论启发，这是一种假设存在两种不同思维模式的心理学模型：其中一种是直觉、快速的“系统 1”（System 1），它依赖启发式方法和先前经验来做出快速判断；另一种是深思熟虑、缓慢的“系统 2”（System 2），它通过分析推理来优化和验证这些初步评估。ReMoD 框架将这一认知范式应用于多模态立场检测任务。

为了便于对方法进行形式化描述，首先给出多模态立场检测的任务定义。给定一个包含文本 u 和图像 v 的多模态输入对 $x = (u, v)$ ，以及一个特定的目标 t ，多模态立场检测的目标是学习一个映射函数 $F(u, v, t) \rightarrow y$ ，预测对该目标所持有的立场标签 $y \in \mathcal{Y}$ 。在此基础上，ReMoD 框架旨在利用双过程推理机制，结合外部知识与历史经验，提升对 y 的预测准确性。




图 2-1 ReMoD 框架示意图

如图 2-1 所示，ReMoD 由三个主要部分组成：1) **多模态知识感知**，负责提取全面的多模态信息并捕获相关的外部知识。2) **经验驱动的直觉推理**（即系统 1），通过查询经验池形成初步的立场假设；3) **元认知反思推理**（即系统 2），利用互补的推理链来审查初步假设，并持续优化双重经验池。

2.1.1 多模态知识感知模块设计

这一初始阶段通过从文本和视觉模态中提取并优化知识，构建了丰富的语义基础。其目标不仅是捕捉高层概念信息，还要获取对于细微推理至关重要的具体、细粒度证据。

2.1.1.1 文本知识获取

对于文本输入 u ，执行三步知识提取过程以构建语义丰富的背景知识。首先，实体识别阶段利用多模态大语言模型（MLLM）配合精心设计的提示词，从输入文本 u 与目标 t 中识别出一组关键语义实体，记为 $\mathcal{E}_u = \{e_1, e_2, \dots, e_m\}$ 。这一过程的形式化表示为：

$$\mathcal{E}_u = \text{MLLM}_{\text{extract}}(u, t) \quad (2-1)$$

其次，为了将这些实体锚定在外部世界知识中，克服模型幻觉并补充长尾知识，本框架引入外部知识库。具体而言，对于每个实体 $e_i \in \mathcal{E}_u$ ，利用维基百科 API 检索其对应的详细背景描述 $d_i = \text{Wiki}(e_i)$ 。由于原始检索到的知识通常较为冗长且包含噪声信息，直接拼接可能导致上下文过长或注意力分散。因此，框架再次利用 MLLM 将检索到的文档集 $\{d_i\}$ 提炼为简洁且语义稠密的摘要。最终的摘要记为文本知识 $\mathcal{K}_u$ ，作为文本模态的增强表示：

$$\mathcal{K}_u = \text{MLLM}_{\text{summarize}}(\{d_i\}_{i=1}^m) \quad (2-2)$$

2.1.1.2 视觉信息锚定

对于图像输入 v ，目标是同时捕捉高层语义概念和低层视觉细节。首先，为了提取语义概念，MLLM 会生成图像描述，并从中识别出一组视觉实体 $\mathcal{E}_v$ 。随后利用这些实体查询维基百科，并将得到的信息总结为浓缩的视觉知识 $\mathcal{K}_v$ 。

然而，仅凭文本化的知识不足以捕捉这些概念在图像中的具体视觉呈现。为此，本框架提出将语义实体锚定在图像的像素空间中。利用识别出的实体集 $\mathcal{E}_v$ 作为文本提示，引导分割任意模型（Segment Anything Model, SAM）进行开放词汇分割。SAM 能够精确分割出图像中与每个实体对应的感兴趣区域，从而得到一组实体对齐的视觉信息 $\mathcal{V}$ 。 $\mathcal{V}$ 中的每个元素 $\bar{v}_i$ 代表了特定语义实体对应的分割子图：

$$\mathcal{V} = \{\bar{v}_i\}_{i=1}^N = \text{SAM}(v, \mathcal{E}_v) \quad (2-3)$$

其中 N 表示识别到的视觉实体及对应子图的数量。

2.1.2 经验驱动的直觉推理（系统 1）模块设计

这一阶段通过利用在训练过程中积累的经验池来快速制定初步的立场假设，从而模拟人类快速、直觉式的判断。该过程主要包括两个步骤：模态协同经验检索和经验驱动的立场预测。

2.1.2.1 模态协同经验检索

为了利用历史数据中的规律来辅助当前决策，ReMoD 维护了模态经验池（Modality Experience Pool, MEP）和语义经验池（Semantic Experience Pool, SEP）。形式上，经验池可以表示为 $\mathbb{P} = \{E_j\}_{j=1}^M$ ，其中 M 为经验总数。每个经验 E_j 存储为一个键值对结构 $E_j = \langle (k_u^j, k_v^j), \text{Value}_j \rangle$ 。键由预先计算的双模态嵌入 (k_u^j, k_v^j) 组成，代表该经验在文本和视觉空间中的核心特征；值 Value_j 则包含了推理路径、预测结果及反思见解等具体经验数据。

检索过程首先将当前的文本输入 u 和子图像集 $\mathcal{V}$ 映射到同一特征空间。利用预训练的 BGE-VL-CLIP 编码器 Enc ，分别计算当前输入的查询向量：

$$q_u = \text{Enc}(u), \quad q_v = \frac{1}{N} \sum_{i=1}^N \text{Enc}(\bar{v}_i) \quad (2-4)$$

这里， q_v 通过对所有视觉子图特征进行平均池化得到，以聚合整体视觉语义。在确定查询向量后，通过计算余弦相似度来衡量当前输入与每个存储经验 E_j 的键向量之间的相似性，从而得到文本 S_u 和视觉 S_v 的单模态相关性得分：

$$S_u(q_u, k_u^j) = \frac{q_u \cdot k_u^j}{\|q_u\| \|k_u^j\|}, \quad S_v(q_v, k_v^j) = \frac{q_v \cdot k_v^j}{\|q_v\| \|k_v^j\|} \quad (2-5)$$

为了获得全面的相关性度量，框架通过加权线性组合将这些得分融合为一个统一的模态相关性得分（Modality Relevance Score, MRS），记为 $S(E_j)$ ：

$$S(E_j) = \alpha \cdot S_u(q_u, E_j) + (1 - \alpha) \cdot S_v(q_v, E_j) \quad (2-6)$$

其中 $\alpha \in [0, 1]$ 是平衡文本与视觉模态检索权重的超参数。基于 $S(E_j)$ 对所有经验进行降序排列，并设定相关性阈值 τ ，筛选出 Top- k 个最相关的经验，分别构成模态经验集 $\{S_i^{\text{ME}}\}_{i=1}^k$ 和语义经验集 $\{S_i^{\text{SE}}\}_{i=1}^k$ ，作为后续推理的上下文参考。

2.1.2.2 经验驱动的立场预测

在检索到相关的既往经验之后，ReMoD 智能体 A_R 开始生成初步的、直觉式的立场假设。本框架构建了一个综合提示词 $\mathcal{P}_{\text{sys1}}$ ，它集成了两个关键要素：(1) 当前的多模态输入任务，包含文本 u 和视觉锚定信息 $\mathcal{V}$ ；(2) 检索到的经验集 $\{S_i^{\text{ME}}\}_{i=1}^k$ 和 $\{S_i^{\text{SE}}\}_{i=1}^k$ 作为上下文示例。

该提示词引导 A_R 从三个不同的视角进行初步分析：纯文本视角、纯视觉视角以及多模态融合视角。对于每个视角 c ，智能体都会生成一个初步的立场预测 $\hat{y}_c$ 及其相应的推理依据 r_c 。这一过程可形式化地表示为：

$$(\hat{y}_c, r_c) = A_R(\mathcal{P}_{sys1}(c, \{\mathcal{S}^{ME}\}_{i=1}^k, \{\mathcal{S}^{SE}\}_{i=1}^k)) \quad (2-7)$$

其中推理视角 $c \in \{u, \mathcal{V}, (u, \mathcal{V})\}$ 分别对应文本、视觉及多模态输入。这些生成的预测对 $(\hat{y}_c, r_c)$ 构成了初步的推理轨迹，它们捕捉了模型对当前样本的直觉判断，并将作为中间变量输入到随后的元认知反思阶段进行审查和优化。

2.1.3 元认知反思推理（系统 2）模块设计

元认知反思推理类比于双过程认知理论中的“系统 2”慢速思考过程，并作为本框架的优化模块。该过程受两个子过程驱动：一是经验构建，通过结构化反思产生新的见解；二是经验演化，通过整合这些新见解来优化经验池。

2.1.3.1 经验构建

经验构建的主要目标是促进元认知反思，使智能体能够从其任务执行结果中提炼出具有指导意义的通用经验，而非仅仅记忆特定的样本。为此，ReMoD 智能体采用了一种类似于思维链（Chain-of-Thought, CoT）的结构化、多步推理过程来生成新的见解。

为了生成模态经验，Modality-CoT 启动了一个自我诊断过程。它评估了针对文本 $\hat{y}_u$ 、视觉 $\hat{y}_\mathcal{V}$ 以及组合多模态输入 $\hat{y}_{(u, \mathcal{V})}$ 的初始预测准确性，并对比其对应的推理依据 r_u 、 $r_\mathcal{V}$ 和 $r_{(u, \mathcal{V})}$ 的一致性与冲突点。通过分析这些初始判断的失败原因（如模态冲突、信息缺失）或成功因素，它提炼出一种高层级的 **模态见解** $\mathcal{I}_m$ 。这种见解不仅是一个简单的总结，更是一种自适应融合策略，规定了在未来的推理中如何动态平衡单模态和多模态线索。

与此同时，Semantic-CoT 负责形成 **语义经验**。这一过程涉及对初始推理的语义锚定进行深度审视。它将智能体的内部推理依据与外部锚定的文本知识 $\mathcal{K}_u$ 及视觉知识 $\mathcal{K}_\mathcal{V}$ 进行综合比对。通过这种综合，智能体能够识别并纠正内容层面的偏见或浅层解释，生成语义见解 $\mathcal{I}_s$ 。 $\mathcal{I}_s$ 是一种可操作的指令，用于指导模型在类似语境下挖掘更深层次的语义关联和背景知识。

2.1.3.2 经验演化

在获取新的见解 $\mathcal{I}_m$ 和 $\mathcal{I}_s$ 后，ReMoD 执行经验演化操作，以动态更新其经验池。首先，基于前述的检索机制，定位到最相关的 Top- k 个既往经验 $\{\bar{\mathcal{S}}_i^{ME}\}_{i=1}^k$ 和

$\{\bar{\mathcal{S}}_i^{\text{SE}}\}_{i=1}^k$ 。若当前检索到的经验相似度低于设定的更新阈值，说明当前样本属于新的分布区域，则将新见解封装为新的键值对条目 $E_{\text{new}} = \langle (q_u, q_v), \mathcal{I} \rangle$ 并直接添加至相应池中。反之，若存在高度相关的旧经验，ReMoD 会对其进行针对性更新，以融合新旧知识，避免知识库的冗余膨胀。

这一演化更新依赖于一种基于 LLM 的融合操作 $\text{Fuse}(\cdot)$ 。对于检索到的每个模态经验 $\bar{\mathcal{S}}_i^{\text{ME}}$ ，ReMoD 启动一个重新推理过程，通过提示词引导 LLM 将既往经验的内容与新的模态见解 $\mathcal{I}_m$ 进行辩证综合。这会生成一个更全面、且适应性更强的更新后模态经验 $\hat{\mathcal{S}}^{\text{ME}}$ ：

$$\hat{\mathcal{S}}^{\text{ME}} = \text{Fuse}(\bar{\mathcal{S}}_i^{\text{ME}}, \mathcal{I}_m) \quad (2-8)$$

随后用 $\hat{\mathcal{S}}^{\text{ME}}$ 覆盖原始条目。语义经验也执行并行的更新过程，利用 $\mathcal{I}_s$ 更新 $\{\bar{\mathcal{S}}_i^{\text{SE}}\}_{i=1}^k$ 以生成新的语义经验 $\hat{\mathcal{S}}_i^{\text{SE}}$ 。这种双重更新机制确保了两个经验池能够随着推理过程的进行而持续进化，模拟人类“吃一堑长一智”的学习过程，构建一个精简且连贯的知识库。

2.1.3.3 立场推理

在推理阶段，ReMoD 首先利用 SAM 从输入图像中提取视觉信息 $\mathcal{V}$ ，捕捉语义实体的细粒度视觉呈现。随后，该视觉信息与文本输入 u 配对形成多模态上下文。接着，它采用模态协同检索机制从模态和语义经验池中获取相关的既往经验。最后，ReMoD 将这些经验与多模态上下文及目标相结合，得出最终的立场预测。这确保了决策既基于即时数据，又受其优化的长期理解所指导。

2.2 初步实验

2.2.1 实验设置

数据集与评价指标。为了评估 ReMoD，本课题在 MMSD 数据集上进行了性能基准测试。该数据集包含五个不同的领域：多模态 COVID-CQ (MCCQ)、多模态俄乌冲突 (MRUC)、多模态台湾问题 (MTWQ)、多模态 2020 推特立场选举 (MTSE) 以及多模态 Will-They-Won't-They (MWTWT)。遵循 MMSD 数据集的设置，采用 Macro-F1 分数作为主要的评价指标。

实现细节。ReMoD 方法以 Qwen-2.5-VL-32B 模型为骨干网络实现。在经验池检索中，系数 α 设置为 0.7，相关性阈值 τ 设置为 0.7，并检索前 $k = 3$ 个经验，以在上下文信息量与噪声之间取得平衡。实体相关知识是利用 Python 的 Wikipedia 库从维基百科获取的。

MODALITY	METHOD	MTSE		MCCQ	MWTWT					MRUC		MTWQ	
		DT	JB	CQ	CA	CE	AC	AH	DF	RUS	UKR	MOC	TOC
Text-only	BERT	48.25	52.04	66.57	75.62	60.85	63.05	59.24	81.53	41.25	46.80	57.77	45.91
	RoBERTa	58.39	60.79	66.57	69.56	65.03	69.74	67.99	79.21	39.52	57.66	55.22	48.88
	KEBERT	64.50	69.81	66.84	71.67	67.56	69.29	69.74	80.57	41.55	59.01	58.15	47.75
	LLaMA2	53.23	52.67	47.40	34.89	41.95	49.09	44.32	30.21	38.84	38.54	55.31	46.51
	GPT4	68.74	66.39	65.84	63.14	65.12	<u>69.93</u>	71.62	52.69	41.64	53.76	58.05	49.81
Vision-only	ResNet	37.89	38.59	47.16	39.89	42.20	43.52	37.05	50.34	35.10	40.00	42.02	33.94
	ViT	40.48	40.42	46.64	46.63	50.00	40.16	46.32	50.86	33.31	39.87	38.63	35.53
	SwinT	39.89	40.43	48.80	46.30	46.99	41.02	47.39	51.32	35.01	40.89	35.03	35.47
Multimodal	BERT+ViT	41.86	45.82	61.32	63.20	44.71	56.45	46.85	73.71	39.28	48.41	47.47	40.86
	ViLT	35.32	48.24	47.85	62.70	56.44	58.06	60.22	73.66	34.62	42.41	44.43	59.51
	CLIP	53.22	65.83	63.65	70.93	67.17	67.43	70.86	79.06	44.99	59.86	55.29	40.98
	TMPT	55.41	61.61	67.67	76.60	63.19	67.25	62.92	81.19	43.56	59.24	55.68	46.82
	TMPT+CoT	66.61	68.75	71.79	74.40	69.96	68.43	63.00	82.71	45.04	60.52	68.95	59.87
	Qwen-VL	43.31	45.13	50.51	43.06	45.49	49.79	46.04	27.73	36.50	40.78	42.14	39.34
	MiMo	66.21	65.89	61.54	45.32	42.19	50.69	42.36	40.26	39.30	58.95	60.07	52.39
	LLaVa	49.48	45.80	60.30	20.48	28.48	33.83	38.94	31.57	36.53	47.47	50.45	47.07
	Qwen2.5-VL	68.07	70.82	63.33	75.27	68.44	67.15	68.91	63.21	41.04	51.34	65.62	56.35
	GPT4-Vision	<u>70.46</u>	<u>72.82</u>	61.63	44.59	47.07	57.47	57.90	37.61	44.83	56.40	66.72	56.90
Backbones	ReMoD	70.87	73.31	72.90*	78.49	71.85	71.89*	<u>70.62</u>	65.54	50.81*	62.42*	69.38	61.13
	- w/ Qwen-VL	65.14	63.84	63.51	55.76	53.46	50.67	52.23	50.06	39.96	49.30	57.36	52.75
	- w/ MiMo	66.43	69.91	70.84	59.25	53.34	61.26	56.35	58.18	42.52	60.22	61.29	54.82
	- w/ LLaVa	58.26	51.61	62.38	24.86	28.88	40.67	43.14	35.77	36.79	50.15	51.81	48.04

表 2-1 In-target 结果 (%)。最高分和次高分分别以 **加粗**和 下划线 表示。* 表示 ReMoD 框架显著优于基准方法 ($p < 0.05$)。虚线用于区分微调方法与非微调方法。w/ 表示骨干网络。

2.2.2 基线方法

本课题将该方法与三类基准方法进行了对比评估：**纯文本基准**：1) BERT，使用 uncased BERT-base 模型；2) RoBERTa，使用 RoBERTa-base 模型；3) KEBERT；4) LLaMA2，使用 LLaMA2-70B-chat；5) GPT4。**纯视觉基准**：1) ResNet，使用 ResNet-50 v1.5；2) ViT，使用 ViT-base-patch16-224 模型；3) Swin Transformer (SwinT)，使用 SwinV2-base-patch4-window12-192-22k 模型。**多模态基准**：1) ViLT，使用 vilt-b32-mlm 模型；2) CLIP，使用 CLIP-ViT-base-patch32 模型；3) BERT+ViT，该模型分别使用 BERT 和 ViT 作为文本和图像编码器；4) Qwen-VL，使用 Qwen-VL-Chat7B；5) Qwen2.5-VL，使用 Qwen2.5-VL-32B-Instruct；6) GPT4-Vision；7) MiMo，使用 MiMo-7B-RL；8) LLaVa，使用 LLaVa-v1.6-Mistral-7B；9) TMPT 和 TMPT+CoT。

2.2.3 主要结果

2.2.3.1 In-target 多模态立场检测

如表 2-1 所示，ReMoD 在 In-target 实验设置下的绝大多数基准测试中均取得了领先的性能，其 Macro-F1 分数在多个复杂数据集上显著超越了包括 GPT-4V 在

MODALITY	METHOD	MTSE		MWTWT				MRUC		MTWQ	
		DT	JB	CA	CE	AC	AH	RUS	UKR	MOC	TOC
Text-only	BERT	32.52	29.97	63.55	61.30	59.18	52.89	22.01	15.45	28.04	9.57
	RoBERTa	26.60	32.21	59.22	59.22	64.86	57.46	27.10	19.98	30.62	15.84
	KEBERT	26.17	31.81	59.70	62.56	63.92	55.53	24.68	28.18	29.17	19.80
	LLaMA2	<u>53.57</u>	<u>53.92</u>	<u>32.47</u>	<u>38.37</u>	<u>48.08</u>	<u>46.13</u>	<u>31.86</u>	<u>36.34</u>	<u>51.46</u>	<u>44.10</u>
	GPT4	70.78	68.83	57.19	60.56	65.63	69.01	40.22	49.18	62.10	52.12
Vision-only	ResNet	25.52	29.70	23.01	24.11	25.21	25.27	23.88	25.57	27.59	24.88
	ViT	28.63	29.70	24.59	28.18	34.06	33.40	27.26	28.51	29.37	23.69
	SwinT	28.54	30.85	28.53	28.50	35.87	34.33	25.44	24.54	27.90	19.69
Multimodal	BERT+ViT	26.70	31.57	59.21	59.30	65.04	59.28	23.33	15.21	24.76	11.70
	ViLT	28.08	29.74	38.33	46.00	55.01	48.55	21.56	23.96	23.54	19.18
	CLIP	28.21	28.99	61.08	55.67	63.80	60.06	25.62	27.40	27.21	15.69
	TMPT	31.69	32.65	66.36	<u>66.39</u>	<u>66.32</u>	61.56	23.87	24.71	32.18	26.48
	TMPT+CoT	54.30	58.46	<u>67.28</u>	<u>63.73</u>	<u>64.87</u>	54.26	<u>48.99</u>	<u>51.75</u>	45.32	43.70
	Qwen-VL	<u>47.62</u>	<u>46.14</u>	<u>38.57</u>	<u>43.36</u>	<u>47.82</u>	<u>41.01</u>	<u>36.95</u>	<u>41.39</u>	<u>44.32</u>	<u>44.08</u>
	MiMo	66.58	66.01	38.11	40.10	44.20	39.05	44.85	50.24	64.65	46.25
	LLaVa	50.26	46.74	26.53	30.77	34.96	36.57	40.67	38.69	48.97	39.80
	Qwen2.5-VL	68.11	67.02	62.59	60.21	62.52	65.19	48.22	45.82	<u>67.08</u>	51.23
Backbones	GPT4-Vision	<u>72.68</u>	<u>71.28</u>	42.23	45.92	54.59	53.19	42.09	47.00	65.00	<u>52.36</u>
	ReMoD	73.78*	72.69*	70.83	66.90	71.82*	<u>67.25</u>	50.07*	52.57*	69.77	64.39*
	- w/ QwenVL	59.48	56.47	59.71	52.10	58.09	50.94	44.12	42.42	60.16	45.79
	- w/ MiMo	67.44	66.09	44.70	40.12	45.59	41.27	46.62	52.23	65.57	46.47
	- w/ LLaVa	53.10	49.52	27.21	30.42	44.13	38.25	42.43	40.64	50.63	45.76

表 2-2 Zero-shot 结果 (%). 最高分和次高分分别以 **加粗**和 下划线 表示。* 表示 ReMoD 框架显著优于基准方法 ($p < 0.05$)。虚线用于区分微调方法与非微调方法。w/ 表示骨干网络。

内的强基线模型。值得强调的是，尽管 TMPT+CoT 凭借 GPT-4 生成的思维链增强了推理能力，在部分指标上表现优异，但 ReMoD 无需依赖昂贵的闭源模型 API 生成训练数据，而是通过内部的经验演化机制自适应地累积和优化模态经验。这种机制使得模型能够针对特定领域的立场分布进行自我修正，从而在保持计算效率的同时实现了更优的分类效果。

对基准方法性能的深入分析揭示了多模态融合中错综复杂的挑战。纯文本模型始终优于纯视觉模型，这证实了文本是立场判定的主要模态。然而，与对应的纯文本版本相比，GPT4-Vision 等高级多模态模型的优异表现验证了视觉线索的补充价值，强调了跨模态整合的必要性。值得注意的是，不同融合方法带来的性能提升并不一致，加之 CLIP 和 TMPT 等较简单框架的乏力表现，突显了一个关键缺陷：这些模型无法处理每个样本中各模态贡献的变化，导致噪声或无关的视觉数据降低了整体性能。相比之下，ReMoD 提出的双过程推理框架有效解决了模态噪声问题。通过系统 2 的“模态协同经验检索”，模型能够动态衡量视觉与文本信息的相关性权重，从而在文本主导或视觉主导的样本中灵活切换关注点。这种自适

应的模态加权机制，结合元认知反思生成的修正见解，使得 ReMoD 在处理包含反讽、隐喻等多义性多模态数据时表现出更强的鲁棒性。

2.2.3.2 Zero-shot 多模态立场检测

如表 2-2 所示，实验结果揭示了依赖领域内训练的模型所固有的脆弱性。虽然 BERT 和 RoBERTa 等较小架构的性能出现了剧烈崩塌，但即使是 GPT4 和 GPT4-Vision 这样强大的 LLM，在面对未见过的目标时也表现出显著的性能波动。这凸显了当前范式的一个根本局限：真正的零样本（zero-shot）泛化仍然是一个艰巨且很大程度上尚未解决的挑战。在这种严苛的测试条件下，ReMoD 依然保持了 SOTA 性能，这主要归功于其独特的“经验迁移”能力。即便在未曾见过的目标域中，系统 2 生成的通用语义见解仍能捕捉到跨领域的立场表达模式。这种从历史经验中提炼高阶元知识的能力，赋予了 ReMoD 卓越的泛化潜能，使其在缺乏目标域训练数据的情况下仍能做出符合逻辑的立场推断。

2.3 阶段性学术成果

在本科毕业设计的前期与中期阶段，本课题已将核心研究框架的理论设计与详实的实验结果进行了系统的整理与提炼，并撰写为学术论文，目前已向自然语言处理领域的顶级国际会议 ACL 2026 提交了长文投稿。具体的论文信息如下：

- 论文题目：MIND Your Reasoning: A Meta-Cognitive Intuitive-Reflective Network for Dual-Reasoning in Multimodal Stance Detection

- 作者列表：Bingbing Wang*, Zhengda Jin (金正达)*, Bin Liang, Wenjie Li, Jing Li, Ruifeng Xu (徐睿峰)[†], Min Zhang (注：* 代表共同第一作者，[†] 代表通讯作者)

- 投稿会议：The 64th Annual Meeting of the Association for Computational Linguistics (ACL 2026)

- 当前状态：在投 (Under Review)

- 内容概述：该论文完整阐述了本中期报告中所探讨的认知双过程驱动框架（报告中命名为 ReMoD 架构，在论文中被进一步升华提炼为 MIND 网络）。论文首次在多模态立场检测领域倡导了从“学习融合”向“学习推理”的范式转变。论文详细论述了多模态知识感知、经验驱动的直觉推理以及元认知反思推理的协同机制，并通过两个维度的思维链实现了经验池的自我演化。该工作在 MMSD 数据集上进行了广泛实验，结果表明该方法在 In-target 与 Zero-shot 场景下均显著优于现有基线模型，展现出极强的泛化能力。该在投论文的核心工作即构成了本毕业设计的主体内容。

3 后期拟完成的研究工作及进度安排

3.1 后期拟完成的研究工作

针对目前的研究进展，后期的主要研究工作将集中在模型性能的深入验证与论文的撰写整理上。具体包括以下几个方面：

1. 消融实验：为了验证本课题所提出模型中各个关键模块（语义经验池、模态经验池和思维链推断模块等）的有效性，将设计并开展消融实验。通过逐一移除或替换模型中的特定组件，观察模型在标准数据集上的性能变化，从而定量分析各模块对最终结果的贡献度。

2. 超参数敏感性分析：为了评估模型的稳定性与鲁棒性，将对模型中的关键超参数进行敏感性分析。通过在一定范围内调整这些参数，记录模型性能的波动情况，确定最优参数组合，并验证模型在不同参数设置下的适应能力。

3. 论文撰写与修订：在完成所有实验与数据分析的基础上，按照学校毕业设计论文的格式要求，撰写毕业论文。主要内容包括绪论、相关技术综述、方法设计、实验结果分析以及总结与展望。完成初稿后，将根据导师的意见进行多轮修改与完善，确保论文逻辑严密、论证充分、格式规范，并准备最终的答辩材料。

3.2 进度安排

根据学校毕业设计的总体时间安排及目前的工作进度，后期的具体进度安排如下：

- 2026年3月上旬 - 2026年3月中旬：完成模型的消融实验，验证各模块有效性；进行超参数敏感性分析，确定最佳参数配置；记录并初步分析实验数据。
- 2026年3月中旬 - 2026年3月下旬：整理全部实验结果；撰写毕业论文的实验章节与结果分析部分，完善论文的其他章节，形成论文初稿。
- 2026年4月上旬 - 2026年4月中旬：将论文初稿提交导师审阅，根据反馈意见进行修改和补充；同时进行查重工作，确保论文符合学术规范。
- 2026年4月中旬 - 2026年4月下旬：定稿毕业论文，提交相关送审材料；准备毕业设计答辩PPT，梳理答辩陈述逻辑，进行预答辩演练。
- 2026年5月：参加毕业设计正式答辩，根据答辩委员会意见进行论文最终修订。

4 存在的困难及解决方案

4.1 存在的困难

在推进多模态立场检测任务及 ReMoD 框架实现的过程中，技术难点主要集中在跨模态信息的有效整合与系统动态演化的稳定性上。ReMoD 框架试图将 SAM 提供的细粒度视觉分割、外部维基百科知识以及多模态大模型的推理能力结合起来，但在实际实验中，不同来源的信息往往处于异构的特征空间。简单的上下文拼接使得模型难以在复杂的视觉场景中精准定位与文本立场相关的关键区域，导致模型在推理时常出现“语义漂移”现象，无法将注意力集中在核心证据上。

同时，引入外部知识虽然补充了必要的背景信息，但也带来了显著的副作用。直接检索到的维基百科条目往往包含大量与当前语境无关的冗余内容，这不仅极大地增加了输入序列的长度，给 Qwen-2.5-VL-32B 等大参数量模型的显存带来了巨大压力，更严重的是，过多的噪声信息干扰了“系统 2”的反思性推理，有时反而诱导模型产生幻觉或错误的归因。

此外，本课题所提出的“经验演化”机制在实现上比预想更为复杂。作为一种从历史推理中学习的动态系统，经验池的维护面临着即时性与多样性的矛盾。初期实验显示，在缺乏精细筛选机制的情况下，经验池倾向于迅速收录大量简单且重复的样本，导致在面对真正困难的样本时，检索模块无法提供具有区分度的参考示例。设计一套既能动态更新高价值推理路径，又能抑制知识库无限膨胀的演化算法，成为了限制系统自适应能力提升的瓶颈。

4.2 解决方案

针对上述跨模态特征对齐困难及知识噪声问题，本课题引入了层次化的知识提炼与语义锚定策略。在数据进入模型之前，通过预处理环节利用大模型的摘要能力进行“知识蒸馏”，将冗长的原始检索文本转化为紧凑且高语义密度的结构化摘要。同时，利用 SAM 生成的分割掩码将抽象的语义实体强制锚定到图像的像素区域，构建实体对齐的视觉表征。这种处理方式有效滤除了大量背景干扰，强制模型将推理焦点集中在对立场判断起决定性作用的核心对象上。

在经验池的动态维护方面，为了解决冗余积累的问题，设计并部署了基于模态协同检索评分的筛选机制与反思性更新策略。系统不再无差别地存储所有成功案例，而是设定了严格的模态平衡系数与相关性阈值，仅保留高质量的推理路径。

更关键的是，采用了基于元认知见解的“融合更新”方案：当产生新的有效经验时，利用模型将其与现有的相似经验进行有机融合，而非简单的追加存储。这不仅维持了经验池的紧凑规模，也显著提升了所存储经验的泛化指导能力。

对于大模型带来的计算资源瓶颈，则采用了模块化开发与离线预计算相结合的工程方案。考虑到图像分割与大规模知识检索的高计算开销，我们将这部分工作剥离为独立的离线预处理流水线，预先生成并存储实体掩码与知识嵌入。在在线推理环节，进一步引入了 vLLM 结合 FlashInfer 的加速方案，使推理速度提高了一倍。这些改进不仅显著缓解了实时显存压力，还将实验迭代周期缩短了约 40%，成功在有限的算力条件下实现了 32B 参数量基座模型的高效运行。

5 论文按时完成的可能性

本课题目前已经完成了 ReMoD 核心框架的设计与代码实现工作。具体而言，已成功构建了受人类双过程认知理论启发的立场检测模型，实现了包括多模态知识感知、经验驱动的直觉推理（System 1）以及元认知反思推理（System 2）在内的完整技术链路。在实验验证方面，已在标准的 MMSD 数据集上完成了 In-target 和 Zero-shot 两个关键场景的性能评估，实验结果显示该方法在准确率和 F1 值等核心指标上均取得了优于主流基线模型的表现，初步验证了所提方法的有效性与先进性。

目前正在进行模型各模块的消融实验与超参数敏感性分析，旨在通过定量数据进一步验证特征提取模块、经验演化机制等关键组件的独立贡献，并评估模型在不同参数配置下的鲁棒性。同时，正在对已生成的实验数据进行可视化的整理与深入的统计分析，为论文的实验结果章节准备详实的素材。

后续将要全面开展毕业论文的撰写与修订工作。计划系统梳理研究成果，按照规范完成绪论、相关工作、方法设计、实验分析及总结展望等章节的写作。在完成论文初稿后，将预留充足时间配合导师进行多轮审阅与修改，并同步准备答辩演示材料。

此外，本课题的核心技术突破与实验验证成果已整理为高质量学术论文《MIND Your Reasoning: A Meta-Cognitive Intuitive-Reflective Network for Dual-Reasoning in Multimodal Stance Detection》，本人作为共同第一作者，已将该工作正式投稿至自然语言处理领域的顶级国际学术会议 ACL 2026。这不仅标志着毕业设计的核心技术链路和实验验证工作已经高度成熟，并在 MMSD 等权威多模态评测基准上取得了显著优于基线模型的表现，同时也为后续毕业论文的撰写提供了结构完整、逻辑严密、论证充分的素材基础。

综上所述，鉴于课题的核心技术难点已被攻克，主要实验结果符合预期，且剩余工作规划清晰、进度可控，本课题完全能够按期完成毕业设计任务，并取得具有一定学术价值的研究成果。