

本科毕业论文（设计）

认知双过程驱动的多模态立场检测

COGNITIVE DUAL-PROCESS DRIVEN
MULTIMODAL STANCE DETECTION

金正达

哈尔滨工业大学

2026 年 5 月

☒ 毕业论文 ☐ 毕业设计

密级：公开

本科毕业论文（设计）

认知双过程驱动的多模态立场检测

本 科 生：金正达

学 号：220110515

指 导 教 师：徐睿峰教授

专 业：计算机科学与技术

学 院：深圳校区计算机科学与技术学院

答 辩 日 期：2026 年 5 月 19 日

学 校：哈尔滨工业大学

摘 要

多模态立场检测是理解社交媒体公众舆论的关键任务。现有的方法主要通过学习融合模态来进行处理，这些方法倾向于融合来自不同模态的信息来学习立场表达，而缺乏显式的推理过程来辨别模态间的动态交互如何共同塑造用户的最终立场，从而导致频繁的误判。针对这些问题，我们提倡从学习融合向学习推理的范式转变。基于此，我们提出了一种基于认知双过程推理机制的多模态立场检测框架 ReMoD (**Rethinking Modality Contribution of stance expression through a Dual-reasoning paradigm**)。受人类认知双过程理论的启发，ReMoD 实现了一个自我改进的循环机制：首先通过查询不断演化的模态经验池和语义经验池，快速生成直觉假设；随后，元认知反思阶段利用模态思维链和语义思维链对初始判断进行审视，提炼出更优的自适应策略，并驱动经验池自身的演化。这种双重经验结构在训练过程中持续精炼，并在推理阶段被调用来指导立场决策，使得最终的鲁棒且具有上下文感知能力的立场判断成为可能。在 MMSD 基准数据集上的大量实验表明，ReMoD 显著优于大多数基线模型，并展现出强大的泛化能力。

关键词：多模态立场检测；双过程机制；思维链；元认知反思；经验池

Abstract

Multimodal Stance Detection (MSD) is a crucial task for understanding public opinion on social media. Existing methods primarily tackle this by learning to fuse modalities. These approaches tend to integrate information from different modalities to learn stance expressions, but they lack an explicit reasoning process to discern how dynamic inter-modal interactions collectively shape the user's final stance, leading to frequent misjudgments. To address these issues, we advocate a paradigm shift from *learning to fuse* to *learning to reason*. Building upon this, we propose ReMoD (**R**ethinking **M**odality **C**ontribution of stance expression through a **D**ual-reasoning paradigm), a multimodal stance detection framework based on a dual-reasoning mechanism. Inspired by the dual-process theory of human cognition, ReMoD implements a self-improving cyclic mechanism: first, it rapidly generates intuitive hypotheses by querying continuously evolving modality and semantic experience pools; subsequently, a metacognitive reflection phase utilizes a Modality Chain-of-Thought and a Semantic Chain-of-Thought to scrutinize initial judgments, extract superior adaptive strategies, and drive the evolution of the experience pools themselves. This dual-experience structure is continuously refined during the training process and invoked during the inference stage to guide stance decision-making, enabling ultimately robust and context-aware stance judgments. Extensive experiments on the MMSD benchmark dataset demonstrate that ReMoD significantly outperforms most baseline models and exhibits strong generalization capabilities.

Keywords: Multimodal Stance Detection, Dual-Process Paradigm, Chain-of-Thought, Metacognitive Reflection, Experience Pool

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 基于大语言模型的立场检测研究现状	3
1.2.2 多模态立场检测研究现状	4
1.2.3 快慢思考机制研究现状	6
1.3 本文的主要研究内容与贡献	7
1.4 本文的组织结构	8
第 2 章 ReMoD 框架的设计	9
2.1 引言	9
2.2 多模态知识感知模块设计	10
2.2.1 文本知识获取	11
2.2.2 视觉信息锚定	12
2.3 经验驱动的直觉推理（系统 1）模块设计	13
2.3.1 模态协同经验检索	13
2.3.2 经验驱动的立场预测	15
2.4 元认知反思推理（系统 2）模块设计	16
2.4.1 经验构建	16
2.4.2 经验演化	17
2.4.3 立场推理	18
2.5 本章小结	18
第 3 章 实验设计与结果分析	19
3.1 引言	19
3.2 实验设置	19
3.3 基线方法	20
3.4 主要结果	20
3.4.1 目标内多模态立场检测	20

3.4.2 零样本多模态立场检测	22
3.5 消融实验	23
3.6 不同骨干网络的效果验证	25
3.7 基于相关性阈值的敏感度分析	25
3.8 典型案例对比分析	26
3.9 本章小结	28
结 论	29
参考文献	31
攻读学士学位期间取得创新性成果	35
哈尔滨工业大学本科毕业论文（设计）原创性声明和使用权限	36
致 谢	37

第 1 章 绪论

1.1 研究背景与意义

随着移动互联网、智能设备的普及与新型社交平台的蓬勃发展^[1]，网络信息传播的载体已从单一的纯文本全面转变为图文、音视频高度交织的多模态形式。在面对诸如全球公共卫生事件、地缘政治冲突以及重要选举等引发广泛社会讨论的复杂公共议题时，用户普遍倾向于结合文本陈述与图片来表达其观点、情绪与政治倾向。在此背景下，多模态立场检测应运而生，并迅速成为自然语言处理与多模态理解交叉领域的核心任务^[2-3]。多模态立场检测旨在综合解析输入中的文本、图像等异构信息，从而精准识别出内容创作者对于某一特定目标所持有的赞成、反对或中立态度^[4]。相较于传统的单文本立场分析，多模态立场检测不仅能更真实、立体地还原复杂的社交语境，弥补单一模态表达的信息缺失，更在政治话语梳理、虚假信息甄别、公共舆情监控及个性化内容推荐等领域具有极其广阔且迫切的现实应用前景^[3,5]。

然而，早期的多模态立场检测研究普遍沿用“学习融合”的深度学习范式^[2,6]。这类模型主要致力于将文本和视觉特征映射至统一的隐式向量空间，通过注意力机制或简单的多层感知机进行权重分配及特征拼接。该范式虽在处理语义直白、图文高度一致的简单场景时具备一定成效，但在面对社交媒体中广泛充斥的复杂“语义陷阱”时却存在显著局限。一方面，单个模态对立场表达的实际贡献往往并非一成不变，而是高度受制于上下文与特定议题；在某些情境中，图片可能是决定立场的关键证据（如展示抗议现场的横幅），而在另一些情境中又可能仅仅是无意义的背景点缀。若模型无法动态评估模态的真实信息含量并有效隔离低质量或无关模态的干扰，极易引发模态间的特征污染。另一方面，真实的社交网络交互中充斥着隐喻、反讽、网络梗以及刻意的图文矛盾，这要求模型必须具备高阶的认知与推理能力。

如图1-1所示，在典型的跨模态反讽样本中，文本可能使用了看似友善或赞美的夸张表达，而配图却是充满讽刺、滑稽或阴暗象征意味的视觉对象。传统的特征融合网络由于本质上仍是基于浅层统计模式的黑盒映射，缺乏显式的逻辑推演过程，极易被文本表面携带的积极情感词汇所欺骗，机械地给出了错误的支持分类。同理，当文本本身存在“如果不... 那会怎样”等带有让步、假设语气



图 1-1 现有“学习融合”范式与本文“学习推理”范式在应对多模态语义陷阱时的机制对比图。

的复杂逻辑结构，或图片使用了需要特定背景知识才能理解的文化符号时，浅层的关键词捕捉与特征对齐同样会导致模型无视其真实的批判或中立立场。由此可见，现有模型之所以在上述图文脱节或逻辑复杂的场景中频繁发生误判，根本原因不在于底层特征抽取能力的不足，而在于缺乏支撑模型剥离表象、探究深意、进行事实核查的高级推理过程。

为打破上述瓶颈，促使多模态分析从“特征层面的盲目融合”向“具备因果逻辑的学习推理”跨越，本文旨在设计并实现一种新颖的多模态立场检测框架。该框架引入了认知心理学中著名的“双过程理论”，构建了一个能够自主评估模态质量、反思推理矛盾、积累并复用决策经验的认知智能体系。通过模

拟人类在面对复杂信息时“先直觉感知、后理性深思”的认知规律，该体系试图为黑盒化的多模态融合引入具有逻辑校验性质的白盒化机制。

本文的研究工作兼具重要的理论意义与应用价值。在理论层面上，本文首创性地将快慢思考双过程推理机制与多模态立场检测任务深度融合。以经验驱动的直觉前馈网络模拟“系统1”的快速响应，以结构化、可解释的元认知反思链路扮演“系统2”的理性纠偏，为多模态信息的深度理解与融合提出了全新的解决方案。它不仅挑战了当前研究中普遍采用的简单融合范式，更为解决不同模态信息质量参差不齐、图文语义关系错综复杂的问题提供了具有认知学依据的新思路，有望推动多模态分析向具备高阶推理能力的“认知智能”阶段迈进。在实践价值层面上，一个更精准、更鲁棒、且具备推理可解释性的多模态立场检测模型具有广泛的现实意义。它能够更敏锐、精确地捕捉社交媒体上的公众情绪底色与深层态度，为社会治理、公共政策制定提供更可靠的数据支撑；同时，在处理图文不符、恶意反讽或刻意误导的复杂网络信息时，该模型能有效识别并降低误导性模态的权重，进而提升舆情监控与虚假信息预警系统的可靠性与智能化水平。

1.2 国内外研究现状

1.2.1 基于大语言模型的立场检测研究现状

近年来，现代立场检测框架的设计已被大语言模型深刻影响，逐渐成为学界热点。早期方法主要侧重于挖掘大模型自身的零样本和少样本泛化潜能，通过直接设计指令提示与思维链策略，在无标注数据或无需微调的情况下引导模型进行立场预测^[7-9]。这类工作通常将立场标签转化为自然语言选项，并借助模板化提示词约束模型输出，使其以“阅读-解释-判别”的方式完成分类；同时，通过示例选择、输出约束与多次采样投票等策略缓解单次生成的不稳定性，从而在低监督条件下获得可用性能。由于立场表达往往与话题背景、隐含前提与社会常识紧密相关，后续研究也逐步关注如何为模型补充可追溯的外部依据。为弥合模型内在知识存在的域外断层，相关工作通过引入外部证据检索机制，将检索到的背景知识与输入对进行融合，并结合反向传播进行微调，从而提升学习效果与模型可信度^[10-11]。

随着研究的深入，后续工作进一步释放了大语言模型处理复杂语义的推理能力，并将研究重点从“能否判断”逐步转向“为何判断”与“如何稳健判断”。

近期的创新包括：通过思维链和提示微调策略有效整合多视角的见解^[12]，在输出结论的同时显式给出中间理由以提升一致性；利用一阶逻辑规则形式化推理过程，以显著增强立场判别的可解释性^[13]，从而将隐式推断转化为可审查的规则验证；以及构建多智能体系统，促使多个大语言模型在分工协作中完成更加严谨的立场检测^[14-16]。这些范式共同指向一个趋势：通过结构化推理链路降低提示词敏感度与偶发幻觉对分类结果的影响，并在复杂语义现象下保持更稳定的决策边界。

然而，尽管大语言模型在上述研究中展现出了强大的文本生成与逻辑推演能力，这些方法主要针对纯文本立场检测任务开发，尚未充分探索图像等多模态信息的深度整合。一方面，立场检测任务本身具有高度的主观性和隐晦性，在真实的社交语境中，当文本充斥着反讽、隐喻或模糊边界的表达时，单一文本模型极易陷入表层语义匹配的陷阱；另一方面，社交媒体中的立场往往依赖视觉证据、场景线索与文化符号等非语言信息进行“反向指认”，仅依靠文本推断容易忽略关键语境。由于缺乏视觉等跨模态上下文的辅助与深层对齐，模型常会输出看似逻辑通顺、但与创作者真实意图相悖的结论，且在面对图文矛盾或视觉噪声时难以给出可验证的取舍依据。此外，大语言模型在执行复杂的多步推理时依然面临计算开销昂贵、提示词敏感度高等问题：提示模板的轻微变动可能引发结论波动，而引入长链推理与外部证据又会进一步抬高推理成本。因而，如何在大规模模型中低成本地引入多模态领域的先验知识，并在控制计算开销的同时，为其嵌入更具纠错能力的自反思逻辑，使其真正适应图文交织的复杂立场推理，仍是当前学界亟待突破的瓶颈。

1.2.2 多模态立场检测研究现状

社交媒体的全面普及极大推动了多模态内容（如文本、图像）以表情包、短视频等新颖形式的大量兴起^[1,17]。这些内容往往通过多样化且语义异构的信号传达隐含观点，给传统的立场检测任务带来了巨大挑战。与单一文本不同，多模态立场表达不仅涉及“文本说了什么”，还涉及“图像呈现了什么”以及两者在语境中如何共同指向目标：同一条文本在不同配图下可能呈现截然相反的立场，而同一张图片在不同评论语境中也可能被重新赋义。对于传统模型而言，建模这种语义异质的跨模态交互仍然十分困难，尤其是在需要同时处理实体指代、事件背景与情感倾向的场景中，简单的特征拼接往往难以捕获“互补、强调、转折、反讽”等细粒度关系；而受 Transformer 架构、大规模预训练框架乃

至大语言模型浪潮的推动，图文特征融合策略凭借自注意力机制和强大的迁移学习能力，在此方面逐渐表现出了显著优势，使得多模态对象间的底层对齐愈发精确。与此同时，研究也逐步从静态对齐走向语境对齐：将对话历史、社交互动信号或外部知识作为额外上下文，以更贴近真实平台中“观点在传播中被重构”的动态过程。

近期涌现出的大量方法通过设计不同的多模态融合机制极大地改进了立场分类的性能，并在任务设定上覆盖了对话、多源社交信号与事实核查等多类场景。例如，Niu et al.^[3] 提出了 MmMtCSD 和 MLLM-SD 模型，专门用于处理多轮对话场景中的文本-图像对的立场判定，其核心在于显式建模轮次间的语义演化以及图像证据对当前发言的支撑或反转作用。Kuo et al.^[18] 利用 S-BERT、BEiT 和 GraphSAGE 综合融合了政治话语中的文本、视觉及社交网络信号，将立场判断从“内容理解”扩展到“传播结构理解”，从而在群体性议题中捕捉更稳定的态度线索。Xie et al.^[19] 通过引入句子引导的视觉注意力机制，使视觉对齐不再依赖全局特征，而是围绕关键语句聚焦于更具判别力的区域，以降低无关背景的干扰。此外，Khiabani et al.^[20] 和 Barel et al.^[21] 利用基于图的线索成功应对了少样本或包含噪声的复杂场景，通过结构化关系缓解标注稀缺带来的不确定性；而 Yao et al.^[22] 则通过网络证据的整合将多模态立场检测扩展到了更为严苛的事实核查领域，使模型能够在“观点表达”与“证据一致性”之间建立更直接的约束。

然而，尽管上述近期方法在理想的图文互补场景下取得了显著进展，但它们通常采用固定的特征级融合策略，往往忽视了模态之间的动态交互以及高度受制于上下文的模态可靠性。现实环境中的多模态信号并不总是“互补”的：图片可能是情绪渲染的噪声，文本可能是反语，甚至二者刻意形成矛盾以制造传播效果。这些方法的核心假设仍建立在“多模态信息必定相互促进”的前提之上，而在真实的社交网络环境中，图文关系极其复杂，常常伴随着模态噪声甚至模态对立。这使得现有模型极易受到噪声或矛盾信息的影响；传统的跨模态注意力机制往往难以区分“有用的视觉证据”与“具有强吸引力但无关的视觉区域”，无法有效抑制视觉噪声对最终决策的负面干扰，甚至会引发严重的特征污染。进一步地，当某一模态本身具备“独立证伪”能力（例如图片直接否定文本描述）时，单纯依赖相似度对齐的融合策略往往缺乏显式的矛盾检测与置信度评估环节，导致模型无法量化不同模态在当前语境下的可信程度，也难以给出可解释的取舍依据。因而，如何打破传统的“盲目融合”固定范式，为多

模态立场检测框架赋权一种可以自主衡量信号置信度的元级逻辑评估机制，进而实现模态间信息的高效去伪存真与动态权重分配，已成为当前多模态立场检测领域的核心难点。

1.2.3 快慢思考机制研究现状

“快慢思考”源于认知心理学范式^[23]，近年来被引入大语言模型以平衡推理质量与推理效率两方面的需求。该理论在大语言模型研究领域获得了广泛关注，即人类的认知系统由直觉驱动、快速响应的“系统 1”和逻辑主导、缓慢深思的“系统 2”协同构成。映射到模型层面，“系统 1”通常对应低成本快速生成或浅层判别过程，擅长处理模式清晰、语义直白的输入；“系统 2”则对应显式的多步推理与验证过程，用于处理需要上下文整合、冲突消解与因果追溯的复杂情形。FS-GEN^[24]框架利用小模型（快思考）快速生成初步输出，而大模型（慢思考）对其进行精炼和验证，以此模拟人类认知中系统 1 与系统 2 的协作模式，并通过“先产出、后校验”的流水线降低整体调用成本。类似地，Fast-Slow-Thinking^[25]框架将快慢思考范式与任务解决相结合，通过在高层规划与细节展开之间进行分层控制，旨在克服传统任务分解方法过分关注细节而忽略全局连贯性的局限，从而提升复杂任务的解题稳定性。四阶段的问答框架 Thinker^[26]则利用结构化的快慢思考过程来增强模型的推理能力，同时优化计算效率，其关键在于将“快速候选生成、证据补充、反思修正、最终输出”等环节显式串联，使推理过程更可控且便于诊断。

针对多模态领域，FAST^[27]框架将该范式扩展至大视觉语言模型，引入了基于问题复杂度的动态推理深度调整机制，使模型能够在简单样本上以较浅的推理深度快速作答，而在存在跨模态歧义或需要细粒度视觉证据定位的样本上触发更充分的慢思考，从而兼顾准确性与成本可控。该思路的关键在于引入可度量的“复杂度/置信度”信号作为决策门控，使推理深度成为输入自适应的变量，而非固定的长链推理。除此之外，在双智能体框架 Talker-Reasoner Agent Model^[28]中，“Talker”智能体快速、直观地生成对话响应，而“Reasoner”智能体则缓慢但更具逻辑性地处理多步推理、工具使用和现实世界规划，并更新智能体状态。该分工将“快速交互”与“严谨求证”解耦，使系统既能保持响应效率，又能在必要时进行更可靠的推理校验。总体而言，这些研究共同证明了快慢思考框架在增强大模型推理与决策过程方面的巨大潜力：通过模拟人类的认知动态，该范式能够提升模型在复杂任务和多模态场景下推理的有效性，并为后续将推理

成本控制、错误诊断与可解释输出统一到同一流程中提供了方法基础。

尽管双过程理论在上述文本推理和通用智能体任务中展现出了巨大潜力，但在多模态立场检测领域的研究尚处于起步阶段。本课题将快慢思考机制引入多模态立场检测任务，旨在通过这一受认知启发的框架，深化模型对多模态信息的理解与融合能力。在海量的图文交互场景中，常规的直白表达完全可以由类似“系统1”的快速前馈网络进行高效判别；而针对那些充斥着语义陷阱、图文反转的复杂样本，则迫切需要“系统2”介入，进行深度的事实核查、常识调取与逻辑反思。力求通过系统1的直觉匹配实现高效的特征感知，并通过系统2的理性反思完成深度的逻辑纠偏，从而从根本上提升多模态立场检测的鲁棒性与可解释性。

1.3 本文的主要研究内容与贡献

为克服传统多模态立场检测面临的低质信息干扰、跨模态反讽及语义盲区等局限，本文致力于推动该任务从“学习特征融合”向“学习认知推理”的范式跨越。本文提出并实现了名为 ReMoD 的智能体框架（**Rethinking Modality Contribution of stance expression through a Dual-reasoning paradigm**），为多模态立场分析打造了一套基于认知双过程机制的自适应推理链路。

ReMoD 框架立足于双过程理论^[23]，构建了直觉预判（系统1）与反思检视（系统2）的协同循环。不同于传统融合模型将两种模态一并映射并直接分类，ReMoD 将“模态贡献评估”“语义一致性核查”与“决策经验沉淀”显式纳入推理流程，使模型在面对图文矛盾或语境含混时具备更可控的纠错路径。在第一阶段，智能体基于对文本与图像概念的初步提取，调用自身积累的模态经验池与语义经验池快速生成多重视角下的试探性立场诊断，并给出相应的依据假设与可疑点提示。在第二阶段，系统激活类似人类深思熟虑的元认知反思流程，借助严密的模态思维链和语义思维链，对初步决策内部所存在的图文对立、常识冲突与证据缺口进行逐项排查与归纳，在必要时对关键证据进行回溯与对齐，从而剥离出可复用的反思经验流入记忆池，实现知识框架的持续迭代与跨样本迁移。

本文的主要研究贡献可概括为如下三点：

- 构建了具备元认知能力的双重推理框架：本文推动多模态立场检测从传统的特征级融合走向可解释的认知推理范式。该双重推理框架在立场判别中显式构建了面向模态贡献评估、置信度核查与矛盾诊断的元认知分析系统，从而

避免模型在语义陷阱样本中仅依赖表层相关性做出决策。

- 设计了经验演化机制：本文构建了一种可自我改进与纠偏的循环机制，通过建立模态与语义双维度经验池持续留存推理中的高层指导策略，并借由大语言模型的多步反思链路对这些策略进行融合精炼与更新，使经验能够在后续样本中被检索复用并对新决策形成约束。

- 实现了突破性的性能：在 MMSD 多领域基准数据集上的实证评估证实，ReMoD 框架不仅在目标内测试中取得了优于各项业界基准的精度，更在高度考验通用推理能力的零样本情境下保持了稳定的泛化表现，从而验证了双过程推理与经验记忆机制在复杂多模态立场推断中的有效性。

1.4 本文的组织结构

本文以提升多模态立场检测在复杂语境下的性能为核心目标，提出了一种基于双过程推理机制的新型框架 ReMoD。围绕“问题提出—方法设计—实验验证—总结展望”的主线，全文共分为四章，各章节的具体内容安排如下：

- **第一章绪论。**主要阐述多模态立场检测的研究背景与实际应用意义，梳理文本立场检测、多模态特征融合以及基于大语言模型的立场检测等方向的研究现状。结合现有模型在处理多模态语义陷阱时面临的局限，引出本文的研究动机，并总结本文的主要研究内容与学术贡献。

- **第二章 ReMoD 框架的设计。**本章详细论述本文所提出的双过程推理框架的整体架构与关键模块的设计。首先介绍面向文本与图像的先验感知与信息组织方式；随后分别阐述模拟“系统 1”的经验驱动直觉推理机制以及模拟“系统 2”的元认知多步反思机制；最后说明两阶段协同完成最终立场判定并进行经验更新的闭环流程。

- **第三章实验设计与结果分析。**本章设计并开展系统性实验以评估 ReMoD 框架的实际表现。首先介绍本文采用的公开多领域基准数据集、对比基线方法以及底层模型参数配置；随后在目标内与零样本两类情境下展示并讨论定量对比结果，并进一步通过消融实验与典型案例验证各核心模块对鲁棒性、可解释性与推理准确性的贡献。

- **第四章总结。**本章对全文的研究工作进行系统回顾与总结，重申本文框架在分析范式与方法设计上的主要贡献，并讨论方法在计算成本与适用场景方面的潜在局限，最后对未来如何进一步进行模型轻量化、提升跨模态证据核查能力及优化推理流程提出工作展望。

第 2 章 ReMoD 框架的设计

2.1 引言

前文已对多模态立场检测任务的研究背景、国内外现状以及相关核心技术进行了系统性的阐述。分析表明,现有基于“学习融合”范式的方法在面对模态贡献度动态变化、跨模态反讽与语义陷阱等复杂场景时,缺乏显式的高级推理能力,难以有效解析多模态信息中蕴含的深层立场语义。为克服这一根本性局限,本章详细介绍本文所提出的核心框架 ReMoD (**Rethinking Modality Contribution of stance expression through a Dual-reasoning paradigm**), 一个面向多模态立场检测任务的、基于认知双过程推理机制的新型智能体框架。

ReMoD 框架的设计灵感源于认知心理学中的双过程理论^[23]。该理论由心理学家丹尼尔·卡尼曼等人系统阐述,其核心思想是人类的认知活动由两套相互协作但运作方式迥异的思维系统驱动。其中,“系统 1”是一种快速、自动化、凭借直觉和经验进行判断的认知模式,它无需刻意的逻辑推导便能对大多数日常情境做出即时反应;而“系统 2”则是一种缓慢、审慎、需要调动注意力进行分析推理的认知模式,被激活以处理复杂、非常规的问题,并对系统 1 的初步判断进行监控、校验和修正。两个系统的有机协作,使人类能够在效率与准确性之间取得动态平衡。ReMoD 框架将这一深刻的认知范式创造性地引入多模态立场检测任务。直觉推理模块(对应系统 1)借助过往推理经验的积累,快速形成对当前样本立场的初步假设;而元认知反思推理模块(对应系统 2)则通过结构化的多步推理链对初步假设进行深入审查与修正,提炼出模态经验和语义经验用于后续的立场检测支持,确保最终预测的鲁棒性和可靠性。这种双重推理范式的核心优势在于,模型不再是简单地融合多模态特征,而是学会了如何“推理”不同模态在具体语境下对立场表达的实际贡献,从而在本质上超越了传统的“学习融合”范式。

为了便于对方法进行形式化描述,首先给出多模态立场检测的任务定义。给定一个包含文本 u 和图像 v 的多模态输入对 $x = (u, v)$, 以及一个特定的目标 t , 多模态立场检测的目标是学习一个映射函数 $F(u, v, t) \rightarrow y$, 预测对该目标所持有的立场标签 $y \in \mathcal{Y}$ 。在此基础上, ReMoD 框架旨在利用双过程推理机制,结合外部知识检索与历史经验的动态积累,全面提升对立场标签 y 预测的准确

性与泛化能力。




图 2-1 ReMoD 框架示意图

如图 2-1 所示，ReMoD 框架由三个核心模块组成，它们分别承担信息获取、快速判断和深度优化的职责：

- **多模态知识感知模块**：作为整个框架的信息基础层，该模块负责从文本和视觉两种模态中系统性地提取语义信息，并通过检索外部知识库来补充和锚定关键实体的背景知识，为后续推理构建全面、丰富的语义表示。

- **经验驱动的直觉推理模块**（对应系统 1）：该模块模拟人类快速直觉判断的认知过程，通过查询在训练阶段不断积累和优化的双重经验池——模态经验池和语义经验池，从历史相似案例中检索可供参考的推理模式，快速形成对当前样本的初步立场假设。

- **元认知反思推理模块**（对应系统 2）：该模块模拟人类深思熟虑的分析推理过程，利用互补的模态思维链和语义思维链两种结构化推理机制，对系统 1 生成的初步假设进行多角度的批判性审查，提炼出具有泛化意义的高级见解，并据此持续优化双重经验池，形成自我改进的闭环学习。

以下各节将依次对上述三个核心模块的设计原理、技术细节与数学形式化表达进行详细阐述。

2.2 多模态知识感知模块设计

多模态知识感知模块是 ReMoD 框架的信息基础层，其核心使命是在推理

启动之前，为后续的直觉推理和反思推理构建一个全面、准确且结构化的语义知识基座。在社交媒体的多模态立场检测场景中，用户发布的内容往往涉及复杂的时事背景、文化隐喻或特定领域术语，这些信息超出了预训练语言模型的内在知识边界。若仅依赖模型参数化知识进行推理，极易产生事实性幻觉或对关键语境的误判。因此，本模块通过系统性地从外部知识库中检索和提炼与输入内容相关的背景知识，有效地弥合了模型内在知识与任务所需世界知识之间的鸿沟。

该模块的设计遵循“先提取、后增强、再锚定”的渐进式信息处理流程，分为文本知识获取和视觉信息锚定两个并行的子模块。文本子模块侧重于从语言层面挖掘深层语义和补充背景事实，而视觉子模块则致力于在保留高层语义理解的同时，将关键概念精确地锚定到图像的像素级区域，实现细粒度的视觉感知。两个子模块的输出共同构成了一个涵盖高层概念知识和低层视觉证据的丰富语义基础，为后续推理模块提供了多维度、多粒度的信息输入。

2.2.1 文本知识获取

对于文本输入 u ，本框架设计了一套三步递进的知识提取流程，旨在从原始文本出发，逐步构建语义丰富且与任务高度相关的背景知识表示。

第一步：关键实体识别。首先，实体识别阶段利用多模态大语言模型配合精心设计的提示词，从输入文本 u 与目标 t 中识别出一组关键语义实体，记为 $\mathcal{E}_u = \{e_1, e_2, \dots, e_m\}$ 。该提示词经过精心设计，引导多模态大语言模型重点关注与立场目标 t 具有语义关联的名词性实体，例如涉及的人物、组织、事件和概念等。这一过程的形式化表示为：

$$\mathcal{E}_u = \text{MLLM}_{\text{extract}}(u, t) \quad (2-1)$$

第二步：外部知识检索。在完成实体识别后，为了将这些实体锚定在外部世界知识中，克服模型可能存在的事实性幻觉并补充训练数据中覆盖不足的长尾知识，本框架引入外部知识库作为可靠的信息来源。具体而言，对于每个识别到的实体 $e_i \in \mathcal{E}_u$ ，利用维基百科接口检索其对应的详细百科描述 $d_i = \text{Wiki}(e_i)$ ，获取该实体的定义、历史背景、关联事件等丰富的结构化与非结构化信息。

第三步：知识提炼与摘要。由于维基百科返回的原始文档通常篇幅较长且包含大量与当前立场检测任务无直接关联的冗余信息，直接将其作为上下文输入不仅会导致提示词过长、增加计算负担，还可能引起模型注意力的分散，降

低推理效率。因此，框架再次利用大语言模型的语言理解与生成能力，将检索到的全部文档集 $\{d_i\}$ 提炼为一份简洁、语义稠密且高度聚焦于任务相关信息的综合摘要。最终生成的摘要记为文本知识 $\mathcal{K}_u$ ，它作为文本模态的增强语义表示，将在后续推理阶段为智能体提供必要的背景知识支撑：

$$\mathcal{K}_u = \text{MLLM}_{\text{summarize}}(\{d_i\}_{i=1}^m) \quad (2-2)$$

通过上述三步递进的处理流程，文本知识获取子模块实现了从原始文本到结构化背景知识的有效转化，为框架提供了经过验证和提炼的高质量文本语义信息。

2.2.2 视觉信息锚定

对于图像输入 v ，本模块的设计目标是同时捕捉高层语义概念和低层视觉细节，构建一个兼具语义可解释性与像素级精确性的视觉表示。这一设计考量源于一个关键洞察：在多模态立场检测中，图像所承载的信息往往不仅是其整体内容的概括性描述，更关键的是图像中特定物体、符号或场景元素的精确视觉呈现方式。

视觉信息锚定的第一步是语义概念的提取。与文本知识获取流程类似，本模块首先利用多模态大语言模型对输入图像 v 生成详细的图像描述，并从中识别出一组核心视觉实体 $\mathcal{E}_v$ 。这些视觉实体代表了图像中与立场表达可能相关的关键语义对象。随后，利用识别出的视觉实体集 $\mathcal{E}_v$ 查询维基百科知识库，获取这些视觉概念对应的百科背景信息，并经过多模态大语言模型摘要处理后生成浓缩的视觉知识 $\mathcal{K}_v$ 。此流程与文本知识获取的后两步保持一致，确保了文本与视觉两个模态在知识增强层面的对称性和一致性。

然而，仅凭文本化的知识描述不足以捕捉这些概念在图像中的具体视觉呈现方式和空间位置关系。为此，本框架将语义实体锚定在图像的像素空间中，实现从“概念级理解”到“像素级感知”的跨越。具体实现方式是利用识别出的实体集 $\mathcal{E}_v$ 作为文本提示，引导预训练的分割任意模型 $\text{SAM}^{[29]}$ 进行开放词汇分割。 SAM 作为一种强大的通用视觉分割基础模型，具备在任意文本提示引导下精确分割图像中对应区域的能力。通过将语义实体名称作为分割提示输入 SAM ，模型能够精确定位并分割出图像中与每个实体对应的区域，从而得到一组实体对齐的、细粒度的视觉子图信息 $\mathcal{V}$ 。 $\mathcal{V}$ 中的每个元素 $\bar{v}_i$ 代表了特定语义实体对应的分割子图像区域：

$$\mathcal{V} = \{\bar{v}_i\}_{i=1}^N = \text{SAM}(v, \mathcal{E}_v) \quad (2-3)$$

其中 N 表示识别到的视觉实体及对应子图的数量。这种基于实体锚定的细粒度视觉表示，相较于直接使用整幅原始图像，具有两方面显著优势：一是有效过滤了图像中与立场判断无关的背景噪声区域，使模型能够聚焦于真正承载立场信息的视觉元素；二是通过实体名称与子图的对齐关系，为后续推理模块提供了具有语义可解释性的结构化视觉输入，便于智能体在推理过程中进行有针对性的视觉证据引用与分析。

综上所述，多模态知识感知模块通过文本知识获取和视觉信息锚定两条并行路径，为 ReMoD 框架的后续推理阶段提供了三类关键信息：经过外部知识增强的文本语义摘要 $\mathcal{K}_u$ 、视觉语义摘要 $\mathcal{K}_v$ ，以及细粒度的实体对齐视觉子图集 $\mathcal{V}$ 。这些丰富的多模态信息共同构成了支撑双过程推理的坚实信息基座。

2.3 经验驱动的直觉推理（系统 1）模块设计

在完成多模态知识感知后，ReMoD 框架进入核心推理阶段的第一步——经验驱动的直觉推理。该模块在认知架构中对应双过程理论的“系统 1”，旨在模拟人类面对问题时快速、近乎自动化的直觉判断过程。在人类认知中，系统 1 的高效运作依赖于长期积累的经验和模式识别能力。类似地，本模块通过查询在训练过程中不断积累和优化的经验池，利用历史相似案例中的推理模式来快速形成对当前样本的初步立场假设。

从技术实现角度而言，该模块的工作流程可分为两个紧密衔接的步骤：首先，通过模态协同经验检索机制从经验池中高效定位与当前输入最为相关的历史经验；其次，基于检索到的经验上下文，引导智能体从多个模态视角生成初步的立场预测及其推理依据。

2.3.1 模态协同经验检索

经验检索是直觉推理的基础环节。为了使模型能够系统性地利用历史推理过程中获得的知识与规律来辅助当前决策，ReMoD 设计并维护了两个功能互补的经验池：模态经验池和语义经验池。模态经验池主要存储关于不同模态（文本、视觉）在立场表达中贡献度与交互关系的推理策略，而语义经验池则侧重于保存与特定语义情境和内容理解相关的推理经验。这种双重经验池的设计使得模型能够同时从模态关系和语义内容两个互补的维度进行经验借鉴。

形式上，每个经验池可以统一表示为 $\mathbb{P} = \{E_j\}_{j=1}^M$ ，其中 M 为当前经验池中存储的经验总数。每个经验条目 E_j 采用键值对的数据结构进行存储，具体形式为 $E_j = \langle (k_u^j, k_v^j), \text{Value}_j \rangle$ 。其中，键由预先计算的双模态嵌入向量 (k_u^j, k_v^j) 组成，分别代表该经验在文本语义空间和视觉语义空间中的核心特征表示，用于支持高效的相似性检索。值 Value_j 则存储了该经验的丰富内容数据，包括原始推理路径、最终预测结果、经反思过程提炼出的高级见解等。这种结构化的存储方式既保证了检索效率，又保留了经验的完整推理信息，使得后续模块能够充分利用历史经验中的深层知识。

在检索阶段，核心任务是高效地度量当前输入与经验池中每个存储经验之间的语义相关性。为此，检索过程首先需要将当前的文本输入 u 和经过锚定处理的子图像集 $\mathcal{V}$ 映射到与经验键向量相同的特征空间中。本框架选用预训练的 BGE-VL-CLIP 编码器 Enc 作为统一的多模态特征提取器^[30]。BGE-VL-CLIP 是一种在大规模图文对数据上预训练的视觉-语言对齐模型，其核心能力在于将文本和图像映射到共享的语义特征空间中，使得语义相近的跨模态内容在该空间中具有较高的余弦相似度。利用该编码器，分别计算当前输入的文本查询向量 q_u 和视觉查询向量 q_v ：

$$q_u = \text{Enc}(u), \quad q_v = \frac{1}{N} \sum_{i=1}^N \text{Enc}(\bar{v}_i) \quad (2-4)$$

其中，文本查询向量 q_u 直接由编码器对文本 u 进行编码得到。视觉查询向量 q_v 的计算则采用了平均池化策略，即对所有 N 个实体对齐视觉子图 $\bar{v}_i$ 的编码特征进行算术平均。这种聚合方式旨在生成一个能够概括当前图像整体视觉语义的紧凑表示，同时避免因个别子图的噪声而导致检索偏差。

在确定查询向量后，框架通过计算余弦相似度来衡量当前输入与经验池中每个存储经验 E_j 的键向量之间的语义相关性，分别得到文本维度的相关性得分 S_u 和视觉维度的相关性得分 S_v ：

$$S_u(q_u, k_u^j) = \frac{q_u \cdot k_u^j}{\|q_u\| \|k_u^j\|}, \quad S_v(q_v, k_v^j) = \frac{q_v \cdot k_v^j}{\|q_v\| \|k_v^j\|} \quad (2-5)$$

单独的文本或视觉相关性得分只能反映某一个模态维度上的经验相似性，而多模态立场检测任务要求同时考虑两个模态的信息。因此，为了获得全面且均衡的相关性度量，框架通过加权线性组合将两个单模态得分融合为一个统一的模态相关性得分，记为 $S(E_j)$ ：

$$S(E_j) = \alpha \cdot S_u(q_u, E_j) + (1 - \alpha) \cdot S_v(q_v, E_j) \quad (2-6)$$

其中 $\alpha \in [0, 1]$ 是一个可调节的超参数，用于平衡文本与视觉模态在经验检索中的相对权重。 α 值的设置反映了对两种模态信息在检索阶段重要性的先验判断。考虑到文本通常是立场判定的核心线索，本框架在实验中将 α 设置为 0.7，赋予文本模态更高的检索权重。

基于计算得到的模态相关性得分 $S(E_j)$ ，框架对经验池中的所有经验进行降序排列，并结合相关性阈值 τ 进行双重筛选。仅当经验的相关性得分不低于阈值 τ 时，该经验才被视为具有参考价值的候选。在满足阈值条件的候选集中，选取排名最靠前的 Top- k 个经验，分别从模态经验池和语义经验池中构成模态经验集 $\{\mathcal{S}_i^{\text{ME}}\}_{i=1}^k$ 和语义经验集 $\{\mathcal{S}_i^{\text{SE}}\}_{i=1}^k$ 。这种阈值与 Top- k 相结合的筛选机制，有效地在经验利用的充分性与信息质量之间取得了平衡：阈值 τ 确保检索到的经验具有基本的相关性保证，避免引入噪声；Top- k 约束则控制了上下文长度，防止因经验过多而导致的注意力分散。

2.3.2 经验驱动的立场预测

在通过模态协同经验检索成功获取到与当前输入相关的历史推理经验之后，ReMoD 智能体 A_R 开始进行初步的、直觉式的立场假设生成。这一步骤的核心设计理念是：将检索到的相关经验作为上下文学习的示例，引导智能体结合当前输入信息和既往推理模式来形成初步判断。

具体而言，本框架构建了一个综合提示词 $\mathcal{P}_{\text{sys1}}$ ，它集成了两个关键信息要素：(1) 当前的多模态输入任务，包含待分析的文本 u 、经过 SAM 锚定处理后的视觉信息 $\mathcal{V}$ 、以及待判定立场的目标 t ；(2) 从双重经验池中检索到的模态经验集 $\{\mathcal{S}_i^{\text{ME}}\}_{i=1}^k$ 和语义经验集 $\{\mathcal{S}_i^{\text{SE}}\}_{i=1}^k$ ，它们作为上下文示例为智能体提供了可供参考的推理范式和历史见解。

该模块设计的一个重要特色在于多视角推理策略。提示词 $\mathcal{P}_{\text{sys1}}$ 引导智能体 A_R 从三个互补的认知视角对当前样本进行初步分析：纯文本视角（仅关注文本 u 中的语言线索）、纯视觉视角（仅关注视觉信息 $\mathcal{V}$ 中的视觉证据）以及多模态融合视角（同时综合考虑文本与视觉信息）。这种多视角设计的目的在于全面捕捉各个模态独立以及协同作用下的立场信号，并通过对比不同视角的判断结果，为后续的反思推理阶段提供丰富的分析素材。对于每个推理视角 c ，智能体都会输出一个初步的立场预测 $\hat{y}_c$ 及其相应的推理依据 r_c 。这一过程可形式化地表示为：

$$(\hat{y}_c, r_c) = A_R(\mathcal{P}_{\text{sys1}}(c, \{\mathcal{S}_i^{\text{ME}}\}_{i=1}^k, \{\mathcal{S}_i^{\text{SE}}\}_{i=1}^k)) \quad (2-7)$$

其中推理视角 $c \in \{u, \mathcal{V}, (u, \mathcal{V})\}$ 分别对应文本、视觉及多模态输入。

最终，三个视角生成的预测对 $\{(\hat{y}_u, r_u), (\hat{y}_{\mathcal{V}}, r_{\mathcal{V}}), (\hat{y}_{(u, \mathcal{V})}, r_{(u, \mathcal{V})})\}$ 共同构成了系统 1 的初步推理轨迹。这些初步判断不仅捕捉了模型对当前样本从不同模态角度的直觉感知，更重要的是，它们之间的一致性或矛盾性本身就蕴含了丰富的元认知信息——例如，当文本视角与视觉视角给出相反的立场预测时，这通常暗示样本中存在跨模态反讽或语义陷阱。这些推理轨迹将作为关键的中间变量，传递至随后的元认知反思推理模块（系统 2）进行深入的批判性审查和优化。

2.4 元认知反思推理（系统 2）模块设计

元认知反思推理是 ReMoD 框架的核心大脑，在双过程理论中对应审慎的“系统 2”，承担着对系统 1 快速直觉判断的监督与校准功能。在面对包含潜在模态冲突或微妙讽刺的复杂案例时，仅凭直觉和历史习惯往往导致错误倾向，需要一种类似于思维链般有意识的、多步骤的深度推理过程来进行事实核验。此外，人类的长期记忆依赖于反思——不仅记录发生了什么，更总结了为何发生以及未来应如何应对。基于此，本框架设计了元认知反思模块，其运作由两个紧密相连的子过程驱动：经验构建与经验演化。两者共同支撑了 ReMoD 从每一次交互中抽取高层次洞见，并不断丰富自身记忆库的自适应演进能力。

2.4.1 经验构建

经验构建的主要目标是促进智能体产生深度的元认知反思，即“对思维过程本身的思考”。其目的在于提炼出具有广泛指导意义的通用原则或启发式策略，而非仅仅死记硬背特定输入样本的标签映射。为此，ReMoD 智能体采用了一种结构化、分层的多步推理机制：模态思维链以分析出模态交互策略，语义思维链以深挖上下文关联，进而生成新的见解。

为了生成模态经验，模态思维链启动了一个自我诊断过程。它首先回溯系统 1 针对文本 $\hat{y}_u$ 、视觉 $\hat{y}_{\mathcal{V}}$ 以及组合输入 $\hat{y}_{(u, \mathcal{V})}$ 的初始预测结果，并严格对比其对应的推理依据 r_u 、 $r_{\mathcal{V}}$ 和 $r_{(u, \mathcal{V})}$ 之间的一致性与分歧点。通过细致分析这些初始判断的成败原因，系统提炼出一种高层级的**模态见解** $\mathcal{I}_m$ 。这种见解超越了对单一案例的解释，上升为一种自适应的融合策略，明确指引未来在相似冲突场景中应当如何有意识地权衡或解耦各模态信号。

与此同时，语义思维链专注于提取深层次的**语义经验**。这一子过程要求智

能体对其初步逻辑背后的语义假设进行深度审视。通过将系统 1 的内部主观推理依据同检索自维基百科的外部客观描述——即文本知识 $\mathcal{K}_u$ 和视觉知识 $\mathcal{K}_v$ ——进行交叉验证，智能体能够敏锐地识别并修正其理解层面的刻板印象或浅显推测。由此生成的语义见解 $\mathcal{I}_s$ ，可以被视为一系列具体的指令或背景说明，为模型在后续处理类似实体或主题时，如何规避知识盲区并建立更准确的实体关联提供清晰蓝图。

2.4.2 经验演化

在生成了新的高质量见解 $\mathcal{I}_m$ 和 $\mathcal{I}_s$ 之后，系统需要将这些成果有效沉淀，由此进入经验演化阶段。这是一个旨在保持模型记忆新鲜度与连贯性的动态更新机制。首先，系统再次利用前文所述的检索机制，重新定位到经验池中与当前任务最相关的候选子集 $\{\bar{\mathcal{S}}_i^{\text{ME}}\}_{i=1}^k$ 和 $\{\bar{\mathcal{S}}_i^{\text{SE}}\}_{i=1}^k$ 。

这一步骤的关键在于甄别当前输入的新颖性。如果系统发现新生成的见解所对应的相关性得分远低于预设的更新阈值，这表明当前样本所在的语义空间属于经验池的未探明领域。面对这种新领域数据，ReMoD 会采取吸收策略，将全新见解连同其映射特征封装为新的数据结构条目 $E_{\text{new}} = \langle (q_u, q_v), \mathcal{I} \rangle$ ，并独立加入对应的经验池中，以此实现知识库的横向拓宽。

反之，若在池中检索到了高度相似的历史经验，直接添加则会导致知识冗余甚至前后矛盾。为解决此问题，ReMoD 引入了基于大语言模型内部整合能力的演化融合操作 $\text{Fuse}(\cdot)$ 。针对每一个被匹配到的相似模态经验 $\bar{\mathcal{S}}_i^{\text{ME}}$ ，框架向大语言模型提供整合提示，要求其将既往积累的经验法则历史与刚刚领悟的新模态见解 $\mathcal{I}_m$ 进行仔细的综合与辩证协调。这一动态融合过程输出的是一份包容性更强、更具适应性的升级版模态经验 $\hat{\mathcal{S}}^{\text{ME}}$ ：

$$\hat{\mathcal{S}}^{\text{ME}} = \text{Fuse}(\bar{\mathcal{S}}_i^{\text{ME}}, \mathcal{I}_m) \quad (2-8)$$

最终，框架用更新后的 $\hat{\mathcal{S}}^{\text{ME}}$ 覆盖原有的条目以维持知识库的精简。语义经验池的演化同样遵循这一路径，利用新语义见解 $\mathcal{I}_s$ 去提炼并生成升级版的语义经验 $\hat{\mathcal{S}}_i^{\text{SE}}$ 。通过这套判定，即独立新增或融合更新的闭环演进机制，ReMoD 的双重经验池不仅避免了无节制的膨胀，更能像人类一样在每一次任务交互中“反省求精”，从而维持对多模态表达规律长期进化的敏锐捕捉。

2.4.3 立场推理

在实际运行的整体推理阶段，ReMoD 将上述设计融合为流水线协同工作。首先执行感知：利用 SAM 的精确分割和预训练多模态大语言模型的知识检索能力，从包含文本 u 与图像 v 的多模态输入中获取实体对齐的视觉信息 $\mathcal{V}$ 和强化语义背景。随后，进入系统 1 的直觉判断通道：通过特征映射向双重经验池（模态经验池和语义经验池）发起查询，以检索那些与当前任务上下文相似度最高的历史策略。最后，通过系统 2 的介入，融合历史模态与语义法则，审慎结合当前任务的所有图文信息和背景线索，推导出最终的立场预测。这种范式既保障了模型决策响应的高效性，又通过经验的验证与反思夯实了其推断的严密性。

2.5 本章小结

本章面向多模态立场检测任务中复杂的模态关系解析与深层语义理解难题，详细阐述了 ReMoD 框架的设计。该框架受认知心理学双过程理论启发，推动了应对多模态立场检测任务从传统的“学习融合”向“学习推理”的范式转变。

整个框架的设计围绕三大核心模块展开：首先，多模态知识感知模块起到了信息基座的作用，它通过维基百科检索为文本引入了丰富的世界知识，利用大模型结合 SAM 将语义概念精准锚定至像素级区域，从而在推理起步时便将视觉噪声降至最低。其次，经验驱动的直觉推理模块（模拟系统 1）旨在实现快速决策。为此框架设计了模态与语义的双重经验池，通过高效的特征检索与多视角上下文学习机制，迅速得出对复杂场景的初步诊断并给出直觉上的初步判断。最后，元认知反思推理模块（模拟系统 2）承担了核心的监控与验证功能。借助模态思维链和语义思维链，该模块深度审视了系统 1 生成的多视角判断中隐含的矛盾，不仅在此基础上推导出更为严谨的最终立场结果，还能从中析出高阶经验见解，反馈给系统经验池，形成动态自适应的知识演化闭环。

本章从算法流程、认知科学动机以及公式推导上对 ReMoD 的工作机制进行了完整论证。通过该框架，多模态智能体不再机械地对齐数据，而是像人类一样学会了在“直觉”与“反思”中权衡模态贡献，为下一步评估该系统在高度复杂的图文舆情场景中的实际表现奠定了坚实的理论前提与方法基础。接下来的一章将通过在公开基准数据集上的实证分析，检验上述机制的实际效能。

第3章 实验设计与结果分析

3.1 引言

在第三章中，本文详细阐述了基于双过程理论的 ReMoD 框架的设计原理，该框架通过直觉推理与反思推理的协同，实现了对多模态立场表达的深度认知与自适应解析。为验证 ReMoD 框架在实际多模态立场检测任务中的有效性与鲁棒性，本章将对其进行全面的实证评估。

本章的内容组织如下：首先介绍本研究的实验设置，包括涵盖多个领域的 MMSD 基准数据集、性能评价指标以及模型的具体实现细节；接着详细列举并分析所选用的基线方法，涵盖纯文本、纯视觉以及先进的多模态基准模型；然后，展示 ReMoD 框架在目标内和零样本设定下的主要实验结果，并对性能提升的内在机制进行深入剖析；随后，通过模块消融实验明确双过程推理机制中各核心组件的独立贡献；进而，通过替换不同规模的大语言模型骨干网络以及分析经验检索相关性阈值的敏感度，验证该框架的泛化能力与设计稳定性；最后，通过典型的案例对比研究，直观清晰地展示 ReMoD 框架如何依靠反思推理理解构复杂的模态冲突与反讽语义。

3.2 实验设置

数据集与评价指标。为了客观评估本文提出的 ReMoD 框架的有效性，本次实验在公开的异构多模态立场检测数据集 MMSD (Multimodal Multi-domain Stance Detection)^[2] 上进行了基准测试。该数据集包含五个具有分布差异的不同领域：多模态 COVID-CQ (MCCQ)、多模态俄乌冲突 (MRUC)、多模态台湾问题 (MTWQ)、多模态 2020 推特立场选举 (MTSE) 以及涉及娱乐领域的多模态 Will-They-Won't-They (MWTWT)。由于立场检测任务中的样本分布往往存在类别不平衡的现象，本节遵循 MMSD 数据集的官方标准设置，采用 Macro-F1 作为主要的性能评价指标，以综合反映模型在多数类与少数类上的整体分类表现。

实现细节。在本章实验中，ReMoD 框架的主干模型采用具有较强多模态理解能力的开源大语言模型 Qwen2.5-VL-32B-Instruct。在模态协同经验检索阶段，为在文本与视觉线索之间取得合理的权重分配，文本相关性加权系数 α 设置为 0.7；为了在提供充足上下文信息与控制背景噪声之间取得平衡，经验匹配的相

关性阈值 τ 设定为 0.7，且每次至多检索前 $k = 3$ 个高度相关的同类经验以进入后续推理流程。此外，在外部知识感知模块中，有关文本与视觉实体的背景定义，均通过维基百科接口实现在线实时检索并经由主干模型进行摘要压缩提取。

3.3 基线方法

为了充分验证本文所提框架的性能优势并剖析已有方法在立场检测任务上的局限性，本章选取了三大类具有代表性的基准方法进行对比实验：

纯文本基准：仅利用推文文本特征进行立场推断，用以评估文本驱动的基准表现。具体方法包含了常用的预训练语言模型：1) BERT^[31] (uncased BERT-base 模型)；2) RoBERTa^[32] (RoBERTa-base 模型)；以及融入外部知识图谱属性的 3) KEBERT^[33]。此外，还包含了大型生成式语言模型的代表：4) LLaMA2^[34] (LLaMA2-70B-chat)，以及前沿的闭源大模型 5) GPT-4，用于测试传统文本模型直接跨域应用时的基线水平。

纯视觉基准：仅依赖图像信息进行分类，评估视觉特征独立表征立场的可靠程度。其中包括经典的卷积特征提取器：1) ResNet^[35] (ResNet-50 v1.5)；采用自注意力机制的视觉基础大模型：2) ViT^[36] (ViT-base-patch16-224)；以及致力于更好捕捉多尺度局部特性的：3) Swin Transformer^[37] (SwinV2-base-patch4-window12-192-22k)。

多模态基准：此类模型综合了图文双路输入，代表了当前本任务的主流技术路线。包括：基于早期简单拼接融合的传统框架 1) BERT+ViT；利用单流 Transformer 进行跨模态对齐融合的 2) ViLT^[38]；以及基于大规模对比学习图文强对齐范式的代表 3) CLIP^[39]。此外，还在充分参照基础上引入了零样本潜力的多种多模态大语言模型，如 4) Qwen-VL-Chat7B^[40]、5) LLaVa-v1.6^[41]、6) MiMo^[42]、7) Qwen2.5-VL-32B-Instruct^[43]，以及商业闭源大模型 8) GPT4-Vision。为求对比公允全面，对比实验同时纳入了近期针对社交媒体定制提出的前沿多模态提示微调框架 9) TMPT 及其依靠指令增强与思维链协同微调演进的版本 TMPT+CoT^[2]。

3.4 主要结果

3.4.1 目标内多模态立场检测

如表 3-1 所示，本节展示了模型在目标内（即训练集和测试集分布于相同

表 3-1 In-target 结果 (%). 最高分和次高分分别以 **加粗** 和 下划线 表示。* 表示 ReMoD 框架显著优于基准方法 ($p < 0.05$)。虚线用于区分微调方法与非微调方法。w/ 表示骨干网络。

MODALITY	METHOD	MTSE		MCCQ	MWTWT					MRUC		MTWQ	
		DT	JB	CQ	CA	CE	AC	AH	DF	RUS	UKR	MOC	TOC
Text-only	BERT	48.25	52.04	66.57	75.62	60.85	63.05	59.24	81.53	41.25	46.80	57.77	45.91
	RoBERTa	58.39	60.79	66.57	69.56	65.03	69.74	67.99	79.21	39.52	57.66	55.22	48.88
	KEBERT	64.50	69.81	66.84	71.67	67.56	69.29	69.74	80.57	41.55	59.01	58.15	47.75
	LLaMA2	53.23	52.67	47.40	34.89	41.95	49.09	44.32	30.21	38.84	38.54	55.31	46.51
	GPT4	68.74	66.39	65.84	63.14	65.12	<u>69.93</u>	71.62	52.69	41.64	53.76	58.05	49.81
Vision-only	ResNet	37.89	38.59	47.16	39.89	42.20	43.52	37.05	50.34	35.10	40.00	42.02	33.94
	ViT	40.48	40.42	46.64	46.63	50.00	40.16	46.32	50.86	33.31	39.87	38.63	35.53
	SwinT	39.89	40.43	48.80	46.30	46.99	41.02	47.39	51.32	35.01	40.89	35.03	35.47
Multimodal	BERT+ViT	41.86	45.82	61.32	63.20	44.71	56.45	46.85	73.71	39.28	48.41	47.47	40.86
	ViLT	35.32	48.24	47.85	62.70	56.44	58.06	60.22	73.66	34.62	42.41	44.43	59.51
	CLIP	53.22	65.83	63.65	70.93	67.17	67.43	70.86	79.06	44.99	59.86	55.29	40.98
	TMPT	55.41	61.61	67.67	76.60	63.19	67.25	62.92	81.19	43.56	59.24	55.68	46.82
	TMPT+CoT	66.61	68.75	<u>71.79</u>	74.40	<u>69.96</u>	68.43	63.00	82.71	45.04	<u>60.52</u>	<u>68.95</u>	<u>59.87</u>
	Qwen-VL	43.31	45.13	<u>50.51</u>	43.06	45.49	49.79	46.04	27.73	36.50	40.78	42.14	39.34
	MiMo	66.21	65.89	61.54	45.32	42.19	50.69	42.36	40.26	39.30	58.95	60.07	52.39
	LLaVa	49.48	45.80	60.30	20.48	28.48	33.83	38.94	31.57	36.53	47.47	50.45	47.07
	Qwen2.5-VL	68.07	70.82	63.33	75.27	68.44	67.15	68.91	63.21	41.04	51.34	65.62	56.35
	GPT4-Vision	<u>70.46</u>	<u>72.82</u>	61.63	44.59	47.07	57.47	57.90	37.61	44.83	56.40	66.72	56.90
Backbones	ReMoD	70.87	73.31	72.90*	78.49	71.85	71.89*	<u>70.62</u>	65.54	50.81*	62.42*	69.38	61.13
	- w/ Qwen-VL	65.14	63.84	63.51	55.76	53.46	50.67	52.23	50.06	39.96	49.30	57.36	52.75
	- w/ MiMo	66.43	69.91	70.84	59.25	53.34	61.26	56.35	58.18	42.52	60.22	61.29	54.82
	- w/ LLaVa	58.26	51.61	62.38	24.86	28.88	40.67	43.14	35.77	36.79	50.15	51.81	48.04

的目标) 场景的实验结果。结果表明, ReMoD 框架在大多数测试子集上均取得了最优成绩。具体而言, 其 Macro-F1 分数在包含隐喻等复杂语篇模式的数据集上, 全面优于绝大多数基线方法, 部分指标甚至超越了闭源的大语言模型 (如 GPT4-Vision)。尽管 TMPT+CoT 框架依赖 GPT-4 离线生成的思维链数据进行了有监督微调, 从而在少部分指标上表现优异, 但 ReMoD 方法无需预先构建高成本的外部推理轨迹数据集。相反, ReMoD 运用系统内部的双过程机制自适应地沉淀并演化分析范式, 在保障极高质量判定精度的同时, 显著降低了数据标注成本。

进一步对比基准方法的表现, 揭示了多模态表征融合所面临的内在挑战。首先, 在单模态性能对比中, 纯文本模型始终优于对应的纯视觉模型, 这表明在现阶段的多模态立场检测任务中, 文本仍然是传达明确立场的核心载体。其次, 在引入多模态融合机制后, 以 GPT4-Vision 为代表的新一代架构进一步提升了整体性能, 证实了视觉线索在立场判定中提供了必要的辅助与补充。然而, 诸如 CLIP 及传统的双流图文架构 (如 BERT+ViT) 的检测精度不仅缺乏稳定提升, 有时甚至低于独立的纯文本基线。这暴露出静态特征融合网络存在过度依赖对齐机制且容易引入噪声的缺陷: 面对跨模态语义不一致的样本, 模型易将

无关图像特征误作有效立场依据，从而弱化整体分类性能。相比之下，本文所提出的 ReMoD 采用“模态协同检索”策略，根据当前输入特征及历史表现动态调节文本与视觉信号的融合权重，促使其在混合型多变立场的图文语篇中呈现出更为鲁棒的抗干扰能力。

3.4.2 零样本多模态立场检测

零样本（即训练集和测试集分布于不同的目标）设定直接反映出模型在面对未知数据分布时的真实泛化水平，相关结果展示于表 3-2。评估表明，绝大多数依赖目标数据精细拟合的有监督模型在零样本场景时往往遭遇明显退化：当议题转移、表达风格改变或图文搭配方式发生变化后，模型在源目标中习得的“表层相关性”不再可靠，容易将与立场无关的情绪词、常见视觉元素或流行语用法误当作判别依据。对于多模态场景而言，这种分布偏移还体现在更复杂的跨模态关系上——同一张图片在不同话题中可能承担不同语用功能，同一段文本在不同配图下也可能被重新赋义，甚至出现刻意制造的图文矛盾与反讽表达。这会使得传统融合模型的对齐机制更容易被噪声牵引，进而产生特征污染与错误归因。

值得注意的是，通用大模型虽然具备更强的语言理解与视觉感知能力，但在缺乏针对性提示约束或外部证据支撑的情况下，同样可能出现推理路径不稳定、对细粒度语境线索把握不足等问题。其原因在于，零样本不仅要求模型“懂内容”，更要求其在不同目标中维持一致的判别准则：能够识别何时应以文本为主导，何时应提升视觉证据权重；能够区分真实立场表达与修辞策略；并能在证据不足或模态冲突时抑制过度自信的结论输出。由此可见，单纯依赖参数中固化的知识与模式匹配，难以自发形成稳定且可校验的推断策略。

反观上述模型的局限性，在同等测试条件下，ReMoD 框架依然能够保持较为稳健的零样本表现。该优势主要归功于其“经验迁移”机理：框架并不将经验简单视作某一目标的记忆片段，而是将其抽象为可复用的判别启发式与验证流程，用以约束多模态信息在不同语境下的取舍逻辑。具体而言，当面对全新的测试数据时，系统一阶段通过经验池检索快速定位与当前样本相近的推理模式，给出候选立场与潜在矛盾点提示，从而在早期就对模态可靠性与语义风险进行预警；随后系统二阶段启动反思链，对候选结论所依赖的关键证据进行逐项核查，显式识别图文一致、互补或对立等关系，并在必要时对不可信模态进行降权过滤。通过“先直觉定位、后反思校验”的闭环机制，ReMoD 得以在零

表 3-2 Zero-shot 结果 (%). 最高分和次高分分别以 **加粗**和下划线表示。* 表示 ReMoD 框架显著优于基准方法 ($p < 0.05$)。虚线用于区分微调方法与非微调方法。w/ 表示骨干网络。

MODALITY	METHOD	MTSE		MWTWT				MRUC		MTWQ	
		DT	JB	CA	CE	AC	AH	RUS	UKR	MOC	TOC
Text-only	BERT	32.52	29.97	63.55	61.30	59.18	52.89	22.01	15.45	28.04	9.57
	RoBERTa	26.60	32.21	59.22	59.22	64.86	57.46	27.10	19.98	30.62	15.84
	KEBERT	26.17	31.81	59.70	62.56	63.92	55.53	24.68	28.18	29.17	19.80
	LLaMA2	<u>53.57</u>	<u>53.92</u>	<u>32.47</u>	<u>38.37</u>	<u>48.08</u>	<u>46.13</u>	<u>31.86</u>	<u>36.34</u>	<u>51.46</u>	<u>44.10</u>
	GPT4	70.78	68.83	57.19	60.56	65.63	69.01	40.22	49.18	62.10	52.12
Vision-only	ResNet	25.52	29.70	23.01	24.11	25.21	25.27	23.88	25.57	27.59	24.88
	ViT	28.63	29.70	24.59	28.18	34.06	33.40	27.26	28.51	29.37	23.69
	SwinT	28.54	30.85	28.53	28.50	35.87	34.33	25.44	24.54	27.90	19.69
Multimodal	BERT+ViT	26.70	31.57	59.21	59.30	65.04	59.28	23.33	15.21	24.76	11.70
	ViLT	28.08	29.74	38.33	46.00	55.01	48.55	21.56	23.96	23.54	19.18
	CLIP	28.21	28.99	61.08	55.67	63.80	60.06	25.62	27.40	27.21	15.69
	TMPT	31.69	32.65	66.36	<u>66.39</u>	<u>66.32</u>	61.56	23.87	24.71	32.18	26.48
	TMPT+CoT	54.30	58.46	<u>67.28</u>	<u>63.73</u>	<u>64.87</u>	54.26	<u>48.99</u>	<u>51.75</u>	45.32	43.70
	Qwen-VL	<u>47.62</u>	<u>46.14</u>	<u>38.57</u>	<u>43.36</u>	<u>47.82</u>	<u>41.01</u>	<u>36.95</u>	<u>41.39</u>	<u>44.32</u>	<u>44.08</u>
	MiMo	66.58	66.01	38.11	40.10	44.20	39.05	44.85	50.24	64.65	46.25
	LLaVa	50.26	46.74	26.53	30.77	34.96	36.57	40.67	38.69	48.97	39.80
	Qwen2.5-VL	68.11	67.02	62.59	60.21	62.52	65.19	48.22	45.82	<u>67.08</u>	51.23
	GPT4-Vision	<u>72.68</u>	<u>71.28</u>	42.23	45.92	54.59	53.19	42.09	47.00	65.00	<u>52.36</u>
Backbones	ReMoD	73.78*	72.69*	70.83	66.90	71.82*	<u>67.25</u>	50.07*	52.57*	69.77	64.39*
	- w/ QwenVL	59.48	56.47	59.71	52.10	58.09	50.94	44.12	42.42	60.16	45.79
	- w/ MiMo	67.44	66.09	44.70	40.12	45.59	41.27	46.62	52.23	65.57	46.47
	- w/ LLaVa	53.10	49.52	27.21	30.42	44.13	38.25	42.43	40.64	50.63	45.76

样本场景下减少对偶然相关特征的依赖，降低模态噪声带来的负迁移风险，并形成更稳定、可诊断的决策过程。

3.5 消融实验

为了量化评估 ReMoD 框架内各核心模块对整体性能的独立贡献，本文在保持主干模型参数固定的前提下进行了控制变量消融实验，结果详见表 3-3。结果一致表明，三大核心模块之间存在显著的协同互补效应。与完整版本的 ReMoD 相比，任何缺失单一模块的变体在目标内和零样本泛化设定下的分类性能均出现了不同程度的下降。

具体而言，模态经验池被证实是影响框架稳定性的最关键因素。当移除该模块后，模型在两种测试设定下的表现均出现显著下滑，且零样本设定的退化更为突出，说明在零样本分布漂移与模态噪声叠加的情况下，若缺乏对历史跨模态交互模式的检索与复用，模型更容易在“文本主导”与“视觉误导”之间产生失衡，从而导致决策边界不稳定。相较之下，目标内设定的下降幅度相对较

表 3-3 目标内和零样本多模态立场检测消融实验结果（%）。

METHOD	MTSE	MCCQ	MWTWT	MRUC	MTWQ
<i>in-target setting</i>					
ReMoD	70.88	72.90	72.18	71.41	69.76
- w/o MEP	69.04	68.38	69.42	70.33	68.45
- w/o SEP	70.65	69.56	67.48	67.05	69.11
- w/o CoT	70.78	67.92	69.13	65.45	69.17
<i>zero-shot setting</i>					
ReMoD	71.19	-	70.59	70.74	71.39
- w/o MEP	66.95	-	63.26	65.71	68.55
- w/o SEP	64.47	-	64.35	68.74	70.41
- w/o CoT	70.85	-	64.77	69.11	71.22

小，但在 MCCQ 等数据域仍表现出明显退化，表明即便在同域训练的条件下，模态贡献的动态调整与抗噪经验依然是避免特征污染的重要保障。上述现象共同指向：MEP 主要承担了对模态可靠性的先验评估与权重分配引导，其缺失会直接削弱框架抵御无关视觉线索与跨模态矛盾的能力。

其次，移除语义经验池同样导致了决策精度的显著下降，且这种退化更集中地体现在需要外部背景与常识桥接的场景中。一方面，在目标内设定下，w/o SEP 在 MWTWT 与 MRUC 上的降幅较大，说明当样本包含隐含前提、指代省略或话题背景依赖时，若缺少对“语义层面推理模板与背景补充策略”的经验复用，模型容易退回到浅层对齐与表面情绪线索的判断。另一方面，在零样本设定下，w/o SEP 在 MTSE 上的下降更为明显，这表明语义经验池所沉淀的并非特定目标的记忆，而是可迁移的语境理解与常识补全路径；当目标转移后，该路径对于稳定推断尤为关键。总体而言，SEP 的作用更偏向于在系统 1 阶段补足“可解释的语义支架”，从而为后续推理提思维链供更可靠的上下文基础。

最后，在禁用系统多步思维链后，模型整体性能同样受到明显限制，但其影响呈现出更强的“任务与域依赖性”。从表 3-3 可见，w/o CoT 在目标内设定下对 MCCQ 与 MRUC 的影响更为显著，而在零样本设定下则在 MWTWT 上出现较大退化，相对而言在 MTWQ 上的变化较小。这说明当样本中存在更强的跨模态冲突、语义陷阱或需要多步证据核查的情形时，仅依赖经验检索提供的先验提示仍不足以保证结论可靠；必须引入系统 2 的多步分析链路，对候选立场的依据进行过滤、对矛盾点进行显式定位，并完成必要的自我校对，才能输出更稳健的最终判断。综合来看，模态经验池、语义经验池与分别对应“模态可靠性评估”“语义背景补全”与“多步逻辑纠偏”三类互补能力，三者的协同构成了 ReMoD 在目标内与零样本两种设定下均能保持鲁棒性的关键原因。

3.6 不同骨干网络的效果验证

为验证双过程推理机制是否具备独立于特定基座模型的广泛适用性，本章将 ReMoD 的核心架构与具备不同参数规模、调优范式的代表性多模态大语言模型进行了适配性评估。实验结果展示在表 3-1 与表 3-2 中。其中，表中加粗的最优成绩所代表的 ReMoD 框架，其主干网络采用了 32B 参数规模的先进大模型（Qwen2.5-VL-32B-Instruct），以充分发挥大体量模型在通识推理与视觉解析上的性能上限。

除此之外，为了探究本框架对较小规模模型的增益效果，本文还选取了多个参数量级在 7B 左右的多模态基础模型（Qwen-VL、MiMo 与 LLaVa）作为测试基座。从实验结果可以看出，受限于自身参数体量与视觉编码能力，这些 7B 级别的模型在未引入双系统时的原始单测指标上整体呈现较弱水平。然而，当它们被接入本文所设计的认知机制框架后，无论是基础版 Qwen-VL，还是采用指令微调的 LLaVa 和 MiMo，其多模态理解与检测能力均迎来了全面且显著的性能增益。特别是与 7B 级预训练模型结合后所呈现出的大幅提升表明，精心设计的高层认知反思与经验提炼机制能够从根本上弥补轻量级多模态模型固有的认知盲区与参数局限，极大拓宽其鲁棒抗扰的应用边界。

3.7 基于相关性阈值的敏感度分析

在模态协同经验检索中，超参数“相关性阈值 (τ)”决定了所召回历史经验线的质量与数量规模，直接影响其信噪比。为此，本节对该参数在区间点（0.1、0.3、0.5、0.7 和 0.9）上的敏感度进行了测试。图 3-1 的变化曲线直观揭示了不同过滤门限对最终立场预测准确率的影响历程与基本规律。

分析显示，阈值设定直接决定了模型汲取支持信息的判准边界：在 0.1 至 0.3 的低阈值阶段，由于过滤标准过低，大量弱相关、长尾甚至带有干扰性质的经验条目被引入，背景噪声掩盖了核心有效知识，导致总体性能下跌；随着阈值跨越 0.5 之后，经验质量保证了模型的准确率逐渐企稳向好。然而，当该指标提升至过于严苛的 0.9 水平时，由于大量具备隐微借鉴价值并有益于泛化推演的启示性弱关联孤例也被机械式屏蔽，系统失去了足够多样的对比参考域，最终陷入因孤立而带来的泛化僵局，指标从而回落。参数设定 $\tau = 0.7$ 恰巧平衡了高质量特征聚类内聚需求及防止有害负迁移之间的折中状态，保证了输入经验的有效性与宽广度，较好地激发了双系统的联动效能。




图 3-1 经验检索相关性阈值敏感度分析。

3.8 典型案例对比分析

在定量评估之余，为进一步刻画双过程框架在复杂语境下的工作方式与纠偏能力，本文选取了两个具有代表性的易混淆图文样例进行对比解析，如图 3-2 所示。此处以在相同骨干模型上直接进行端到端“零样本思维链”推理的基线作为参照，从而更直观地呈现 ReMoD 各模块在处理语境伪装与跨模态干扰时的作用。

图例 (a) 聚焦于一条包含西方青年亚文化语用特征的涉俄乌推文。该样例在表层上呈现出情绪极性混杂的表达结构，容易诱导仅依赖字面线索的基线模型产生偏差判断：参照模型主要关注前端“stan Putin（作普京热诚的粉丝）”这一显性短语，从而倾向于给出“支持”立场的预测，但未能充分结合句末强烈负向评判词“cringe（引人作呕的）”所指向的真实语用意图。相比之下，ReMoD 在经验检索阶段即可对“显性正向线索与整体语境不一致”的风险发出提示（“应注意情感错综表现时的极性隐蔽反转”），并进一步触发系统二反思链对关键证据进行核查。借助知识检索与语义澄清模块，框架能够识别“cringe”在该亚文化语境中的批判内核，并结合图文线索对反讽关系进行验证，从而将看似拥戴




图 3-2 基于相同大语言模型骨干网络的直接 CoT 基线与本文 ReMoD 系统间差异对比案例研究。

的表层表达还原为对特定言行的否定立场，最终得到更为稳健的“反对”结论。

实例 (b) 的难点来自“客观通知文本”与“具强情绪联想的配图”之间的错配关系。由于图片呈现了具有象征意义的外交互动场景，参照模型容易将其情绪取向错误地迁移到文本之上，进而将原本偏客观陈述的内容误读为对相关政策变动的正向评价。对此，ReMoD 通过经验约束与反思校验的配合，能够更清晰地区分“事实陈述”与“情绪暗示”的贡献来源：在早期阶段，框架以文本为主对句子功能进行判定，并提示需警惕配图带来的情感绑定；在反思阶段，则

对图文一致性与立场证据充分性进行复核，避免将象征性视觉线索直接等同于作者态度。最终，模型能够将该样例识别为对行政措施变更的客观重申，而非带有明确褒贬的态度表达，从而更合理地给出“中立”判断。

3.9 本章小结

本章全面展示了基于双过程理论的 ReMoD 框架的多域立场检测实验评估与结果分析流程。围绕 MMSD 基准数据集，本文依次给出了实验设置与实现细节，对比了涵盖文本、视觉与多模态路线的代表性基线，并在目标内与零样本两类关键设定下系统考察了模型的检测能力与泛化表现。综合对比结果表明，ReMoD 能够在多域场景中保持更为稳定的判别效果，尤其在存在模态噪声、语义不一致与修辞伪装等复杂输入时，仍能有效抑制特征污染并提升整体预测可靠性。

进一步的分析揭示了该优势背后的机制来源。本章的消融实验从控制变量角度明确了模态经验池、语义经验池以及多步反思推理等核心组件的独立贡献与协同关系，验证了“经验检索提供先验约束、反思校验完成逻辑纠偏”的闭环范式能够显著增强模型对跨模态冲突与隐含语境的处理能力。与此同时，通过替换不同规模与不同调优范式的多模态骨干网络，本章验证了 ReMoD 作为认知机制框架具备良好的可迁移性与兼容性，能够在不同基座上持续发挥增益作用。

此外，本章还对经验检索相关性阈值的敏感度进行了分析，说明合理的经验过滤标准对于平衡有效信息补充与噪声引入具有关键意义；并通过典型案例对比，直观展示了 ReMoD 如何在多模态隐喻、反讽与图文冲突等情形下完成证据核查与结论修正。综上，本章实验从定量对比与定性解析两方面共同验证了 ReMoD 在多模态立场检测任务中的有效性与鲁棒性，并为后续章节的总结与展望提供了坚实的实证依据。

结 论

本文提出了 ReMoD——一种受人类认知启发、采用双过程推理范式的多模态立场检测框架。该框架将经验驱动的直觉推理与审慎的反思推理有机结合：在早期阶段，通过经验检索快速对当前样本的模态贡献与潜在语义风险进行定位；在后续阶段，通过反思链对关键证据进行逐步核查与一致性验证，从而在复杂社交语境中实现更为稳健的立场判定。与依赖静态融合的传统方法相比，ReMoD 更强调对跨模态信息“可用性”的动态评估与对推理过程“可校验性”的显式约束，从而降低了无关视觉线索、语境伪装与图文冲突对决策的干扰。

围绕上述目标，本文构建了由“经验积累—经验检索—反思校验”组成的闭环机制，并通过双经验池对知识形态进行分工沉淀。一方面，模态经验池用于记录在不同语境下文本与视觉线索的可靠性模式，为后续输入提供可迁移的模态权重调整依据；另一方面，语义经验池用于沉淀更高层次的语境理解与推断启发式，为隐含前提、反讽修辞与背景依赖等现象提供可复用的语义支架。通过这种分层抽象的经验表达，ReMoD 能够在面对领域迁移与分布偏移时减少对偶然相关特征的依赖，并以更稳定的推断准则完成跨域泛化。

在公开多域多模态立场检测基准 MMSD 上的实验验证表明，ReMoD 在目标内与零样本跨领域设定下均表现出较强的鲁棒性与泛化能力。进一步的消融实验与敏感度分析验证了各核心组件对整体性能的独立贡献与协同关系，说明仅依赖单一经验检索或单次端到端推理难以稳定覆盖跨模态冲突与语境伪装等复杂情形；而“经验提示 + 反思核验”的双过程闭环能够在决策链路中提供必要的纠偏能力。典型案例对比分析则从定性角度直观展示了该框架在处理极性隐蔽反转、象征性视觉误导与事实陈述类文本等样例时的推理差异与改进来源。

尽管取得了上述进展，本工作仍存在一定局限性。其一，双过程推理带来更高的计算成本与推理延迟：框架在知识感知、经验检索与反思校验等阶段通常需要多轮模型调用与上下文组织，难以直接满足对时延敏感的实时应用场景。其二，外部知识检索与经验池质量对整体稳定性具有重要影响；当检索到的背景信息不充分、经验匹配出现偏差或输入样本包含强噪声时，推理链路可能出现误导与误差累积。其三，当前经验的组织与更新仍主要依赖预设的检索与过

滤策略，对于更开放的领域迁移与新兴话题的快速演化，仍有进一步提升空间。

未来工作可以从以下方向展开。在效率层面，可探索知识蒸馏、模型压缩与推理路径裁剪等方法，将双过程推理的关键能力迁移到更轻量的部署形态；同时引入自适应计算机制，使反思校验在高不确定或高冲突样本上重点触发，在低风险样本上保持较低开销。在检索与经验管理层面，可研究更鲁棒的经验表示与去噪策略，引入冲突检测、置信度估计与经验可信度更新机制，以降低错误经验与外部噪声对推断的负面影响。在评测与应用层面，可将 **ReMoD** 推广到更丰富的多模态立场场景与更复杂的语用现象中，并结合可解释性评估与偏差分析，进一步完善其在真实社交媒体环境中的可靠性与可迁移性。

参考文献

- [1] DAR S S, REHMAN M Z U, BAIS K, et al.A social context-aware graph-based multimodal attentive learning framework for disaster content classification during emergencies[J].Expert Systems with Applications, 2025, 259: 125337.
- [2] LIANG B, LI A, ZHAO J, et al.Multi-modal stance detection: New datasets and model[C]//Findings of the Association for Computational Linguistics.2024: 12373-12387.
- [3] NIU F, CHENG Z, FU X, et al.Multimodal multi-turn conversation stance detection: A challenge dataset and effective model[C]//Proceedings of the 32nd ACM International Conference on Multimedia.2024: 3867-3876.
- [4] LIANG B, CHEN Z, GUI L, et al.Zero-shot stance detection via contrastive learning [C]//Proceedings of the ACM Web Conference 2022.2022: 2738-2747.
- [5] PANGTEY L, BHATNAGAR A, BANSAL S, et al.Large language models meet stance detection: A survey of tasks, methods, applications, challenges and future directions[A].2025.
- [6] ZHANG B, MA J, FU X, et al.Logic augmented multi-decision fusion framework for stance detection on social media[J].Information Fusion, 2025: 103214.
- [7] ZHANG B, FU X, DING D, et al.Investigating chain-of-thought with chatgpt for stance detection on social media[A].2023.
- [8] ZHANG B, DING D, JING L, et al.How would stance detection techniques evolve after the launch of chatgpt?[A].2022.
- [9] 王正佳, 李霏, 姬东鸿, 等.基于多掩码与提示句向量融合分类的立场检测 [J/OL].计算机技术与发展, 2023, 33(12): 156-162.DOI: CNKI:SUN:WJFZ.0.2023-12-022.
- [10] LI A, LIANG B, ZHAO J, et al.Stance detection on social media with background knowledge[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing.2023: 15703-15717.
- [11] 韩霄龙, 曾曦, 刘锟, 等.基于 LoRA 高效微调通用语言大模型的文本立场检测[J/OL].计算机与现代化, 2025(01): 1-6.DOI: CNKI:SUN:JYXH.0.2025-01-01.

- [12] DING D, CHEN R, JING L, et al. Cross-target stance detection by exploiting target analytical perspectives[C]//IEEE International Conference on Acoustics, Speech and Signal Processing, 2024.2024: 10651-10655.
- [13] ZHANG B, DING D, HUANG Z, et al. Knowledge-augmented interpretable network for zero-shot stance detection on social media[J].IEEE Transactions on Computational Social Systems, 2024.
- [14] LAN X, GAO C, JIN D, et al. Stance detection with collaborative role-infused llm-based agents[C]//Proceedings of the International Association for the Advancement of Artificial Intelligence Conference: Vol. 18.2024: 891-903.
- [15] WANG X, WANG Y, CHENG S, et al. Deem: Dynamic experienced expert modeling for stance detection[C]//Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation, 2024.2024: 4530-4541.
- [16] 尚钰, 刘锟, 韩霄龙. 基于大语言模型智能体的跨域立场检测[J/OL]. 信息安全与通信保密, 2024(08): 62-71. DOI: CNKI:SUN:TXBM.0.2024-08-011.
- [17] BANSAL S, GOWDA K, REHMAN M Z U, et al. A hybrid filtering for micro-video hashtag recommendation using graph-based deep neural network[J]. Engineering Applications of Artificial Intelligence, 2024, 138: 109417.
- [18] KUO K H, WANG M H, KAO H Y, et al. Advancing stance detection of political fan pages: A multimodal approach[C]//Companion Proceedings of the ACM Web Conference 2024.2024: 702-705.
- [19] XIE J, LIU S, LIU R, et al. Sern: Stance extraction and reasoning network for fake news detection[C]//IEEE International Conference on Acoustics, Speech and Signal Processing, 2021.2021: 2520-2524.
- [20] KHIABANI P J, ZUBIAGA A. Few-shot learning for cross-target stance detection by aggregating multimodal embeddings[J]. IEEE Transactions on Computational Social Systems, 2023, 11(2): 2081-2090.
- [21] BAREL G, TSUR O, VILENCHIK D. Acquired taste: Multimodal stance detection with textual and structural embeddings[C]//Proceedings of the 31st International Conference on Computational Linguistics.2025: 6492-6504.

- [22] YAO B M, SHAH A, SUN L, et al.End-to-end multimodal fact-checking and explanation generation: A challenging dataset and models[C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval.2023: 2733-2743.
- [23] KAHNEMAN D.Fast and slow thinking[J].Allen Lane and Penguin Books, New York, 2011.
- [24] ZHANG K, WANG J, DING N, et al.Fast and slow generating: An empirical study on large and small language models collaborative decoding[A].2024.
- [25] SUN Y, ZHANG Y, ZHAO Z, et al.Fast-slow-thinking: Complex task solving with large language models[A].2025.
- [26] CHUNG S, DU W, FU J.Thinker: Learning to think fast and slow[A].2025.
- [27] XIAO W, GAN L, DAI W, et al.Fast-slow thinking for large vision-language model reasoning[A].2025.
- [28] CHRISTAKOPOULOU K, MOURAD S, MATARIĆ M.Agents thinking fast and slow: A talker-reasoner architecture[A].2024.
- [29] RAVI N, GABEUR V, HU Y T, et al.Sam 2: Segment anything in images and videos [A].2024.
- [30] ZHOU J, XIONG Y, LIU Z, et al.Megapairs: Massive data synthesis for universal multimodal retrieval[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers).2025: 19076-19095.
- [31] DEVLIN J, CHANG M W, LEE K, et al.Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, volume 1 (long and short papers).2019: 4171-4186.
- [32] LIU Y, OTT M, GOYAL N, et al.Roberta: A robustly optimized bert pretraining approach[A].2019.
- [33] KAWINTIRANON K, SINGH L.Polibertweet: a pre-trained language model for analyzing political content on twitter[C]//Proceedings of the Thirteenth Language Resources and Evaluation Conference.2022: 7360-7367.
- [34] TOUVRON H, MARTIN L, STONE K, et al.Llama 2: Open foundation and fine-tuned chat models[A].2023.

- [35] HE K, ZHANG X, REN S, et al.Deep residual learning for image recognition[C]//
Proceedings of the IEEE conference on Computer Vision and Pattern Recognition.
2016: 770-778.
- [36] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al.An image is worth 16x16
words: Transformers for image recognition at scale[A].2020.
- [37] LIU Z, LIN Y, CAO Y, et al.Swin transformer: Hierarchical vision transformer us-
ing shifted windows[C]//Proceedings of the IEEE/CVF International Conference on
Computer Vision.2021: 10012-10022.
- [38] KIM W, SON B, KIM I.Vilt: Vision-and-language transformer without convolu-
tion or region supervision[C]//International Conference on Machine Learning.2021:
5583-5594.
- [39] RADFORD A, KIM J W, HALLACY C, et al.Learning transferable visual models
from natural language supervision[C]//International Conference on Machine Learn-
ing.2021: 8748-8763.
- [40] BAI J, BAI S, YANG S, et al.Qwen-vl: A frontier large vision-language model with
versatile abilities: Vol. 1[A].2023: 3.
- [41] LI F, ZHANG R, ZHANG H, et al.Llava-next-interleave: Tackling multi-image,
video, and 3d in large multimodal models[A].2024.
- [42] XIAOMI L, XIA B, SHEN B, et al.Mimo: Unlocking the reasoning potential of
language model—from pretraining to posttraining[A].2025.
- [43] BAI S, CHEN K, LIU X, et al.Qwen2.5-vl technical report[A].2025.

攻读学士学位期间取得创新性成果

（一）发表的相关论文

- [1] Bingbing Wang#, **Zhengda Jin**#, Bin Liang, Wenjie Li, Jing Li*, Ruifeng Xu*, Min Zhang. MIND Your Reasoning: A Meta-Cognitive Intuitive-Reflective Network for Dual-Reasoning in Multimodal Stance Detection[C]// Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (ACL 2026), accepted (to appear). (CCF-A, 共一作者)
- [2] **Zhengda Jin**, Bingbing Wang, Geng Tu, Ruifeng Xu*. Overview of the NLPCC 2025 Shared Task 8: Personalized Emotional Support Conversation[C]// Natural Language Processing and Chinese Computing (NLPCC 2025). DOI: 10.1007/978-981-95-3352-7_43. (CCF-C, 第一作者)
- [3] Bingbing Wang#, Zihan Wang#, **Zhengda Jin**, Jing Li, Ruifeng Xu*, Min Zhang. Negotiating the Punchline: Contextual Meme Understanding via Discrete Semantic Energy Minimization[C]// The 49th International ACM SIGIR Conference on Research and Development in Information Retrieval, Short Papers Track (SIGIR 2026). (CCF-A 短文, 第二作者)
- [4] Bingbing Wang, Jingjie Lin, Zhixin Bai, Zihan Wang, Shengzhe Sun, **Zhengda Jin**, Zhiyuan Wen, Geng Tu, Jing Li, Erik Cambria, Ruifeng Xu*. Internet meme on social media: A comprehensive review and new perspectives[J]. Information Fusion, 2026, 130: 104102. DOI: 10.1016/j.inffus.2025.104102. (CCF-B, 第六作者)

哈尔滨工业大学本科毕业论文（设计）

原创性声明和使用权限

本科毕业论文（设计）原创性声明

本人郑重声明：此处所提交的本科毕业论文（设计）《认知双过程驱动的多模态立场检测》，是本人在导师指导下，在哈尔滨工业大学攻读学士学位期间独立进行研究工作所取得的成果，且毕业论文（设计）中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本毕业论文（设计）的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。本毕业论文（设计）对使用 AI 工具的情况进行了明确标注。

作者签名：金正达

日期：2026 年 5 月 24 日

本科毕业论文（设计）使用权限

本科毕业论文（设计）是本科生在哈尔滨工业大学攻读学士学位期间完成的成果，知识产权归属哈尔滨工业大学。本科毕业论文（设计）的使用权限如下：

(1) 学校可以采用影印、缩印或其他复制手段保存本科生上交的毕业论文（设计），并向有关部门报送本科毕业论文（设计）；(2) 根据需要，学校可以将本科毕业论文（设计）部分或全部内容编入有关数据库进行检索和提供相应阅览服务；(3) 本科生毕业后发表与此毕业论文（设计）研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉本科毕业论文（设计）的使用权限，并将遵守有关规定。

作者签名：金正达

日期：2026 年 5 月 24 日

导师签名：徐睿

日期：2026 年 5 月 24 日

致 谢

本科四年的求学过程，让我从一个对专业知识与科研方法一无所知的门外汉，逐渐成长为能够独立思考、独立研究的毕业生。这段经历中，我得到了许多人的帮助与支持，在此谨向所有关心、指导与帮助过我的人致以诚挚的感谢。

首先衷心感谢我的导师徐睿峰老师。感谢您接受我成为您的学生，进入您的实验室进行科研学习和训练。感谢您对我专业知识的传授、科研方法的指导以及学术规范的强调。感谢您在选题和论文写作方面给予的细致指导与严格要求。您在关键节点的点拨让我能够少走弯路，在遇到困难时也能重新梳理问题、找到可行的解决路径。您严谨的学术态度与务实的工作作风不仅提升了我对研究的理解，也让我明白了把一件事情做扎实、做完整的重要性。同时，还要特别感谢王冰冰师姐，在我进入实验室的初期给予的耐心指导与无私帮助，细心回答我的各种问题，分享了许多宝贵的经验与建议，让我能够更快地适应实验室的环境与要求。

感谢学院与各位任课老师在本科四年中的培养与帮助。课堂上的系统训练为我打下了专业基础，课程作业与实践环节让我逐步形成工程化的思维方式。在论文撰写过程中，老师们对规范写作、格式要求与学术诚信的强调，使我能够以更严格的标准审视自己的表达与论证。感谢答辩委员会的老师们在百忙之中审阅论文并提出宝贵意见，这些建议将对我后续学习与改进产生长期帮助。

最后，感谢我的家人。感谢你们长期以来的理解、鼓励与包容，在我压力较大或进度不顺时给予我坚定的支持与安全感。也感谢一路上给予我帮助的朋友们，是你们让我的大学生活更加充实而明亮。

谨以此文致谢，并将这段经历作为新的起点。未来我将继续保持求真务实的态度，不断学习、不断反思，努力以更好的自己回应所有人的期许。