# 第8讲数据库索引(2)



#### 基本内容

- 1. 为什么需要索引与什么是索引
- 2. 索引的简单分类
- 3. B+树索引
- 4. 散列索引

#### 重点与难点

- > 理解索引的作用,掌握应用索引改进数据库查询性能的方法
- 理解不同类型索引的概念: 稠密索引与稀疏索引,主索引与辅助索引,聚簇索引与非聚簇索引,倒排索引,多级索引等
- ▶ 理解B+树索引,怎样建立、维护和利用B+树索引(算法层面)
- > 理解散列索引,包括静态散列索引与动态散列索引(算法层面)

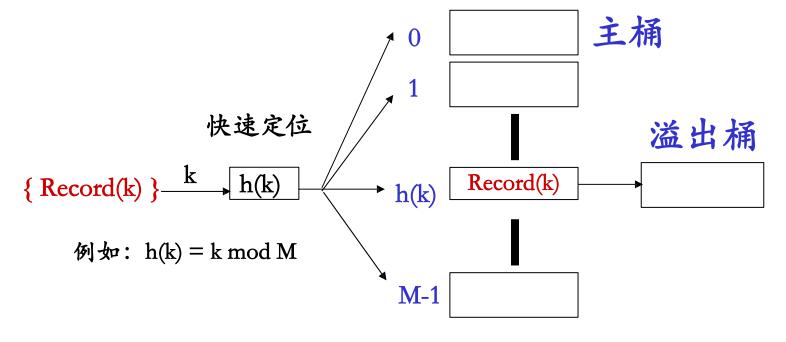


### 散列索引 (1)散列的基本概念

#### > 散列

- ✓ 有M个桶,每个桶是有相同容量的存储(可以是内存页,也可以是磁盘块)
- ✓ 散列函数h(k), 可以将键值k映射到 $\{0, 1, \dots, M-1\}$ 中的某一个值
- ✓ 将具有键值k的记录Record(k) 存储在对应h(k)编号的桶中

▶目标:选择一个合适的散列函数,将一个Record集合(每个Record集合(每个Record都包含一个关键字k)均匀地映射到M个桶中。即:对于集合中任一个关键字,经散列函数映射到地址集合中任何一个地址的概率是近乎相等的。





## 散列索引 (2)散列索引

#### > 散列索引

- ✓ 内存数据可采用散列确定存储页,主文件可采用散列确定存储块,索引亦可采用散列确定索引项的存储块
- ✓ M个桶。一个桶可以是一个存储块,亦可是若干个连续的存储块。

示例:假设1存储块可存放2个键值及其指针

M=4;1个桶为1个存储块

h(x)满足:

h(e)=0; h(b)=h(f)=h(s)=1

h(g)=2; h(a)=h(c)=3

问:如何查询键值a的索引项?

计算 h(a)=3

读取3号桶,获得键值a的索引项.

需要1个磁盘块读取

0	е
1	b f
2	g
3	a
	С



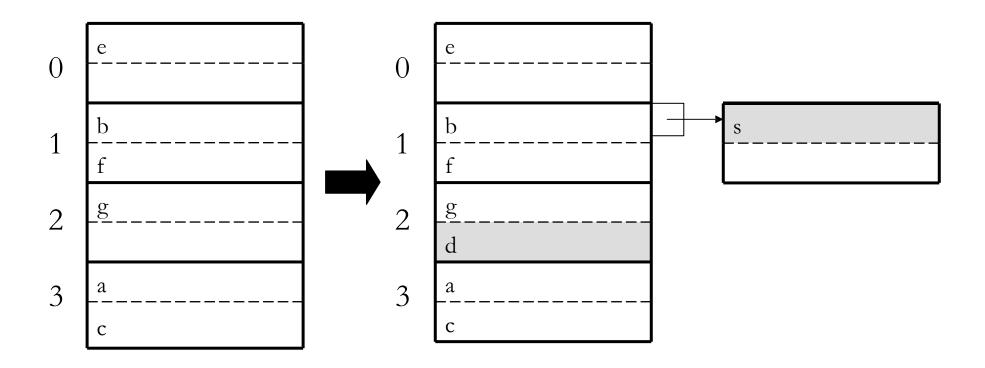
# 散列索引 (3)散列索引的插入和删除

问:如何插入键值d的索引项?

- ✓ 计算h(d)=2
- ✓ 如2号桶有空间,则将索引项d插入2号桶中

问:如何插入键值s的索引项?

- ✓ 计算 h(s)=1
- ✓ 1号桶无空间,则申请一溢出桶,插入s

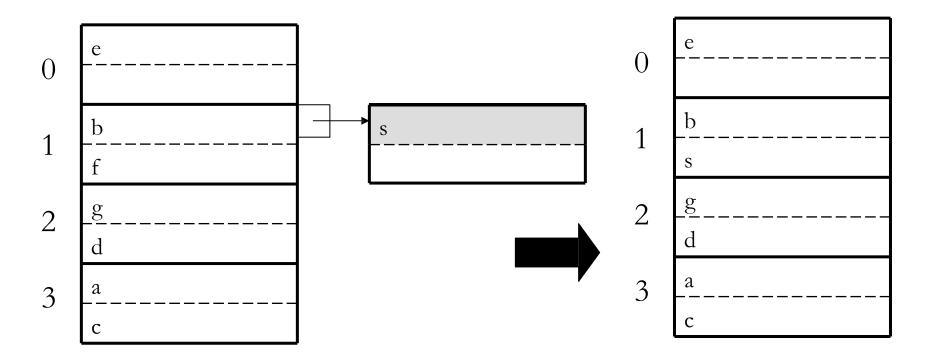




# 散列索引(3)散列索引的插入和删除

#### 问:如何删除键值f.

- ✓ 计算h(f)=1
- ✓ 删除1号桶中的键值f
- ✓ 将溢出桶中的s合并到主桶中, 删除溢出桶





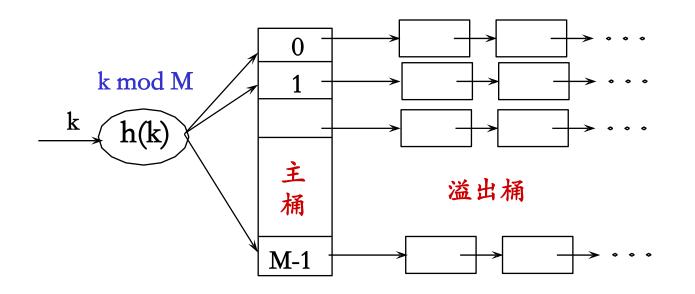
### 散列索引 (4)散列的问题

#### ▶ 散列索引的目标:

最好是没有溢出桶,每一个散列值仅 有一个桶。读写每一个键值都只读写 一个存储块。

#### > 均匀分布如何做到?

期望将所有数据分布均匀地存储于M个桶中,使每一个桶的数据成为具有某种特征值h(k)的数据集合。 →散列函数的选择。



#### ▶ 桶的数目M如何确定?

在键值几倍于桶的数目时,每个散列值都可能多于一个桶,形成一个主桶和多个溢出桶的列表,此时需要二次检索:先散列找到主桶号,再依据链表逐一找到每个溢出桶。---桶的数目的确定。



### 散列索引 (4)散列的问题

#### > 静态散列索引

- ✓ 桶的数目M是固定值
- ✓ 如果桶的数目M不变: M过大,则浪费; M过小,则将产生更多的溢出桶,增加散列索引检索的时间。

#### > 动态散列索引

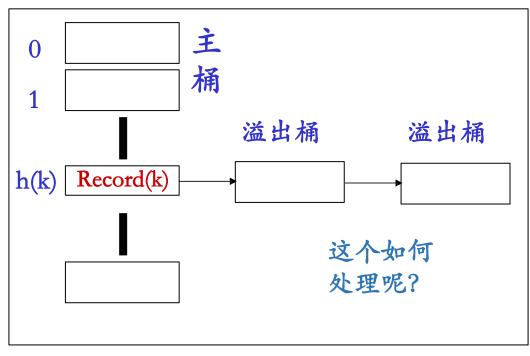
- ✓ 桶的数目随键值增多,动态增加
- ✓ h(k)是和桶的数目M相关的。 M的变化会否影响原来存储的内容呢? 是否需要将原来已经散列-存储的数据按新的桶数重新进行散列-存储呢?



### 可扩展散列索引 (1)拟解决的问题

→ 动态散列索引 可扩展散列索引 线性散列索引

- ✓ 桶的数目随键值增多,动态增加
- ✓ h(k)是和桶的数目M相关的。 M的变化会否影响原来存储的内容呢? 是否需要将原来已经散列-存储的数据按新的桶数重新进行散列-存储呢?





# 可扩展散列索引 (2)基本思想

#### > 可扩展散列索引

- ✓ 为桶引入一间接层,即用一个指向块的指针数组来表示桶,而不是用数据块本身组成的数组来表示桶
- ✓ 指针数组能增长, **其长度总是2的幂**。因而数组每增长一次, 桶的数目就翻倍。不过, 并非每个桶都有一个数据块; 如果某些桶中的所有记录可以放在一个块中, 则这些桶可能共享一个块。
- ✓ 散列函数h为每个键计算出一个K位二进制序列,该K足够大,比如32。但是桶的数目总是使用从序列第一位或最后一位算起的若干位,此位数小于 K,比如说i位。也就是说,当i是使用的位数时,桶数组将有2i个项。



### 可扩展散列索引 (3)基本思想示例

参数k 参数i 参数n=2<sup>i</sup>

i为散列函数当前已经使用到的最多位数。即当前的桶数为2i.

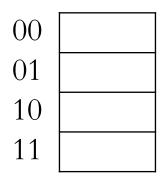
右上角标记本块 散列函数使用位 数。--局部

可变的桶 (指针数组)

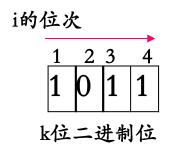
由2<sup>0</sup>个, 2<sup>1</sup>个, 2<sup>2</sup>个… 逐渐增加至2<sup>k</sup>个 i=1 0(010) 1

1(011) 1

k为散列函数所可能使用的最多位数。即可能的最大桶的数目为2k,逐渐被使用。



0



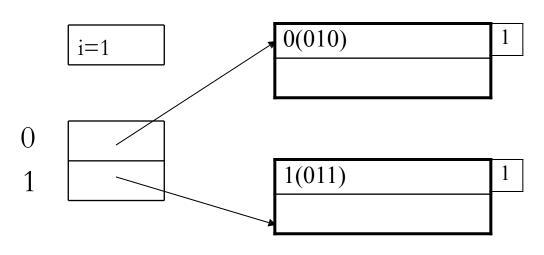
索引块 取前位,按照 前i位的值找到 对应的索引块



$$k=4$$

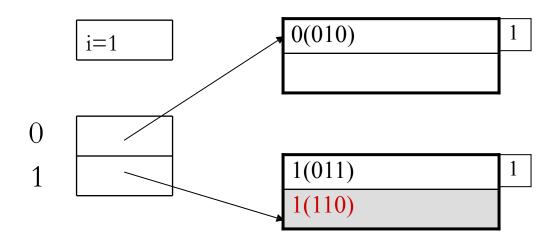
$$i=1$$

$$n=2^{i}=2$$



#### ▶ 插入 1110

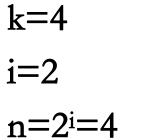
- 取前i位,确定索引块。 如有空间,则存储

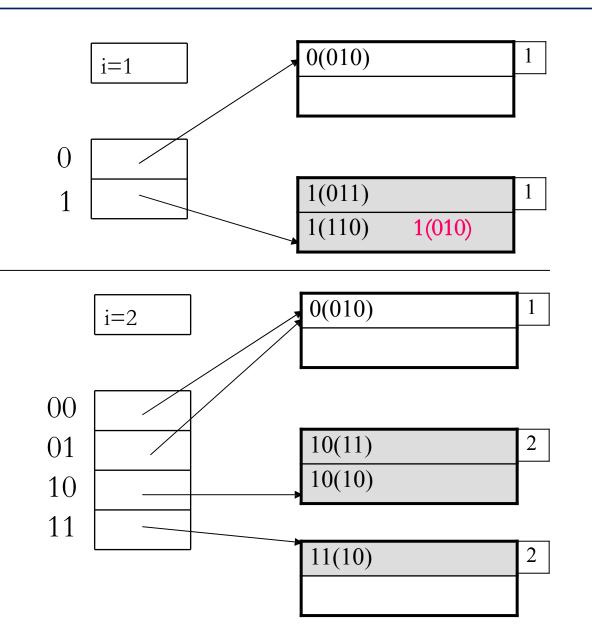




#### ▶ 插入 1010

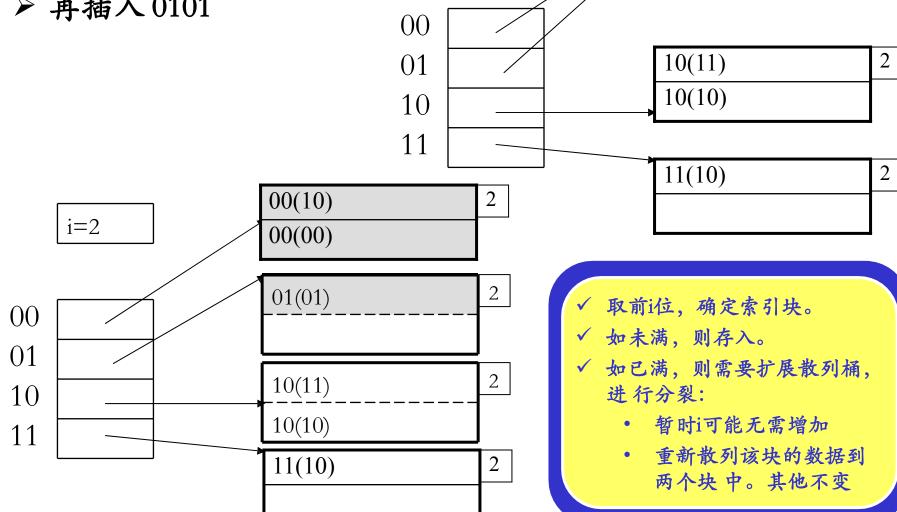
- √ 取前i位,确定索引块。
- ✓ 如已满,则需要扩展散列桶, 进行分裂:
  - i增加1
  - 重新散列该块的数据到两个块中。其他不变







- ▶ 插入 0000
- ▶ 再插入 0101



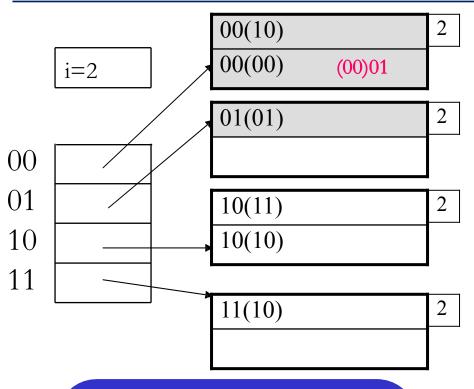
i=2

0(010)

0(101)

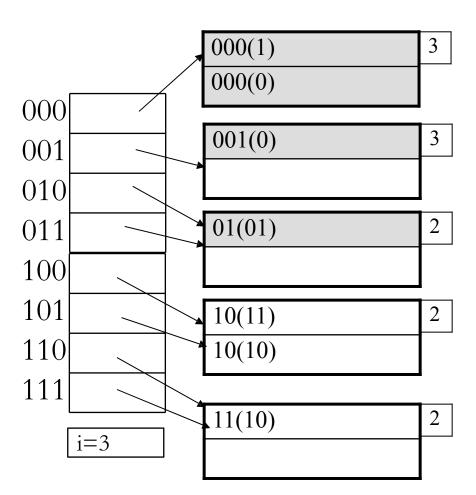
0(000)





- ✓ 取前i位,确定索引块。
- ✓ 如未满,则存入。
- ✓ 如已满,则需要扩展散列桶, 进行分裂:
  - 此时i需增加1
  - 重新散列该块的数据到两个块中。其他不变

▶ 插入 0001





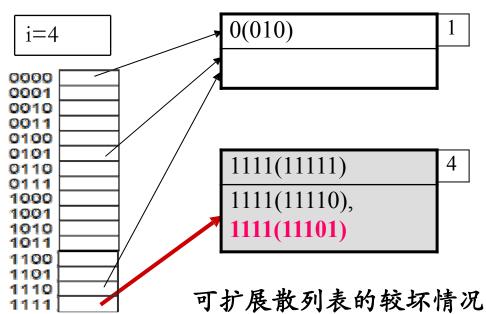
## 可扩展散列索引 (5)存在的问题

#### > 问题



- ✓ 当桶数组需要翻倍时,要做大量的工作(当i很大时);
- ✓ 当桶数翻倍后, 其在主存中可能就装不下了, 或者要占用更大的空间
- ✓ 如果每块的记录数很少,那么很有可能某一块的分裂比在逻辑上需要的分裂时间提前很多。例如:块中存放2个记录,即使记录总数远小于2<sup>20</sup>,但也可能出现三个记录的前20位二进制位序列一样,在这种情况下,将不得不使用i=20和100万个桶数组。

i=1时3个数组在一个桶中 ;要分裂;则2个桶 i=2时三个数组仍旧在一个 桶中;要分裂,则2<sup>2</sup>个桶 i=3时三个数组仍旧在一个 桶中;要分裂,则2<sup>3</sup>个桶 .....

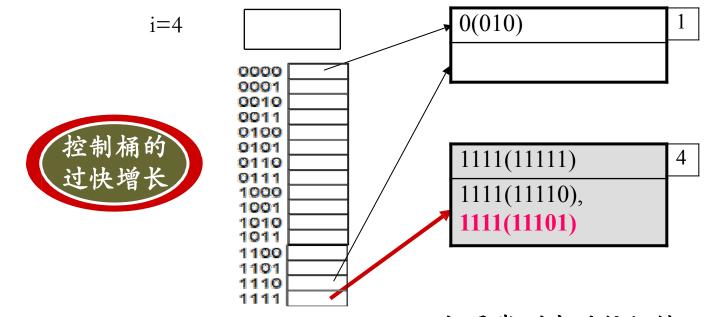




#### 线性散列索引 (1)拟解决的问题

#### > 问题

- ✓ 桶的数目过快增长,但其利用率不足
- ✓ 例如: 块中存放2个记录,即使记录总数远小于2<sup>20</sup>,但也可能出现三个记录 的前20位二进制位序列一样,在这种情况下,将不得不使用i=20和100万个桶 数组。但大部分桶都空闲未用。

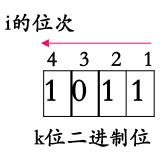




### 线性散列索引 (2)基本思想

#### > 线性散列索引

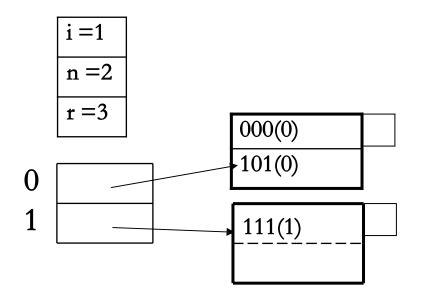
- ✓ 桶数n的选择: 总是使存储块的平均记录数,保持与存储块所能容纳的记录 总数成一个固定的比例,例如80%。超过此比例,则桶数增长1块,分裂。——线性增长,每次增1。
- ✓ 存储块并不总是可以分裂,所以允许有溢出块,尽管每个桶的平均溢出块 数远小于1。
- ✓ 用来做桶数组项序号的二进制位数是「log<sub>2</sub>n」,其中n是当前的桶数。 这些位总是从散列函数得到的位序列的右端(即低位)开始取。



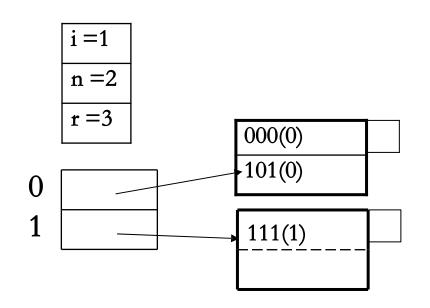


### 线性散列索引 (2)基本思想

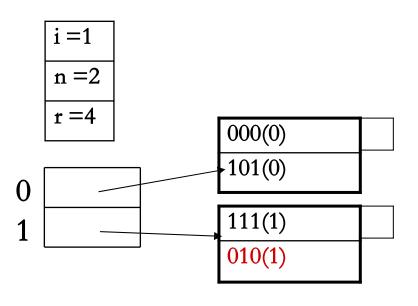
- ✓ 假定散列函数值的i位为桶数组项编号,且有一个键值为K的记录想要插入到编号为a<sub>1</sub>a<sub>2</sub>···a<sub>i</sub>的桶中,即a<sub>1</sub>a<sub>2</sub>···a<sub>i</sub>是h(K)的后i位。把a<sub>1</sub>a<sub>2</sub>···a<sub>i</sub>当作二进制整数,设它为m。n为当前桶数
  - 如果m<n,则编号为m的桶存在,并把记录存入该桶中。
  - 如果n≤m<2i,那么桶还不存在,因此我们把记录存入桶m-2i-1,也</li>
     就是当我们把a₁(它肯定是1)改为0时对应的桶。



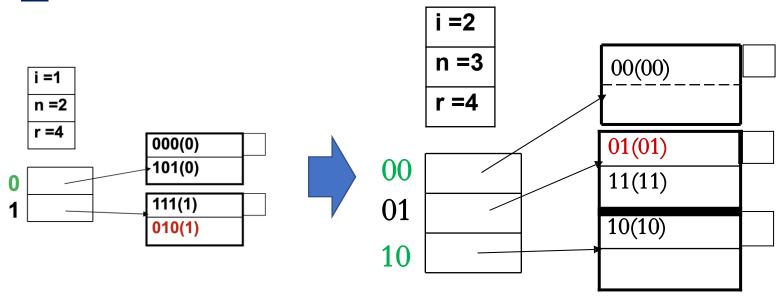




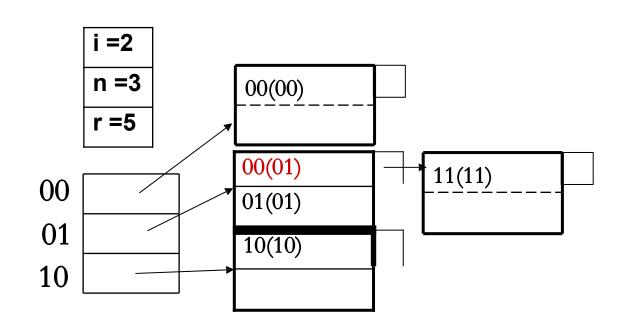
- ✓ 插入0101的记录,如右图。
- ✓ 此时r/n=4/2=2>1.7, 桶数 需要增1, 即要增加一桶,n=3
- ✓ 需要分裂。10桶要由00桶分 裂而来(低位相同而最高位不 同的那一个桶)



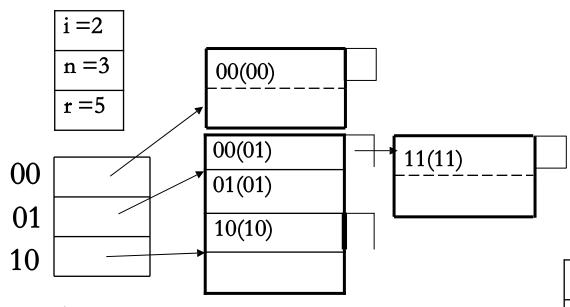




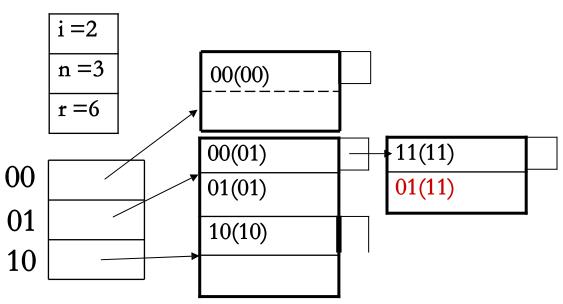
- •插入0001的记录,如右图。
- •此时r/n=5/3=1.66<1.7, 桶数无需增加



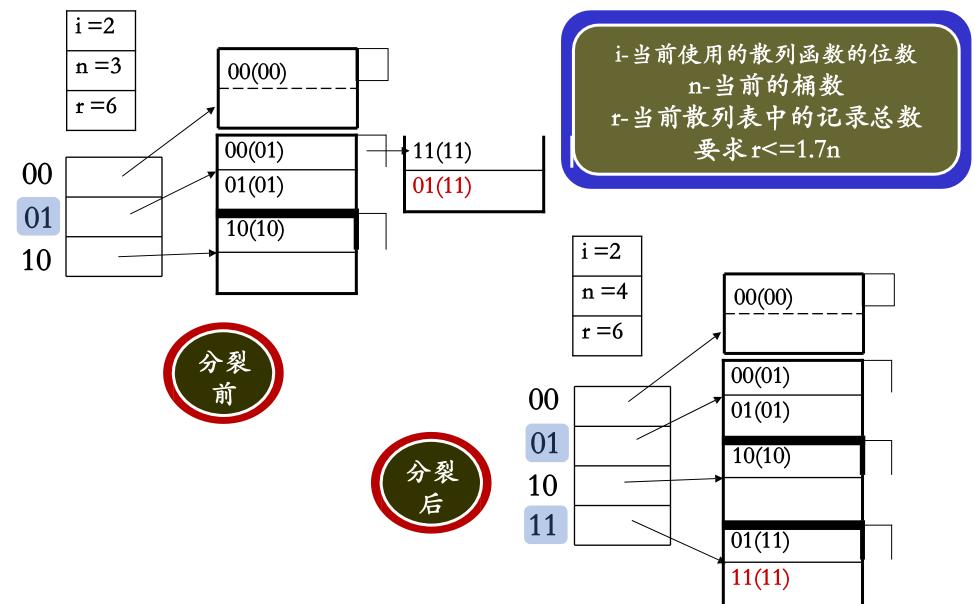




- ✓ 插入0111的记录,如右图。
- ✓ 因没有11桶,则插入01桶。
- ✓ 此时r/n=6/3=2>1.7, 桶数需要增1, 即要增加一桶11, n 仍然为3
- ✓ 需要分裂。11要由01桶分裂而来(低位相同而最高位不同的那一个桶)





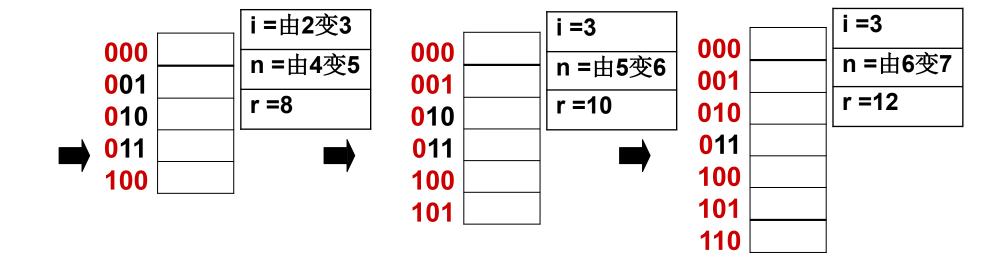




#### 线性散列索引 (4)回顾操作特点



- •键值由低位向高位次序使用。对应索引项存储在由桶数组指针指向的存储块
- ·当r/n(当前索引项数除以桶数)大于一定比例时,按次序增加1个桶
- •假设该桶为 $1a_2a_3...a_i$ ,则该桶由 $0a_2a_3...a_i$ 对应的块分裂而来
- ·当桶数超过2<sup>i</sup>个桶时,则使 i增1。





## 回顾本讲学习了什么?

